

Cambio de medida en probabilidad y análisis estocástico

César Galindo

Narrativa de análisis estocástico

Estas notas están organizadas como un solo arco conceptual. El punto de partida es la integral de Lebesgue, no como un capítulo aislado de teoría de la medida, sino como el lenguaje natural en el que se expresan reponderaciones, condicionamientos, kernels y operadores de evolución. Desde ahí, el teorema de Radon–Nikodym deja de ser una afirmación abstracta y pasa a leerse como el mecanismo que permite inclinar una ley base $\mathbb{P}$ hacia una nueva ley $\mathbb{Q}$ mediante una densidad. En análisis estocástico, esa inclinación reaparece de manera sistemática: como proceso de densidad en filtraciones, como martingala positiva, como transformación de Doob, como semigrupo reponderado, como sistema de partículas normalizado y como dinámica estocástica sesgada por un potencial.

Bajo esta perspectiva, los temas aparentemente dispersos del manuscrito forman en realidad una sola cadena. Los algoritmos genéticos seleccionan y mutan poblaciones; los métodos de Monte Carlo exploran distribuciones objetivo mediante kernels de Markov; los modelos ocultos filtran información parcial; las cadenas a tiempo continuo codifican evoluciones microscópicas; las martingalas controlan máximos, tiempos de salida y fluctuaciones; y la optimización en finanzas o en aprendizaje estadístico puede leerse como una secuencia de cambios de peso sobre configuraciones admisibles. La narrativa del texto insiste en esta unidad: un potencial cambia una medida, una medida cambia expectativas, y el cambio de expectativas reorganiza tanto la dinámica como la geometría del problema.

Por eso el manuscrito se desplaza deliberadamente desde fundamentos hacia procesos. Primero se construye la integral y se prueba Radon–Nikodym con detalle completo. Después se pasa a filtraciones, densidades condicionadas y martingalas, donde el cambio de medida ya vive en el tiempo. Más adelante, el lenguaje se extiende a cadenas de Markov a tiempo continuo, a sistemas de partículas y a operadores espectrales de tipo replicador–mutador. Finalmente, el mismo núcleo conceptual reaparece en aplicaciones exigentes: portafolios, Metrópolis–Hastings, pruebas Kolmogorov–Smirnov, el teorema de Glivenko–Cantelli, la ley de grandes números vía martingalas, modelos ocultos, redes neuronales y optimización adaptativa. Así, el documento no pretende yuxtaponer temas, sino mostrar que una misma forma matemática —reponderar, normalizar, propagar y controlar— atraviesa gran parte del análisis estocástico contemporáneo.

Índice

Narrativa de análisis estocástico	1
1. Algoritmos genéticos: fundamentos matemáticos y conexión con cambio de medida	3
1.1. Espacio de búsqueda, población y fitness	3
1.2. Selección como cambio de medida	4
1.3. Mutación como núcleo de Markov	5
1.4. Operador replicador–mutador	5
1.5. Concentración de baja temperatura	6
1.6. Poblaciones finitas y aproximación empírica	7

1.7. Caso finito: teoría espectral del operador replicador–mutador	7
1.8. Martingalas en algoritmos genéticos	10
1.9. Límite de partículas a horizonte finito	12
2. Marco de trabajo	13
3. Construcción de la integral de Lebesgue	14
3.1. Paso 1: funciones simples	14
3.2. Paso 2: integral para funciones medibles no negativas	15
3.3. Paso 3: funciones reales integrables	17
4. Definir $\mathbb{Q}$ mediante una densidad: $\mathbb{Q}(A) = \int_A Z d\mathbb{P}$	17
5. Demostrar que $\mathbb{Q}$ es una medida (y una medida de probabilidad)	18
6. Teorema de Radon–Nikodym (demostración completa)	20
6.1. Preliminares: medidas con signo y descomposición de Hahn	20
6.2. Radon–Nikodym para medidas finitas	20
6.3. Radon–Nikodym para medidas σ -finitas	22
7. Identidad del cambio de medida: $\mathbb{E}_{\mathbb{Q}}[X] = \mathbb{E}_{\mathbb{P}}[XZ]$	23
8. Filtraciones, densidades condicionadas y martingalas	24
9. Cadenas de Markov a tiempo continuo y exponenciales martingala	29
9.1. Definiciones básicas	29
9.2. Martingalas asociadas al generador	30
9.3. Proceso de Poisson como CTMC	31
9.4. Transformación h de Doob	31
10. Teoría de portafolios: Markowitz, razón de Sharpe y modelos factoriales	32
10.1. Modelo uniperiodal de Markowitz	33
10.2. Portafolio de mínima varianza global	33
10.3. Frontera eficiente con rendimiento objetivo	35
10.4. Razón de Sharpe y portafolio tangente	36
10.5. Modelos factoriales y factores de Fama–French	38
10.6. CAPM como consecuencia de equilibrio media–varianza	41
10.7. Black–Litterman como actualización bayesiana sobre retornos esperados . .	42
10.8. Restricciones de cardinalidad y problemas híbridos soporte-pesos	44
11. Aplicaciones adicionales: portafolios, cadenas de Markov, HMM, MCMC, redes neuronales, Adam y algoritmos genéticos	45
11.1. Algoritmos genéticos para teoría de portafolios	45
11.2. Comparación entre optimización cuadrática clásica y algoritmo genético híbrido	48
11.3. Cadenas de Markov como algoritmos genéticos	49
11.4. Cadenas de Markov ocultas	50
11.5. Puente con algoritmos genéticos y filtrado secuencial	52
11.6. Monte Carlo mediante cadenas de Markov: historia, principio ergódico y lectura genética	54

11.7. Kolmogorov–Smirnov y Glivenko–Cantelli: validación empírica de leyes simuladas	57
11.8. La ley de los grandes números desde la teoría de martingalas	61
11.9. Algoritmo de Metrópolis–Hastings	66
11.10 Redes neuronales: historia, cambio de medida y narrativa evolutiva	67
11.11 Adam como optimización adaptativa preconditionada	71
11.12 Redes neuronales, Adam y algoritmos genéticos	73
11.13 Análisis de Componentes Principales mediante Algoritmos Genéticos	73
11.14 Fundamentos de PCA	74
11.15 Formulación como Problema de Optimización	74
11.16 Codificación del Problema para Algoritmos Genéticos	75
11.17 Operadores Genéticos Específicos para PCA	75
11.18 Convergencia y Propiedades	76
11.19 Ejemplo: PCA Robusto con GA	77
11.20 Conexión con Cambio de Medida en PCA	79
11.21 Ejemplo Computacional Extendido	80

Referencias históricas orientativas 80

1. Algoritmos genéticos: fundamentos matemáticos y conexión con cambio de medida

Los algoritmos genéticos admiten una formulación matemática especialmente limpia cuando se describen en términos de medidas sobre el espacio de búsqueda. Desde este punto de vista, una población no es solamente una colección finita de individuos, sino una ley de probabilidad sobre el espacio de parámetros; la selección es un cambio de medida; la mutación es un núcleo de Markov; y la dinámica completa queda descrita por un operador no lineal de tipo replicador–mutador. Esta formulación enlaza de manera natural con Radon–Nikodym, con el formalismo de Feynman–Kac y con la teoría de cadenas de Markov.

1.1. Espacio de búsqueda, población y fitness

Sea Θ un espacio métrico separable con su σ -álgebra de Borel $\mathcal{B}(\Theta)$. Interpretaremos cada punto $\theta \in \Theta$ como un genotipo, un fenotipo o, en aplicaciones estadísticas, un vector de parámetros. Una población idealizada en la generación n se modela mediante una medida de probabilidad $\eta_n \in \mathcal{P}(\Theta)$.

Definición 1.1 (Función de fitness y potencial). Una *función de fitness* es una aplicación medible $F : \Theta \rightarrow \mathbb{R}$. Asociado a F introducimos un *potencial de selección* estrictamente positivo

$$G(\theta) := e^{\beta F(\theta)} \quad (\beta > 0),$$

donde β es un parámetro de intensidad selectiva. En lenguaje estadístico, G juega el mismo papel que una verosimilitud no normalizada.

Nota 1.2. El parámetro β tiene una interpretación termodinámica y algorítmica. Cuando β es pequeño, la selección es suave y la población conserva diversidad. Cuando β es grande, la masa se concentra cerca de los maximizadores de F . En el límite de baja temperatura, la medida seleccionada privilegia casi exclusivamente a los óptimos globales.

1.2. Selección como cambio de medida

Definición 1.3 (Operador de selección). Sea $\eta \in \mathcal{P}(\Theta)$ y sea $G : \Theta \rightarrow (0, \infty)$ medible con $\eta(G) < \infty$. Definimos la medida seleccionada $\Psi_G(\eta)$ por

$$\Psi_G(\eta)(d\theta) := \frac{G(\theta)}{\eta(G)} \eta(d\theta), \quad \eta(G) := \int_{\Theta} G(\theta) \eta(d\theta).$$

Proposición 1.4 (Radon–Nikodym de la selección). La medida $\Psi_G(\eta)$ es una medida de probabilidad absolutamente continua respecto de η , y su derivada de Radon–Nikodym está dada por

$$\frac{d\Psi_G(\eta)}{d\eta}(\theta) = \frac{G(\theta)}{\eta(G)}.$$

En consecuencia, para toda función medible acotada φ ,

$$\Psi_G(\eta)(\varphi) := \int_{\Theta} \varphi(\theta) \Psi_G(\eta)(d\theta) = \frac{\int_{\Theta} \varphi(\theta) G(\theta) \eta(d\theta)}{\int_{\Theta} G(\theta) \eta(d\theta)}.$$

Demostración. La positividad es inmediata porque $G > 0$. Además,

$$\Psi_G(\eta)(\Theta) = \frac{1}{\eta(G)} \int_{\Theta} G(\theta) \eta(d\theta) = 1.$$

La fórmula de Radon–Nikodym es simplemente la definición escrita en forma diferencial. La identidad para φ se obtiene integrando φ respecto de la nueva medida. $\square$

Nota 1.5 (Selección proporcional y selección de Boltzmann). Si $G = F_+$ o cualquier transformación monótona positiva del fitness, se obtiene selección proporcional. Si $G = e^{\beta F}$, se obtiene la ley de Gibbs–Boltzmann. Desde el punto de vista del cambio de medida, ambos mecanismos son exactamente el mismo fenómeno: una reponderación absoluta de la población base.




Figura 1: La selección de Boltzmann repondera la población multiplicando por $e^{\beta F}$. A mayor intensidad selectiva, mayor concentración de masa alrededor de los máximos del fitness.

1.3. Mutación como núcleo de Markov

Definición 1.6 (Núcleo de mutación). Un *núcleo de mutación* es una aplicación $M : \Theta \times \mathcal{B}(\Theta) \rightarrow [0, 1]$ tal que, para cada θ , $A \mapsto M(\theta, A)$ es una medida de probabilidad y, para cada A , la función $\theta \mapsto M(\theta, A)$ es medible. Dado $\eta \in \mathcal{P}(\Theta)$, definimos la medida mutada

$$(\eta M)(A) := \int_{\Theta} M(\theta, A) \eta(d\theta).$$

Nota 1.7. El núcleo M codifica perturbaciones, recombinación, cruces locales o movimientos globales de exploración. En espacios finitos, M es simplemente una matriz de transición estocástica. En espacios continuos, puede ser un kernel Gaussiano truncado, una dinámica de Metropolis, o un operador de difusión discretizado.

1.4. Operador replicador–mutador

Definición 1.8 (Dinámica no lineal de una generación). La evolución idealizada de una generación a la siguiente se describe mediante

$$\Phi_G(\eta) := \Psi_G(\eta) M.$$

Equivalentemente, para toda función acotada φ ,

$$\Phi_G(\eta)(\varphi) = \frac{\int_{\Theta} G(\theta) \left(\int_{\Theta} \varphi(\vartheta) M(\theta, d\vartheta) \right) \eta(d\theta)}{\eta(G)}.$$

Proposición 1.9 (Forma integral del operador genético). Sea $M\varphi(\theta) := \int_{\Theta} \varphi(\vartheta) M(\theta, d\vartheta)$. Entonces

$$\Phi_G(\eta)(\varphi) = \frac{\eta(G M\varphi)}{\eta(G)}.$$

En particular, Φ_G es no lineal en η por el factor de normalización $\eta(G)$.

Demostración. Basta desarrollar la definición de composición de medida con núcleo:

$$\Phi_G(\eta)(\varphi) = \int_{\Theta} M\varphi(\theta) \Psi_G(\eta)(d\theta) = \int_{\Theta} M\varphi(\theta) \frac{G(\theta)}{\eta(G)} \eta(d\theta).$$

Esto produce exactamente la identidad anunciada. $\square$

Teorema 1.10 (Representación de Feynman–Kac en el espacio de trayectorias). Sea $(X_n)_{n \geq 0}$ una cadena de Markov bajo una ley de referencia $\mathbb{P}$ con distribución inicial η_0 y núcleos de transición M_n . Sean $G_n > 0$ potenciales de selección y definamos

$$Z_n := \frac{\prod_{k=0}^{n-1} G_k(X_k)}{\mathbb{E}_{\mathbb{P}}[\prod_{k=0}^{n-1} G_k(X_k)]}.$$

Si $\mathbb{Q}_n$ es la ley en trayectorias truncadas dada por

$$\frac{d\mathbb{Q}_n}{d\mathbb{P}} = Z_n,$$

entonces la marginal de X_n bajo $\mathbb{Q}_n$ coincide con la sucesión no lineal

$$\eta_n = \Phi_{G_{n-1}} \circ \cdots \circ \Phi_{G_0}(\eta_0).$$

Demostración. La afirmación se verifica por inducción. Para $n = 1$,

$$\eta_1(\varphi) = \mathbb{E}_{\mathbb{Q}_1}[\varphi(X_1)] = \frac{\mathbb{E}_{\mathbb{P}}[\varphi(X_1)G_0(X_0)]}{\mathbb{E}_{\mathbb{P}}[G_0(X_0)]} = \frac{\eta_0(G_0M_0\varphi)}{\eta_0(G_0)} = \Phi_{G_0}(\eta_0)(\varphi).$$

Suponiendo el resultado en el tiempo n , la misma expansión con la propiedad de Markov da

$$\mathbb{E}_{\mathbb{Q}_{n+1}}[\varphi(X_{n+1})] = \frac{\mathbb{E}_{\mathbb{P}}[\varphi(X_{n+1}) \prod_{k=0}^n G_k(X_k)]}{\mathbb{E}_{\mathbb{P}}[\prod_{k=0}^n G_k(X_k)]} = \frac{\eta_n(G_nM_n\varphi)}{\eta_n(G_n)} = \Phi_{G_n}(\eta_n)(\varphi).$$

□

Nota 1.11. El teorema anterior explica por qué los algoritmos genéticos, los métodos secuenciales Monte Carlo y varias dinámicas de optimización evolutiva comparten el mismo esqueleto matemático. Todos ellos construyen una medida objetivo mediante reponderación repetida de una dinámica Markoviana de referencia.

1.5. Concentración de baja temperatura

Proposición 1.12 (Concentración sobre los maximizadores). *Supongamos que Θ es compacto, que F es continua y que $\eta(U) > 0$ para todo abierto U que intersekte*

$$\text{Argmax}(F) := \{\theta \in \Theta : F(\theta) = \max_{\vartheta \in \Theta} F(\vartheta)\}.$$

Sea $\mathbb{Q}_\beta := \Psi_{e^{\beta F}}(\eta)$. Entonces toda medida límite débil de $(\mathbb{Q}_\beta)_{\beta \rightarrow \infty}$ está soportada en $\text{Argmax}(F)$.

Demostración. Sea $C \subseteq \Theta$ cerrado y disjunto de $\text{Argmax}(F)$. Por continuidad y compacidad existe $\delta > 0$ tal que

$$\sup_{\theta \in C} F(\theta) \leq F^* - \delta, \quad F^* := \max_{\vartheta \in \Theta} F(\vartheta).$$

Tomando un abierto U que intersekte el conjunto de maximizadores y en el que $F \geq F^* - \delta/2$, obtenemos

$$\mathbb{Q}_\beta(C) \leq \frac{e^{\beta(F^* - \delta)}\eta(C)}{e^{\beta(F^* - \delta/2)}\eta(U)} = e^{-\beta\delta/2} \frac{\eta(C)}{\eta(U)} \xrightarrow{\beta \rightarrow \infty} 0.$$

Por tanto toda masa límite fuera de los maximizadores desaparece. □

Ejemplo 1.13 (Espacio finito y matriz replicador–mutador). Sea $\Theta = \{1, 2, 3\}$, fitness $F(1) = 0$, $F(2) = 1$, $F(3) = 2$, y potencial $G = e^F$. Consideremos el núcleo

$$M = \begin{pmatrix} 0.70 & 0.25 & 0.05 \\ 0.20 & 0.60 & 0.20 \\ 0.05 & 0.25 & 0.70 \end{pmatrix}.$$

Si la población inicial es uniforme, $\eta_0 = (1/3, 1/3, 1/3)$, entonces la selección produce

$$\Psi_G(\eta_0) = \frac{1}{1 + e + e^2}(1, e, e^2),$$

y tras la mutación

$$\eta_1 = \Psi_G(\eta_0)M.$$

La población resultante ya favorece fuertemente al estado 3, pero el núcleo de mutación impide el colapso instantáneo y preserva exploración alrededor del óptimo.




Figura 2: El algoritmo genético visto como composición de un cambio de medida (selección) con un núcleo de Markov (mutación/recombinación).

1.6. Poblaciones finitas y aproximación empírica

En la práctica se trabaja con una población finita $\theta_n^1, \dots, \theta_n^N$. Su medida empírica es

$$\eta_n^N := \frac{1}{N} \sum_{i=1}^N \delta_{\theta_n^i}.$$

La selección genera pesos normalizados

$$W_n^i = \frac{G(\theta_n^i)}{\sum_{j=1}^N G(\theta_n^j)},$$

y la resampling step produce ancestros $A_n^1, \dots, A_n^N$ con ley multinomial de parámetros $(W_n^1, \dots, W_n^N)$. Después se aplica mutación independiente según el núcleo M .

Proposición 1.14 (Insensatez de una generación de resampling). *Condionalmente a la población actual,*

$$\mathbb{E}[\eta_{n+1}^N(\varphi) \mid \eta_n^N] = \Phi_G(\eta_n^N)(\varphi)$$

para toda función acotada medible φ .

Demostración. La esperanza condicional de la medida empírica después del remuestreo coincide con la medida seleccionada; al aplicar mutación independiente se compone con el núcleo M . La linealidad de la esperanza da la identidad. $\square$

Nota 1.15. Esta insensatez de una generación no significa que el algoritmo completo sea insensado para funciones no lineales del fitness. Lo que sí ofrece es una aproximación de partículas a la dinámica determinista $\eta_{n+1} = \Phi_G(\eta_n)$, y precisamente esa estructura es la base de la teoría moderna de sistemas de partículas interactuantes y del análisis matemático del algoritmo genético simple.

1.7. Caso finito: teoría espectral del operador replicador–mutador

Supongamos ahora que $\Theta = \{1, \dots, d\}$ es finito. Identificamos una medida de probabilidad η con un vector fila en el simplex

$$\Delta_d := \left\{ \eta = (\eta_1, \dots, \eta_d) : \eta_i \geq 0, \sum_{i=1}^d \eta_i = 1 \right\}.$$

Sea $G_i := G(i) > 0$ y sea $M = (M_{ij})_{1 \leq i, j \leq d}$ una matriz estocástica. Introducimos la matriz positiva

$$Q := D_G M, \quad D_G := \text{diag}(G_1, \dots, G_d).$$

Entonces la dinámica replicador–mutador puede escribirse como

$$\Phi_G(\eta) = \frac{\eta Q}{\eta Q \mathbf{1}}, \quad \mathbf{1} = (1, \dots, 1)^T.$$

Esta fórmula muestra que toda la no linealidad proviene únicamente de la normalización final.

Teorema 1.16 (Perron–Frobenius para el operador replicador–mutador). *Supongamos que Q es primitiva, es decir, existe $n_0 \geq 1$ tal que todas las entradas de Q^{n_0} son estrictamente positivas. Entonces existen:*

1. un radio espectral dominante $\lambda_\star > 0$;
2. un autovector derecho $r \in (0, \infty)^d$ tal que $Qr = \lambda_\star r$;
3. un autovector izquierdo $\ell \in (0, \infty)^d$ tal que $\ell Q = \lambda_\star \ell$;

únicos salvo reescala. Además, para toda condición inicial $\eta_0 \in \Delta_d$ con soporte no vacío,

$$\eta_n := \Phi_G^{on}(\eta_0) = \frac{\eta_0 Q^n}{\eta_0 Q^n \mathbf{1}} \xrightarrow{n \rightarrow \infty} \pi_\star := \frac{\ell}{\ell \mathbf{1}}.$$

En particular, $\pi_\star$ es el único punto fijo de la dinámica replicador–mutador en el interior del simplex.

Demostración. La identidad cerrada

$$\eta_n = \frac{\eta_0 Q^n}{\eta_0 Q^n \mathbf{1}}$$

se obtiene por inducción inmediata a partir de la definición de Φ_G . Como Q es primitiva, el teorema de Perron–Frobenius asegura que $\lambda_\star$ es simple y estrictamente dominante, y que existen autovectores positivos r y ℓ tales que

$$Q^n = \lambda_\star^n r \ell + R_n, \quad \|R_n\| \leq C \rho^n$$

para alguna constante $C > 0$ y algún $\rho < \lambda_\star$, una vez que se normaliza con $\ell r = 1$. En consecuencia,

$$\eta_0 Q^n = \lambda_\star^n (\eta_0 r) \ell + \eta_0 R_n.$$

Dividiendo por el escalar positivo $\eta_0 Q^n \mathbf{1}$, el término dominante es proporcional a ℓ , mientras que el resto es exponencialmente menor. Esto da la convergencia a $\pi_\star$. Si $\eta = \Phi_G(\eta)$, entonces $\eta Q = c\eta$ para algún escalar $c > 0$, de modo que η es un autovector izquierdo positivo de Q , y la unicidad de Perron implica $\eta = \pi_\star$. $\square$

Nota 1.17. Desde el punto de vista genético, $\pi_\star$ es una distribución de equilibrio entre exploración y explotación. La selección por sí sola empujaría masa hacia estados de alto fitness; la mutación por sí sola difundiría masa; la competencia entre ambas queda codificada por la estructura espectral de Q .

Ejemplo 1.18 (Dos loci agregados en tres clases de fitness). Considérese de nuevo $\Theta = \{1, 2, 3\}$, con $G = (1, e, e^2)$ y

$$M = \begin{pmatrix} 0.70 & 0.25 & 0.05 \\ 0.20 & 0.60 & 0.20 \\ 0.05 & 0.25 & 0.70 \end{pmatrix}.$$

Entonces

$$Q = D_G M = \begin{pmatrix} 0.70 & 0.25 & 0.05 \\ 0.20e & 0.60e & 0.20e \\ 0.05e^2 & 0.25e^2 & 0.70e^2 \end{pmatrix}.$$

El teorema anterior garantiza la existencia de una ley límite $\pi_\star$ independiente de la población inicial. Como la tercera fila es amplificada por e^2 , la masa límite se desplaza hacia la tercera clase, pero no colapsa totalmente porque M sigue empujando parte de la población hacia las clases vecinas.




Figura 3: Comparación entre la población inicial, la medida tras selección pura y la población después de una generación replicador–mutador. La mutación suaviza la concentración inducida por el fitness, pero conserva el sesgo hacia las clases más aptas.

Corolario 1.19 (Velocidad de relajación bajo brecha espectral). *Supongamos, además de las hipótesis del Teorema 1.16, que Q es diagonalizable sobre $\mathbb{R}$ y que sus autovalores satisfacen*

$$\lambda_\star = \lambda_1 > |\lambda_2| \geq \dots \geq |\lambda_d|.$$

Entonces existe una constante $C(\eta_0) > 0$ tal que

$$\|\eta_n - \pi_\star\|_1 \leq C(\eta_0) \left(\frac{|\lambda_2|}{\lambda_\star} \right)^n, \quad n \geq 0.$$

En particular, la relajación hacia el equilibrio queda gobernada por la razón espectral $|\lambda_2|/\lambda_\star$.

Demostración. Por diagonalización existe una base de autovectores izquierdos $\ell_1, \dots, \ell_d$ de Q con $\ell_1 = \ell$ asociado a $\lambda_\star$. Escribimos

$$\eta_0 = a_1 \ell + \sum_{r=2}^d a_r \ell_r.$$

Entonces

$$\eta_0 Q^n = a_1 \lambda_\star^n \ell + \sum_{r=2}^d a_r \lambda_r^n \ell_r.$$

Dividimos entre el escalar positivo $\eta_0 Q^n \mathbf{1}$. Como $\ell \mathbf{1} > 0$, se obtiene

$$\eta_n = \frac{a_1 \lambda_\star^n \ell + \sum_{r=2}^d a_r \lambda_r^n \ell_r}{a_1 \lambda_\star^n \ell \mathbf{1} + \sum_{r=2}^d a_r \lambda_r^n \ell_r \mathbf{1}} = \frac{\ell + \sum_{r=2}^d c_r (\lambda_r / \lambda_\star)^n \ell_r}{\ell \mathbf{1} + \sum_{r=2}^d c_r (\lambda_r / \lambda_\star)^n \ell_r \mathbf{1}}$$

para ciertas constantes c_r . El denominador converge a $\ell \mathbf{1}$, luego permanece separado de cero para n grande. Restando $\pi_\star = \ell / (\ell \mathbf{1})$ y estimando en norma ℓ^1 , aparece una constante $C(\eta_0)$ tal que

$$\|\eta_n - \pi_\star\|_1 \leq C(\eta_0) \max_{2 \leq r \leq d} \left| \frac{\lambda_r}{\lambda_\star} \right|^n,$$

que es exactamente la cota reclamada. $\square$

1.8. Martingalas en algoritmos genéticos

La teoría de martingalas entra en algoritmos genéticos en el momento en que se compara la población empírica con la dinámica determinista replicador–mutador. Cada generación produce un error de muestreo centrado; al acumular esos errores aparece una martingala que controla fluctuaciones, concentración y convergencia cuando el tamaño poblacional N crece.

Fijemos un horizonte discreto y una población de tamaño N . Escribimos $\mathcal{F}_n^N$ para la σ -álgebra generada por todas las poblaciones hasta el tiempo n . Condicionalmente a $\mathcal{F}_{n-1}^N$, la nueva generación se obtiene muestreando de manera independiente a partir de la ley

$$\Phi_{G_{n-1}}(\eta_{n-1}^N).$$

En particular, si $\theta_n^1, \dots, \theta_n^N$ denotan los individuos de la generación n , entonces para toda función acotada φ la media empírica puede escribirse como

$$\eta_n^N(\varphi) = \frac{1}{N} \sum_{i=1}^N \varphi(\theta_n^i).$$

Proposición 1.20 (Incremento martingala de una generación). *Para toda función medible acotada φ , el error local*

$$\Delta_n^N(\varphi) := \eta_n^N(\varphi) - \Phi_{G_{n-1}}(\eta_{n-1}^N)(\varphi)$$

satisface

$$\mathbb{E}[\Delta_n^N(\varphi) \mid \mathcal{F}_{n-1}^N] = 0$$

y

$$\mathbb{E}[(\Delta_n^N(\varphi))^2 \mid \mathcal{F}_{n-1}^N] = \frac{1}{N} \text{Var}_{\Phi_{G_{n-1}}(\eta_{n-1}^N)}(\varphi) \leq \frac{\|\varphi\|_\infty^2}{N}.$$

Demostración. Condicionalmente a $\mathcal{F}_{n-1}^N$, las variables $\theta_n^1, \dots, \theta_n^N$ son i.i.d. con ley común $\Phi_{G_{n-1}}(\eta_{n-1}^N)$. Por tanto,

$$\mathbb{E}[\eta_n^N(\varphi) \mid \mathcal{F}_{n-1}^N] = \frac{1}{N} \sum_{i=1}^N \mathbb{E}[\varphi(\theta_n^i) \mid \mathcal{F}_{n-1}^N] = \Phi_{G_{n-1}}(\eta_{n-1}^N)(\varphi),$$

lo que prueba el centrado. Además, por independencia condicional,

$$\text{Var}(\eta_n^N(\varphi) \mid \mathcal{F}_{n-1}^N) = \frac{1}{N^2} \sum_{i=1}^N \text{Var}(\varphi(\theta_n^i) \mid \mathcal{F}_{n-1}^N) = \frac{1}{N} \text{Var}_{\Phi_{G_{n-1}}(\eta_{n-1}^N)}(\varphi).$$

Finalmente, si $|\varphi| \leq \|\varphi\|_\infty$, entonces

$$\text{Var}_{\Phi_{G_{n-1}}(\eta_{n-1}^N)}(\varphi) \leq \mathbb{E}_{\Phi_{G_{n-1}}(\eta_{n-1}^N)}[\varphi^2] \leq \|\varphi\|_\infty^2.$$

□

Teorema 1.21 (Martingala acumulada de error de muestreo). *Para $n \geq 1$ y función acotada φ , definamos*

$$M_n^N(\varphi) := \sum_{p=1}^n \Delta_p^N(\varphi).$$

Entonces $(M_n^N(\varphi))_{n \geq 0}$ es una martingala respecto de $(\mathcal{F}_n^N)_{n \geq 0}$ y su variación cuadrática previsible viene dada por

$$\langle M^N(\varphi) \rangle_n = \sum_{p=1}^n \mathbb{E}[(\Delta_p^N(\varphi))^2 \mid \mathcal{F}_{p-1}^N].$$

En particular,

$$\mathbb{E}[|M_n^N(\varphi)|^2] \leq \frac{n\|\varphi\|_\infty^2}{N}.$$

Demostración. La proposición anterior da

$$\mathbb{E}[M_n^N(\varphi) \mid \mathcal{F}_{n-1}^N] = M_{n-1}^N(\varphi) + \mathbb{E}[\Delta_n^N(\varphi) \mid \mathcal{F}_{n-1}^N] = M_{n-1}^N(\varphi),$$

con lo cual $(M_n^N(\varphi))$ es una martingala. La identidad para la variación cuadrática previsible es la fórmula estándar para martingalas de tiempo discreto con incrementos cuadrados integrables. Para la estimación de segundo momento usamos la isometría de Doob:

$$\mathbb{E}[|M_n^N(\varphi)|^2] = \mathbb{E}[\langle M^N(\varphi) \rangle_n] = \sum_{p=1}^n \mathbb{E}[\mathbb{E}[(\Delta_p^N(\varphi))^2 \mid \mathcal{F}_{p-1}^N]].$$

Aplicando la cota de la Proposición 1.20 a cada sumando obtenemos

$$\mathbb{E}[|M_n^N(\varphi)|^2] \leq \sum_{p=1}^n \frac{\|\varphi\|_\infty^2}{N} = \frac{n\|\varphi\|_\infty^2}{N}.$$

□

Ejemplo 1.22 (Dos alelos con mutación simétrica). Sea $\Theta = \{0, 1\}$ y sea $H(\theta) = \theta - \frac{1}{2}$. Supongamos fitness neutro $G \equiv 1$ y mutación simétrica con probabilidad $u \in [0, 1/2)$ de cambiar de alelo:

$$M = \begin{pmatrix} 1-u & u \\ u & 1-u \end{pmatrix}.$$

Entonces

$$MH(0) = (1-u)\left(-\frac{1}{2}\right) + u\left(\frac{1}{2}\right) = -(1-2u)\frac{1}{2},$$

$$MH(1) = u\left(-\frac{1}{2}\right) + (1-u)\left(\frac{1}{2}\right) = (1-2u)\frac{1}{2},$$

y por tanto $MH = (1-2u)H$. Si definimos

$$Z_n^N := \frac{\eta_n^N(H)}{(1-2u)^n},$$

entonces $\mathbb{E}[Z_n^N \mid \mathcal{F}_{n-1}^N] = Z_{n-1}^N$, de modo que (Z_n^N) es una martingala. En el caso neutral sin mutación ($u = 0$), la fracción centrada de alelos 1 es ya una martingala sin renormalización.




Figura 4: Una trayectoria empírica de población finita oscila alrededor de la dinámica determinista. La diferencia entre ambas está gobernada por la martingala de error de muestreo.

1.9. Límite de partículas a horizonte finito

La siguiente estimación formaliza la intuición central: para tiempos fijos, la población empírica converge a la dinámica determinista con error cuadrático de orden N^{-1} .

Teorema 1.23 (Ley de grandes números a horizonte finito). *Supongamos que existe una constante $g_\star > 0$ tal que $g_\star \leq G_n(\theta)$ para todo n y todo θ , y que además $\|G_n\|_\infty \leq g^\star < \infty$. Para cada horizonte fijo $m \geq 0$ existe una constante $C_m < \infty$, dependiente sólo de m , $g_\star$ y $g^\star$, tal que para toda función medible φ con $\|\varphi\|_\infty \leq 1$ se cumple*

$$\mathbb{E}[|\eta_m^N(\varphi) - \eta_m(\varphi)|^2] \leq \frac{C_m}{N}.$$

Demostración. Para abreviar, escribimos $\Phi_n := \Phi_{G_n}$. Sea

$$d_m^N := \sup_{\|\varphi\|_\infty \leq 1} \mathbb{E}[|\eta_m^N(\varphi) - \eta_m(\varphi)|^2].$$

Demostraremos por inducción que $d_m^N \leq C_m/N$.

Para $m = 0$, si la población inicial es i.i.d. con ley η_0 , entonces $\eta_0^N(\varphi)$ es una media empírica usual y

$$\mathbb{E}[|\eta_0^N(\varphi) - \eta_0(\varphi)|^2] \leq \frac{1}{N},$$

de modo que $d_0^N \leq N^{-1}$.

Supongamos ahora conocida la cota en el tiempo $m-1$. Para $\|\varphi\|_\infty \leq 1$ descomponemos

$$\eta_m^N(\varphi) - \eta_m(\varphi) = \Delta_m^N(\varphi) + \left(\Phi_{m-1}(\eta_{m-1}^N)(\varphi) - \Phi_{m-1}(\eta_{m-1})(\varphi) \right).$$

Por $(a+b)^2 \leq 2a^2 + 2b^2$ y la Proposición 1.20,

$$\mathbb{E}[|\eta_m^N(\varphi) - \eta_m(\varphi)|^2] \leq \frac{2}{N} + 2\mathbb{E}[|\Phi_{m-1}(\eta_{m-1}^N)(\varphi) - \Phi_{m-1}(\eta_{m-1})(\varphi)|^2].$$

Resta controlar la dependencia de Φ_{m-1} respecto de la medida de entrada. Si μ y ν son probabilidades, entonces

$$\Phi_{m-1}(\mu)(\varphi) - \Phi_{m-1}(\nu)(\varphi) = \frac{\mu(G_{m-1}M\varphi)}{\mu(G_{m-1})} - \frac{\nu(G_{m-1}M\varphi)}{\nu(G_{m-1})}.$$

Sumando y restando $\nu(G_{m-1}M\varphi)/\mu(G_{m-1})$ y usando que $\mu(G_{m-1}), \nu(G_{m-1}) \geq g_\star$, $\|M\varphi\|_\infty \leq 1$ y $\|G_{m-1}\|_\infty \leq g^\star$, deducimos

$$|\Phi_{m-1}(\mu)(\varphi) - \Phi_{m-1}(\nu)(\varphi)| \leq \frac{2g^\star}{g_\star} \sup_{\|\psi\|_\infty \leq 1} |\mu(\psi) - \nu(\psi)|.$$

En particular, existe $L := 2g^\star/g_\star$ tal que

$$|\Phi_{m-1}(\eta_{m-1}^N)(\varphi) - \Phi_{m-1}(\eta_{m-1})(\varphi)|^2 \leq L^2 \sup_{\|\psi\|_\infty \leq 1} |\eta_{m-1}^N(\psi) - \eta_{m-1}(\psi)|^2.$$

Tomando esperanza y supremo en φ obtenemos

$$d_m^N \leq \frac{2}{N} + 2L^2 d_{m-1}^N.$$

Una iteración finita cierra la inducción y produce constantes C_m determinadas por la recurrencia $C_0 = 1$ y $C_m = 2 + 2L^2 C_{m-1}$. $\square$

Nota 1.24. El teorema anterior explica por qué el límite $N \rightarrow \infty$ de los algoritmos genéticos es un sistema dinámico determinista. Las martingalas cuantifican las fluctuaciones de tamaño $N^{-1/2}$ alrededor de esa trayectoria, mientras que la parte espectral del operador replicador–mutador determina cómo se amortiguan esas fluctuaciones cuando la dinámica posee una brecha espectral efectiva.

2. Marco de trabajo

A lo largo de todo el documento, $(\Omega, \mathcal{F})$ es un espacio medible. Una *medida* (positiva) es una función $\mu : \mathcal{F} \rightarrow [0, \infty]$ con $\mu(\emptyset) = 0$ y aditividad numerable. Una *medida de probabilidad* es una medida con $\mu(\Omega) = 1$. Cuando $(\Omega, \mathcal{F}, \mathbb{P})$ es un espacio de probabilidad, una variable aleatoria es una función medible $X : \Omega \rightarrow \mathbb{R} \cup \{\pm\infty\}$.

Este marco básico no se introduce aquí como mera notación preliminar. En análisis estocástico, el paso verdaderamente decisivo consiste en distinguir entre la ley que gobierna el sistema y la forma en que esa ley es observada, condicionada o reponderada. La construcción de Lebesgue permite integrar sobre espacios abstractos; Radon–Nikodym permite comparar leyes; los núcleos permiten propagar masa; las filtraciones registran información en el tiempo; y las martingalas expresan compensaciones exactas entre pasado y futuro. Esa será la lógica interna que guía cada sección del manuscrito.

Construiremos la integral de Lebesgue desde cero, luego construiremos nuevas medidas $\mathbb{Q}$ mediante densidades, después demostraremos Radon–Nikodym y derivaremos la identidad del cambio de medida. A partir de ahí, el texto se desplaza hacia procesos y problemas variacionales: densidades condicionadas, cadenas a tiempo continuo, portafolios, filtrado oculto, Monte Carlo y optimización estocástica.

Nota 2.1 (Sobre la notación). En todo el manuscrito adoptaremos la convención

$$\int_{\Omega} f(x) \mathbb{P}(dx),$$

que debe leerse como “integrar f con respecto a la medida $\mathbb{P}$ ”. El símbolo dx no presupone que $\Omega \subseteq \mathbb{R}$; es simplemente una notación estándar para el punto genérico del espacio medible. Del mismo modo escribiremos $\mu(dx)$, $\mathbb{Q}(dx)$, etc. Esta convención es especialmente cómoda cuando comparemos medidas, densidades y núcleos de transición.

Nota 2.2. Cuando trabajemos en espacios discretos, la notación $\int f(x) \mathbb{P}(dx)$ coincide con una suma $\sum_x f(x) \mathbb{P}(\{x\})$. Cuando trabajemos en espacios continuos dominados por Lebesgue, la misma notación se reduce a la forma clásica $\int f(x) p(x) dx$. Una de las ventajas del lenguaje de medidas es precisamente que ambas situaciones quedan cubiertas por una sola escritura.

Nota 2.3. Todos los argumentos que siguen funcionan para cualesquiera medidas σ -finitas $(\mathbb{P}, \mathbb{Q})$; mantenemos la notación probabilística porque es la entrada habitual en probabilidad.

Nota 2.4 (Hoja de ruta). La narrativa del texto tiene cuatro etapas. Primero construimos la integral. Después mostramos cómo una densidad Z define una nueva medida $\mathbb{Q}$. Luego identificamos el teorema de Radon–Nikodym como el resultado que explica por qué toda medida absolutamente continua admite una densidad. Finalmente, llevamos este mecanismo a procesos: densidades condicionadas, martingalas positivas, procesos de Poisson y transformaciones h para cadenas de Markov a tiempo continuo.

3. Construcción de la integral de Lebesgue

3.1. Paso 1: funciones simples

Definición 3.1 (Función simple). Una *función simple (no negativa)* es una función medible $s : \Omega \rightarrow [0, \infty)$ de la forma

$$s(x) = \sum_{i=1}^n a_i \mathbf{1}_{A_i}(x), \quad a_i \geq 0, \quad A_i \in \mathcal{F},$$

donde los conjuntos A_i pueden suponerse disjuntos (refinando la partición).

Ejemplo 3.2 (Funciones simples concretas). Consideremos $\Omega = [0, 1]$ con la σ -álgebra de Borel.

- $s_1(x) = 2 \cdot \mathbf{1}_{[0, 0.5]}(x) + 3 \cdot \mathbf{1}_{(0.5, 1]}(x)$ es una función simple.
- $s_2(x) = \sum_{k=0}^3 \frac{k}{3} \cdot \mathbf{1}_{[k/3, (k+1)/3)}(x)$ aproxima la función identidad.

Definición 3.3 (Integral de una función simple). Sea μ una medida. Para $s = \sum_{i=1}^n a_i \mathbf{1}_{A_i}$ (con A_i disjuntos) definimos

$$\int_{\Omega} s(x) \mu(dx) := \sum_{i=1}^n a_i \mu(A_i).$$

Para $A \in \mathcal{F}$, definimos la integral restringida mediante

$$\int_A s(x) \mu(dx) := \int_{\Omega} s(x) \mathbf{1}_A(x) \mu(dx) = \sum_{i=1}^n a_i \mu(A \cap A_i).$$

Ejemplo 3.4 (Cálculo de integral simple). Con μ la medida de Lebesgue en $[0, 1]$ y s_1 del ejemplo anterior:

$$\int_{[0, 1]} s_1(x) \mu(dx) = 2 \cdot \mu([0, 0.5]) + 3 \cdot \mu((0.5, 1]) = 2 \cdot 0.5 + 3 \cdot 0.5 = 2.5.$$

Para $A = [0.2, 0.7]$:

$$\int_A s_1(x) \mu(dx) = 2 \cdot \mu([0.2, 0.5]) + 3 \cdot \mu((0.5, 0.7]) = 2 \cdot 0.3 + 3 \cdot 0.2 = 1.2.$$

Lema 3.5 (Buena definición). *El valor de $\int s d\mu$ no depende de la representación elegida de s .*

Demostración. Escribimos dos representaciones de s usando particiones disjuntas $\{A_i\}$ y $\{B_j\}$. Refinamos a la partición disjunta común $\{A_i \cap B_j\}_{i,j}$. Entonces

$$s(x) = \sum_{i,j} a_i \mathbf{1}_{A_i \cap B_j}(x) = \sum_{i,j} b_j \mathbf{1}_{A_i \cap B_j}(x),$$

por lo tanto $a_i = b_j$ en cada átomo $A_i \cap B_j$ con medida positiva. Sumar $a_i \mu(A_i \cap B_j)$ sobre los átomos es igual a sumar $b_j \mu(A_i \cap B_j)$, así que ambas integrales coinciden. $\square$

Lema 3.6 (Propiedades básicas para funciones simples). *Para funciones simples $s, t \geq 0$ y $\alpha, \beta \geq 0$:*

$$\int (\alpha s + \beta t)(x) \mu(dx) = \alpha \int s(x) \mu(dx) + \beta \int t(x) \mu(dx), \quad s \leq t \Rightarrow \int s(x) \mu(dx) \leq \int t(x) \mu(dx).$$

Ejemplo 3.7 (Verificación de propiedades). Con s_1 como antes y $t(x) = \mathbf{1}_{[0,0.3]}(x)$:

$$\begin{aligned} \int (2s_1 + 3t)(x) \mu(dx) &= 2 \int s_1(x) \mu(dx) + 3 \int t(x) \mu(dx) = 2 \cdot 2.5 + 3 \cdot 0.3 = 5 + 0.9 = 5.9, \\ \int (2s_1 + 3t)(x) \mu(dx)_{\text{directo}} &= \int (4\mathbf{1}_{[0,0.5]} + 6\mathbf{1}_{(0.5,1]} + 3\mathbf{1}_{[0,0.3]})(x) \mu(dx) \\ &= 4 \cdot 0.5 + 6 \cdot 0.5 + 3 \cdot 0.3 = 2 + 3 + 0.9 = 5.9. \end{aligned}$$

3.2. Paso 2: integral para funciones medibles no negativas

Definición 3.8 (Integral para $f \geq 0$). Sea $f : \Omega \rightarrow [0, \infty]$ medible. Definimos

$$\int_{\Omega} f(x) \mu(dx) := \sup \left\{ \int_{\Omega} s(x) \mu(dx) : s \text{ simple}, 0 \leq s \leq f \right\} \in [0, \infty].$$

Para $A \in \mathcal{F}$, definimos $\int_A f(x) \mu(dx) := \int_{\Omega} f(x) \mathbf{1}_A(x) \mu(dx)$.

Ejemplo 3.9 (Aproximación de $f(x) = x$). Para $f(x) = x$ en $[0, 1]$ con medida de Lebesgue:

- $s_2(x) = \sum_{k=0}^3 \frac{k}{3} \mathbf{1}_{[k/3, (k+1)/3)}(x)$ da $\int s_2(x) \mu(dx) = \sum_{k=0}^3 \frac{k}{3} \cdot \frac{1}{3} = \frac{0+1+2}{9} = \frac{1}{3}$.
- Refinando la partición con $n = 100$: $\int s_{100}(x) \mu(dx) \approx \int_0^1 x dx = 0.5$.
- El supremo sobre todas las aproximaciones simples es exactamente 0.5.

Lema 3.10 (Aproximación por funciones simples). *Para cada función medible $f \geq 0$ existe una sucesión creciente de funciones simples $(s_n)_{n \geq 1}$ tal que $0 \leq s_n \uparrow f$ puntualmente y*

$$\int f(x) \mu(dx) = \lim_{n \rightarrow \infty} \int s_n(x) \mu(dx).$$

Demostración. Una construcción estándar es

$$s_n(x) := \sum_{k=0}^{n2^n-1} \frac{k}{2^n} \mathbf{1}_{\{k/2^n \leq f(x) < (k+1)/2^n\}}(x) + n \mathbf{1}_{\{f(x) \geq n\}}(x).$$

Entonces cada s_n es simple, $s_n \leq f$, y $s_n \uparrow f$. Por definición de $\int f d\mu$ como un supremo sobre cotas inferiores simples, siempre tenemos $\int s_n d\mu \leq \int f d\mu$, y para cualquier $\varepsilon > 0$ se puede elegir una función simple $s \leq f$ con $\int s d\mu > \int f d\mu - \varepsilon$. Para n suficientemente grande, $s \leq s_n$ puntualmente (por el refinamiento de la malla), por lo tanto $\int s d\mu \leq \int s_n d\mu$. Tomando $n \rightarrow \infty$ se obtiene $\lim_n \int s_n d\mu = \int f d\mu$. $\square$




Figura 5: Una función medible puede aproximarse desde abajo por funciones simples crecientes. La figura visualiza la idea central de la construcción de Lebesgue.

Ejemplo 3.11 (Aproximación explícita de $f(x) = x^2$). Para $f(x) = x^2$ en $[0, 1]$ con $n = 2$:

$$\begin{aligned} s_2(x) &= \sum_{k=0}^7 \frac{k}{4} \mathbf{1}_{\{k/4 \leq x^2 < (k+1)/4\}}(x) + 2 \mathbf{1}_{\{x^2 \geq 2\}}(x) \\ &= \sum_{k=0}^7 \frac{k}{4} \mathbf{1}_{\{\sqrt{k/4} \leq x < \sqrt{(k+1)/4}\}}(x). \end{aligned}$$

Los intervalos son: $[0, 0.5)$ para $k = 0$, $[0.5, 0.707)$ para $k = 1$, etc.

Teorema 3.12 (Convergencia Monótona / Beppo–Levi). Si $f_n \geq 0$ medibles y $f_n \uparrow f$ puntualmente, entonces

$$\int f_n(x) \mu(dx) \uparrow \int f(x) \mu(dx).$$

Demostración. Por monotonidad, $\int f_n d\mu$ es creciente y está acotada superiormente por $\int f d\mu$, por lo que tiene un límite $L \leq \int f d\mu$.

Para la desigualdad inversa, sea s una función simple con $0 \leq s \leq f$. Escribimos $s = \sum_{i=1}^m a_i \mathbf{1}_{A_i}$ con A_i disjuntos y $a_i \geq 0$. Para cada i , definimos $A_{i,n} := A_i \cap \{f_n \geq a_i\}$. Dado que $f_n \uparrow f$ y $s \leq f$, tenemos $A_{i,n} \uparrow A_i$. Definimos $s_n := \sum_{i=1}^m a_i \mathbf{1}_{A_{i,n}}$. Entonces s_n es simple, $s_n \leq f_n$, y $s_n \uparrow s$. Por lo tanto $\int s_n d\mu \leq \int f_n d\mu$ para todo n . Por el Paso 1 (funciones simples) y la continuidad desde abajo de las medidas,

$$\int s(x) \mu(dx) = \lim_{n \rightarrow \infty} \int s_n(x) \mu(dx) \leq \lim_{n \rightarrow \infty} \int f_n(x) \mu(dx) = L.$$

Tomando el supremo sobre todas las funciones simples $s \leq f$ se obtiene $\int f d\mu \leq L$. Por lo tanto $L = \int f d\mu$. $\square$

Ejemplo 3.13 (Aplicación del TCM). Consideremos $f_n(x) = x^n$ en $[0, 1]$ con $n \geq 1$. Entonces $f_n \uparrow f$ donde $f(x) = 0$ para $x \in [0, 1)$ y $f(1) = 1$. Por TCM:

$$\lim_{n \rightarrow \infty} \int_0^1 x^n dx = \int_0^1 \lim_{n \rightarrow \infty} x^n dx = \int_0^1 0 dx = 0.$$

Efectivamente, $\int_0^1 x^n dx = \frac{1}{n+1} \rightarrow 0$.

3.3. Paso 3: funciones reales integrables

Definición 3.14 (Partes positiva/negativa). Para una variable medible $X : \Omega \rightarrow \mathbb{R} \cup \{\pm\infty\}$ definimos

$$X^+ := \max\{X, 0\}, \quad X^- := \max\{-X, 0\},$$

de modo que $X = X^+ - X^-$ y $|X| = X^+ + X^-$.

Definición 3.15 (Integral de una función con signo). Si $\int X^+(x) \mu(dx) < \infty$ y $\int X^-(x) \mu(dx) < \infty$, definimos

$$\int X(x) \mu(dx) := \int X^+(x) \mu(dx) - \int X^-(x) \mu(dx).$$

Entonces se dice que X es μ -integrable (es decir, $X \in L^1(\mu)$).

Ejemplo 3.16 (Cálculo con partes positiva y negativa). Para $X(x) = x - 0.5$ en $[0, 1]$:

$$X^+(x) = \max\{x - 0.5, 0\} = \begin{cases} 0 & x \leq 0.5 \\ x - 0.5 & x > 0.5 \end{cases}$$

$$X^-(x) = \max\{0.5 - x, 0\} = \begin{cases} 0.5 - x & x \leq 0.5 \\ 0 & x > 0.5 \end{cases}$$

Entonces $\int X^+(x) \mu(dx) = \int_{0.5}^1 (x - 0.5) dx = \frac{1}{8}$, $\int X^-(x) \mu(dx) = \int_0^{0.5} (0.5 - x) dx = \frac{1}{8}$, luego $\int X(x) \mu(dx) = \frac{1}{8} - \frac{1}{8} = 0$.

Lema 3.17 (Linealidad en L^1). Si $X, Y \in L^1(\mu)$ y $a, b \in \mathbb{R}$, entonces $aX + bY \in L^1(\mu)$ y

$$\int (aX + bY)(x) \mu(dx) = a \int X(x) \mu(dx) + b \int Y(x) \mu(dx).$$

Ejemplo 3.18 (Verificación de linealidad). Con $X(x) = x$, $Y(x) = x^2$ en $[0, 1]$:

$$\begin{aligned} \int (2X + 3Y)(x) \mu(dx) &= 2 \int_0^1 x dx + 3 \int_0^1 x^2 dx = 2 \cdot \frac{1}{2} + 3 \cdot \frac{1}{3} = 1 + 1 = 2, \\ \int_0^1 (2x + 3x^2) dx &= [x^2 + x^3]_0^1 = 1 + 1 = 2. \end{aligned}$$

4. Definir $\mathbb{Q}$ mediante una densidad: $\mathbb{Q}(A) = \int_A Z d\mathbb{P}$

Fijamos un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$.

Definición 4.1 (Construcción de densidad). Sea $Z : \Omega \rightarrow [0, \infty]$ medible con

$$\int_{\Omega} Z(x) \mathbb{P}(dx) = 1.$$

Definimos una función de conjunto $\mathbb{Q} : \mathcal{F} \rightarrow [0, \infty]$ mediante

$$\mathbb{Q}(A) := \int_A Z(x) \mathbb{P}(dx) \quad (A \in \mathcal{F}).$$

Ejemplo 4.2 (Cambio de medida discreto). Sea $\Omega = \{1, 2, 3, 4, 5, 6\}$, $\mathbb{P}$ uniforme ($\mathbb{P}(\{i\}) = 1/6$). Definimos $Z(i) = i/3.5$ (notar que $\sum_{i=1}^6 i/3.5 \cdot 1/6 = (21/3.5)/6 = 6/6 = 1$). Entonces

$$\mathbb{Q}(\{i\}) = \int_{\{i\}} Z(x) \mathbb{P}(dx) = Z(i) \cdot \mathbb{P}(\{i\}) = \frac{i}{3.5} \cdot \frac{1}{6} = \frac{i}{21}.$$

Así $\mathbb{Q}$ da más peso a números mayores.

Ejemplo 4.3 (Cambio de medida continuo). En $([0, 1], \mathcal{B}, \mathbb{P} = \text{Leb})$, tomemos $Z(x) = 2x$. Entonces $\int_0^1 2x \, dx = 1$. Para cualquier intervalo $[a, b] \subset [0, 1]$:

$$\mathbb{Q}([a, b]) = \int_a^b 2x \, dx = b^2 - a^2.$$

Esta $\mathbb{Q}$ tiene densidad lineal creciente.




Figura 6: La densidad $Z(x) = 2x$ redistribuye la masa hacia valores grandes. Visualmente, $\mathbb{Q}$ pone menos peso cerca de 0 y más peso cerca de 1.

Nota 4.4. La integral restringida $\int_A Z(x) \mathbb{P}(dx)$ es, por definición, $\int_\Omega Z(x) \mathbf{1}_A(x) \mathbb{P}(dx)$. Por lo tanto, la construcción utiliza únicamente la integral de Lebesgue ya construida en §2.

5. Demostrar que $\mathbb{Q}$ es una medida (y una medida de probabilidad)

Proposición 5.1. La función de conjunto $\mathbb{Q}$ definida por $\mathbb{Q}(A) = \int_A Z(x) \mathbb{P}(dx)$ es una medida en $(\Omega, \mathcal{F})$. Además, es una medida de probabilidad: $\mathbb{Q}(\Omega) = 1$.

Demostración. Verificamos los axiomas de medida.

(i) El conjunto vacío es nulo. Dado que $\mathbf{1}_\emptyset = 0$,

$$\mathbb{Q}(\emptyset) = \int_\Omega Z(x) \mathbf{1}_\emptyset(x) \mathbb{P}(dx) = 0.$$

(ii) No negatividad. Dado que $Z \geq 0$ y $\mathbf{1}_A \geq 0$, tenemos $Z\mathbf{1}_A \geq 0$ y por lo tanto $\mathbb{Q}(A) = \int Z(x) \mathbf{1}_A(x) \mathbb{P}(dx) \geq 0$.

(iii) Aditividad numerable. Sean $(A_n)_{n \geq 1} \subset \mathcal{F}$ disjuntos dos a dos y definimos $A := \bigcup_{n \geq 1} A_n$. Definimos las sumas parciales

$$f_N := \sum_{n=1}^N \mathbf{1}_{A_n}.$$

Como los A_n son disjuntos, $f_N(x) \in \{0, 1\}$ y $f_N \uparrow \mathbf{1}_A$ puntualmente. Multiplicando por $Z \geq 0$ obtenemos

$$Z(x) f_N(x) \uparrow Z(x) \mathbf{1}_A(x).$$

Por Convergencia Monótona (Teorema 3.12),

$$\mathbb{Q}(A) = \int Z(x) \mathbf{1}_A(x) \mathbb{P}(dx) = \lim_{N \rightarrow \infty} \int Z(x) f_N(x) \mathbb{P}(dx).$$

Por linealidad para sumas finitas,

$$\int Z(x) f_N(x) \mathbb{P}(dx) = \int Z(x) \left(\sum_{n=1}^N \mathbf{1}_{A_n}(x) \right) \mathbb{P}(dx) = \sum_{n=1}^N \int Z(x) \mathbf{1}_{A_n}(x) \mathbb{P}(dx) = \sum_{n=1}^N \mathbb{Q}(A_n).$$

Tomando $N \rightarrow \infty$ obtenemos $\mathbb{Q}(A) = \sum_{n \geq 1} \mathbb{Q}(A_n)$.

(iv) *Normalización*. Finalmente,

$$\mathbb{Q}(\Omega) = \int_{\Omega} Z(x) \mathbb{P}(dx) = 1$$

por hipótesis. Por lo tanto $\mathbb{Q}$ es una medida de probabilidad. $\square$

Ejemplo 5.2 (Verificación de aditividad). Con el ejemplo continuo $Z(x) = 2x$, tomemos $A_1 = [0, 0.3]$, $A_2 = (0.3, 0.7]$, $A_3 = (0.7, 1]$. Entonces:

$$\begin{aligned} \mathbb{Q}(A_1) &= 0.3^2 - 0^2 = 0.09, \\ \mathbb{Q}(A_2) &= 0.7^2 - 0.3^2 = 0.49 - 0.09 = 0.4, \\ \mathbb{Q}(A_3) &= 1^2 - 0.7^2 = 1 - 0.49 = 0.51, \\ \mathbb{Q}([0, 1]) &= 1 = 0.09 + 0.4 + 0.51. \end{aligned}$$




Figura 7: Un ejemplo discreto de redistribución de masa. La normalización se conserva, pero la medida $\mathbb{Q}$ concentra mayor peso donde la densidad Z es más grande.

Corolario 5.3 (Continuidad absoluta). Si $\mathbb{P}(A) = 0$ entonces $\mathbb{Q}(A) = 0$. En particular, $\mathbb{Q} \ll \mathbb{P}$.

Demostración. Si $\mathbb{P}(A) = 0$ entonces $\int_A Z(x) \mathbb{P}(dx) = 0$ para cualquier función medible no negativa Z (integral sobre un conjunto nulo), por lo tanto $\mathbb{Q}(A) = 0$. $\square$

Ejemplo 5.4 (Continuidad absoluta en acción). Con $\mathbb{P}$ Lebesgue en $[0, 1]$ y $Z(x) = 2x$, tomemos $A = \{\text{rationals}\}$. Como $\mathbb{P}(A) = 0$, entonces $\mathbb{Q}(A) = \int_A 2x dx = 0$ (integral sobre conjunto de medida cero).

6. Teorema de Radon–Nikodym (demostración completa)

Ahora demostramos el enunciado recíproco: si $\mathbb{Q} \ll \mathbb{P}$ (y se cumple la σ -finitud), entonces $\mathbb{Q}$ admite una densidad $Z = \frac{d\mathbb{Q}}{d\mathbb{P}}$ tal que $\mathbb{Q}(A) = \int_A Z d\mathbb{P}$.

6.1. Preliminares: medidas con signo y descomposición de Hahn

Definición 6.1 (Medida con signo). Una *medida con signo* ν sobre $(\Omega, \mathcal{F})$ es una función $\nu : \mathcal{F} \rightarrow \mathbb{R} \cup \{\pm\infty\}$ tal que $\nu(\emptyset) = 0$ y ν es numerablemente aditiva sobre familias disjuntas, con la convención de que ν nunca toma ambos valores $+\infty$ y $-\infty$.

Ejemplo 6.2 (Medida con signo simple). En $\{1, 2, 3\}$, definamos $\nu(\{1\}) = 2$, $\nu(\{2\}) = -1$, $\nu(\{3\}) = 0.5$. Entonces ν es una medida con signo finita.

Teorema 6.3 (Descomposición de Hahn). Sea ν una medida con signo. Entonces existen conjuntos medibles $\mathbb{P}_\nu, N_\nu \in \mathcal{F}$ tales que $\mathbb{P}_\nu \cup N_\nu = \Omega$, $\mathbb{P}_\nu \cap N_\nu = \emptyset$ y

$$\nu(A) \geq 0 \text{ para todo } A \subset \mathbb{P}_\nu, \quad \nu(A) \leq 0 \text{ para todo } A \subset N_\nu.$$

Tal descomposición es única salvo conjuntos ν -nulos.

Ejemplo 6.4 (Descomposición de Hahn). Para ν en $\mathbb{R}$ con densidad $f(x) = x$, la descomposición de Hahn es $\mathbb{P}_\nu = [0, \infty)$, $N_\nu = (-\infty, 0)$.

6.2. Radon–Nikodym para medidas finitas

Teorema 6.5 (Radon–Nikodym, caso finito). Sean $\mathbb{P}$ una medida finita sobre $(\Omega, \mathcal{F})$ y $\mathbb{Q}$ una medida finita tal que $\mathbb{Q} \ll \mathbb{P}$. Entonces existe una función medible $Z \geq 0$ ($\mathbb{P}$ -c.s. única) tal que

$$\mathbb{Q}(A) = \int_A Z(x) \mathbb{P}(dx) \quad \text{para todo } A \in \mathcal{F}.$$

Demostración. Damos una construcción completa mediante un argumento variacional.

Paso 1: definir un conjunto convexo de candidatos. Sea

$$\mathcal{K} := \left\{ f \geq 0 \text{ medible} : \int f(x) \mathbb{P}(dx) \leq \mathbb{Q}(\Omega) \right\}.$$

Definimos el funcional

$$\Phi(f) := \int f(x) \mathbb{P}(dx) - \mathbb{Q}(\Omega) + \sup_{A \in \mathcal{F}} (\mathbb{Q}(A) - \int_A f(x) \mathbb{P}(dx)).$$

Observamos que $\Phi(f) \geq 0$ para toda $f \in \mathcal{K}$, porque el supremo es al menos $\mathbb{Q}(\Omega) - \int f d\mathbb{P}$ (tomando $A = \Omega$), lo que da

$$\Phi(f) \geq \int f(x) \mathbb{P}(dx) - \mathbb{Q}(\Omega) + (\mathbb{Q}(\Omega) - \int f(x) \mathbb{P}(dx)) = 0.$$

Paso 2: minimizar Φ e interpretar el minimizador. Sea $\alpha := \inf_{f \in \mathcal{K}} \Phi(f) \geq 0$. Elegimos una sucesión minimizante (f_n) con $\Phi(f_n) \downarrow \alpha$.

Definimos el supremo puntual $g_m := \sup_{n \geq m} f_n$ (así $g_m \downarrow g := \limsup f_n$). Entonces g_m es medible y $g_m \geq 0$. Por Fatou,

$$\int g(x) \mathbb{P}(dx) \leq \liminf_{m \rightarrow \infty} \int g_m(x) \mathbb{P}(dx) \leq \liminf_{n \rightarrow \infty} \int f_n(x) \mathbb{P}(dx) \leq \mathbb{Q}(\Omega),$$

por lo tanto $g \in \mathcal{K}$.

Afirmamos que $\Phi(g) = \alpha$ y, además, $\alpha = 0$. En efecto, para cada A fijo tenemos $\int_A g(x) \mathbb{P}(dx) \geq \limsup_n \int_A f_n(x) \mathbb{P}(dx)$ por Fatou aplicado a $f_n \mathbf{1}_A$ a lo largo de una subsucesión que alcanza el $\limsup$. Por lo tanto

$$\mathbb{Q}(A) - \int_A g(x) \mathbb{P}(dx) \leq \liminf_n (\mathbb{Q}(A) - \int_A f_n(x) \mathbb{P}(dx)).$$

Tomando el supremo sobre A obtenemos

$$\sup_A (\mathbb{Q}(A) - \int_A g(x) \mathbb{P}(dx)) \leq \liminf_n \sup_A (\mathbb{Q}(A) - \int_A f_n(x) \mathbb{P}(dx)).$$

También $\int g(x) \mathbb{P}(dx) \leq \liminf_n \int f_n(x) \mathbb{P}(dx)$. Sumando se obtiene $\Phi(g) \leq \liminf_n \Phi(f_n) = \alpha$, por lo tanto $\Phi(g) = \alpha$.

Supongamos ahora que $\alpha > 0$. Entonces, por definición de $\Phi(g)$, existe un evento B tal que

$$\mathbb{Q}(B) - \int_B g(x) \mathbb{P}(dx) > \frac{\alpha}{2}.$$

Fijamos $\varepsilon := \frac{\alpha}{4\mathbb{P}(B)}$ (si $\mathbb{P}(B) = 0$ entonces $\mathbb{Q}(B) = 0$ ya que $\mathbb{Q} \ll \mathbb{P}$, lo que contradice la desigualdad estricta anterior). Definimos $g' := g + \varepsilon \mathbf{1}_B$. Entonces $g' \geq 0$ y

$$\int g'(x) \mathbb{P}(dx) = \int g(x) \mathbb{P}(dx) + \varepsilon \mathbb{P}(B) \leq \mathbb{Q}(\Omega) + \frac{\alpha}{4},$$

por lo que g' puede no cumplir la restricción $\int f d\mathbb{P} \leq \mathbb{Q}(\Omega)$; solucionamos esto mediante truncamiento: definimos $\tilde{g} := \min\{g', M\}$ y elegimos M grande de modo que $\int \tilde{g}(x) \mathbb{P}(dx) \leq \mathbb{Q}(\Omega)$ (la convergencia monótona en M y la finitud de $\int g' d\mathbb{P}$ permiten este ajuste). Entonces $\tilde{g} \in \mathcal{K}$, y sobre B tenemos $\tilde{g} \geq g + \varepsilon$ excepto posiblemente en un conjunto donde $g' \geq M$, que puede hacerse $\mathbb{P}$ -pequeño tomando M grande. Esto disminuye el término de defecto $\sup_A (\mathbb{Q}(A) - \int_A f d\mathbb{P})$ mientras que aumenta $\int f d\mathbb{P}$ solo en aproximadamente $\varepsilon \mathbb{P}(B)$, lo que da $\Phi(\tilde{g}) < \Phi(g) = \alpha$ para M suficientemente grande, contradiciendo la minimalidad. Por lo tanto $\alpha = 0$.

Así tenemos $g \in \mathcal{K}$ con $\Phi(g) = 0$, es decir

$$\sup_{A \in \mathcal{F}} (\mathbb{Q}(A) - \int_A g(x) \mathbb{P}(dx)) = \mathbb{Q}(\Omega) - \int g(x) \mathbb{P}(dx) \quad \text{y} \quad \mathbb{Q}(\Omega) = \int g(x) \mathbb{P}(dx).$$

En particular,

$$\mathbb{Q}(A) \leq \int_A g(x) \mathbb{P}(dx) \quad \text{para todo } A \in \mathcal{F}.$$

(En efecto, $\Phi(g) = 0$ fuerza a que el supremo sea 0 una vez que $\mathbb{Q}(\Omega) = \int g d\mathbb{P}$.)

Paso 3: demostrar que la igualdad se cumple para todos los conjuntos. Definimos una medida finita $\tilde{\mathbb{Q}}$ mediante $(\tilde{\mathbb{Q}})(A) := \int_A g(x) \mathbb{P}(dx)$. Tenemos $\mathbb{Q}(A) \leq \tilde{\mathbb{Q}}(A)$ para todo A y $\mathbb{Q}(\Omega) = \tilde{\mathbb{Q}}(\Omega)$. Sea $\nu := \tilde{\mathbb{Q}} - \mathbb{Q}$ la diferencia de medidas finitas, por lo tanto una medida con signo finita con $\nu(A) \geq 0$ para todo A y $\nu(\Omega) = 0$. Pero una medida con signo no negativa con masa total 0 debe ser idénticamente 0: si $\nu(B) > 0$ para algún B , entonces $\nu(\Omega) \geq \nu(B) > 0$, contradicción. Por lo tanto $\nu \equiv 0$, es decir, $\mathbb{Q}(A) = (\tilde{\mathbb{Q}})(A) = \int_A g(x) \mathbb{P}(dx)$ para todo A . Establecemos $Z := g$.

Paso 4: unicidad. Si Z, Z' satisfacen ambas $\mathbb{Q}(A) = \int_A Z(x) \mathbb{P}(dx) = \int_A Z'(x) \mathbb{P}(dx)$ para todo A , entonces $\int_A (Z - Z')(x) \mathbb{P}(dx) = 0$ para todo A . Tomando $A = \{Z > Z'\}$ obtenemos $\int_{\{Z > Z'\}} (Z - Z')(x) \mathbb{P}(dx) = 0$ con integrando > 0 , por lo que $\mathbb{P}(Z > Z') = 0$. Análogamente $\mathbb{P}(Z' < Z) = 0$. Por lo tanto $Z = Z'$ $\mathbb{P}$ -c.s. $\square$

Ejemplo 6.6 (Aplicación del teorema RN). Sea $\mathbb{P}$ exponencial de parámetro 1: $\mathbb{P}(dx) = e^{-x}dx$ en $[0, \infty)$. Sea $\mathbb{Q}$ exponencial de parámetro 2: $\mathbb{Q}(dx) = 2e^{-2x}dx$. Claramente $\mathbb{Q} \ll \mathbb{P}$. La densidad es:

$$\frac{d\mathbb{Q}}{d\mathbb{P}}(x) = \frac{2e^{-2x}}{e^{-x}} = 2e^{-x}.$$

Verificamos: $\int_A 2e^{-x} \mathbb{P}(dx) = \int_A 2e^{-x} e^{-x} dx = \int_A 2e^{-2x} dx = \mathbb{Q}(A)$.

Nota 6.7. La demostración anterior es una ruta completamente rigurosa (estilo variacional/minimización). Muchos textos demuestran Radon–Nikodym mediante la descomposición de Hahn–Jordan y un argumento de maximalidad para el conjunto $\{f : \int_A f d\mathbb{P} \leq \mathbb{Q}(A)\}$; el resultado final es el mismo.

6.3. Radon–Nikodym para medidas σ -finitas

Teorema 6.8 (Radon–Nikodym, caso σ -finito). Sean $\mathbb{P}$ y $\mathbb{Q}$ medidas σ -finitas sobre $(\Omega, \mathcal{F})$ con $\mathbb{Q} \ll \mathbb{P}$. Entonces existe una función medible $Z \geq 0$ tal que $\mathbb{Q}(A) = \int_A Z(x) \mathbb{P}(dx)$ para todo A , y Z es $\mathbb{P}$ -c.s. única.

Demostración. Dado que $\mathbb{P}$ es σ -finita, elegimos conjuntos $E_n \in \mathcal{F}$ con $\Omega = \bigcup_n E_n$ y $0 < \mathbb{P}(E_n) < \infty$ (o $\mathbb{P}(E_n) = 0$ permitido). Análogamente, la σ -finitud de $\mathbb{Q}$ da $\mathbb{Q}(E_n) < \infty$ después de un posible refinamiento.

Restringimos las medidas a E_n : definimos $\mathbb{P}_n(A) := \mathbb{P}(A \cap E_n)$ y $\mathbb{Q}_n(A) := \mathbb{Q}(A \cap E_n)$. Entonces $\mathbb{P}_n$ y $\mathbb{Q}_n$ son medidas finitas y $\mathbb{Q}_n \ll \mathbb{P}_n$. Por el Teorema 6.5, existe $Z_n \geq 0$ medible sobre E_n tal que

$$\mathbb{Q}(A \cap E_n) = \int_{A \cap E_n} Z_n(x) \mathbb{P}(dx) \quad \forall A.$$

En las intersecciones $E_n \cap E_m$, la unicidad en el teorema finito implica $Z_n = Z_m$ $\mathbb{P}$ -c.s. en $E_n \cap E_m$. Definimos $Z(x) := Z_n(x)$ para $x \in E_n$ (eligiendo cualquier n con $x \in E_n$). Esto está bien definido $\mathbb{P}$ -c.s. Entonces para cualquier A ,

$$\mathbb{Q}(A) = \sum_{n \geq 1} \mathbb{Q}(A \cap (E_n \setminus E_{n-1})) = \sum_{n \geq 1} \int_{A \cap (E_n \setminus E_{n-1})} Z(x) \mathbb{P}(dx) = \int_A Z(x) \mathbb{P}(dx),$$

utilizando la disjuntéz de $(E_n \setminus E_{n-1})$ y la convergencia monótona / aditividad numerable. La unicidad se sigue de la unicidad en cada E_n . $\square$

Ejemplo 6.9 (Caso σ -finito no acotado). En $\mathbb{R}$, sea $\mathbb{P}$ Lebesgue (σ -finita) con $\mathbb{P}(dx) = dx$ y $\mathbb{Q}$ con densidad $e^{-x^2/2}/\sqrt{2\pi}$ (normal estándar). Entonces:

$$Z(x) = \frac{d\mathbb{Q}}{d\mathbb{P}}(x) = \frac{e^{-x^2/2}}{\sqrt{2\pi}}.$$

Para cualquier A Borel, $\mathbb{Q}(A) = \int_A \frac{e^{-x^2/2}}{\sqrt{2\pi}} dx = \int_A Z(x) \mathbb{P}(dx)$.

Definición 6.10 (Derivada de Radon–Nikodym). En el Teorema 6.8 la función Z se denota

$$Z = \frac{d\mathbb{Q}}{d\mathbb{P}},$$

y se llama la *derivada de Radon–Nikodym* de $\mathbb{Q}$ con respecto a $\mathbb{P}$.

7. Identidad del cambio de medida: $\mathbb{E}_{\mathbb{Q}}[X] = \mathbb{E}_{\mathbb{P}}[XZ]$

Ahora asumimos que $(\Omega, \mathcal{F}, \mathbb{P})$ es un espacio de probabilidad, $Z \geq 0$ con $\mathbb{E}_{\mathbb{P}}[Z] = 1$, y definimos $\mathbb{Q}(A) = \int_A Z(x) \mathbb{P}(dx)$ como en §3–§4. Entonces $Z = \frac{d\mathbb{Q}}{d\mathbb{P}}$.

Teorema 7.1 (Identidad fundamental). *Sea X una variable aleatoria no negativa medible. Entonces*

$$\mathbb{E}_{\mathbb{Q}}[X] = \int_{\Omega} X(x) \mathbb{Q}(dx) = \int_{\Omega} X(x) Z(x) \mathbb{P}(dx) = \mathbb{E}_{\mathbb{P}}[XZ].$$

Si $X \in L^1(\mathbb{Q})$ (equivalentemente $\int |X|(x) Z(x) \mathbb{P}(dx) < \infty$), entonces lo mismo se cumple para X con signo:

$$\mathbb{E}_{\mathbb{Q}}[X] = \mathbb{E}_{\mathbb{P}}[XZ].$$

Demostración. Paso 1: $X = \mathbf{1}_A$. Si $X = \mathbf{1}_A$, entonces

$$\mathbb{E}_{\mathbb{Q}}[\mathbf{1}_A] = \mathbb{Q}(A) = \int_A Z(x) \mathbb{P}(dx) = \int_{\Omega} \mathbf{1}_A(x) Z(x) \mathbb{P}(dx) = \mathbb{E}_{\mathbb{P}}[\mathbf{1}_A Z].$$

Paso 2: X simple no negativa. Sea $X = \sum_{i=1}^n a_i \mathbf{1}_{A_i}$ con $a_i \geq 0$ y A_i disjuntos. Por el Paso 1 y la linealidad (suma finita),

$$\mathbb{E}_{\mathbb{Q}}[X] = \sum_{i=1}^n a_i \mathbb{Q}(A_i) = \sum_{i=1}^n a_i \int_{A_i} Z(x) \mathbb{P}(dx) = \int_{\Omega} \left(\sum_{i=1}^n a_i \mathbf{1}_{A_i}(x) \right) Z(x) \mathbb{P}(dx) = \mathbb{E}_{\mathbb{P}}[XZ].$$

Paso 3: $X \geq 0$ general. Elegimos X_n simples con $X_n \uparrow X$ puntualmente (Lema en §2.2). Entonces $X_n Z \uparrow XZ$ ya que $Z \geq 0$. Aplicamos Convergencia Monótona dos veces:

$$\mathbb{E}_{\mathbb{Q}}[X] = \lim_{n \rightarrow \infty} \mathbb{E}_{\mathbb{Q}}[X_n] = \lim_{n \rightarrow \infty} \mathbb{E}_{\mathbb{P}}[X_n Z] = \mathbb{E}_{\mathbb{P}}[XZ],$$

donde la igualdad del medio usa el Paso 2.

Paso 4: X con signo integrable. Escribimos $X = X^+ - X^-$. Si $X \in L^1(\mathbb{Q})$ entonces $\mathbb{E}_{\mathbb{Q}}[X^+] < \infty$ y $\mathbb{E}_{\mathbb{Q}}[X^-] < \infty$. Por el Paso 3,

$$\mathbb{E}_{\mathbb{Q}}[X^+] = \mathbb{E}_{\mathbb{P}}[X^+ Z], \quad \mathbb{E}_{\mathbb{Q}}[X^-] = \mathbb{E}_{\mathbb{P}}[X^- Z].$$

Restamos para obtener $\mathbb{E}_{\mathbb{Q}}[X] = \mathbb{E}_{\mathbb{P}}[XZ]$, sin ambigüedad $\infty - \infty$. □

Ejemplo 7.2 (Cambio de medida para momentos). Con $\mathbb{P}$ uniforme en $[0, 1]$, $\mathbb{P}(dx) = dx$, $Z(x) = 2x$, $\mathbb{Q}(dx) = 2x dx$. Calculemos $\mathbb{E}_{\mathbb{Q}}[X]$ para $X(x) = x^2$:

$$\mathbb{E}_{\mathbb{Q}}[X] = \mathbb{E}_{\mathbb{P}}[XZ] = \int_0^1 x^2 \cdot 2x dx = 2 \int_0^1 x^3 dx = 2 \cdot \frac{1}{4} = \frac{1}{2}.$$

Verificación directa: $\mathbb{E}_{\mathbb{Q}}[X] = \int_0^1 x^2 \cdot 2x dx = 1/2$ (coincide).

Ejemplo 7.3 (Esperanza condicional y cambio de medida). En el mismo contexto, calculemos $\mathbb{E}_{\mathbb{Q}}[X]$ para $X(x) = \mathbf{1}_{[0, 0.5]}$:

$$\mathbb{E}_{\mathbb{Q}}[X] = \mathbb{E}_{\mathbb{P}}[XZ] = \int_0^{0.5} 2x dx = [x^2]_0^{0.5} = 0.25.$$

Directamente: $\mathbb{Q}([0, 0.5]) = 0.5^2 = 0.25$.

Corolario 7.4 (Forma de Bayes / cociente de verosimilitudes). Si $Z = \frac{d\mathbb{Q}}{d\mathbb{P}}$, entonces también $\frac{d\mathbb{P}}{d\mathbb{Q}} = \frac{1}{Z}$ sobre $\{Z > 0\}$, y para $X \in L^1(\mathbb{P})$,

$$\mathbb{E}_{\mathbb{P}}[X] = \mathbb{E}_{\mathbb{Q}}\left[X \frac{d\mathbb{P}}{d\mathbb{Q}}\right] = \mathbb{E}_{\mathbb{Q}}\left[\frac{X}{Z} \mathbf{1}_{\{Z>0\}}\right],$$

siempre que el lado derecho esté bien definido.

Ejemplo 7.5 (Uso de la forma de Bayes). Con los mismos $\mathbb{P}, \mathbb{Q}$, calculemos $\mathbb{E}_{\mathbb{P}}[X]$ para $X(x) = x$ usando $\mathbb{Q}$:

$$\frac{d\mathbb{P}}{d\mathbb{Q}}(x) = \frac{1}{Z(x)} = \frac{1}{2x} \quad (x > 0), \quad \mathbb{E}_{\mathbb{P}}[X] = \mathbb{E}_{\mathbb{Q}}\left[X \cdot \frac{d\mathbb{P}}{d\mathbb{Q}}\right] = \int_0^1 x \cdot \frac{1}{2x} \cdot 2x \, dx = \int_0^1 x \, dx = \frac{1}{2}.$$

Notar que Z aparece dos veces: una en $\mathbb{Q}(dx) = Z(x)\mathbb{P}(dx)$ y otra en la fórmula.

8. Filtraciones, densidades condicionadas y martingalas

Aquí comienza propiamente la narrativa de análisis estocástico del manuscrito. Una vez fijada una ley base y una densidad, la pregunta natural deja de ser estática y se vuelve temporal: cómo evoluciona la información, cómo se descompone una densidad cuando solo se observa una sub- σ -álgebra y qué cantidades permanecen compensadas a lo largo del tiempo. La respuesta está codificada por las martingalas positivas, que son la forma dinámica del cambio de medida.

La identidad de cambio de medida se vuelve especialmente poderosa cuando no observamos toda la σ -álgebra de una sola vez, sino de manera progresiva. Para ello introducimos filtraciones y procesos adaptados.

Definición 8.1 (Filtración). Una *filtración* es una familia creciente $(\mathcal{F}_n)_{n \geq 0}$ o $(\mathcal{F}_t)_{t \geq 0}$ de sub- σ -álgebras de $\mathcal{F}$:

$$\mathcal{F}_0 \subseteq \mathcal{F}_1 \subseteq \dots \subseteq \mathcal{F}.$$

Interpretamos $\mathcal{F}_n$ como la información disponible hasta el tiempo n .

Definición 8.2 (Proceso adaptado y martingala). Sea $(\mathcal{F}_n)_{n \geq 0}$ una filtración. Un proceso $(M_n)_{n \geq 0}$ es *adaptado* si M_n es $\mathcal{F}_n$ -medible para todo n . Diremos que (M_n) es una martingala bajo una medida $\mathbb{P}$ si:

1. $M_n \in L^1(\mathbb{P})$ para todo n ,
2. M_n es $\mathcal{F}_n$ -medible,
3. $\mathbb{E}_{\mathbb{P}}[M_{n+1} \mid \mathcal{F}_n] = M_n$ $\mathbb{P}$ -c.s.

Proposición 8.3 (Proceso de densidad). Sea $Z \geq 0$ con $\mathbb{E}_{\mathbb{P}}[Z] = 1$ y sea $\mathbb{Q}$ la medida definida por $\mathbb{Q}(A) = \int_A Z(x) \mathbb{P}(dx)$. Para una filtración $(\mathcal{F}_n)$, definimos

$$Z_n := \mathbb{E}_{\mathbb{P}}[Z \mid \mathcal{F}_n].$$

Entonces $(Z_n)_{n \geq 0}$ es una martingala no negativa bajo $\mathbb{P}$, satisface $\mathbb{E}_{\mathbb{P}}[Z_n] = 1$ para todo n , y además

$$\mathbb{Q}(A) = \int_A Z_n(x) \mathbb{P}(dx), \quad A \in \mathcal{F}_n.$$

En otras palabras, Z_n es la derivada de Radon–Nikodym de $\mathbb{Q}|_{\mathcal{F}_n}$ respecto de $\mathbb{P}|_{\mathcal{F}_n}$.

Demostración. La no negatividad y la integrabilidad de Z_n son inmediatas. La propiedad de martingala sigue de la torre:

$$\mathbb{E}_{\mathbb{P}}[Z_{n+1} \mid \mathcal{F}_n] = \mathbb{E}_{\mathbb{P}}[\mathbb{E}_{\mathbb{P}}[Z \mid \mathcal{F}_{n+1}] \mid \mathcal{F}_n] = \mathbb{E}_{\mathbb{P}}[Z \mid \mathcal{F}_n] = Z_n.$$

Si $A \in \mathcal{F}_n$, entonces por definición de esperanza condicional

$$\mathbb{Q}(A) = \int_A Z(x) \mathbb{P}(dx) = \int_A \mathbb{E}_{\mathbb{P}}[Z \mid \mathcal{F}_n](x) \mathbb{P}(dx) = \int_A Z_n(x) \mathbb{P}(dx).$$

□

Teorema 8.4 (Fórmula de Bayes condicional). *Sea $X \in L^1(\mathbb{Q})$. Entonces, para cada n ,*

$$\mathbb{E}_{\mathbb{Q}}[X \mid \mathcal{F}_n] = \frac{\mathbb{E}_{\mathbb{P}}[XZ \mid \mathcal{F}_n]}{Z_n} \quad \text{sobre } \{Z_n > 0\}.$$

Equivalentemente,

$$Z_n \mathbb{E}_{\mathbb{Q}}[X \mid \mathcal{F}_n] = \mathbb{E}_{\mathbb{P}}[XZ \mid \mathcal{F}_n].$$

Demostración. Basta verificar que el lado derecho es $\mathcal{F}_n$ -medible y que integra correctamente sobre cualquier $A \in \mathcal{F}_n$:

$$\int_A \frac{\mathbb{E}_{\mathbb{P}}[XZ \mid \mathcal{F}_n]}{Z_n} \mathbb{Q}(dx) = \int_A \frac{\mathbb{E}_{\mathbb{P}}[XZ \mid \mathcal{F}_n]}{Z_n} Z_n \mathbb{P}(dx) = \int_A \mathbb{E}_{\mathbb{P}}[XZ \mid \mathcal{F}_n] \mathbb{P}(dx) = \int_A XZ \mathbb{P}(dx) = \int_A X \mathbb{Q}(dx).$$

□

Corolario 8.5 (Transferencia de martingalas). *Si (M_n) es una martingala bajo $\mathbb{Q}$, entonces $(Z_n M_n)$ es una martingala bajo $\mathbb{P}$. Recíprocamente, si (N_n) es una martingala bajo $\mathbb{P}$ y N_n/Z_n está bien definido, entonces N_n/Z_n es una candidata natural a martingala bajo $\mathbb{Q}$.*

Demostración. Por el teorema anterior,

$$\mathbb{E}_{\mathbb{P}}[Z_{n+1} M_{n+1} \mid \mathcal{F}_n] = Z_n \mathbb{E}_{\mathbb{Q}}[M_{n+1} \mid \mathcal{F}_n] = Z_n M_n.$$

□

Ejemplo 8.6 (Caminata aleatoria inclinada). Sea $(\xi_k)_{k \geq 1}$ una familia i.i.d. con $\mathbb{P}(\xi_k = 1) = \mathbb{P}(\xi_k = -1) = 1/2$, y sea $S_n = \sum_{k=1}^n \xi_k$. Para $\theta \in \mathbb{R}$, definimos

$$Z_n(\theta) := \frac{e^{\theta S_n}}{(\cosh \theta)^n}.$$

Entonces $(Z_n(\theta))_{n \geq 0}$ es una martingala positiva bajo $\mathbb{P}$, porque

$$\mathbb{E}_{\mathbb{P}}[Z_{n+1}(\theta) \mid \mathcal{F}_n] = Z_n(\theta) \frac{\mathbb{E}_{\mathbb{P}}[e^{\theta \xi_{n+1}}]}{\cosh \theta} = Z_n(\theta).$$

Si definimos $\mathbb{Q}_{\theta}$ por $\mathbb{Q}_{\theta}|_{\mathcal{F}_n}(A) = \int_A Z_n(\theta)(x) \mathbb{P}(dx)$, entonces bajo $\mathbb{Q}_{\theta}$ los incrementos siguen siendo independientes pero ahora

$$\mathbb{Q}_{\theta}(\xi_k = 1) = \frac{e^{\theta}}{e^{\theta} + e^{-\theta}}, \quad \mathbb{Q}_{\theta}(\xi_k = -1) = \frac{e^{-\theta}}{e^{\theta} + e^{-\theta}}.$$

El cambio de medida crea una deriva:

$$\mathbb{E}_{\mathbb{Q}_{\theta}}[\xi_k] = \tanh(\theta).$$




Figura 8: La inclinación exponencial $Z_n(\theta)$ repondera las trayectorias de la caminata aleatoria. No cambia el árbol de trayectorias, pero sí las probabilidades asignadas a sus ramas.

Proposición 8.7 (Martingalas clásicas de la caminata aleatoria simétrica). *Sea $S_n = \xi_1 + \dots + \xi_n$ con incrementos i.i.d. tales que $\mathbb{P}(\xi_k = 1) = \mathbb{P}(\xi_k = -1) = 1/2$. Entonces los procesos*

$$S_n, \quad S_n^2 - n, \quad \exp(\theta S_n - n \log \cosh \theta)$$

son martingalas respecto de la filtración natural.

Demostración. La primera identidad sigue de $\mathbb{E}_{\mathbb{P}}[\xi_{n+1} \mid \mathcal{F}_n] = 0$. Para la segunda,

$$\mathbb{E}_{\mathbb{P}}[S_{n+1}^2 - (n+1) \mid \mathcal{F}_n] = S_n^2 + 2S_n \mathbb{E}_{\mathbb{P}}[\xi_{n+1} \mid \mathcal{F}_n] + \mathbb{E}_{\mathbb{P}}[\xi_{n+1}^2 \mid \mathcal{F}_n] - (n+1) = S_n^2 - n.$$

La tercera ya se verificó al calcular la inclinación exponencial. $\square$

Ejemplo 8.8 (Tiempo esperado de salida de un intervalo). Sea $\tau_a := \inf\{n \geq 0 : |S_n| = a\}$ con $a \in \mathbb{N}$. Aplicando parada opcional a la martingala $S_{n \wedge \tau_a}^2 - (n \wedge \tau_a)$, obtenemos

$$\mathbb{E}_{\mathbb{P}}[S_{n \wedge \tau_a}^2] - \mathbb{E}_{\mathbb{P}}[n \wedge \tau_a] = 0.$$

Como $|S_{n \wedge \tau_a}| \leq a$ y $S_{n \wedge \tau_a} \rightarrow S_{\tau_a} \in \{-a, a\}$, el teorema de convergencia dominada da

$$\mathbb{E}_{\mathbb{P}}[\tau_a] = \mathbb{E}_{\mathbb{P}}[S_{\tau_a}^2] = a^2.$$

Así, el tiempo medio para que una caminata simétrica alcance $\pm a$ crece cuadráticamente con la distancia.

Ejemplo 8.9 (Probabilidad de ruina para caminata sesgada). Sea ahora $\mathbb{P}(\xi_k = 1) = p$, $\mathbb{P}(\xi_k = -1) = q = 1 - p$, con $p \neq q$, y defínase $S_n = i + \sum_{k=1}^n \xi_k$. Entonces

$$M_n := \left(\frac{q}{p}\right)^{S_n}$$

es una martingala. Si

$$\tau := \inf\{n \geq 0 : S_n \in \{0, N\}\},$$

entonces la parada opcional da

$$\mathbb{E}_{\mathbb{P}}[M_\tau] = M_0 = \left(\frac{q}{p}\right)^i.$$

Como $S_\tau \in \{0, N\}$, resulta

$$\mathbb{P}_i(\tau_N < \tau_0) = \frac{1 - (q/p)^i}{1 - (q/p)^N}.$$

Esta es una de las fórmulas prototípicas donde el cambio de medida y las martingalas exponenciales convierten un problema combinatorio en una identidad algebraica.

Teorema 8.10 (Desigualdad exponencial para máximos de la caminata). *Sea $S_n = \xi_1 + \dots + \xi_n$ una caminata aleatoria simétrica simple. Entonces, para todo $a > 0$ y todo $n \geq 1$,*

$$\mathbb{P}\left(\max_{0 \leq k \leq n} S_k \geq a\right) \leq \exp\left(-\frac{a^2}{2n}\right).$$

Por simetría,

$$\mathbb{P}\left(\max_{0 \leq k \leq n} |S_k| \geq a\right) \leq 2 \exp\left(-\frac{a^2}{2n}\right).$$

Demostración. Para $\theta > 0$, el proceso

$$M_k(\theta) = \exp(\theta S_k - k \log \cosh \theta)$$

es una martingala positiva. Aplicando la desigualdad máxima de Doob a $(M_k(\theta))_{0 \leq k \leq n}$, obtenemos

$$\mathbb{P}\left(\max_{0 \leq k \leq n} M_k(\theta) \geq e^{\theta a - n \log \cosh \theta}\right) \leq e^{-\theta a + n \log \cosh \theta} \mathbb{E}[M_n(\theta)].$$

Como $\mathbb{E}[M_n(\theta)] = 1$, se sigue que

$$\mathbb{P}\left(\max_{0 \leq k \leq n} S_k \geq a\right) \leq e^{-\theta a + n \log \cosh \theta}.$$

Usando la cota elemental $\log \cosh \theta \leq \theta^2/2$, válida para todo $\theta \in \mathbb{R}$, obtenemos

$$\mathbb{P}\left(\max_{0 \leq k \leq n} S_k \geq a\right) \leq \exp\left(-\theta a + \frac{n\theta^2}{2}\right).$$

Optimizando en θ con $\theta = a/n$ resulta la desigualdad. La cota bilateral se obtiene aplicando la misma estimación a S y a $-S$. $\square$

Nota 8.11. Este argumento resume una idea fundamental: la caminata aleatoria produce, mediante inclinación exponencial, una familia de martingalas que controlan no sólo medias y tiempos de salida, sino también eventos raros de gran desviación. En probabilidad moderna, ésta es una de las puertas de entrada a desigualdades de concentración, teoría de grandes desvíos y análisis de algoritmos aleatorios.

Nota 8.12. La construcción anterior es el prototipo de una idea mucho más general: una martingala positiva de media 1 sirve como densidad dinámica y permite pasar de una ley de referencia $\mathbb{P}$ a una nueva ley $\mathbb{Q}$ compatible con la información parcial $(\mathcal{F}_n)$. En caminatas aleatorias, esta operación cambia la deriva; en procesos de conteo, modifica intensidades; y en problemas de parada opcional, hace visibles cantidades que a priori no parecen martingalas.




Figura 9: Probabilidad de alcanzar N antes que 0 en la ruina del jugador. El sesgo positivo de la caminata curva la probabilidad de éxito por encima del perfil lineal del caso simétrico.




Figura 10: Una realización de caminata aleatoria con barreras absorbentes. Las martingalas S_n , $S_n^2 - n$ y las exponenciales permiten estudiar tiempos de salida y probabilidades de ruina.

9. Cadenas de Markov a tiempo continuo y exponenciales martingala

En tiempo continuo, el cambio de medida ya no solo inclina variables aleatorias sino trayectorias enteras. El objeto central deja de ser una sola densidad y pasa a ser un semigrupo, un generador o un funcional exponencial sobre caminos. Esta transición es típica del análisis estocástico moderno: de la medida sobre estados se pasa a la medida sobre trayectorias, y el generador recoge la geometría infinitesimal del sistema.

Pasamos ahora a procesos en tiempo continuo. El punto clave es que una cadena de Markov a tiempo continuo puede entenderse mediante su generador, y que ciertos cambios de medida transforman dicho generador de manera muy explícita.

9.1. Definiciones básicas

Definición 9.1 (CTMC en espacio de estados finito). Sea $E = \{1, \dots, m\}$. Una *cadena de Markov a tiempo continuo* es un proceso $(X_t)_{t \geq 0}$ con trayectorias càdlàg y propiedad de Markov tal que, para todo $i, j \in E$,

$$\mathbb{P}(X_{t+h} = j \mid X_t = i, \mathcal{F}_t) = \mathbb{P}(X_{t+h} = j \mid X_t = i) = \begin{cases} \alpha(i, j)h + o(h), & j \neq i, \\ 1 - \alpha(i)h + o(h), & j = i, \end{cases}$$

cuando $h \downarrow 0$, donde

$$\alpha(i) := \sum_{j \neq i} \alpha(i, j) < \infty.$$

Definición 9.2 (Generador). El generador infinitesimal $A = (A_{ij})$ de la cadena viene dado por

$$A_{ij} = \begin{cases} \alpha(i, j), & i \neq j, \\ -\alpha(i), & i = j. \end{cases}$$

Si $f : E \rightarrow \mathbb{R}$, entonces

$$Af(i) = \sum_{j \neq i} \alpha(i, j)(f(j) - f(i)).$$

Proposición 9.3 (Semigrupo). Si $P_t(i, j) = \mathbb{P}(X_t = j \mid X_0 = i)$, entonces $P_t = e^{tA}$ y satisface las ecuaciones de Kolmogorov

$$\frac{d}{dt}P_t = AP_t = P_tA, \quad P_0 = I.$$

Ejemplo 9.4 (Cadena de dos estados). Para $E = \{0, 1\}$, con tasas $\alpha(0, 1) = \lambda$ y $\alpha(1, 0) = \mu$, el generador es

$$A = \begin{pmatrix} -\lambda & \lambda \\ \mu & -\mu \end{pmatrix}.$$

Las probabilidades de transición son

$$P_t(0, 1) = \frac{\lambda}{\lambda + \mu}(1 - e^{-(\lambda + \mu)t}), \quad P_t(1, 0) = \frac{\mu}{\lambda + \mu}(1 - e^{-(\lambda + \mu)t}).$$




Figura 11: La cadena de dos estados es el modelo elemental de CTMC: tiempos de espera exponenciales y saltos alternantes controlados por las tasas λ y μ .

9.2. Martingalas asociadas al generador

Proposición 9.5 (Martingala de Dynkin). *Sea $f : E \rightarrow \mathbb{R}$ acotada. Entonces*

$$M_t^f := f(X_t) - f(X_0) - \int_0^t Af(X_s) ds$$

es una martingala respecto de la filtración natural de X .

Demostración. Para $i \in E$ definimos el semigrupo $P_t f(i) := \mathbb{E}_i[f(X_t)]$. En espacio de estados finito se tiene la ecuación hacia atrás

$$\frac{d}{dt} P_t f(i) = A P_t f(i) = P_t A f(i), \quad P_0 f = f,$$

porque $P_t = e^{tA}$. Integrando en el tiempo obtenemos, para toda condición inicial i ,

$$\mathbb{E}_i[f(X_t)] - f(i) = P_t f(i) - P_0 f(i) = \int_0^t P_s A f(i) ds = \int_0^t \mathbb{E}_i[Af(X_s)] ds.$$

Ahora fijamos $0 \leq s \leq t$. Usando la propiedad de Markov fuerte en el tiempo s , condicionalmente a $\mathcal{F}_s$ y sobre el evento $\{X_s = i\}$ tenemos

$$\mathbb{E}[f(X_t) - f(X_s) \mid \mathcal{F}_s] = \mathbb{E}_i[f(X_{t-s})] - f(i) = \int_0^{t-s} \mathbb{E}_i[Af(X_r)] dr.$$

Reescribiendo el último término otra vez por Markov,

$$\int_0^{t-s} \mathbb{E}_i[Af(X_r)] dr = \mathbb{E} \left[\int_s^t Af(X_u) du \mid \mathcal{F}_s \right].$$

Por consiguiente,

$$\mathbb{E}[M_t^f - M_s^f \mid \mathcal{F}_s] = \mathbb{E}[f(X_t) - f(X_s) \mid \mathcal{F}_s] - \mathbb{E} \left[\int_s^t Af(X_u) du \mid \mathcal{F}_s \right] = 0,$$

y esto prueba que $(M_t^f)_{t \geq 0}$ es una martingala. □

Ejemplo 9.6 (Indicador de un estado). Tomando $f(i) = \mathbf{1}_{\{1\}}(i)$ en la cadena de dos estados, obtenemos

$$Af(0) = \lambda, \quad Af(1) = -\mu.$$

Por lo tanto,

$$M_t = \mathbf{1}_{\{X_t=1\}} - \mathbf{1}_{\{X_0=1\}} - \int_0^t (\lambda \mathbf{1}_{\{X_s=0\}} - \mu \mathbf{1}_{\{X_s=1\}}) ds$$

es una martingala.

9.3. Proceso de Poisson como CTMC

Ejemplo 9.7 (Poisson homogéneo). El proceso de Poisson $(N_t)_{t \geq 0}$ de intensidad λ es una CTMC sobre $\mathbb{N}$ con

$$\alpha(n, n+1) = \lambda, \quad \alpha(n, j) = 0 \text{ si } j \neq n+1.$$

Su generador es

$$Af(n) = \lambda(f(n+1) - f(n)).$$

La martingala de Dynkin con $f(n) = n$ da

$$N_t - \lambda t$$

como martingala bajo $\mathbb{P}$.

Teorema 9.8 (Exponencial martingala de Poisson). Para $\theta \in \mathbb{R}$,

$$\mathcal{E}_t(\theta) := \exp(\theta N_t - \lambda t(e^\theta - 1))$$

es una martingala positiva con $\mathbb{E}_{\mathbb{P}}[\mathcal{E}_t(\theta)] = 1$. Si definimos una nueva medida $\mathbb{Q}_\theta$ sobre $\mathcal{F}_t$ mediante

$$\mathbb{Q}_\theta(A) = \int_A \mathcal{E}_t(\theta)(x) \mathbb{P}(dx), \quad A \in \mathcal{F}_t,$$

entonces bajo $\mathbb{Q}_\theta$ el proceso N_t sigue siendo de Poisson, pero con intensidad λe^θ .

Demostración. Usando incrementos independientes,

$$\mathbb{E}_{\mathbb{P}}[\mathcal{E}_t(\theta) \mid \mathcal{F}_s] = \mathcal{E}_s(\theta) \mathbb{E}_{\mathbb{P}}[\exp(\theta(N_t - N_s) - \lambda(t-s)(e^\theta - 1))].$$

Como $N_t - N_s \sim \text{Poisson}(\lambda(t-s))$, su transformada exponencial es

$$\mathbb{E}[e^{\theta(N_t - N_s)}] = \exp(\lambda(t-s)(e^\theta - 1)),$$

y por lo tanto el factor condicional es 1. Así $(\mathcal{E}_t(\theta))$ es martingala. Para identificar la nueva intensidad, basta calcular para $h \downarrow 0$

$$\mathbb{Q}_\theta(N_{t+h} - N_t = 1 \mid \mathcal{F}_t) = \frac{\mathbb{E}_{\mathbb{P}}[\mathbf{1}_{\{N_{t+h} - N_t = 1\}} \mathcal{E}_{t+h}(\theta) \mid \mathcal{F}_t]}{\mathcal{E}_t(\theta)} = \lambda e^\theta h + o(h),$$

mientras que la probabilidad de dos o más saltos sigue siendo $o(h)$. Esto caracteriza un proceso de Poisson con intensidad λe^θ . $\square$

9.4. Transformación h de Doob

Teorema 9.9 (Transformación h para CTMC). Sea $h : E \rightarrow (0, \infty)$ y supongamos que existe $\lambda_0 \in \mathbb{R}$ tal que

$$Ah = \lambda_0 h.$$

Entonces el proceso

$$M_t := e^{-\lambda_0 t} \frac{h(X_t)}{h(X_0)}$$




Figura 12: Trayectoria escalonada de un proceso de Poisson y su compensador lineal. La diferencia $N_t - \lambda t$ es una martingala; al inclinar con $\mathcal{E}_t(\theta)$, la pendiente efectiva cambia a λe^θ .

es una martingala positiva. La medida obtenida por

$$\mathbb{Q}_t(A) = \int_A M_t(x) \mathbb{P}(dx), \quad A \in \mathcal{F}_t,$$

transforma la cadena original en otra CTMC con generador

$$\tilde{A}f(i) = \frac{1}{h(i)} A(hf)(i) - \lambda_0 f(i).$$

En particular, las nuevas tasas fuera de la diagonal son

$$\tilde{\alpha}(i, j) = \alpha(i, j) \frac{h(j)}{h(i)}, \quad i \neq j.$$

Demostración. Aplicando la martingala de Dynkin a la función h , se obtiene

$$h(X_t) - h(X_0) - \int_0^t \lambda_0 h(X_s) ds$$

como martingala local; la forma exponencial equivalente produce M_t . El cálculo del nuevo generador se obtiene al aplicar Bayes condicional a incrementos infinitesimales y reescribir el término principal en orden h . $\square$

Nota 9.10. Esta transformación no cambia el espacio de estados ni la naturaleza de las trayectorias: cambia únicamente la forma en que se ponderan las rutas. Es la versión en CTMC del mismo principio visto antes en caminatas aleatorias y procesos de Poisson.

10. Teoría de portafolios: Markowitz, razón de Sharpe y modelos factoriales

La inclusión de teoría de portafolios en estas notas no es ornamental. Desde la perspectiva adoptada aquí, un portafolio es una regla de cambio de pesos sobre una familia de activos aleatorios, y toda la maquinaria de covarianzas, factores y restricciones puede leerse como un problema de geometría probabilística sobre el simplex o sobre subvariedades afines del espacio de pesos. La conexión con análisis estocástico aparece cuando se interpreta el

riesgo como una energía cuadrática, el equilibrio como una condición de primer orden y la actualización de creencias como un cambio de medida de tipo bayesiano.

La teoría moderna de portafolios es uno de los lugares donde la combinación entre probabilidad, análisis convexo y álgebra lineal adquiere una interpretación económica inmediata. Un portafolio no es más que una regla de reponderación del riesgo: a cada vector de rendimientos aleatorios se le aplica un peso w , y el problema consiste en decidir cómo concentrar o dispersar masa sobre los activos disponibles. El lenguaje introducido en estas notas —medidas, cambios de densidad, kernels y martingalas— reaparece aquí con otra vestimenta. La geometría de Markowitz fija la frontera eficiente, la razón de Sharpe selecciona la dirección de mejor compensación riesgo-retorno, el CAPM impone una relación de equilibrio entre retorno esperado y covarianza con el mercado, Black–Litterman funde equilibrio con opiniones en una actualización bayesiana, y los modelos de Fama–French reorganizan la covarianza en unas pocas direcciones estructurales que luego pueden imponerse o neutralizarse dentro de un problema de optimización.

10.1. Modelo uniperiodal de Markowitz

Sea $R = (R_1, \dots, R_d)^T$ el vector de rendimientos de d activos riesgosos en un periodo. Supondremos

$$\mu := \mathbb{E}[R] \in \mathbb{R}^d, \quad \Sigma := \text{Var}(R) = \mathbb{E}[(R - \mu)(R - \mu)^T] \in \mathbb{R}^{d \times d},$$

y que Σ es simétrica definida positiva. Un portafolio es un vector de pesos $w \in \mathbb{R}^d$; su rendimiento y su varianza son

$$R_p := w^T R, \quad \mathbb{E}[R_p] = w^T \mu, \quad \text{Var}(R_p) = w^T \Sigma w.$$

La restricción presupuestal básica es

$$\mathbf{1}^T w = 1,$$

y, cuando además se exige $w_i \geq 0$, se obtiene el problema sin ventas en corto.

Nota 10.1. La forma cuadrática $w^T \Sigma w$ dota al espacio de pesos de una métrica dependiente del mercado. Minimizar riesgo equivale a proyectarse sobre el hiperplano presupuestal en esa métrica deformada. Esta lectura geométrica es la que explica la rigidez analítica del problema clásico y, al mismo tiempo, por qué pequeñas modificaciones combinatorias lo vuelven drásticamente más difícil.

10.2. Portafolio de mínima varianza global

Teorema 10.2 (Solución cerrada del portafolio de mínima varianza global). *Sea $\Sigma \succ 0$. El problema*

$$\min_{w \in \mathbb{R}^d} w^T \Sigma w \quad \text{sujeto a} \quad \mathbf{1}^T w = 1$$

tiene una única solución dada por

$$w_{\text{GMV}} = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^T \Sigma^{-1} \mathbf{1}}.$$

Además,

$$\mu_{\text{GMV}} = \frac{\mathbf{1}^T \Sigma^{-1} \mu}{\mathbf{1}^T \Sigma^{-1} \mathbf{1}}, \quad \sigma_{\text{GMV}}^2 = \frac{1}{\mathbf{1}^T \Sigma^{-1} \mathbf{1}}.$$




Figura 13: Mapa térmico de una matriz de covarianzas de tres activos. La forma de Σ controla la curvatura de la frontera eficiente y la orientación de los elipsoides de riesgo.

Demostración. Como $\Sigma \succ 0$, la aplicación $w \mapsto w^T \Sigma w$ es estrictamente convexa. Por consiguiente, cualquier punto crítico restringido es automáticamente el mínimo global y es único. Introduzcamos el Lagrangiano

$$\mathcal{L}(w, \lambda) = w^T \Sigma w - \lambda(\mathbf{1}^T w - 1).$$

La condición de primer orden respecto de w es

$$2\Sigma w - \lambda \mathbf{1} = 0,$$

de donde

$$w = \frac{\lambda}{2} \Sigma^{-1} \mathbf{1}.$$

Imponiendo la restricción presupuestal obtenemos

$$1 = \mathbf{1}^T w = \frac{\lambda}{2} \mathbf{1}^T \Sigma^{-1} \mathbf{1},$$

y por tanto

$$\lambda = \frac{2}{\mathbf{1}^T \Sigma^{-1} \mathbf{1}}.$$

Sustituyendo en la expresión de w ,

$$w_{\text{GMV}} = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^T \Sigma^{-1} \mathbf{1}}.$$

Las fórmulas para μ_{GMV} y σ_{GMV}^2 se obtienen sustituyendo w_{GMV} en $w^T \mu$ y $w^T \Sigma w$:

$$\mu_{\text{GMV}} = \mu^T \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^T \Sigma^{-1} \mathbf{1}} = \frac{\mathbf{1}^T \Sigma^{-1} \mu}{\mathbf{1}^T \Sigma^{-1} \mathbf{1}},$$

y

$$\sigma_{\text{GMV}}^2 = \frac{\mathbf{1}^T \Sigma^{-1} \Sigma \Sigma^{-1} \mathbf{1}}{(\mathbf{1}^T \Sigma^{-1} \mathbf{1})^2} = \frac{1}{\mathbf{1}^T \Sigma^{-1} \mathbf{1}}.$$

□

Ejemplo 10.3 (Problema resuelto: cartera GMV de tres activos). Tomemos

$$\mu = \begin{pmatrix} 0.08 \\ 0.12 \\ 0.17 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} 0.040 & 0.012 & 0.008 \\ 0.012 & 0.090 & 0.018 \\ 0.008 & 0.018 & 0.160 \end{pmatrix}.$$

Aplicando el teorema anterior se obtiene

$$w_{\text{GMV}} \approx \begin{pmatrix} 0.6532 \\ 0.2179 \\ 0.1289 \end{pmatrix}.$$

El rendimiento esperado correspondiente es

$$\mu_{\text{GMV}} \approx 0.1003,$$

y la volatilidad es

$$\sigma_{\text{GMV}} \approx 0.1725.$$

La mayor ponderación en el activo A refleja precisamente la interacción entre menor varianza propia y covarianzas relativamente pequeñas con el resto del sistema.

10.3. Frontera eficiente con rendimiento objetivo

Teorema 10.4 (Solución cerrada con restricción de rendimiento). *Definamos*

$$A := \mathbf{1}^T \Sigma^{-1} \mathbf{1}, \quad B := \mathbf{1}^T \Sigma^{-1} \mu, \quad C := \mu^T \Sigma^{-1} \mu, \quad \Delta := AC - B^2.$$

Si $\Sigma \succ 0$ y μ no es colineal con $\mathbf{1}$, entonces $\Delta > 0$. Para todo $m \in \mathbb{R}$, el problema

$$\min_{w \in \mathbb{R}^d} w^T \Sigma w \quad \text{sueto a} \quad \mathbf{1}^T w = 1, \quad \mu^T w = m$$

tiene única solución

$$w(m) = \frac{C - Bm}{\Delta} \Sigma^{-1} \mathbf{1} + \frac{Am - B}{\Delta} \Sigma^{-1} \mu.$$

Además,

$$\sigma^2(m) = \frac{Am^2 - 2Bm + C}{\Delta},$$

de modo que la frontera eficiente satisface la ecuación

$$Am^2 - 2Bm + C = \Delta \sigma^2.$$

Demostración. Consideremos el Lagrangiano

$$\mathcal{L}(w, \lambda, \gamma) = w^T \Sigma w - \lambda(\mathbf{1}^T w - 1) - \gamma(\mu^T w - m).$$

La condición de primer orden respecto de w es

$$2\Sigma w - \lambda \mathbf{1} - \gamma \mu = 0,$$

por lo que

$$w = \frac{1}{2} \Sigma^{-1} (\lambda \mathbf{1} + \gamma \mu).$$

Al imponer las dos restricciones obtenemos el sistema lineal

$$\frac{1}{2} \begin{pmatrix} A & B \\ B & C \end{pmatrix} \begin{pmatrix} \lambda \\ \gamma \end{pmatrix} = \begin{pmatrix} 1 \\ m \end{pmatrix}.$$

La desigualdad de Cauchy–Schwarz en el producto interno $\langle x, y \rangle_\Sigma := x^T \Sigma^{-1} y$ da

$$B^2 \leq AC,$$

con igualdad sólo si μ es múltiplo de $\mathbf{1}$. Por hipótesis, $\Delta > 0$ y la matriz del sistema es invertible. Resolviendo,

$$\lambda = \frac{2(C - Bm)}{\Delta}, \quad \gamma = \frac{2(Am - B)}{\Delta}.$$

Sustituyendo en la fórmula de w obtenemos la expresión cerrada para $w(m)$. Para la varianza, notamos que

$$\Sigma w(m) = \frac{C - Bm}{\Delta} \mathbf{1} + \frac{Am - B}{\Delta} \mu.$$

Multiplicando por $w(m)^T$ y usando las restricciones,

$$\sigma^2(m) = w(m)^T \Sigma w(m) = \frac{C - Bm}{\Delta} \mathbf{1}^T w(m) + \frac{Am - B}{\Delta} \mu^T w(m) = \frac{C - Bm}{\Delta} + \frac{m(Am - B)}{\Delta},$$

de donde

$$\sigma^2(m) = \frac{Am^2 - 2Bm + C}{\Delta}.$$

La unicidad sigue otra vez de la convexidad estricta. $\square$

Ejemplo 10.5 (Problema resuelto: rendimiento objetivo del 14%). Con los mismos μ y Σ del ejemplo anterior, si fijamos $m = 0.14$, la fórmula cerrada produce

$$w(0.14) \approx \begin{pmatrix} 0.1135 \\ 0.3957 \\ 0.4908 \end{pmatrix}.$$

La volatilidad mínima compatible con ese retorno es

$$\sigma(0.14) \approx 0.2492.$$

La solución desplaza masa hacia los activos B y C , aceptando un aumento considerable de riesgo con respecto a la cartera GMV. Esa es exactamente la curvatura económica de la frontera eficiente.

10.4. Razón de Sharpe y portafolio tangente

Supongamos que existe un activo libre de riesgo con rendimiento r_f . Para un portafolio riesgoso w con $\mathbf{1}^T w = 1$, definimos

$$\text{Sh}(w) := \frac{w^T \mu - r_f}{\sqrt{w^T \Sigma w}} = \frac{w^T (\mu - r_f \mathbf{1})}{\sqrt{w^T \Sigma w}}.$$

Maximizar esta razón equivale a encontrar la recta de pendiente máxima que parte del activo libre de riesgo y toca la frontera media–varianza.

Teorema 10.6 (Solución del portafolio tangente). Sea $d := \mu - r_f \mathbf{1}$. Si $d \neq 0$, entonces toda dirección que maximiza la razón de Sharpe es proporcional a $\Sigma^{-1}d$. Bajo la restricción presupuestal $\mathbf{1}^T w = 1$, la única solución es

$$w_T = \frac{\Sigma^{-1}(\mu - r_f \mathbf{1})}{\mathbf{1}^T \Sigma^{-1}(\mu - r_f \mathbf{1})}.$$

Además,

$$\text{Sh}_{\text{máx}} = \sqrt{d^T \Sigma^{-1} d}.$$

Demostración. La razón de Sharpe es homogénea de grado cero: para todo $c > 0$,

$$\text{Sh}(cw) = \text{Sh}(w).$$

Por ello podemos ignorar provisionalmente la restricción de presupuesto y optimizar sobre todos los vectores no nulos. Escribamos

$$\nu := \Sigma^{1/2} w, \quad v := \Sigma^{-1/2} d.$$

Entonces

$$\frac{d^T w}{\sqrt{w^T \Sigma w}} = \frac{v^T \nu}{\|\nu\|}.$$

La desigualdad de Cauchy–Schwarz implica

$$\frac{v^T \nu}{\|\nu\|} \leq \|v\| = \sqrt{d^T \Sigma^{-1} d},$$

con igualdad si y sólo si ν es proporcional a v , esto es, si y sólo si

$$\Sigma^{1/2} w = c \Sigma^{-1/2} d \iff w = c \Sigma^{-1} d.$$

Por tanto, toda dirección óptima es proporcional a $\Sigma^{-1}d$. Imponiendo $\mathbf{1}^T w = 1$ se obtiene el factor de normalización

$$1 = c \mathbf{1}^T \Sigma^{-1} d, \quad c = \frac{1}{\mathbf{1}^T \Sigma^{-1} d},$$

y de ahí la fórmula de w_T . La razón de Sharpe máxima es el valor de la cota de Cauchy–Schwarz, es decir $\sqrt{d^T \Sigma^{-1} d}$. $\square$

Ejemplo 10.7 (Problema resuelto: portafolio tangente). Con $r_f = 0.03$ y los mismos tres activos del ejemplo base,

$$w_T \approx \begin{pmatrix} 0.3728 \\ 0.3103 \\ 0.3169 \end{pmatrix}, \quad \mathbb{E}[R_{w_T}] \approx 0.1209, \quad \sigma(w_T) \approx 0.1962.$$

La razón de Sharpe resultante es

$$\text{Sh}(w_T) \approx 0.4634.$$

La distribución de pesos es más equilibrada que en el portafolio de mínima varianza porque el criterio ahora no es riesgo absoluto, sino retorno en exceso por unidad de volatilidad.




Figura 14: Frontera eficiente y línea de asignación de capital. La cartera tangente maximiza la razón de Sharpe y determina la recta de pendiente máxima que parte del activo libre de riesgo.

10.5. Modelos factoriales y factores de Fama–French

La versión moderna del problema no trabaja únicamente con la matriz de covarianzas empírica, sino con una descomposición estructural del riesgo. En el enfoque de Fama–French, los rendimientos en exceso se explican por unos pocos factores comunes: mercado, tamaño, valor y, en modelos ampliados, rentabilidad e inversión. Matemáticamente, esto reduce el problema a una covarianza de baja dimensión más un término idiosincrático.

Definición 10.8 (Modelo factorial lineal). Sea $r_t \in \mathbb{R}^d$ el vector de rendimientos en exceso sobre el activo libre de riesgo. Un modelo factorial con k factores escribe

$$r_t = \alpha + Bf_t + \varepsilon_t,$$

donde $\alpha \in \mathbb{R}^d$, $B \in \mathbb{R}^{d \times k}$, $f_t \in \mathbb{R}^k$ con media $\lambda := \mathbb{E}[f_t]$ y covarianza $\Sigma_f := \text{Var}(f_t)$, y $\varepsilon_t \in \mathbb{R}^d$ satisface

$$\mathbb{E}[\varepsilon_t] = 0, \quad \text{Var}(\varepsilon_t) = D, \quad \text{Cov}(f_t, \varepsilon_t) = 0.$$

Proposición 10.9 (Momentos bajo un modelo factorial). *Bajo las hipótesis anteriores,*

$$\mathbb{E}[r_t] = \alpha + B\lambda, \quad \text{Var}(r_t) = B\Sigma_f B^T + D.$$

Si el modelo valora exactamente los activos, entonces $\alpha = 0$.

Demostración. Tomando esperanza en la ecuación del modelo obtenemos

$$\mathbb{E}[r_t] = \alpha + B\mathbb{E}[f_t] + \mathbb{E}[\varepsilon_t] = \alpha + B\lambda.$$

Restando la media,

$$r_t - \mathbb{E}[r_t] = B(f_t - \lambda) + \varepsilon_t.$$

Por tanto,

$$\text{Var}(r_t) = \mathbb{E}[(B(f_t - \lambda) + \varepsilon_t)(B(f_t - \lambda) + \varepsilon_t)^T].$$

Al expandir aparecen cuatro términos. Dos de ellos son

$$B\mathbb{E}[(f_t - \lambda)(f_t - \lambda)^T]B^T = B\Sigma_f B^T, \quad \mathbb{E}[\varepsilon_t \varepsilon_t^T] = D,$$

y los dos términos cruzados se anulan por la hipótesis $\text{Cov}(f_t, \varepsilon_t) = 0$. Esto prueba la identidad. $\square$

Proposición 10.10 (Fórmula de Woodbury para la covarianza factorial). *Si $D \succ 0$ y $\Sigma_f \succ 0$, entonces*

$$(B\Sigma_f B^T + D)^{-1} = D^{-1} - D^{-1}B(\Sigma_f^{-1} + B^T D^{-1}B)^{-1}B^T D^{-1}.$$

Demostración. Sea

$$M := D^{-1} - D^{-1}B(\Sigma_f^{-1} + B^T D^{-1}B)^{-1}B^T D^{-1}.$$

Basta verificar que $(B\Sigma_f B^T + D)M = I$. Primero,

$$DM = I - B(\Sigma_f^{-1} + B^T D^{-1}B)^{-1}B^T D^{-1}.$$

Además,

$$B\Sigma_f B^T M = B\Sigma_f B^T D^{-1} - B\Sigma_f B^T D^{-1}B(\Sigma_f^{-1} + B^T D^{-1}B)^{-1}B^T D^{-1}.$$

Sumando ambas expresiones se obtiene

$$(B\Sigma_f B^T + D)M = I + B\left[\Sigma_f - (\Sigma_f^{-1} + B^T D^{-1}B)^{-1} - \Sigma_f B^T D^{-1}B(\Sigma_f^{-1} + B^T D^{-1}B)^{-1}\right]B^T D^{-1}.$$

Ahora bien,

$$\Sigma_f(\Sigma_f^{-1} + B^T D^{-1}B) = I + \Sigma_f B^T D^{-1}B,$$

y al multiplicar a derecha por $(\Sigma_f^{-1} + B^T D^{-1}B)^{-1}$ obtenemos

$$\Sigma_f = (I + \Sigma_f B^T D^{-1}B)(\Sigma_f^{-1} + B^T D^{-1}B)^{-1}.$$

Sustituyendo esta identidad en el corchete anterior, el término entre corchetes es cero. Por tanto $(B\Sigma_f B^T + D)M = I$, como queríamos. $\square$

Teorema 10.11 (Optimización media-varianza con restricciones lineales). *Sean $\Sigma \succ 0$, $\mu \in \mathbb{R}^d$, $\gamma > 0$, y sea $C \in \mathbb{R}^{d \times k}$ de rango completo con $c \in \mathbb{R}^k$. El problema*

$$\max_{w \in \mathbb{R}^d} \mu^T w - \frac{\gamma}{2} w^T \Sigma w \quad \text{sujeto a} \quad C^T w = c$$

tiene única solución

$$w^* = \frac{1}{\gamma} \Sigma^{-1} \mu - \Sigma^{-1} C (C^T \Sigma^{-1} C)^{-1} \left(C^T \frac{1}{\gamma} \Sigma^{-1} \mu - c \right).$$

Demostración. La función objetivo es estrictamente cóncava, de modo que cualquier punto KKT será el único máximo global. El Lagrangiano es

$$\mathcal{L}(w, \nu) = \mu^T w - \frac{\gamma}{2} w^T \Sigma w + \nu^T (c - C^T w).$$

La condición de primer orden respecto de w es

$$\mu - \gamma \Sigma w - C \nu = 0,$$

lo que implica

$$w = \frac{1}{\gamma} \Sigma^{-1} (\mu - C\nu).$$

Imponiendo las restricciones se obtiene

$$c = C^T w = \frac{1}{\gamma} C^T \Sigma^{-1} (\mu - C\nu).$$

Reordenando,

$$C^T \Sigma^{-1} C \nu = C^T \frac{1}{\gamma} \Sigma^{-1} \mu - c.$$

La matriz $C^T \Sigma^{-1} C$ es invertible porque C tiene rango completo y $\Sigma^{-1} \succ 0$. Por tanto,

$$\nu = (C^T \Sigma^{-1} C)^{-1} \left(C^T \frac{1}{\gamma} \Sigma^{-1} \mu - c \right).$$

Sustituyendo en la expresión de w obtenemos la fórmula anunciada. La unicidad sigue de la concavidad estricta. $\square$

Nota 10.12 (Presupuesto y neutralidad factorial). Tomando

$$C = [\mathbf{1} \ B], \quad c = (1, b)^T,$$

se impone simultáneamente presupuesto y exposición factorial prescrita. En particular, la elección $b = 0$ fuerza neutralidad con respecto a los factores incluidos en B . Así, la combinación Markowitz–Fama–French aparece como un único problema cuadrático con restricciones lineales plenamente soluble.




Figura 15: Estructura de un modelo de Fama–French. Pocas direcciones comunes capturan la parte sistemática del riesgo, mientras que los residuos idiosincráticos permanecen en el nivel de cada activo.

10.6. CAPM como consecuencia de equilibrio media–varianza

La razón de Sharpe y el portafolio tangente admiten una lectura de equilibrio. Si todos los inversionistas perciben la misma matriz de covarianzas y los mismos retornos esperados, y sólo difieren en su aversión al riesgo, entonces todos demandan la misma combinación de activos riesgosos y difieren únicamente en la escala con la que la combinan con el activo libre de riesgo. El resultado es que el portafolio de mercado coincide con la cartera tangente, y de ahí emerge la ecuación del CAPM.

Teorema 10.13 (Forma matricial del CAPM). *Supongamos que existe un portafolio de mercado w_M tal que, en equilibrio, el agregado de la demanda riesgosa es proporcional a w_M . Entonces existe un escalar $\delta > 0$ con*

$$\mu - r_f \mathbf{1} = \delta \Sigma w_M.$$

En particular, si $R_M := w_M^T R$, entonces para cada activo i se cumple

$$\mathbb{E}[R_i] - r_f = \beta_i (\mathbb{E}[R_M] - r_f), \quad \beta_i := \frac{\text{Cov}(R_i, R_M)}{\text{Var}(R_M)}.$$

Demostración. Por el Teorema 10.6, cualquier inversionista que maximiza utilidad media–varianza con activo libre de riesgo demanda una canasta riesgosa proporcional a $\Sigma^{-1}(\mu - r_f \mathbf{1})$. Si el equilibrio agrega dichas demandas y el mercado limpia, el portafolio riesgoso agregado debe ser colineal con esa misma dirección; esto es,

$$w_M = c \Sigma^{-1}(\mu - r_f \mathbf{1})$$

para algún $c > 0$. Reordenando,

$$\mu - r_f \mathbf{1} = \delta \Sigma w_M, \quad \delta := c^{-1} > 0.$$

Tomando la i -ésima coordenada obtenemos

$$\mathbb{E}[R_i] - r_f = \delta (\Sigma w_M)_i.$$

Ahora bien,

$$(\Sigma w_M)_i = e_i^T \Sigma w_M = \text{Cov}(R_i, R_M),$$

pues $R_M = w_M^T R$. Por otra parte,

$$\mathbb{E}[R_M] - r_f = w_M^T (\mu - r_f \mathbf{1}) = \delta w_M^T \Sigma w_M = \delta \text{Var}(R_M).$$

Sustituyendo $\delta = \frac{\mathbb{E}[R_M] - r_f}{\text{Var}(R_M)}$ en la primera igualdad se obtiene

$$\mathbb{E}[R_i] - r_f = \frac{\text{Cov}(R_i, R_M)}{\text{Var}(R_M)} (\mathbb{E}[R_M] - r_f) = \beta_i (\mathbb{E}[R_M] - r_f).$$

□

Nota 10.14. La ecuación del CAPM no afirma que sólo el mercado “importe”, sino que bajo una estructura muy particular de equilibrio la parte relevante del riesgo es precisamente la covarianza con el portafolio tangente agregado. En cuanto aparecen fricciones, múltiples horizontes, restricciones de short-selling o exposiciones heterogéneas, el modelo factorial general vuelve a ser el lenguaje más flexible.




Figura 16: Línea del mercado de valores del CAPM. Los retornos esperados quedan organizados linealmente por la exposición beta al portafolio de mercado.

10.7. Black–Litterman como actualización bayesiana sobre retornos esperados

El paso desde CAPM a Black–Litterman consiste en reemplazar el “retorno esperado dado” por una distribución a priori sobre retornos en exceso. El equilibrio produce una media implícita π , mientras que las opiniones del inversionista entran como observaciones ruidosas de combinaciones lineales de esa media. El posterior resultante es una fusión estrictamente probabilística entre mercado y vistas subjetivas.

Definición 10.15 (Prior de equilibrio y vistas lineales). Sea $\pi \in \mathbb{R}^d$ el vector de retornos implícitos de equilibrio y sea $\tau > 0$. Suponemos un prior gaussiano

$$\mu \sim \mathcal{N}(\pi, \tau\Sigma).$$

Las vistas del inversionista se modelan como

$$q = P\mu + \eta, \quad \eta \sim \mathcal{N}(0, \Omega),$$

donde $P \in \mathbb{R}^{m \times d}$ codifica combinaciones lineales de activos o carteras, $q \in \mathbb{R}^m$ es el vector de opiniones y $\Omega \succ 0$ mide la incertidumbre asociada a ellas.

Teorema 10.16 (Fórmula posterior de Black–Litterman). *Bajo las hipótesis anteriores, la distribución posterior de μ condicionada por las vistas es gaussiana:*

$$\mu \mid q \sim \mathcal{N}(m_{BL}, V_{BL}),$$

con

$$V_{BL} = \left((\tau\Sigma)^{-1} + P^T\Omega^{-1}P \right)^{-1}$$

y

$$m_{BL} = V_{BL} \left((\tau\Sigma)^{-1}\pi + P^T\Omega^{-1}q \right).$$

Demostración. La densidad conjunta, salvo constante multiplicativa, es

$$\exp \left(-\frac{1}{2}(\mu - \pi)^T(\tau\Sigma)^{-1}(\mu - \pi) - \frac{1}{2}(q - P\mu)^T\Omega^{-1}(q - P\mu) \right).$$

Expandimos ambos términos cuadráticos en μ :

$$\begin{aligned}(\mu - \pi)^T (\tau \Sigma)^{-1} (\mu - \pi) &= \mu^T (\tau \Sigma)^{-1} \mu - 2\pi^T (\tau \Sigma)^{-1} \mu + \pi^T (\tau \Sigma)^{-1} \pi, \\(q - P\mu)^T \Omega^{-1} (q - P\mu) &= \mu^T P^T \Omega^{-1} P \mu - 2q^T \Omega^{-1} P \mu + q^T \Omega^{-1} q.\end{aligned}$$

Agrupando los términos dependientes de μ obtenemos

$$-\frac{1}{2} \mu^T \left((\tau \Sigma)^{-1} + P^T \Omega^{-1} P \right) \mu + \mu^T \left((\tau \Sigma)^{-1} \pi + P^T \Omega^{-1} q \right) + \text{constante}.$$

Sea

$$A := (\tau \Sigma)^{-1} + P^T \Omega^{-1} P, \quad b := (\tau \Sigma)^{-1} \pi + P^T \Omega^{-1} q.$$

Como $A \succ 0$, podemos completar el cuadrado:

$$-\frac{1}{2} \mu^T A \mu + \mu^T b = -\frac{1}{2} (\mu - A^{-1} b)^T A (\mu - A^{-1} b) + \frac{1}{2} b^T A^{-1} b.$$

De aquí se deduce que la ley posterior es gaussiana con media $A^{-1} b$ y covarianza A^{-1} , exactamente las fórmulas anunciadas. $\square$

Nota 10.17 (Black–Litterman como regularización geométrica). La media posterior m_{BL} no sustituye violentamente a π por las vistas q , sino que interpola entre ambas según la precisión relativa de $(\tau \Sigma)^{-1}$ y Ω^{-1} . En particular, cuando Ω es grande las opiniones pesan poco; cuando τ es grande el prior de equilibrio es débil y las vistas dominan.

Ejemplo 10.18 (Una vista relativa). Supongamos $d = 3$ activos y una única vista del tipo “el activo 1 superará al activo 2 en 2%”. Entonces

$$P = \begin{pmatrix} 1 & -1 & 0 \end{pmatrix}, \quad q = 0.02,$$

y la media posterior es

$$m_{BL} = \left((\tau \Sigma)^{-1} + P^T \Omega^{-1} P \right)^{-1} \left((\tau \Sigma)^{-1} \pi + P^T \Omega^{-1} 0.02 \right).$$

La corrección no afecta sólo a los dos activos involucrados; por la presencia de Σ , la vista se propaga a todo el sistema a través de las covarianzas cruzadas.




Figura 17: Black–Litterman como mecanismo de fusión entre equilibrio de mercado y opiniones del inversionista.

10.8. Restricciones de cardinalidad y problemas híbridos soporte-pesos

Las extensiones realmente difíciles del problema de Markowitz aparecen cuando la factibilidad deja de ser convexa. La restricción $\|w\|_0 \leq K$ impone que sólo se puedan mantener K posiciones activas y transforma el problema en una optimización mixta continua-discreta. El punto clave es que, una vez fijado el soporte, la parte continua vuelve a ser un problema cuadrático soluble en forma cerrada. Esa descomposición es exactamente la que hace natural el uso de algoritmos genéticos sobre máscaras de soporte.

Definición 10.19 (Problema de cardinalidad media-varianza). Para $K \in \{1, \dots, d\}$ definimos

$$\mathcal{W}_K := \{w \in \mathbb{R}^d : \mathbf{1}^T w = 1, w_i \geq 0, \|w\|_0 \leq K\}.$$

El problema de mínima varianza con cardinalidad es

$$\min_{w \in \mathcal{W}_K} w^T \Sigma w.$$

Más generalmente, el problema media-varianza con aversión $\gamma > 0$ es

$$\max_{w \in \mathcal{W}_K} \mu^T w - \frac{\gamma}{2} w^T \Sigma w.$$

Teorema 10.20 (Reducción a subproblemas por soporte). Para cada subconjunto $S \subset \{1, \dots, d\}$ con $|S| \leq K$, sea Σ_{SS} la submatriz principal correspondiente, μ_S el subvector de medias y $\mathbf{1}_S$ el vector de unos de dimensión $|S|$. Entonces

$$\min_{w \in \mathcal{W}_K} w^T \Sigma w = \min_{|S| \leq K} \frac{1}{\mathbf{1}_S^T \Sigma_{SS}^{-1} \mathbf{1}_S},$$

y para cada soporte fijo S el minimizador restringido es

$$w_i^{(S)} = \begin{cases} \frac{(\Sigma_{SS}^{-1} \mathbf{1}_S)_i}{\mathbf{1}_S^T \Sigma_{SS}^{-1} \mathbf{1}_S}, & i \in S, \\ 0, & i \notin S. \end{cases}$$

Demostración. Fijado un soporte S , cualquier w admisible con $\text{supp}(w) \subseteq S$ puede escribirse como $w = (w_S, 0)$, donde $w_S \in \mathbb{R}^{|S|}$ satisface $\mathbf{1}_S^T w_S = 1$ y $w_S \geq 0$. El riesgo se reduce a

$$w^T \Sigma w = w_S^T \Sigma_{SS} w_S.$$

Si ignoramos provisionalmente la desigualdad $w_S \geq 0$, el Teorema 10.2 aplicado a la submatriz Σ_{SS} da el minimizador

$$\hat{w}_S = \frac{\Sigma_{SS}^{-1} \mathbf{1}_S}{\mathbf{1}_S^T \Sigma_{SS}^{-1} \mathbf{1}_S}$$

y el valor mínimo

$$\hat{w}_S^T \Sigma_{SS} \hat{w}_S = \frac{1}{\mathbf{1}_S^T \Sigma_{SS}^{-1} \mathbf{1}_S}.$$


Cuando además $\hat{w}_S \geq 0$, este es también el minimizador del subproblema con restricción de no negatividad. En general, el conjunto global de soportes factibles puede restringirse a los que producen pesos no negativos o puede resolverse el subproblema cuadrático con desigualdades para cada S . En cualquier caso, el problema global es la envolvente inferior de todos los valores óptimos por soporte, y la fórmula anterior describe el caso interior, que es el relevante en la construcción híbrida soporte-pesos. $\square$

Proposición 10.21 (Cartera tangente restringida a un soporte). Sea $d_S := \mu_S - r_f \mathbf{1}_S$. Si $\mathbf{1}_S^T \Sigma_{SS}^{-1} d_S \neq 0$, entonces el portafolio tangente restringido al soporte S está dado por

$$w_i^{T,(S)} = \begin{cases} \frac{(\Sigma_{SS}^{-1} d_S)_i}{\mathbf{1}_S^T \Sigma_{SS}^{-1} d_S}, & i \in S, \\ 0, & i \notin S. \end{cases}$$

Demostración. Es exactamente el Teorema 10.6 aplicado en el subespacio generado por los activos de S , extendiendo después por ceros fuera del soporte. $\square$

Nota 10.22 (Por qué el GA encaja de forma natural). El espacio difícil no es el de los pesos continuos, sino el de los soportes y restricciones discretas. Una arquitectura híbrida razonable es: el cromosoma codifica la máscara binaria $z \in \{0, 1\}^d$ con $\sum_i z_i \leq K$; dado z , se resuelve exactamente el problema cuadrático sobre el soporte activo; la selección genética actúa sólo sobre la parte combinatoria. En otras palabras, el GA no sustituye a Markowitz: lo envuelve cuando el problema exacto deja de ser convexo.



búsqueda híbrida: discreta + continua

Figura 18: Descomposición híbrida del problema de portafolios con cardinalidad. El algoritmo genético explora soportes; la optimización cuadrática resuelve los pesos dentro de cada soporte.

11. Aplicaciones adicionales: portafolios, cadenas de Markov, HMM, MCMC, redes neuronales, Adam y algoritmos genéticos

Esta sección reúne aplicaciones donde el mismo patrón matemático vuelve a aparecer bajo distintos nombres. En todos los casos hay un espacio de configuraciones, una regla de ponderación o energía, y un mecanismo dinámico que propaga esa ponderación a lo largo del tiempo o de las iteraciones. Esa repetición estructural es precisamente la razón de haber mantenido una narrativa unificada desde el inicio del documento.

11.1. Algoritmos genéticos para teoría de portafolios

En portafolios reales aparecen restricciones que destruyen la convexidad del problema clásico: cardinalidad máxima, costos de transacción, límites por sector, neutralidad factorial, umbrales mínimos de inversión y rebalanceo con rotación acotada. En ese régimen, la teoría cerrada de Markowitz deja de ser suficiente y los algoritmos genéticos se vuelven una herramienta natural. La ventaja conceptual es que la población explora simultáneamente

múltiples geometrías de portafolio, mientras que la selección convierte una función objetivo penalizada en un cambio de medida sobre el espacio factible.

Sea

$$\mathcal{W} := \left\{ w \in \mathbb{R}^d : \mathbf{1}^T w = 1, w_i \geq 0, \|w\|_0 \leq K, \ell_i \leq w_i \leq u_i \text{ si } w_i > 0 \right\}$$

el conjunto factible de pesos con cardinalidad a lo más K . Dado un portafolio previo w^{old} , una función objetivo penalizada natural es

$$J(w) := \mu^T w - \frac{\lambda}{2} w^T \Sigma w - \tau \|w - w^{\text{old}}\|_1 - \rho \|B^T w - b\|^2, \quad w \in \mathcal{W},$$

donde $\lambda > 0$ controla la aversión al riesgo, $\tau \geq 0$ penaliza rotación y $\rho \geq 0$ fuerza exposición factorial cercana a un blanco b .

Definición 11.1 (Codificación genética de un portafolio). Un cromosoma está compuesto por dos bloques:

$$\chi = (z, u), \quad z \in \{0, 1\}^d, \quad u \in [0, 1]^d.$$

El vector binario z decide qué activos están presentes, y u asigna intensidades preliminares. La decodificación factible se define por

$$w_i(\chi) = \frac{z_i u_i}{\sum_{j=1}^d z_j u_j},$$

seguida, si es necesario, por un operador de reparación que garantice cardinalidad, cotas y restricciones lineales adicionales.

Nota 11.2. La normalización anterior hace visible el nexo con el cambio de medida: los pesos finales son exactamente una reponderación relativa de masas positivas. Cuando se repara además por restricciones factoriales o sectoriales, el cromosoma se proyecta sobre una subvariedad factible del simplex.

Definición 11.3 (Selección, cruce y mutación). Sea η_n la ley de la población en la generación n sobre el espacio de cromosomas factibles. Introducimos el potencial de selección

$$G_\beta(\chi) := e^{\beta J(w(\chi))}, \quad \beta > 0,$$

y escribimos $K_{\text{gen}}(\chi, d\chi')$ para el kernel conjunto de cruce, mutación y reparación. La evolución idealizada viene dada por

$$\eta_{n+1}(d\chi') = \frac{\int G_\beta(\chi) K_{\text{gen}}(\chi, d\chi') \eta_n(d\chi)}{\int G_\beta(\chi) \eta_n(d\chi)}.$$

Proposición 11.4 (Interpretación replicador–mutador para portafolios). *La dinámica anterior es un operador replicador–mutador sobre cromosomas. Para toda función acotada φ sobre el espacio de estados,*

$$\eta_{n+1}(\varphi) = \frac{\eta_n(G_\beta K_{\text{gen}} \varphi)}{\eta_n(G_\beta)}, \quad K_{\text{gen}} \varphi(\chi) := \int \varphi(\chi') K_{\text{gen}}(\chi, d\chi').$$

En particular, la selección es un cambio de medida y la variación genética es un núcleo de Markov.

Demostración. La identidad se obtiene simplemente al integrar φ respecto de η_{n+1} :

$$\eta_{n+1}(\varphi) = \int \varphi(\chi') \eta_{n+1}(d\chi') = \frac{\int \int \varphi(\chi') G_\beta(\chi) K_{\text{gen}}(\chi, d\chi') \eta_n(d\chi)}{\eta_n(G_\beta)}.$$

Intercambiando el orden de integración,

$$\eta_{n+1}(\varphi) = \frac{\int G_\beta(\chi) \left(\int \varphi(\chi') K_{\text{gen}}(\chi, d\chi') \right) \eta_n(d\chi)}{\eta_n(G_\beta)} = \frac{\eta_n(G_\beta K_{\text{gen}} \varphi)}{\eta_n(G_\beta)}.$$

Esto prueba la afirmación y deja explícita la descomposición selección/mutación. $\square$

Teorema 11.5 (Monotonía elitista del mejor fitness). *Supongamos que en cada generación el algoritmo copia sin modificación al menos un cromosoma con fitness máximo de la generación anterior. Sea*

$$M_n := \max_{1 \leq i \leq N} J(w(\chi_n^{(i)}))$$

el mejor valor de la población en la generación n . Entonces la sucesión $(M_n)_{n \geq 0}$ es no decreciente.

Demostración. Por hipótesis, si χ_n^* es un cromosoma tal que

$$J(w(\chi_n^*)) = M_n,$$

entonces existe al menos un individuo $\chi_{n+1}^{(j)}$ en la nueva generación idéntico a χ_n^* . Por consiguiente,

$$M_{n+1} = \max_{1 \leq i \leq N} J(w(\chi_{n+1}^{(i)})) \geq J(w(\chi_{n+1}^{(j)})) = J(w(\chi_n^*)) = M_n.$$

Luego $M_{n+1} \geq M_n$ para todo n . $\square$

Nota 11.6. La monotonía elitista no garantiza convergencia global al óptimo, pero sí evita una patología frecuente en heurísticas puramente estocásticas: perder soluciones de alta calidad ya descubiertas. En optimización de portafolios esto es especialmente importante cuando la función objetivo es cara de evaluar y el espacio factible tiene paredes combinatorias pronunciadas.

Ejemplo 11.7 (Portafolio con cardinalidad y neutralidad factorial). Considérese un universo de $d = 30$ activos, un límite de cardinalidad $K = 8$ y una estructura de factores Fama–French de tres dimensiones. El problema

$$\max_{w \in \mathcal{W}} \mu^T w - \frac{\lambda}{2} w^T \Sigma w \quad \text{sujeto a} \quad B^T w = 0$$

combina una parte cuadrática convexa con una restricción combinatoria no convexa. Un algoritmo genético trabaja de forma natural con esta mezcla: los bits del cromosoma administran la cardinalidad; la mutación cambia el soporte; el bloque continuo modifica intensidades; y la etapa de reparación proyecta el individuo sobre el conjunto con neutralidad factorial. En la práctica, esta arquitectura suele descubrir soluciones competitivas allí donde la enumeración exacta resulta prohibitiva.




Figura 19: Algoritmo genético para portafolios con restricciones reales. La selección repondera la población por el fitness penalizado, mientras que cruce, mutación y reparación constituyen el kernel de transición sobre el espacio factible.

11.2. Comparación entre optimización cuadrática clásica y algoritmo genético híbrido

Conviene distinguir con precisión dos regímenes. Cuando el problema es puramente cuadrático y convexo, la teoría clásica resuelve el portafolio exacto: existe una única solución, las condiciones KKT son suficientes y la frontera eficiente puede describirse analíticamente. En cambio, cuando se agregan cardinalidad, costos no convexos, lotes mínimos, neutralidades combinadas, límites por emisor o reglas de rebalanceo con histéresis, el problema deja de ser una sola superficie convexa y pasa a ser una unión de muchas celdas factibles. En ese escenario, el algoritmo genético híbrido es un procedimiento de exploración sobre subproblemas exactos.

Formalmente, para cada máscara $z \in \{0, 1\}^d$ con $\sum_i z_i \leq K$, definimos el soporte activo $S(z) := \{i : z_i = 1\}$ y el valor

$$J(z) := \max_{w: \text{supp}(w) \subseteq S(z)} \left\{ \mu^T w - \frac{\gamma}{2} w^T \Sigma w - \mathcal{P}(w) \right\},$$

donde $\mathcal{P}$ recoge penalizaciones por rotación, sector, tracking error o exposición factorial. El problema global es entonces

$$\max_{z \in \{0, 1\}^d, \sum z_i \leq K} J(z).$$

La teoría cuadrática clásica calcula exactamente $J(z)$ para cada soporte; el algoritmo genético aproxima la maximización exterior sobre z .

Proposición 11.8 (Descomposición exacta del problema híbrido). *Si para todo soporte admisible S la penalización $\mathcal{P}$ es convexa en el subconjunto continuo correspondiente, entonces el problema interior que define $J(z)$ admite un único óptimo y la dificultad del problema total reside exclusivamente en la búsqueda combinatoria sobre máscaras.*

Demostración. Fijado un soporte S , el conjunto de pesos con ese soporte y las restricciones lineales habituales es convexo. La función objetivo

$$w \mapsto \mu^T w - \frac{\gamma}{2} w^T \Sigma w - \mathcal{P}(w)$$

es estrictamente cóncava porque $\Sigma \succ 0$ y $\mathcal{P}$ es convexa. Por tanto, el máximo interior existe y es único. Una vez resuelto ese subproblema para cada máscara, el problema global queda reducido a comparar los valores óptimos $J(z)$ sobre un conjunto finito, aunque extremadamente grande, de máscaras. Esa capa exterior es puramente combinatoria. $\square$

Nota 11.9. La moraleja metodológica es importante. Markowitz, CAPM y Black–Litterman no son “alternativas” a los algoritmos genéticos; son la maquinaria analítica que permite evaluar, filtrar y refinar cada individuo de la población cuando el individuo representa un soporte o una familia de restricciones no convexas.




Figura 20: Optimización cuadrática clásica frente a búsqueda genética híbrida. La primera resuelve el núcleo convexo; la segunda explora la geometría discreta que queda fuera del alcance de la teoría cerrada.

11.3. Cadenas de Markov como algoritmos genéticos

Una forma útil de interpretar un algoritmo genético finito consiste en observar únicamente el estado agregado de la población. Si el espacio de poblaciones posibles es finito o numerable, la evolución generación a generación define una cadena de Markov homogénea o no homogénea, según se mantengan fijos o adaptativos los parámetros de selección y mutación.

Definición 11.10 (Cadena de poblaciones). Sea E el conjunto de poblaciones posibles. Un estado $x \in E$ puede representar, por ejemplo, un multiconjunto de cromosomas de tamaño N , o bien un resumen suficiente de la población (mejor individuo, diversidad, media empírica, etc.). La dinámica del algoritmo genético induce una matriz de transición

$$K(x, y) = \mathbb{P}(X_{n+1} = y \mid X_n = x).$$

Cuando K es irreducible y aperiódica, existe una única distribución invariante π y la cadena converge hacia ella.

Nota 11.11. La naturaleza Markoviana proviene de que una nueva generación depende de la actual únicamente a través de los operadores de selección, cruce y mutación. En formulaciones más ricas, el estado puede ampliarse para incluir temperaturas, tasas adaptativas o memoria de élites; aun así, el proceso ampliado sigue siendo Markoviano.

Definición 11.12 (Kernel tipo Metropolis para búsqueda evolutiva). Sea $F : E \rightarrow \mathbb{R}$ una función de aptitud y sea $M(x, y)$ un kernel de propuesta irreducible. Definimos

$$\alpha_\beta(x, y) = 1 \wedge \exp(\beta(F(y) - F(x))),$$

y el kernel

$$K_\beta(x, y) = M(x, y)\alpha_\beta(x, y), \quad y \neq x,$$

con término diagonal

$$K_\beta(x, x) = 1 - \sum_{y \neq x} K_\beta(x, y).$$

Teorema 11.13 (Medida invariante de Gibbs para búsqueda genética Markoviana). *Supongamos que M es simétrico: $M(x, y) = M(y, x)$. Entonces la medida*

$$\pi_\beta(x) = \frac{e^{\beta F(x)}}{\sum_{z \in E} e^{\beta F(z)}}$$

es invariante para K_β . Si además M es irreducible, la cadena converge a π_β desde cualquier estado inicial.

Demostración. Basta verificar balance detallado. Para $x \neq y$,

$$\pi_\beta(x) K_\beta(x, y) = \frac{e^{\beta F(x)}}{Z_\beta} M(x, y) (1 \wedge e^{\beta(F(y) - F(x))}).$$

Como M es simétrico, la expresión anterior coincide con

$$\frac{e^{\beta F(y)}}{Z_\beta} M(y, x) (1 \wedge e^{\beta(F(x) - F(y))}) = \pi_\beta(y) K_\beta(y, x).$$

Por tanto π_β satisface balance detallado y es invariante. La convergencia sigue de irreducibilidad y aperiodicidad estándar en cadenas finitas. $\square$

Nota 11.14. El teorema anterior muestra con claridad la conexión entre algoritmos genéticos, simulated annealing y métodos MCMC. Todos pueden interpretarse como mecanismos para construir una cadena de Markov cuya distribución invariante favorece regiones de alta aptitud. El cambio de medida vuelve a aparecer porque π_β es una reponderación tipo Gibbs del conteo uniforme sobre E .

Ejemplo 11.15 (Paisaje discreto con dos cuencas de atracción). Sea $E = \{0, 1, 2, 3, 4\}$ con fitness

$$F(0) = 0, \quad F(1) = 1.2, \quad F(2) = 2.4, \quad F(3) = 1.8, \quad F(4) = 3.1.$$

Tómese M como caminata aleatoria del vecino más cercano con reflexión en los extremos. Para β grande, la distribución π_β concentra la mayor parte de la masa en el estado 4, pero la estructura del kernel mantiene visitas ocasionales a 2 y 3, permitiendo exploración local alrededor de otro pico secundario.

11.4. Cadenas de Markov ocultas

Las cadenas de Markov ocultas (Hidden Markov Models, HMM) ofrecen una segunda aplicación natural del cambio de medida. El estado subyacente X_n evoluciona como cadena de Markov, pero lo que se observa es un proceso Y_n generado a partir de X_n . El problema central es filtrar la ley de X_n condicionada a las observaciones.

Definición 11.16 (Modelo oculto). Un HMM discreto está compuesto por:

1. una cadena de Markov $(X_n)_{n \geq 0}$ en un espacio E con distribución inicial μ y transición $K(x, dx')$;




Figura 21: Una cadena de Markov sobre el espacio de soluciones puede funcionar como algoritmo genético agregado: la mutación propone movimientos locales y la selección sesga la dinámica hacia estados de mayor fitness.

2. un espacio de observaciones $(Y, \mathcal{Y})$;
3. un núcleo de emisión $G(x, dy)$, o equivalentemente una densidad $g(y | x)$ respecto de una medida dominante $\nu(dy)$.

Condicionamente a (X_n) , las observaciones (Y_n) son independientes y satisfacen

$$\mathbb{P}(Y_n \in dy | X_n = x) = G(x, dy) = g(y | x)\nu(dy).$$

Teorema 11.17 (Recursión de filtrado de Bayes). *Sea*

$$\phi_n(dx) := \mathbb{P}(X_n \in dx | Y_0 = y_0, \dots, Y_n = y_n)$$

la distribución filtrada. Entonces se verifica la recursión

$$\phi_n(dx) = \frac{g(y_n | x) \int_E K(x', dx) \phi_{n-1}(dx')}{\int_E g(y_n | z) \int_E K(x', dz) \phi_{n-1}(dx')}, \quad n \geq 1.$$

Demostración. La medida predictiva es

$$\phi_{n|n-1}(dx) := \int_E K(x', dx) \phi_{n-1}(dx').$$

Al observar y_n , Bayes da

$$\phi_n(dx) = \frac{g(y_n | x) \phi_{n|n-1}(dx)}{\int_E g(y_n | z) \phi_{n|n-1}(dz)}.$$

Sustituyendo la expresión de $\phi_{n|n-1}$ se obtiene la fórmula anunciada. $\square$

Nota 11.18 (Filtrado como cambio de medida). La actualización de Bayes en HMM es exactamente un cambio de medida: la predictiva $\phi_{n|n-1}$ se repondera por la verosimilitud $x \mapsto g(y_n | x)$ y luego se normaliza. En otras palabras,

$$\phi_n = \Psi_{g(y_n|\cdot)}(\phi_{n|n-1}).$$

Esto revela que el filtro de Bayes y la etapa de selección en algoritmos genéticos comparten la misma estructura matemática.

Ejemplo 11.19 (HMM de dos regímenes). Sea $E = \{\text{alto}, \text{bajo}\}$ con matriz de transición

$$K = \begin{pmatrix} 0.92 & 0.08 \\ 0.15 & 0.85 \end{pmatrix},$$

y observaciones Gaussianas

$$Y_n \mid \{X_n = \text{alto}\} \sim \mathcal{N}(2, 1), \quad Y_n \mid \{X_n = \text{bajo}\} \sim \mathcal{N}(-1, 1).$$

Si una observación y_n es grande y positiva, entonces el factor de verosimilitud $g(y_n \mid \text{alto})/g(y_n \mid \text{bajo})$ aumenta fuertemente y la medida filtrada asigna mucha más masa al régimen alto. El efecto es un cambio de medida gobernado por la evidencia observacional.

Proposición 11.20 (Algoritmo hacia adelante y verosimilitud marginal). *Supongamos que E es finito. Para una observación fija $y_{0:n} = (y_0, \dots, y_n)$, definimos las cantidades hacia adelante*

$$\alpha_n(x) := \mathbb{P}(Y_0 = y_0, \dots, Y_n = y_n, X_n = x).$$

Entonces

$$\alpha_0(x) = \mu(x)g(y_0 \mid x),$$

y, para $n \geq 1$,

$$\alpha_n(x) = g(y_n \mid x) \sum_{x' \in E} \alpha_{n-1}(x')K(x', x).$$

Además, la verosimilitud marginal de la muestra observada está dada por

$$\mathbb{P}(Y_0 = y_0, \dots, Y_n = y_n) = \sum_{x \in E} \alpha_n(x),$$

y la distribución filtrada satisface

$$\phi_n(x) = \frac{\alpha_n(x)}{\sum_{z \in E} \alpha_n(z)}.$$

Demostración. La identidad inicial es inmediata por la regla del producto. Para el paso inductivo, descomponemos según el estado previo:

$$\alpha_n(x) = \sum_{x' \in E} \mathbb{P}(Y_0 = y_0, \dots, Y_n = y_n, X_{n-1} = x', X_n = x).$$

Usando la propiedad de Markov y la independencia condicional de las observaciones,

$$\alpha_n(x) = g(y_n \mid x) \sum_{x' \in E} \alpha_{n-1}(x')K(x', x).$$

Sumando en x se obtiene la verosimilitud marginal, y la fórmula de ϕ_n es simplemente una normalización. $\square$

Nota 11.21. La recursión hacia adelante es la contraparte observacional de la dinámica replicador–mutador: primero se propaga la masa por el kernel K , y luego se repondera por el potencial positivo $x \mapsto g(y_n \mid x)$. Esta identidad estructural es la razón profunda por la cual los filtros de partículas, los HMM y los algoritmos genéticos comparten tantas herramientas analíticas.

11.5. Puente con algoritmos genéticos y filtrado secuencial

La analogía entre HMM y algoritmos genéticos puede formularse así. En ambos contextos hay una medida base propagada por un núcleo de Markov y una etapa de reponderación mediante un potencial positivo. En HMM el potencial es la verosimilitud de la observación; en algoritmos genéticos es el fitness. En ambos casos surgen aproximaciones de partículas con remuestreo, y por eso muchas pruebas de estabilidad y convergencia tienen exactamente la misma forma.




Figura 22: Actualización de Bayes en un HMM de dos regímenes. La observación positiva multiplica la predictiva por la verosimilitud y desplaza la masa hacia el estado alto.




Figura 23: Estructura básica de una cadena de Markov oculta. El filtrado se obtiene reponderando la ley predictiva del estado oculto con la verosimilitud asociada a la observación actual.

11.6. Monte Carlo mediante cadenas de Markov: historia, principio ergódico y lectura genética

El término *Monte Carlo mediante cadenas de Markov* (MCMC, por sus siglas en inglés) designa una idea que hoy parece inevitable, pero que históricamente surgió de una necesidad muy concreta: calcular integrales de alta dimensión que no podían atacarse por cuadratura clásica. La familia Monte Carlo nació en el ambiente de la física estadística y la computación de mediados del siglo XX: en lugar de evaluar exactamente una integral, se aproximaba por promedios aleatorios. La innovación decisiva de MCMC consistió en relajar una exigencia demasiado fuerte: no hace falta producir muestras independientes de la ley objetivo; basta construir una cadena de Markov que tenga esa ley como distribución invariante y explotar el promedio temporal de una trayectoria suficientemente larga.

La historia tiene tres momentos estructurales. Primero, los métodos Monte Carlo de los años cuarenta introdujeron el uso sistemático del azar como herramienta numérica. Segundo, el algoritmo de Metropolis de 1953 mostró cómo simular estados de baja energía en física estadística mediante propuestas locales y reglas de aceptación; Hastings, en 1970, dio la formulación general con propuestas no necesariamente simétricas. Tercero, desde los años ochenta y noventa, con el muestreador de Gibbs, la restauración bayesiana de imágenes y la computación bayesiana moderna, MCMC se convirtió en una tecnología general para inferencia, optimización estocástica, aprendizaje estadístico y modelos jerárquicos.

Desde la narrativa de este manuscrito, MCMC es otro rostro del mismo principio: una medida complicada se vuelve accesible mediante una dinámica simple que alterna *mutación* y *selección*. La mutación propone nuevos estados; la selección acepta, rechaza o repondera esas propuestas de acuerdo con una energía, pérdida, verosimilitud o fitness. Así, la cadena no explora el espacio de forma neutral: lo recorre con una inclinación probabilística que codifica la distribución objetivo.

Definición 11.22 (Problema básico de MCMC). Sea $(E, \mathcal{E})$ un espacio medible y sea π una medida de probabilidad objetivo. En muchos problemas se conoce solamente una densidad no normalizada

$$\pi(dx) = \frac{\tilde{\pi}(x)}{Z} \lambda(dx), \quad Z = \int_E \tilde{\pi}(x) \lambda(dx),$$

donde Z es desconocida o impracticable. El objetivo es aproximar

$$I_\varphi := \int_E \varphi(x) \pi(dx)$$

para funciones observables $\varphi : E \rightarrow \mathbb{R}$ mediante una cadena de Markov $(X_n)_{n \geq 0}$ con kernel K tal que $\pi K = \pi$.

Teorema 11.23 (Principio ergódico de MCMC). *Supongamos que (X_n) es una cadena de Markov irreducible, aperiódica y positiva recurrente sobre un espacio finito E , con distribución invariante única π . Entonces, para toda función $\varphi : E \rightarrow \mathbb{R}$,*

$$\frac{1}{N} \sum_{n=0}^{N-1} \varphi(X_n) \xrightarrow[N \rightarrow \infty]{a.s.} \sum_{x \in E} \varphi(x) \pi(x).$$

Demostración. En espacio finito, irreducibilidad y aperiodicidad implican ergodicidad. La cadena visita cada estado con frecuencia asintótica igual a su masa estacionaria:

$$\frac{1}{N} \sum_{n=0}^{N-1} \mathbf{1}_{\{X_n=x\}} \xrightarrow[N \rightarrow \infty]{a.s.} \pi(x).$$

Como toda función φ en un espacio finito se escribe como

$$\varphi = \sum_{x \in E} \varphi(x) \mathbf{1}_{\{x\}},$$

la convergencia de los promedios temporales se obtiene sumando la convergencia de frecuencias estado por estado. $\square$

Proposición 11.24 (Balance detallado como certificado de invariancia). *Si un kernel K satisface*

$$\pi(dx)K(x, dy) = \pi(dy)K(y, dx),$$

entonces π es invariante para K .

Demostración. Integramos ambos lados respecto de x . Para todo conjunto medible A ,

$$\int_E \pi(dx)K(x, A) = \int_A \int_E \pi(dy)K(y, dx) = \int_A \pi(dy) = \pi(A),$$

porque $K(y, E) = 1$. Por tanto $\pi K = \pi$. $\square$

Nota 11.25 (La constante de normalización desaparece). La potencia computacional de MCMC se debe a que las reglas de aceptación suelen depender de cocientes del tipo

$$\frac{\pi(y)}{\pi(x)} = \frac{\tilde{\pi}(y)}{\tilde{\pi}(x)}.$$

La constante Z se cancela. Esto es exactamente lo que ocurre también en selección genética por pesos relativos: no importa conocer la aptitud normalizada de cada individuo, sino su peso relativo frente a los demás.

Definición 11.26 (Lectura genética de un kernel MCMC). Un paso MCMC puede descomponerse en tres operadores:

1. *propuesta o mutación*: desde x se propone $Y \sim q(x, dy)$;
2. *evaluación*: se compara la calidad relativa mediante una razón $R(x, Y)$ construida con energía, pérdida, posterior o fitness;
3. *selección*: se acepta Y con probabilidad $\alpha(x, Y)$ y, en caso contrario, se conserva x .

En lenguaje evolutivo, la trayectoria (X_n) es una población de tamaño uno con memoria Markoviana; los algoritmos genéticos son la versión poblacional, paralela y recombinante de la misma lógica.

Proposición 11.27 (Kernel mutación–selección). *Sea $F : E \rightarrow \mathbb{R}$ un fitness, $\beta > 0$ una temperatura inversa y $q(x, dy)$ un kernel de propuesta simétrico. El kernel*

$$K_\beta(x, dy) = q(x, dy)(1 \wedge e^{\beta(F(y)-F(x))}) + \delta_x(dy) \int_E q(x, dz)(1 - 1 \wedge e^{\beta(F(z)-F(x))})$$

tiene como distribución invariante

$$\pi_\beta(dx) = \frac{e^{\beta F(x)}}{Z_\beta} \lambda(dx).$$

Demostración. Es el argumento de balance detallado del algoritmo de Metropolis aplicado a la densidad no normalizada $\tilde{\pi}_\beta(x) = e^{\beta F(x)}$. La simetría de q cancela los términos de propuesta y la aceptación compensa exactamente la diferencia de masas $e^{\beta F(y)}/e^{\beta F(x)}$. $\square$

Nota 11.28 (Temperatura, exploración y explotación). Cuando β es pequeño, π_β se parece a la medida base y la cadena explora. Cuando β crece, π_β concentra masa en máximos de F y la cadena explota. Esta es la misma tensión que organiza un algoritmo genético: demasiada mutación destruye la memoria de buenos individuos; demasiada selección colapsa la diversidad y puede atrapar a la población en máximos locales.

Definición 11.29 (Promedio MCMC y tamaño efectivo de muestra). Dada una trayectoria $X_0, \dots, X_{N-1}$, el estimador MCMC de I_φ es

$$\hat{I}_N(\varphi) = \frac{1}{N} \sum_{n=0}^{N-1} \varphi(X_n).$$

A diferencia del Monte Carlo independiente, las observaciones están correlacionadas. Formalmente, si ρ_k denota la autocorrelación lag- k de $\varphi(X_n)$, una aproximación heurística del tamaño efectivo de muestra es

$$\text{ESS} \approx \frac{N}{1 + 2 \sum_{k \geq 1} \rho_k}.$$

Nota 11.30. La autocorrelación es el precio de usar una trayectoria dependiente. En lenguaje genético, equivale a poca diversidad entre generaciones consecutivas. Por eso las mejoras prácticas de MCMC buscan propuestas que mezclen bien: movimientos globales, adaptación de escala, Hamiltonian Monte Carlo, tempering paralelo o esquemas poblacionales.

Ejemplo 11.31 (Inferencia bayesiana como cambio de medida). Sea θ un parámetro, $p(\theta)$ una previa y $L(y | \theta)$ la verosimilitud. La posterior es

$$\pi(d\theta | y) = \frac{L(y | \theta)p(\theta)}{\int L(y | \vartheta)p(\vartheta)d\vartheta} d\theta.$$

MCMC construye una cadena con invariante $\pi(\cdot | y)$. La verosimilitud actúa como potencial de selección: parámetros que explican mejor los datos reciben más masa. Esta es la misma estructura que en un algoritmo genético, con fitness $F(\theta) = \log L(y | \theta) + \log p(\theta)$.




Figura 24: Lectura genética de MCMC. La propuesta funciona como mutación; la regla de aceptación funciona como selección probabilística; la distribución invariante es la medida inclinada por energía, posterior o fitness.




Figura 25: Trayectoria MCMC esquemática. Las repeticiones horizontales representan rechazos; los saltos representan mutaciones aceptadas. El promedio temporal reemplaza al promedio bajo muestras independientes.

11.7. Kolmogorov–Smirnov y Glivenko–Cantelli: validación empírica de leyes simuladas

Los métodos anteriores producen distribuciones empíricas. Un algoritmo genético produce la ley empírica de una población; MCMC produce la ley empírica de una trayectoria; una red neuronal produce distribuciones predictivas, residuos o probabilidades calibradas. En todos esos casos aparece una pregunta elemental y profunda: *¿la distribución observada se parece a la distribución que el modelo promete?* El puente clásico entre teoría y diagnóstico está dado por la función de distribución empírica, el estadístico de Kolmogorov–Smirnov y el teorema de Glivenko–Cantelli.

Históricamente, esta línea pertenece al nacimiento de la estadística no paramétrica moderna. Glivenko y Cantelli formularon en los años treinta la convergencia uniforme de la función de distribución empírica hacia la función de distribución verdadera. Kolmogorov identificó la ley límite universal del supremo reescalado, y Smirnov desarrolló las versiones de contraste y dos muestras. La importancia conceptual es enorme: la distancia uniforme entre distribuciones no requiere especificar momentos, regresiones ni parámetros. Compara leyes completas.

Definición 11.32 (Función de distribución empírica). Sea $X_1, \dots, X_N$ una muestra real. Su función de distribución empírica es

$$\hat{F}_N(t) := \frac{1}{N} \sum_{i=1}^N \mathbf{1}_{\{X_i \leq t\}}, \quad t \in \mathbb{R}.$$

Si $F(t) = \mathbb{P}(X \leq t)$ es la función de distribución verdadera, entonces $\hat{F}_N$ es una medida empírica acumulada: asigna masa $1/N$ a cada observación y resume toda la muestra como una función escalonada.

Definición 11.33 (Estadístico de Kolmogorov–Smirnov de una muestra). Dada una distribución de referencia F , el estadístico de Kolmogorov–Smirnov es

$$D_N(F) := \sup_{t \in \mathbb{R}} |\hat{F}_N(t) - F(t)|.$$

Mide la mayor discrepancia vertical entre la distribución empírica y la distribución teórica. En particular, $D_N(F)$ no sólo detecta diferencias de media o varianza: puede detectar desplazamientos, colas mal ajustadas, asimetrías y falta de calibración global.

Definición 11.34 (Kolmogorov–Smirnov de dos muestras). Si $X_1, \dots, X_m$ e $Y_1, \dots, Y_n$ son dos muestras independientes con funciones empíricas $\hat{F}_m$ y $\hat{G}_n$, el estadístico de dos muestras es

$$D_{m,n} := \sup_{t \in \mathbb{R}} |\hat{F}_m(t) - \hat{G}_n(t)|.$$

Esta versión compara dos mecanismos generadores sin imponer una forma paramétrica previa. En aplicaciones evolutivas puede comparar la población inicial y la población final; en MCMC puede comparar dos cadenas; en redes neuronales puede comparar residuos de entrenamiento y validación.

Teorema 11.35 (Glivenko–Cantelli). Sea $X_1, X_2, \dots$ una sucesión i.i.d. con función de distribución F . Entonces

$$\sup_{t \in \mathbb{R}} |\hat{F}_N(t) - F(t)| \xrightarrow[N \rightarrow \infty]{a.s.} 0.$$

Es decir, la distribución empírica converge uniformemente a la distribución verdadera.

Demostración. La idea es pasar de convergencia puntual a convergencia uniforme usando monotonía. Para cada punto fijo t , la ley fuerte de los grandes números da

$$\hat{F}_N(t) = \frac{1}{N} \sum_{i=1}^N \mathbf{1}_{\{X_i \leq t\}} \xrightarrow[N \rightarrow \infty]{a.s.} F(t).$$

Fijado $\varepsilon > 0$, se eligen puntos

$$-\infty = t_0 < t_1 < \dots < t_k = +\infty$$

de modo que el incremento de F entre puntos consecutivos sea, salvo los posibles saltos, menor que ε . En los puntos finitos de la malla la convergencia puntual es simultánea porque la malla es finita. Si $t_{j-1} < t \leq t_j$, la monotonía de F y de $\hat{F}_N$ permite encerrar $\hat{F}_N(t) - F(t)$ y $F(t) - \hat{F}_N(t)$ entre errores evaluados en los puntos de la malla más un incremento de tamaño controlado. Tomando el máximo sobre la malla y después $N \rightarrow \infty$, se obtiene que el supremo queda por debajo de una constante arbitrariamente pequeña. Como ε era arbitrario, la convergencia uniforme queda demostrada. $\square$

Teorema 11.36 (Kolmogorov–Smirnov: ley límite). Supongamos que F es continua y que $X_1, \dots, X_N$ son i.i.d. con distribución F . Entonces

$$\sqrt{N} D_N(F) \Rightarrow \sup_{0 \leq u \leq 1} |B^0(u)|,$$

donde B^0 es un puente browniano, es decir, un proceso gaussiano centrado con covarianza

$$\text{Cov}(B^0(s), B^0(t)) = \min(s, t) - st.$$

Además, para $x > 0$,

$$\mathbb{P}\left(\sup_{0 \leq u \leq 1} |B^0(u)| \leq x\right) = 1 - 2 \sum_{k=1}^{\infty} (-1)^{k-1} e^{-2k^2 x^2}.$$

Demostración. Por la transformación integral de probabilidad, si F es continua entonces $U_i = F(X_i)$ tiene distribución uniforme en $[0, 1]$. Por tanto el problema se reduce al proceso empírico uniforme

$$\alpha_N(u) := \sqrt{N} (\hat{F}_N(F^{-1}(u)) - u), \quad 0 \leq u \leq 1.$$

El teorema funcional de Donsker afirma que α_N converge débilmente en el espacio de funciones cadlag al puente browniano B^0 . La aplicación $f \mapsto \sup_{0 \leq u \leq 1} |f(u)|$ es continua en los puntos continuos, y el puente browniano tiene trayectorias continuas casi seguramente. El teorema de la aplicación continua produce la convergencia del estadístico. La fórmula explícita de la distribución límite se obtiene por el principio de reflexión aplicado al puente browniano. $\square$

Proposición 11.37 (Cota exponencial de Dvoretzky–Kiefer–Wolfowitz). *Para toda distribución F y todo $\varepsilon > 0$,*

$$\mathbb{P} \left(\sup_{t \in \mathbb{R}} |\hat{F}_N(t) - F(t)| > \varepsilon \right) \leq 2e^{-2N\varepsilon^2}.$$

En particular, la probabilidad de una discrepancia uniforme grande decrece exponencialmente con el tamaño de muestra.

Nota 11.38 (Lectura para algoritmos genéticos). Sea η_k^M la medida empírica de una población de tamaño M en la generación k . Para un observable escalar $Z = h(\theta)$, la función empírica

$$\hat{F}_{k,M}(t) = \eta_k^M \{ \theta : h(\theta) \leq t \}$$

permite medir si la población está concentrándose, diversificándose o colapsando. Un criterio tipo KS puede comparar generaciones sucesivas,

$$D_{k,k+1}^{(h)} = \sup_t |\hat{F}_{k,M}(t) - \hat{F}_{k+1,M}(t)|,$$

o comparar la población final con una ley objetivo de Gibbs proporcional a $e^{\beta F(\theta)}$. En esta lectura, Glivenko–Cantelli justifica que la población empírica aproxima una ley ideal cuando el tamaño poblacional crece, mientras que KS mide el error visible de esa aproximación.

Nota 11.39 (Lectura para MCMC). Si $X_0, \dots, X_{N-1}$ es una cadena con invariante π y $h : E \rightarrow \mathbb{R}$, se puede estudiar

$$\hat{F}_N^h(t) = \frac{1}{N} \sum_{n=0}^{N-1} \mathbf{1}_{\{h(X_n) \leq t\}}.$$

Bajo ergodicidad, $\hat{F}_N^h(t)$ converge para cada t a $F_h(t) = \pi\{x : h(x) \leq t\}$. Sin embargo, las observaciones MCMC son dependientes: el estadístico KS sigue siendo un diagnóstico útil, pero sus valores críticos i.i.d. ya no son automáticamente válidos. En la práctica se corrige con tamaño efectivo de muestra, cadenas independientes, bloques, bootstrap dependiente o diagnósticos complementarios de mezcla.

Nota 11.40 (Lectura para redes neuronales). En clasificación probabilística y regresión probabilística, la prueba KS aparece como herramienta de calibración. Si el modelo entrega una distribución predictiva $\hat{F}(\cdot | X_i)$ y se observa Y_i , entonces los valores transformados

$$U_i = \hat{F}(Y_i | X_i)$$

deberían parecer uniformes en $[0, 1]$ cuando el modelo está bien calibrado. Aplicar KS contra la uniforme permite detectar sobreconfianza, subconfianza, colas mal aprendidas o errores sistemáticos de calibración. En términos evolutivos, este diagnóstico puede entrar directamente al fitness: arquitecturas con menor discrepancia KS son seleccionadas porque no sólo predicen, sino que calibran mejor la incertidumbre.

Contexto	Objeto empírico	Uso de KS / Glivenko–Cantelli
Algoritmo genético	Distribución de fitness, pérdidas o parámetros en la población	Controla diversidad, convergencia poblacional y distancia a una ley de Gibbs objetivo.
MCMC	Distribución de observables a lo largo de la cadena	Diagnostica mezcla y discrepancia frente a la distribución invariante; requiere cautela por dependencia.
Red neuronal	Residuos, probabilidades calibradas o errores de validación	Evalúa calibración, estabilidad fuera de muestra y calidad probabilística del modelo.

Cuadro 1: Uso transversal de Kolmogorov–Smirnov y Glivenko–Cantelli. La misma distancia uniforme organiza validación estadística en poblaciones evolutivas, trayectorias MCMC y modelos neuronales.




Figura 26: Estadístico de Kolmogorov–Smirnov. La distancia D_N es la mayor separación vertical entre la distribución empírica y la distribución objetivo. Glivenko–Cantelli afirma que esa separación converge uniformemente a cero bajo muestreo i.i.d.

Observación 11.41 (Mensaje metodológico). Kolmogorov–Smirnov y Glivenko–Cantelli no son añadidos ornamentales. Son el punto donde la narrativa del manuscrito se vuelve verificable: los algoritmos cambian medidas, pero la estadística empírica debe comprobar si la medida generada realmente se aproxima a la medida objetivo. KS cuantifica la discrepancia; Glivenko–Cantelli da la garantía asintótica; MCMC, redes neuronales y algoritmos genéticos aportan los mecanismos computacionales que producen las muestras.

11.8. La ley de los grandes números desde la teoría de martingalas

La ley de los grandes números suele presentarse primero bajo independencia: si $X_1, X_2, \dots$ son observaciones con media común μ , entonces el promedio $n^{-1} \sum_{k=1}^n X_k$ debe estabilizarse alrededor de μ . Esa versión es fundamental, pero resulta demasiado estrecha para los algoritmos que nos interesan. Una cadena MCMC no produce observaciones independientes; un algoritmo genético genera poblaciones por selección y mutación condicionadas al pasado; el descenso estocástico calcula gradientes ruidosos que dependen de los parámetros actuales; Adam reescala gradientes con memoria. En todos estos casos, la independencia desaparece, pero queda una estructura más fina: el error nuevo, condicionado al pasado, tiene media cero. Ese es exactamente el lenguaje de las martingalas.

Históricamente, esta idea marca una transición conceptual. Borel, Kolmogorov y Khintchine dieron las formas clásicas de la ley de grandes números. Doob reorganizó la probabilidad moderna alrededor de filtraciones, tiempos de paro y martingalas. Desde entonces, una parte importante de la teoría límite dejó de depender exclusivamente de independencia y pasó a depender de dos mecanismos: *adaptación al pasado* y *cancelación condicional*. La ley de grandes números para martingalas dice, en esencia, que si los errores impredecibles tienen varianza acumulada suficientemente controlada, entonces su promedio desaparece.

Definición 11.42 (Diferencias de martingala). Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad filtrado por $(\mathcal{F}_n)_{n \geq 0}$. Una sucesión integrable $(D_n)_{n \geq 1}$ es una sucesión de *diferencias de martingala* si

$$D_n \in L^1(\mathbb{P}), \quad D_n \text{ es } \mathcal{F}_n\text{-medible}, \quad \mathbb{E}[D_n \mid \mathcal{F}_{n-1}] = 0.$$

Entonces

$$M_n := \sum_{k=1}^n D_k$$

es una martingala respecto de $(\mathcal{F}_n)$.

La interpretación es sencilla y poderosa. D_n puede depender de todo el pasado, pero no puede tener sesgo visible desde el pasado. Es ruido nuevo, no necesariamente independiente, pero sí condicionalmente centrado.

Lema 11.43 (Lema de Kronecker). Sea $(a_k)_{k \geq 1}$ una sucesión real. Si la serie

$$\sum_{k=1}^{\infty} \frac{a_k}{k}$$

converge, entonces

$$\frac{1}{n} \sum_{k=1}^n a_k \longrightarrow 0.$$

Demostración. Es una forma discreta de sumación por partes. Definamos $s_n = \sum_{k=1}^n a_k/k$, con $s_n \rightarrow s$. Como $a_k = k(s_k - s_{k-1})$, se tiene

$$\sum_{k=1}^n a_k = \sum_{k=1}^n k(s_k - s_{k-1}) = ns_n - \sum_{k=0}^{n-1} s_k,$$

con la convención $s_0 = 0$. Por tanto

$$\frac{1}{n} \sum_{k=1}^n a_k = s_n - \frac{1}{n} \sum_{k=0}^{n-1} s_k.$$

El promedio de Cesàro de una sucesión convergente converge al mismo límite s . La diferencia converge a cero. $\square$

Teorema 11.44 (Ley fuerte de grandes números para diferencias de martingala). *Sea $(D_n, \mathcal{F}_n)_{n \geq 1}$ una sucesión de diferencias de martingala cuadrado-integrables. Si*

$$\sum_{n=1}^{\infty} \frac{\mathbb{E}[D_n^2]}{n^2} < \infty,$$

entonces

$$\frac{1}{n} \sum_{k=1}^n D_k \xrightarrow[n \rightarrow \infty]{a.s.} 0.$$

En particular, basta que $\sup_n \mathbb{E}[D_n^2] < \infty$.

Demostración. Consideremos la martingala

$$T_n := \sum_{k=1}^n \frac{D_k}{k}.$$

Es martingala porque cada D_k/k sigue teniendo esperanza condicional cero. Además, las diferencias de martingala son ortogonales en L^2 : si $i < j$, entonces

$$\mathbb{E}[D_i D_j] = \mathbb{E}[D_i \mathbb{E}(D_j \mid \mathcal{F}_{j-1})] = 0,$$

ya que D_i es $\mathcal{F}_{j-1}$ -medible. Por tanto

$$\mathbb{E}[T_n^2] = \sum_{k=1}^n \frac{\mathbb{E}[D_k^2]}{k^2} \leq \sum_{k=1}^{\infty} \frac{\mathbb{E}[D_k^2]}{k^2} < \infty.$$

Así, (T_n) es una martingala acotada en L^2 . Por el teorema de convergencia de martingalas, T_n converge casi seguramente. Aplicando el lema de Kronecker a $a_k = D_k$, obtenemos

$$\frac{1}{n} \sum_{k=1}^n D_k \longrightarrow 0 \quad \text{c.s.}$$

La última afirmación se sigue de que $\sum n^{-2} < \infty$. $\square$

Corolario 11.45 (Ley fuerte clásica, versión cuadrado-integrable). *Si $X_1, X_2, \dots$ son independientes, idénticamente distribuidas, con $\mathbb{E}[X_1] = \mu$ y $\mathbb{E}[X_1^2] < \infty$, entonces*

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow[n \rightarrow \infty]{a.s.} \mu.$$

Demostración. Tomemos $\mathcal{F}_n = \sigma(X_1, \dots, X_n)$ y $D_n = X_n - \mu$. Entonces (D_n) es una sucesión de diferencias de martingala. Además $\sup_n \mathbb{E}[D_n^2] = \text{Var}(X_1) < \infty$. El teorema anterior da

$$\frac{1}{n} \sum_{k=1}^n (X_k - \mu) \rightarrow 0 \quad \text{c.s.,}$$

que es la afirmación. $\square$

La prueba anterior no pretende reemplazar la ley fuerte más general bajo integrabilidad L^1 ; esa versión requiere una truncación adicional. Su valor aquí es otro: muestra el mecanismo que sobrevive cuando las variables dejan de ser independientes.

Proposición 11.46 (Descomposición predecible más ruido martingala). *Sea $(Y_n)_{n \geq 1}$ una sucesión integrable y adaptada. Definamos*

$$A_n := \sum_{k=1}^n \mathbb{E}[Y_k \mid \mathcal{F}_{k-1}], \quad M_n := \sum_{k=1}^n (Y_k - \mathbb{E}[Y_k \mid \mathcal{F}_{k-1}]).$$

Entonces

$$\sum_{k=1}^n Y_k = A_n + M_n,$$

y (M_n) es una martingala. Si las diferencias

$$D_k := Y_k - \mathbb{E}[Y_k \mid \mathcal{F}_{k-1}]$$

satisfacen la condición del Teorema 11.44, entonces

$$\frac{1}{n} \sum_{k=1}^n Y_k - \frac{A_n}{n} \xrightarrow[n \rightarrow \infty]{a.s.} 0.$$

Demostración. La identidad es algebraica. Además

$$\mathbb{E}[D_k \mid \mathcal{F}_{k-1}] = \mathbb{E}[Y_k \mid \mathcal{F}_{k-1}] - \mathbb{E}[Y_k \mid \mathcal{F}_{k-1}] = 0,$$

de modo que M_n es martingala. La convergencia del promedio de M_n es exactamente el Teorema 11.44. $\square$

Esta proposición es una forma abstracta de la filosofía del manuscrito. Todo algoritmo adaptativo puede leerse como

observación acumulada = parte predecible + ruido martingala.

La ley de grandes números para martingalas dice que, bajo control de varianza, el segundo término se vuelve invisible a escala macroscópica.

Teorema 11.47 (Ley de grandes números para cadenas de Markov vía ecuación de Poisson). *Sea $(X_n)_{n \geq 0}$ una cadena de Markov con kernel P e invariante π . Sea $h : E \rightarrow \mathbb{R}$ un observable centrado, es decir $\pi h = 0$. Supongamos que existe una función acotada $g : E \rightarrow \mathbb{R}$ que resuelve la ecuación de Poisson*

$$h = g - Pg.$$

Entonces

$$\frac{1}{n} \sum_{k=0}^{n-1} h(X_k) \xrightarrow[n \rightarrow \infty]{a.s.} 0.$$

En consecuencia, para un observable general f con $h = f - \pi f$, se obtiene

$$\frac{1}{n} \sum_{k=0}^{n-1} f(X_k) \xrightarrow[n \rightarrow \infty]{a.s.} \pi f.$$

Demostración. Definamos

$$D_{k+1} := g(X_{k+1}) - Pg(X_k), \quad k \geq 0.$$

Como $\mathbb{E}[g(X_{k+1}) \mid \mathcal{F}_k] = Pg(X_k)$, la sucesión (D_{k+1}) es de diferencias de martingala. Además, g acotada implica varianza uniformemente acotada. Por el Teorema 11.44,

$$\frac{1}{n} \sum_{k=0}^{n-1} D_{k+1} \rightarrow 0 \quad \text{c.s.}$$

Por otro lado,

$$\sum_{k=0}^{n-1} h(X_k) = \sum_{k=0}^{n-1} (g(X_k) - Pg(X_k)) = g(X_0) - g(X_n) + \sum_{k=0}^{n-1} (g(X_{k+1}) - Pg(X_k)).$$

Dividiendo entre n , el término de borde $(g(X_0) - g(X_n))/n$ converge a cero porque g es acotada, y el término martingala converge a cero por la ley fuerte para martingalas. $\square$

Nota 11.48 (Lectura para MCMC). En MCMC, la cantidad estimada es casi siempre un promedio temporal

$$\hat{I}_n = \frac{1}{n} \sum_{k=0}^{n-1} f(X_k).$$

La cadena es dependiente, de modo que no se puede invocar sin más la ley i.i.d. La prueba vía martingalas explica qué reemplaza a la independencia: si el observable admite una ecuación de Poisson, la suma aditiva se descompone en un borde telescópico más una martingala. El borde desaparece por división entre n ; la martingala desaparece por cancelación condicional. Así se obtiene la consistencia del promedio MCMC.

Nota 11.49 (Lectura para algoritmos genéticos). Sea η_k^N la medida empírica de una población de tamaño N en la generación k , y sea Φ el operador ideal selección–mutación que enviaría la ley actual a la ley esperada de la siguiente generación. Para un observable acotado φ , el error

$$\eta_{k+1}^N(\varphi) - \Phi(\eta_k^N)(\varphi)$$

tiene media condicional cero dado el pasado, bajo el modelo usual de muestreo de descendientes condicionado a la población actual. Por tanto, las fluctuaciones de la población alrededor de la dinámica ideal son ruido martingala. La selección describe la deriva; la mutación describe el kernel; la martingala mide el error finito de población. Cuando N crece, ese error se promedia y la dinámica empírica sigue a la dinámica determinista de leyes.

Nota 11.50 (Lectura para redes neuronales, SGD y Adam). En descenso estocástico se observa un gradiente ruidoso

$$G_{n+1} = \nabla L(\theta_n) + \xi_{n+1}, \quad \mathbb{E}[\xi_{n+1} \mid \mathcal{F}_n] = 0.$$

El término $\nabla L(\theta_n)$ es la parte predecible; ξ_{n+1} es la diferencia de martingala. En SGD clásico, una condición típica es

$$\sum_n \gamma_n^2 \mathbb{E}[\|\xi_{n+1}\|^2 \mid \mathcal{F}_n] < \infty,$$

donde γ_n es el tamaño de paso. Esa condición hace converger la serie de ruido ponderado $\sum_n \gamma_n \xi_{n+1}$ y permite que el algoritmo siga, en promedio, el flujo de descenso. En Adam, RMSProp y variantes adaptativas, la misma intuición persiste, aunque el preconditionamiento y la memoria introducen términos adicionales: la teoría debe controlar una martingala vectorial transformada por matrices adaptadas al pasado.

Proposición 11.51 (Concentración exponencial: Azuma–Hoeffding). *Sea $(D_k, \mathcal{F}_k)$ una sucesión de diferencias de martingala tal que $|D_k| \leq c_k$ casi seguramente. Si $M_n = \sum_{k=1}^n D_k$, entonces, para todo $t > 0$,*

$$\mathbb{P}(M_n \geq t) \leq \exp\left(-\frac{t^2}{2 \sum_{k=1}^n c_k^2}\right),$$

y por simetría

$$\mathbb{P}(|M_n| \geq t) \leq 2 \exp\left(-\frac{t^2}{2 \sum_{k=1}^n c_k^2}\right).$$

Demostración. Para cada $\lambda > 0$, la acotación condicional de Hoeffding da

$$\mathbb{E}[e^{\lambda D_k} \mid \mathcal{F}_{k-1}] \leq \exp\left(\frac{\lambda^2 c_k^2}{2}\right).$$

Iterando esperanzas condicionadas,

$$\mathbb{E}[e^{\lambda M_n}] \leq \exp\left(\frac{\lambda^2}{2} \sum_{k=1}^n c_k^2\right).$$

Por Markov,


$$\mathbb{P}(M_n \geq t) \leq \exp\left(-\lambda t + \frac{\lambda^2}{2} \sum_{k=1}^n c_k^2\right).$$

Optimizando en $\lambda = t / \sum c_k^2$ se obtiene la cota. La desigualdad bilateral se obtiene aplicando el resultado a M_n y a $-M_n$. $\square$

Objeto	Parte predecible	Ruido martingala
MCMC	Promedio bajo la ley invariante o solución de Poisson	Fluctuación temporal dependiente de la trayectoria.
Algoritmo genético	Operador ideal selección–mutación Φ	Error de muestreo finito de la población.
SGD / Adam	Gradiente verdadero o preconditionado	Ruido de minibatch condicionado a los parámetros actuales.
Calibración empírica	Función de distribución objetivo	Error empírico acumulado de la muestra observada.

Cuadro 2: Lectura martingal de los algoritmos. La parte predecible dirige la dinámica; el ruido martingala se cancela a escala de promedios bajo control de varianza o concentración.

Observación 11.52 (Mensaje metodológico). La ley de grandes números para martingalas es el eslabón que faltaba entre teoría de probabilidad y algoritmos adaptativos. Glivenko–Cantelli explica por qué una muestra i.i.d. reconstruye una ley; Kolmogorov–Smirnov mide la discrepancia visible; la LLN vía martingalas explica por qué los promedios siguen siendo estables cuando la muestra se produce secuencialmente, con dependencia y retroalimentación. Por eso es natural en MCMC, algoritmos genéticos, redes neuronales entrenadas por minibatches y métodos adaptativos como Adam.



LLN vía martingalas: la dependencia es admisible si el sesgo condicional es cero y la varianza está controlada.

Figura 27: Descomposición martingal. Una suma adaptada se separa en una parte predecible y una innovación de media condicional cero. La ley de grandes números para martingalas elimina la innovación en escala de promedios.

11.9. Algoritmo de Metrópolis–Hastings

El algoritmo de Metrópolis–Hastings es una realización paradigmática del principio de cambio de medida: se quiere construir una cadena de Markov cuya ley invariante sea una medida objetivo π , normalmente conocida sólo hasta una constante de normalización.

Definición 11.53 (Kernel de propuesta y probabilidad de aceptación). Sea $(E, \mathcal{E})$ un espacio medible. Dado un kernel de propuesta $q(x, dy)$ y una medida objetivo π dominada por una medida de referencia λ , escribimos

$$\pi(dx) = \frac{\tilde{\pi}(x)}{Z} \lambda(dx),$$

donde $\tilde{\pi}$ es una densidad no normalizada. Definimos la razón de Hastings

$$r(x, y) := \frac{\tilde{\pi}(y)q(y, dx)}{\tilde{\pi}(x)q(x, dy)},$$

y la probabilidad de aceptación

$$\alpha(x, y) := 1 \wedge r(x, y).$$

El kernel de transición de Metrópolis–Hastings es entonces

$$K(x, dy) = q(x, dy)\alpha(x, y) + \delta_x(dy) \left(1 - \int_E q(x, dz)\alpha(x, z)\right).$$

Teorema 11.54 (Balance detallado para Metrópolis–Hastings). *El kernel K satisface la identidad de balance detallado*

$$\pi(dx)K(x, dy) = \pi(dy)K(y, dx),$$

y por tanto π es medida invariante de la cadena.

Demostración. Basta tratar la parte fuera de la diagonal. Para $x \neq y$,

$$\pi(dx)K(x, dy) = \pi(dx)q(x, dy)\alpha(x, y).$$

Si $r(x, y) \leq 1$, entonces $\alpha(x, y) = r(x, y)$ y

$$\pi(dx)q(x, dy)\alpha(x, y) = \pi(dx)q(x, dy)\frac{\tilde{\pi}(y)q(y, dx)}{\tilde{\pi}(x)q(x, dy)} = \pi(dy)q(y, dx).$$

En este caso $r(y, x) = 1/r(x, y) \geq 1$, de modo que $\alpha(y, x) = 1$ y por tanto

$$\pi(dx)K(x, dy) = \pi(dy)q(y, dx)\alpha(y, x) = \pi(dy)K(y, dx).$$

Si $r(x, y) > 1$, el mismo razonamiento con los papeles de x y y intercambiados produce la misma identidad. Sobre la diagonal, la igualdad se obtiene al restar de ambas medidas el flujo total hacia los estados distintos de x . Integrando en x se concluye que π es invariante. $\square$

Ejemplo 11.55 (Propuesta simétrica). Si $q(x, dy) = q(y, dx)$, entonces

$$\alpha(x, y) = 1 \wedge \frac{\tilde{\pi}(y)}{\tilde{\pi}(x)}.$$

Esto muestra con claridad el mecanismo de cambio de medida: los movimientos hacia regiones de mayor densidad objetivo se aceptan siempre, mientras que los movimientos hacia regiones menos probables se atenúan por el cociente de densidades.




Figura 28: En Metrópolis–Hastings con propuesta simétrica, la aceptación depende sólo del cociente entre densidades objetivo. Los movimientos hacia el centro de la distribución gaussiana se aceptan con probabilidad alta.

11.10. Redes neuronales: historia, cambio de medida y narrativa evolutiva

Las redes neuronales modernas son una de las manifestaciones más visibles de una idea antigua: representar una función compleja mediante la composición de muchas transformaciones simples. Su historia puede leerse en capas. En 1943, McCulloch y Pitts propusieron un modelo lógico de neurona artificial. En 1958, Rosenblatt introdujo el perceptrón como regla de aprendizaje lineal. Después vino una etapa crítica: las limitaciones de los perceptrones lineales mostraron que la profundidad, las no linealidades y el entrenamiento eficiente eran indispensables. La retropropagación, formulada en distintos contextos y popularizada en los años ochenta, convirtió la regla de la cadena en una tecnología computacional. Más

tarde, las redes recurrentes, las máquinas de Boltzmann, los modelos convolucionales, el aprendizaje profundo de los años 2000, las arquitecturas con atención y los transformadores hicieron de las redes neuronales un lenguaje general para aproximación, predicción, representación y control.

La lectura de este manuscrito no reduce las redes neuronales a una técnica de programación. Las interpreta como un problema de geometría probabilística sobre un espacio de parámetros de muy alta dimensión. Entrenar una red significa mover masa hacia regiones de baja pérdida; muestrear redes significa construir una medida sobre parámetros; seleccionar arquitecturas significa optimizar en un espacio mixto discreto-continuo. Por eso las redes neuronales encajan de forma natural con algoritmos genéticos, MCMC y cambio de medida: todas estas herramientas administran una tensión entre exploración, concentración y estabilidad.

Periodo	Hito	Lectura para este manuscrito
1940s–1950s	Neurona lógica y perceptrón	Primer paso: parametrizar reglas de decisión por pesos ajustables.
1980s	Backpropagation y redes multicapa	La regla de la cadena convierte el entrenamiento en flujo sobre parámetros.
1990s–2000s	SVM, regularización, redes profundas iniciales	Se vuelve central la geometría de generalización y el control de complejidad.
2010s	Deep learning a gran escala	La optimización estocástica y la sobreparametrización dominan la práctica.
Actualidad	Modelos fundacionales y búsqueda de arquitecturas	La selección de modelos se vuelve poblacional, energética y combinatoria.

Definición 11.56 (Red neuronal feed-forward). Sea $x \in \mathbb{R}^{d_0}$. Una red feed-forward de profundidad L se define por

$$h_0 = x, \quad h_\ell = \sigma_\ell(W_\ell h_{\ell-1} + b_\ell), \quad 1 \leq \ell \leq L-1, \quad f_\theta(x) = W_L h_{L-1} + b_L,$$

donde

$$\theta = (W_1, b_1, \dots, W_L, b_L)$$

es el vector de parámetros. Dada una muestra $(x_i, y_i)_{i=1}^n$, la pérdida empírica regularizada se escribe

$$\mathcal{L}_n(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(f_\theta(x_i), y_i) + \lambda \Omega(\theta),$$

con Ω un término de regularización.

Nota 11.57 (La red como composición geométrica). Cada capa realiza una transformación afín seguida de una no linealidad. La profundidad no sólo aumenta el número de parámetros: cambia la geometría de las representaciones. Las primeras capas construyen coordenadas internas; las capas intermedias recombinan rasgos; las últimas traducen la representación a una decisión, precio, probabilidad, score o política.

Proposición 11.58 (Backpropagation como adjunto de la regla de la cadena). Sea

$$z_\ell = W_\ell h_{\ell-1} + b_\ell, \quad h_\ell = \sigma_\ell(z_\ell),$$

y supongamos diferenciabilidad. Para una observación, definimos el error final

$$\delta_L := \nabla_{z_L} \ell(f_\theta(x), y).$$

Para $\ell = L - 1, \dots, 1$, los errores retropropagados satisfacen

$$\delta_\ell = (W_{\ell+1}^T \delta_{\ell+1}) \odot \sigma'_\ell(z_\ell).$$

Además,

$$\nabla_{W_\ell} \ell = \delta_\ell h_{\ell-1}^T, \quad \nabla_{b_\ell} \ell = \delta_\ell.$$

Demostración. La identidad se obtiene aplicando la regla de la cadena desde la salida hacia la entrada. Si $z_{\ell+1} = W_{\ell+1} h_\ell + b_{\ell+1}$ y $h_\ell = \sigma_\ell(z_\ell)$, entonces

$$\frac{\partial \ell}{\partial z_\ell} = \frac{\partial h_\ell}{\partial z_\ell}^T \frac{\partial z_{\ell+1}}{\partial h_\ell}^T \frac{\partial \ell}{\partial z_{\ell+1}} = \sigma'_\ell(z_\ell) \odot (W_{\ell+1}^T \delta_{\ell+1}).$$

La derivada de $z_\ell = W_\ell h_{\ell-1} + b_\ell$ respecto de W_ℓ y b_ℓ da las dos fórmulas de gradiente. $\square$

Definición 11.59 (Medida de Gibbs sobre parámetros neuronales). Sea $\mu(d\theta)$ una medida base sobre el espacio de parámetros o sobre un subconjunto factible Θ . Para $\beta > 0$, definimos

$$\Pi_{\beta,n}(d\theta) = \frac{e^{-\beta \mathcal{L}_n(\theta)}}{Z_{\beta,n}} \mu(d\theta), \quad Z_{\beta,n} = \int_{\Theta} e^{-\beta \mathcal{L}_n(\theta)} \mu(d\theta).$$

Esta ley asigna mayor masa a redes de baja pérdida. Cuando β crece, la masa se concentra en valles cada vez más profundos de la función de pérdida.

Proposición 11.60 (Concentración de Gibbs en mínimos empíricos). *Supongamos que Θ es compacto, que $\mathcal{L}_n$ es continua y que $\mu(U) > 0$ para todo abierto U que intersekte el conjunto de minimizadores*

$$\text{Argmin}(\mathcal{L}_n) = \{\theta \in \Theta : \mathcal{L}_n(\theta) = \inf_{\vartheta \in \Theta} \mathcal{L}_n(\vartheta)\}.$$

Entonces toda medida límite débil de $(\Pi_{\beta,n})_{\beta \rightarrow \infty}$ está soportada en $\text{Argmin}(\mathcal{L}_n)$.

Demostración. Sea $C \subseteq \Theta$ cerrado y disjunto del conjunto de minimizadores. Por continuidad y compacidad, existe $\delta > 0$ tal que

$$\inf_{\theta \in C} \mathcal{L}_n(\theta) \geq \mathcal{L}_n^* + \delta, \quad \mathcal{L}_n^* := \inf_{\vartheta \in \Theta} \mathcal{L}_n(\vartheta).$$

Tomamos un abierto U que intersekte el conjunto de minimizadores y en el que $\mathcal{L}_n \leq \mathcal{L}_n^* + \delta/2$. Entonces

$$\Pi_{\beta,n}(C) \leq \frac{e^{-\beta(\mathcal{L}_n^* + \delta)} \mu(C)}{e^{-\beta(\mathcal{L}_n^* + \delta/2)} \mu(U)} = e^{-\beta\delta/2} \frac{\mu(C)}{\mu(U)} \rightarrow 0.$$

Toda medida límite asigna masa cero a cerrados separados de los mínimos, y por tanto está soportada en el conjunto de minimizadores. $\square$

Nota 11.61 (Mínimos planos y generalización). El resultado anterior habla de pérdida empírica, no de generalización. En redes sobreparametrizadas suelen existir muchos mínimos con pérdida cercana a cero. Desde una perspectiva probabilística, no sólo importa la profundidad del valle, sino también su volumen: una región amplia de baja pérdida puede recibir más masa Gibbs que un mínimo estrecho. Esta observación explica por qué métodos con ruido, promedios de modelos, ensambles, MCMC o mutaciones pequeñas pueden favorecer soluciones más estables.

Definición 11.62 (Cromosoma neuronal). Un cromosoma neuronal puede codificar simultáneamente

$$\chi = (a, \theta, \eta),$$

donde a representa la arquitectura (número de capas, anchuras, conexiones, activaciones), θ los pesos de la red y η hiperparámetros de entrenamiento (tasa de aprendizaje, regularización, dropout, tamaño de lote). Una función de fitness típica es

$$F(\chi) = -\mathcal{L}_{\text{val}}(\theta, a) - \rho \text{Complexity}(a) - \gamma \text{Cost}(a),$$

donde se penalizan error de validación, complejidad y costo computacional.

Proposición 11.63 (Replicador–mutador para redes neuronales). Sea η_k la ley de una población de cromosomas neuronales en la generación k . Sea

$$G_\beta(\chi) = e^{\beta F(\chi)}$$

el potencial de selección, y sea $M(\chi, d\chi')$ un kernel que combina mutación de arquitectura, perturbación de pesos, cruce y, opcionalmente, una etapa local de entrenamiento por gradiente. Entonces la evolución idealizada

$$\eta_{k+1}(d\chi') = \frac{\int G_\beta(\chi) M(\chi, d\chi') \eta_k(d\chi)}{\int G_\beta(\chi) \eta_k(d\chi)}$$

es exactamente una dinámica replicador–mutador sobre el espacio de redes.

Demostración. Para toda función acotada φ ,

$$\eta_{k+1}(\varphi) = \frac{\eta_k(G_\beta M \varphi)}{\eta_k(G_\beta)}, \quad M \varphi(\chi) = \int \varphi(\chi') M(\chi, d\chi').$$

La normalización por $\eta_k(G_\beta)$ es un cambio de medida por fitness, mientras que M propaga diversidad por mutación, recombinación y refinamiento local. $\square$

Nota 11.64 (Neuroevolución e híbridos). En la práctica, un algoritmo genético rara vez compite directamente contra backpropagation en el ajuste fino de millones de pesos. Su papel natural es más estratégico: explorar arquitecturas, inicializaciones, hiperparámetros, subconjuntos de variables o familias de regularización. Después, Adam o SGD refinan localmente cada individuo prometedor. La arquitectura híbrida es entonces:

$$\text{GA global} \quad + \quad \text{descenso local} \quad + \quad \text{selección por validación.}$$

Esta combinación es conceptualmente sólida porque separa el problema discreto y combinatorio del problema diferencial y continuo.

Definición 11.65 (Mutaciones neuronales). Algunas mutaciones naturales son:

1. perturbación gaussiana de pesos: $\theta' = \theta + \sigma \xi$;
2. crecimiento de arquitectura: añadir una neurona, capa o conexión residual;
3. poda: eliminar pesos o unidades con baja contribución;
4. cambio de activación: sustituir tanh, ReLU, GELU u otra no linealidad;
5. mutación de hiperparámetros: cambiar tasa de aprendizaje, regularización o batch size.

Cada una define un kernel de Markov sobre una parte del cromosoma neuronal.

Ejemplo 11.66 (Búsqueda de arquitectura con refinamiento local). Supongamos que se desea predecir una variable financiera o económica Y a partir de covariables X . El cromosoma codifica $a = (L, m_1, \dots, m_L, \sigma, \lambda)$ y una inicialización θ_0 . Para cada cromosoma se entrena durante pocas épocas con Adam, obteniendo $\theta_T(a)$. El fitness se define por

$$F(a, \theta_0) = -\text{MSE}_{\text{val}}(f_{a, \theta_T}) - \rho \sum_{\ell=1}^L m_{\ell}.$$

Así, la población no busca sólo baja pérdida: busca baja pérdida con complejidad controlada. Esta es una forma de selección evolutiva que aproxima una penalización estadística de generalización.




Figura 29: Arquitectura híbrida para redes neuronales. El algoritmo genético explora arquitecturas e hiperparámetros; Adam refina pesos; la validación define el fitness que repondera la siguiente generación.




Figura 30: Medida de Gibbs sobre parámetros neuronales. Al crecer la temperatura inversa, el cambio de medida concentra masa en regiones de baja pérdida; la versión genética reemplaza el punto único por una población de candidatos.

11.11. Adam como optimización adaptativa preconditionada

Adam puede interpretarse como un descenso estocástico de gradiente con dos memorias exponenciales: una para el primer momento del gradiente y otra para su segundo momento

coordenado a coordenado. La normalización por el segundo momento corrige escalas anisótropas del paisaje de pérdida.

Definición 11.67 (Iteración de Adam). Sea $\theta_t \in \mathbb{R}^p$ el parámetro en el tiempo t , y sea g_t una realización del gradiente estocástico. Adam actualiza

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^{\odot 2},$$

con $m_0 = v_0 = 0$, donde $g_t^{\odot 2}$ denota el cuadrado coordenado a coordenado. Los estimadores corregidos por sesgo son

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t},$$

y la actualización final es

$$\theta_{t+1} = \theta_t - \alpha \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon},$$

donde todas las operaciones en el denominador se entienden componente a componente.

Proposición 11.68 (Corrección exacta del sesgo en el caso estacionario). *Supongamos que $(g_t)_{t \geq 1}$ es una sucesión i.i.d. con*

$$\mathbb{E}[g_t] = \mathfrak{g}, \quad \mathbb{E}[g_t^{\odot 2}] = \mathfrak{s}.$$

Entonces, para todo $t \geq 1$,

$$\mathbb{E}[m_t] = (1 - \beta_1^t) \mathfrak{g}, \quad \mathbb{E}[v_t] = (1 - \beta_2^t) \mathfrak{s},$$

y por tanto

$$\mathbb{E}[\hat{m}_t] = \mathfrak{g}, \quad \mathbb{E}[\hat{v}_t] = \mathfrak{s}.$$

Demostración. Desenrollando la recursión de m_t obtenemos

$$m_t = (1 - \beta_1) \sum_{j=1}^t \beta_1^{t-j} g_j.$$

Tomando esperanza y usando que $\mathbb{E}[g_j] = \mathfrak{g}$,

$$\mathbb{E}[m_t] = (1 - \beta_1) \sum_{j=1}^t \beta_1^{t-j} \mathfrak{g} = (1 - \beta_1) \frac{1 - \beta_1^t}{1 - \beta_1} \mathfrak{g} = (1 - \beta_1^t) \mathfrak{g}.$$

El mismo argumento aplicado a v_t da

$$v_t = (1 - \beta_2) \sum_{j=1}^t \beta_2^{t-j} g_j^{\odot 2}, \quad \mathbb{E}[v_t] = (1 - \beta_2^t) \mathfrak{s}.$$

Dividiendo por $1 - \beta_1^t$ y $1 - \beta_2^t$ concluimos la corrección exacta del sesgo en esperanza. $\square$

Proposición 11.69 (Caso de gradiente constante). *Si $g_t \equiv g \in \mathbb{R}^p$ para todo t , entonces*

$$\hat{m}_t = g, \quad \hat{v}_t = g^{\odot 2},$$

y la actualización de Adam se reduce a

$$\theta_{t+1} = \theta_t - \alpha \frac{g}{|g| + \varepsilon},$$

con valor absoluto tomado componente a componente.

Demostración. Usando la fórmula cerrada del argumento anterior,

$$m_t = (1 - \beta_1) \sum_{j=1}^t \beta_1^{t-j} g = (1 - \beta_1^t) g,$$

y de forma análoga

$$v_t = (1 - \beta_2) g^{\odot 2}.$$

La corrección por sesgo da inmediatamente $\hat{m}_t = g$ y $\hat{v}_t = g^{\odot 2}$. Sustituyendo en la fórmula de actualización se obtiene la expresión deseada. $\square$

Nota 11.70. En un valle anisótropo, las componentes del gradiente pueden tener escalas muy distintas. Adam divide cada coordenada por una estimación suavizada de su magnitud cuadrática, lo que produce pasos más equilibrados que los de SGD clásico. Desde el punto de vista geométrico, esto equivale a usar una métrica diagonal adaptativa en el espacio de parámetros.




Figura 31: En un valle cuadrático anisótropo $100\theta_1^2 + \theta_2^2$, Adam corrige la diferencia de escalas entre coordenadas y progresa de manera más equilibrada hacia el mínimo.

11.12. Redes neuronales, Adam y algoritmos genéticos

Las tres familias de métodos pueden unificarse. Un algoritmo genético mantiene una población de parámetros y la repondera por un potencial tipo $e^{-\beta L_n}$. Metrópolis–Hastings propone mutaciones y corrige mediante aceptación para preservar una ley objetivo. Adam, por su parte, realiza un flujo determinista o estocástico preconditionado que desciende en la misma función de pérdida. En problemas modernos de aprendizaje profundo es frecuente combinar estas ideas: poblaciones evolutivas para explorar arquitectura, kernels MCMC para inyectar diversidad y Adam para refinar localmente a los individuos mejor adaptados.

11.13. Análisis de Componentes Principales mediante Algoritmos Genéticos

El Análisis de Componentes Principales (PCA) es una técnica fundamental de reducción de dimensionalidad que busca proyecciones lineales que maximicen la varianza de los datos. Tradicionalmente, PCA se resuelve mediante descomposición espectral (eigenvalores/eigenvectores) de la matriz de covarianza. Sin embargo, presentamos aquí una formulación alternativa mediante algoritmos genéticos que resulta útil cuando:

- La matriz de covarianza es demasiado grande para su descomposición directa.
- Se busca robustez frente a outliers.
- Se desea incorporar restricciones no lineales o criterios adicionales.
- Se trabaja con datos masivos (big data) donde los métodos iterativos pueden ser más eficientes.

11.14. Fundamentos de PCA

Definición 11.71 (Matriz de datos). Sea $\mathbf{X} \in \mathbb{R}^{n \times p}$ una matriz de n observaciones y p variables. Suponemos que las columnas están centradas (media cero). La matriz de covarianza muestral es

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}^T \mathbf{X} \in \mathbb{R}^{p \times p}.$$

Definición 11.72 (Componentes Principales). El primer componente principal es el vector $\mathbf{w}_1 \in \mathbb{R}^p$ con $\|\mathbf{w}_1\| = 1$ que maximiza la varianza de la proyección:

$$\mathbf{w}_1 = \arg \max_{\|\mathbf{w}\|=1} \mathbf{w}^T \mathbf{S} \mathbf{w} = \arg \max_{\|\mathbf{w}\|=1} \frac{1}{n-1} \|\mathbf{X} \mathbf{w}\|^2.$$

Los siguientes componentes $\mathbf{w}_2, \dots, \mathbf{w}_k$ maximizan la misma expresión sujetos a ortogonalidad con los anteriores.

Nota 11.73 (Solución analítica). Los vectores $\mathbf{w}_j$ son los eigenvectores de $\mathbf{S}$ asociados a los k mayores eigenvalores $\lambda_1 \geq \dots \geq \lambda_k$. La proporción de varianza explicada por los primeros k componentes es $\sum_{j=1}^k \lambda_j / \sum_{j=1}^p \lambda_j$.

11.15. Formulación como Problema de Optimización

El PCA puede replantearse como un problema de optimización global:

Teorema 11.74 (Caracterización variacional de PCA). *Para cualquier $k \leq p$, los primeros k componentes principales son la solución del problema de optimización*

$$\max_{\substack{\mathbf{W} \in \mathbb{R}^{p \times k} \\ \mathbf{W}^T \mathbf{W} = \mathbf{I}_k}} \text{Tr}(\mathbf{W}^T \mathbf{S} \mathbf{W}),$$

donde $\text{Tr}(\cdot)$ denota la traza. Equivalentemente, se maximiza la suma de varianzas de las proyecciones.

Demostración. La condición $\mathbf{W}^T \mathbf{W} = \mathbf{I}_k$ impone columnas ortonormales. Por el principio de Rayleigh-Ritz, el máximo se alcanza cuando las columnas de $\mathbf{W}$ son los k eigenvectores principales de $\mathbf{S}$. $\square$

Corolario 11.75 (Caso secuencial). *El j -ésimo componente principal puede obtenerse resolviendo*

$$\mathbf{w}_j = \arg \max_{\|\mathbf{w}\|=1, \mathbf{w} \perp \mathbf{w}_1, \dots, \mathbf{w}_{j-1}} \mathbf{w}^T \mathbf{S} \mathbf{w}.$$




Figura 32: Visualización geométrica de PCA: la primera componente principal sigue la dirección de máxima dispersión, mientras que la segunda recoge la variación residual ortogonal.

11.16. Codificación del Problema para Algoritmos Genéticos

Definición 11.76 (Individuo). En el contexto de GA para PCA, cada individuo representa un conjunto de direcciones de proyección. Dos codificaciones posibles:

- **Codificación directa:** Un individuo es una matriz $\mathbf{W} \in \mathbb{R}^{p \times k}$ (o un vector $\mathbf{w}$ para un único componente).
- **Codificación angular:** Para $k = 1$, el vector $\mathbf{w}$ puede representarse mediante ángulos en coordenadas esféricas: $\mathbf{w} = (\cos \phi_1, \sin \phi_1 \cos \phi_2, \dots)$.

Definición 11.77 (Fitness). La función de fitness para un individuo $\mathbf{W}$ (con columnas ortonormales) es la varianza total explicada:

$$\text{fitness}(\mathbf{W}) = \text{Tr}(\mathbf{W}^T \mathbf{S} \mathbf{W}) = \sum_{j=1}^k \mathbf{w}_j^T \mathbf{S} \mathbf{w}_j.$$

Para un único vector $\mathbf{w}$ (primer componente), la fitness es simplemente $\mathbf{w}^T \mathbf{S} \mathbf{w}$.

Nota 11.78 (Manejo de restricciones). La condición de ortonormalidad $\mathbf{W}^T \mathbf{W} = \mathbf{I}_k$ debe imponerse. Esto puede hacerse mediante:

- **Penalización:** Fitness modificada = $\text{Tr}(\mathbf{W}^T \mathbf{S} \mathbf{W}) - \rho \|\mathbf{W}^T \mathbf{W} - \mathbf{I}_k\|_F^2$.
- **Reparación:** Proyectar cada individuo al conjunto de matrices ortonormales mediante descomposición QR o Gram-Schmidt.
- **Codificación inherente:** Usar representaciones que garanticen ortonormalidad (ej: ángulos).

11.17. Operadores Genéticos Específicos para PCA

Definición 11.79 (Mutación para vectores direccionales). Para un vector $\mathbf{w}$ con $\|\mathbf{w}\| = 1$, la mutación debe preservar la norma. Definimos:

- **Mutación por rotación:** $\mathbf{w}' = \frac{\mathbf{w} + \varepsilon \mathbf{u}}{\|\mathbf{w} + \varepsilon \mathbf{u}\|}$, donde $\mathbf{u} \sim \mathcal{N}(0, \mathbf{I}_p)$ y ε controla la magnitud.
- **Mutación angular:** En coordenadas esféricas, se perturban los ángulos: $\phi'_i = \phi_i + \delta_i$, $\delta_i \sim \mathcal{N}(0, \sigma_{\text{mut}}^2)$.

Definición 11.80 (Cruce para matrices ortonormales). Dadas dos matrices padres $\mathbf{W}^{(1)}$ y $\mathbf{W}^{(2)}$ con columnas ortonormales:

- **Cruce de columnas:** Intercambiar aleatoriamente algunas columnas entre padres.
- **Cruce por interpolación:** Para cada columna j , generar $\tilde{\mathbf{w}}_j = \alpha \mathbf{w}_j^{(1)} + (1 - \alpha) \mathbf{w}_j^{(2)}$ con $\alpha \sim U(0, 1)$, luego ortonormalizar.
- **Cruce basado en ángulos:** Promediar los ángulos en representación esférica.

Definición 11.81 (Selección). La selección favorece individuos con mayor varianza explicada. Métodos comunes:

- Selección por ruleta proporcional a la fitness.
- Selección por torneo.
- Selección por rango.

11.18. Convergencia y Propiedades

Teorema 11.82 (Convergencia del GA para PCA). Sea $\{\mathbf{W}^{(t)}\}_{t \geq 1}$ la población de un algoritmo genético con:

- *Fitness* $\text{Tr}(\mathbf{W}^T \mathbf{S} \mathbf{W})$.
- *Mutación* que garantiza exploración ergódica del espacio de matrices ortonormales.
- *Selección* que preserva el mejor individuo (elitismo).

Entonces, la secuencia de mejores fitness converge casi seguramente al máximo global $\sum_{j=1}^k \lambda_j$, donde λ_j son los mayores eigenvalores de $\mathbf{S}$.

Demostración. Trabajamos sobre la variedad compacta de Stiefel

$$\text{St}(p, k) := \{\mathbf{W} \in \mathbb{R}^{p \times k} : \mathbf{W}^T \mathbf{W} = \mathbf{I}_k\}.$$

La función de fitness

$$F(\mathbf{W}) := \text{Tr}(\mathbf{W}^T \mathbf{S} \mathbf{W})$$

es continua sobre $\text{St}(p, k)$, luego alcanza su máximo global $F_\star = \sum_{j=1}^k \lambda_j$. Sea B_t la mejor fitness de la población en la generación t . Por elitismo, el mejor individuo se conserva, así que

$$B_{t+1} \geq B_t \quad \text{casi seguramente.}$$

Como además $B_t \leq F_\star$, la sucesión no decreciente (B_t) converge casi seguramente a un límite aleatorio $B_\infty \leq F_\star$.

Fijemos $\varepsilon > 0$ y definamos el conjunto abierto

$$U_\varepsilon := \{\mathbf{W} \in \text{St}(p, k) : F(\mathbf{W}) > F_\star - \varepsilon\}.$$

Por hipótesis de exploración ergódica uniforme, existe $\delta_\varepsilon > 0$ tal que, desde cualquier población admisible, la probabilidad de que al menos un descendiente entre en U_ε durante la siguiente generación es al menos δ_ε . En consecuencia,

$$\mathbb{P}(B_{t+1} \leq F_\star - \varepsilon \mid \mathcal{F}_t) \leq 1 - \delta_\varepsilon$$

en el evento $\{B_t \leq F_\star - \varepsilon\}$. Iterando esta estimación obtenemos

$$\mathbb{P}(B_t \leq F_\star - \varepsilon \text{ para todo } t \geq 0) \leq \lim_{m \rightarrow \infty} (1 - \delta_\varepsilon)^m = 0.$$

Por tanto, con probabilidad uno existe un tiempo aleatorio T_ε tal que $B_{T_\varepsilon} > F_\star - \varepsilon$. El elitismo implica entonces que

$$B_t \geq B_{T_\varepsilon} > F_\star - \varepsilon, \quad t \geq T_\varepsilon.$$

Así, $B_\infty \geq F_\star - \varepsilon$ casi seguramente. Como $\varepsilon > 0$ es arbitrario, concluimos que $B_\infty = F_\star$ casi seguramente. Esto demuestra la convergencia reclamada. $\square$

Nota 11.83 (Comparación con el método espectral). El GA para PCA no supera en eficiencia al método de eigenvalores para matrices de tamaño moderado ($p \lesssim 1000$). Sin embargo, sus ventajas aparecen cuando:

- p es extremadamente grande y no se puede almacenar/computar $\mathbf{S}$ explícitamente.
- Se buscan componentes que maximicen otros criterios no lineales (kernel PCA, robust PCA).
- Se requiere incorporar restricciones adicionales (esparsidad, no negatividad).

11.19. Ejemplo: PCA Robusto con GA

Definición 11.84 (PCA robusto). El PCA tradicional es sensible a outliers porque maximiza varianza (L2-norm). Una alternativa robusta es maximizar la suma de L1-normas de las proyecciones:

$$\mathbf{w}_{\text{robust}} = \arg \max_{\|\mathbf{w}\|=1} \sum_{i=1}^n |\mathbf{x}_i^T \mathbf{w}| = \|\mathbf{X}\mathbf{w}\|_1.$$

Este problema no tiene solución analítica cerrada.

Ejemplo 11.85 (Implementación con GA). Para datos con outliers, la fitness robusta $\|\mathbf{X}\mathbf{w}\|_1$ es multimodal y no diferenciable. Un GA con:

- Individuos: vectores $\mathbf{w} \in \mathbb{R}^p$, $\|\mathbf{w}\| = 1$ (codificación angular).
- Fitness: $\sum_{i=1}^n |\mathbf{x}_i^T \mathbf{w}|$.
- Mutación: rotación aleatoria con paso adaptativo.
- Cruce: interpolación esférica.

encuentra direcciones más robustas que el PCA estándar precisamente porque la función objetivo penaliza linealmente los outliers y no cuadráticamente.

Teorema 11.86 (Consistencia del PCA robusto vía GA). Sea $X \in \mathbb{R}^p$ una variable aleatoria con $\mathbb{E}\|X\| < \infty$, y sea

$$M(w) := \mathbb{E}[|X^T w|], \quad w \in \mathbb{S}^{p-1}.$$

Supongamos que M posee un único maximizador $w_\star$ en la esfera unitaria. Para una muestra i.i.d. $X_1, \dots, X_n$, definimos el criterio empírico

$$M_n(w) := \frac{1}{n} \sum_{i=1}^n |X_i^T w|.$$

Supongamos además que el algoritmo genético produce un estimador $\hat{w}_n \in \mathbb{S}^{p-1}$ tal que

$$M_n(\hat{w}_n) \geq \sup_{w \in \mathbb{S}^{p-1}} M_n(w) - \varepsilon_n, \quad \varepsilon_n \xrightarrow{n \rightarrow \infty} 0 \quad \text{casi seguramente.}$$

Entonces

$$\hat{w}_n \xrightarrow[n \rightarrow \infty]{a.s.} w_\star.$$

Demostración. Para cada $w \in \mathbb{S}^{p-1}$, la función $x \mapsto |x^T w|$ está dominada por $\|x\|$, cuya esperanza es finita. Además,

$$||x^T w| - |x^T v|| \leq \|x\| \|w - v\|.$$

Como la esfera unitaria es compacta, la clase

$$\mathcal{F} := \{x \mapsto |x^T w| : w \in \mathbb{S}^{p-1}\}$$

es equicontinua y dominada por la función integrable $x \mapsto \|x\|$. Un argumento estándar de malla finita y continuidad uniforme da entonces la ley fuerte uniforme:

$$\sup_{w \in \mathbb{S}^{p-1}} |M_n(w) - M(w)| \xrightarrow[n \rightarrow \infty]{a.s.} 0.$$

Fijemos $\delta > 0$. Por unicidad del maximizador, el compacto

$$K_\delta := \{w \in \mathbb{S}^{p-1} : \|w - w_\star\| \geq \delta\}$$

no contiene maximizadores de M , de modo que

$$\gamma_\delta := M(w_\star) - \sup_{w \in K_\delta} M(w) > 0.$$

En el evento de probabilidad uno donde convergen uniformemente M_n a M y $\varepsilon_n \rightarrow 0$, existe N_δ tal que para todo $n \geq N_\delta$,

$$\sup_{w \in \mathbb{S}^{p-1}} |M_n(w) - M(w)| < \frac{\gamma_\delta}{3} \quad \text{y} \quad \varepsilon_n < \frac{\gamma_\delta}{3}.$$

Si para algún $n \geq N_\delta$ se tuviera $\hat{w}_n \in K_\delta$, entonces

$$M_n(\hat{w}_n) \leq \sup_{w \in K_\delta} M(w) + \frac{\gamma_\delta}{3} = M(w_\star) - \gamma_\delta + \frac{\gamma_\delta}{3} = M(w_\star) - \frac{2\gamma_\delta}{3},$$

mientras que

$$M_n(w_\star) \geq M(w_\star) - \frac{\gamma_\delta}{3}.$$

Por tanto,

$$M_n(\hat{w}_n) \leq M_n(w_\star) - \frac{\gamma_\delta}{3},$$

lo que contradice la optimalidad aproximada de $\hat{w}_n$. Concluimos que para n grande, $\hat{w}_n \notin K_\delta$, es decir, $\|\hat{w}_n - w_\star\| < \delta$. Como $\delta > 0$ es arbitrario, la convergencia casi segura queda probada. $\square$

11.20. Conexión con Cambio de Medida en PCA

Nota 11.87 (Interpretación probabilística). El PCA puede interpretarse como encontrar la proyección que maximiza la verosimilitud de un modelo de factores Gaussianos. Específicamente, si suponemos $\mathbf{x} = \mathbf{W}\mathbf{z} + \varepsilon$ con $\mathbf{z} \sim \mathcal{N}(0, \mathbf{I}_k)$ y $\varepsilon \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$, maximizar la verosimilitud conduce a un problema equivalente a PCA cuando $\sigma^2 \rightarrow 0$.

Teorema 11.88 (PCA como estimación por máxima verosimilitud). Sea $x_1, \dots, x_n \in \mathbb{R}^p$ una muestra centrada. Consideremos el modelo Gaussiano

$$X = \tau WZ + \varepsilon, \quad Z \sim \mathcal{N}(0, I_k), \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I_p),$$

donde $W \in \mathbb{R}^{p \times k}$ satisface $W^T W = I_k$ y $\tau, \sigma > 0$ son fijos. Entonces la matriz de covarianza de X es

$$C_W = \tau^2 W W^T + \sigma^2 I_p.$$

El estimador máximo-verosímil del subespacio generado por las columnas de W coincide con el subespacio principal de dimensión k de la matriz de covarianza muestral S .

Demostración. La log-verosimilitud (salvo constantes independientes de W) para una muestra centrada con covarianza muestral S es

$$\ell(W) = -\frac{n}{2} \left(\log \det C_W + \text{Tr}(S C_W^{-1}) \right).$$

Usamos primero que $W W^T$ es el proyector ortogonal sobre el subespacio imagen de W , luego sus autovalores son 1 con multiplicidad k y 0 con multiplicidad $p - k$. De aquí,

$$\det C_W = (\sigma^2 + \tau^2)^k (\sigma^2)^{p-k},$$

que no depende de la orientación del subespacio, sólo de su dimensión. Por tanto, maximizar $\ell(W)$ equivale a minimizar $\text{Tr}(S C_W^{-1})$.

Aplicamos la identidad de Woodbury en la forma

$$C_W^{-1} = \sigma^{-2} I_p - \frac{\tau^2}{\sigma^2(\sigma^2 + \tau^2)} W W^T.$$

Entonces

$$\text{Tr}(S C_W^{-1}) = \sigma^{-2} \text{Tr}(S) - \frac{\tau^2}{\sigma^2(\sigma^2 + \tau^2)} \text{Tr}(S W W^T).$$

Usando la ciclicidad de la traza,

$$\text{Tr}(S W W^T) = \text{Tr}(W^T S W).$$

Así, minimizar $\text{Tr}(S C_W^{-1})$ es equivalente a maximizar $\text{Tr}(W^T S W)$ sobre todas las matrices ortonormales W . Por el principio de Ky Fan, el máximo de esa cantidad es la suma de los k mayores eigenvalores de S y se alcanza exactamente cuando las columnas de W generan el subespacio principal correspondiente. Esto prueba la afirmación. $\square$

Nota 11.89 (Cambio de medida en el espacio de proyecciones). El algoritmo genético realiza implícitamente un cambio de medida en el espacio de direcciones: parte de una distribución uniforme (o inicial) y, mediante selección basada en fitness, converge hacia una medida concentrada en las direcciones óptimas. Este proceso es análogo al muestreo por importancia secuencial donde la distribución objetivo es proporcional a $e^{\text{fitness}(\mathbf{W})/\tau}$ con temperatura τ que decrece.

11.21. Ejemplo Computacional Extendido

Ejemplo 11.90 (PCA con GA en datos de alta dimensión). Consideremos un problema con $p = 5000$ variables y $n = 200$ observaciones. La matriz $\mathbf{S}$ requeriría almacenar $\approx 25 \times 10^6$ elementos (200 MB en doble precisión). Un GA puede operar directamente sobre $\mathbf{X}$ sin construir $\mathbf{S}$:

- **Representación:** Población de 100 vectores $\mathbf{w}$ de longitud p , almacenados como arrays dispersos.
- **Fitness:** Para cada $\mathbf{w}$, computar $\mathbf{y} = \mathbf{X}\mathbf{w}$ (costo $O(np)$) y luego $\mathbf{y}^T\mathbf{y}$ (costo $O(n)$). Total $O(np)$ por individuo.
- **Mutación:** Añadir ruido esparso (solo 1 % de componentes modificados) para mantener eficiencia.
- **Cruce:** Promedio de dos vectores padres con posterior normalización.

Este enfoque permite obtener los primeros componentes sin jamás construir $\mathbf{S}$, siendo viable para p muy grande donde los métodos clásicos fallan por limitaciones de memoria.

Referencias históricas orientativas

- N. Metropolis, A. W. Rosenbluth, M. N. Rosenbluth, A. H. Teller y E. Teller, “Equation of State Calculations by Fast Computing Machines”, 1953.
- W. K. Hastings, “Monte Carlo Sampling Methods Using Markov Chains and Their Applications”, 1970.
- S. Geman y D. Geman, “Stochastic Relaxation, Gibbs Distributions, and the Bayesian Restoration of Images”, 1984.
- A. E. Gelfand y A. F. M. Smith, “Sampling-Based Approaches to Calculating Marginal Densities”, 1990.
- W. S. McCulloch y W. Pitts, “A Logical Calculus of the Ideas Immanent in Nervous Activity”, 1943.
- F. Rosenblatt, “The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain”, 1958.
- D. E. Rumelhart, G. E. Hinton y R. J. Williams, “Learning Representations by Back-Propagating Errors”, 1986.
- J. H. Holland, *Adaptation in Natural and Artificial Systems*, 1975.
- D. E. Goldberg, *Genetic Algorithms in Search, Optimization, and Machine Learning*, 1989.
- K. O. Stanley y R. Miikkulainen, “Evolving Neural Networks through Augmenting Topologies”, 2002.
- D. P. Kingma y J. Ba, “Adam: A Method for Stochastic Optimization”, 2015.
- A. N. Kolmogorov, “Sulla determinazione empirica di una legge di distribuzione”, 1933.

- N. V. Smirnov, trabajos sobre discrepancias empíricas y pruebas de dos muestras, 1939–1948.
- V. I. Glivenko, “Sulla determinazione empirica delle leggi di probabilità”, 1933.
- F. P. Cantelli, trabajos sobre convergencia uniforme de distribuciones empíricas, 1933.
- A. Dvoretzky, J. Kiefer y J. Wolfowitz, “Asymptotic Minimax Character of the Sample Distribution Function and of the Classical Multinomial Estimator”, 1956.
- P. Massart, “The Tight Constant in the Dvoretzky–Kiefer–Wolfowitz Inequality”, 1990.
- J. L. Doob, *Stochastic Processes*, 1953.
- P. Hall y C. C. Heyde, *Martingale Limit Theory and Its Application*, 1980.
- D. Williams, *Probability with Martingales*, 1991.
- H. Robbins y D. Siegmund, “A convergence theorem for non negative almost supermartingales and some applications”, 1971.