

Aleatoriedad vs. recursividad del precio de los activos bursátiles: Un análisis comparativo para México y Estados Unidos

César Galindo¹ Claudia Cristina Reyes Montes de Oca²

¹ *Profesor Investigador, Universidad Panamericana, Campus Ciudad Panamericana*

² *Maestría en Economía, FES Acatlán, Universidad Nacional Autónoma de México*

14 de agosto de 2026

Resumen. ¿Se comportan los precios bursátiles como una caminata aleatoria, o cargan memoria, estructura y patrones parcialmente predecibles? Este artículo responde con datos diarios reales del IPC mexicano (1991–2025, $n = 8,490$ rendimientos) y del Dow Jones Industrial Average (1992–2025, $n = 8,499$), calculando –sin tomar cifras de la literatura– cinco lentes complementarias: (i) fundamentos de martingalas y la Hipótesis de Mercados Eficientes (HME); (ii) ajuste de distribuciones Gamma por ciclo bursátil; (iii) Teoría de Matrices Aleatorias (Marchenko–Pastur) sobre las correlaciones de 17 componentes del IPC y 28 del DJIA; (iv) la Representación de Lamperti y el exponente de Hurst, estimado por DFA y por rango reescalado (R/S); y (v) modelos GJR-GARCH junto con Teoría del Valor Extremo (GPD) para el backtesting de Valor en Riesgo. Los rendimientos exhiben curtosis en exceso de 6.8 (IPC) y 13.0 (DJI); el exponente de Hurst por DFA no difiere establemente de $1/2$ para el IPC ($\hat{H} = 0.504$, IC95 %: $[0.458, 0.512]$) pero sí para el DJI ($\hat{H} = 0.462$, IC95 %: $[0.414, 0.476]$, antipersistencia), mientras que R/S sugiere persistencia leve en ambos ($\hat{H} \approx 0.52$ – 0.55) –desacuerdo entre métodos que se discute explícitamente en vez de ocultarse. El VaR gaussiano al 99 % es rechazado por el test de Kupiec en ambos mercados ($p < 0.0001$); el VaR histórico y el VaR EVT/GPD no lo son. La transición RMT dinámica del DJI muestra que el mayor eigenvalor λ_1 nunca cae por debajo del umbral de Marchenko–Pastur –el factor de mercado siempre es genuino– pero su magnitud se triplica en crisis (mediana 11.5 vs. máximo 18.6 en abril de 2020). Un benchmark walk-forward de cinco algoritmos de Machine Learning (Random Forest, XGBoost, LightGBM, Gradient Boosting, Ridge) confirma que, pese a la estructura documentada, ninguno predice la dirección del rendimiento del día siguiente por encima de 53.1 %; para el DJI, los cinco quedan por debajo del predictor trivial de mayoría de clase –ni una búsqueda por algoritmo genético sobre *features* e hiperparámetros cambia esta conclusión de forma convincente. El espectro MFDFA confirma multifractalidad genuina en ambos índices ($\Delta\alpha \approx 0.25$ – 0.28); modelos de Lévy (NIG para IPC, Variance Gamma para DJI) superan ampliamente a la Normal por AIC, dando contenido paramétrico concreto al proceso de Lévy subyacente exigido por la Representación de Lamperti; y la log-volatilidad, medida sin el sesgo de ventanas traslapadas, resulta extremadamente rugosa ($\hat{H} \approx 0.009$), en la línea de la literatura de volatilidad rugosa de Gatheral–Jaisson–Rosenbaum y de la descomposición de Alòs–León–Vives. Una verificación Monte Carlo no circular confirma la fórmula de transición BBP para los factores RMT con error < 0.25 %. Una regresión Fama–French de 5 factores encuentra α diario significativamente negativo para el DJI (-5.25 % anualizado, atribuible a su ponderación por precio) y no significativo para el IPC. Replicando el núcleo del análisis en China (SSE) y Singapur (STI), el rechazo del VaR gaussiano y la ausencia de predictibilidad ML explotable se generalizan a los 4 mercados, Singapur muestra Hurst significativamente por encima de $1/2$ (China no, pese a tener el punto estimado más alto), y China exhibe el apalancamiento GARCH más débil de los cuatro mercados. La dinámica de eigenvalores RMT es cualitativamente consistente con el movimiento browniano de Dyson (1962): no se rechaza el *surmise* de Wigner en los espaciamientos desdoblados, y sí se rechaza Poisson; el criterio del cuarto momento de Nualart–Peccati (2005) es compatible con normalidad asintótica para $\lambda_1(t)$. Un ajuste Ornstein–Uhlenbeck a la volatilidad realizada da vidas medias de reversión de 48–104 días según el mercado. Finalmente, pronósticos walk-forward con Prophet (Taylor–Letham 2018) son **4.3–6.7 veces peores** que la caminata aleatoria en RMSE en los 7 mercados –el resultado más contundente del artículo a favor de la HME débil, obtenido con una familia de modelos completamente distinta a las anteriores. Un Estimador Rotacionalmente Invariante (RIE, Ledoit–Péché 2011; Bun–Bouchaud–Potters 2017) aplicado a portafolios de mínima varianza global **no** reduce la varianza realizada fuera de muestra frente a la matriz cruda en nuestros datos –contrario a la literatura clásica de limpieza RMT, atribuible al régimen de $q = p/T$ muy pequeño (14–28 activos, miles de días) frente a los universos amplios de acciones donde ese beneficio se documentó originalmente; en

Índice

1. Introducción	3
2. Marco teórico	4
2.1. Filtraciones, martingalas y el juego justo	4
2.2. Cálculo estocástico en tiempo continuo	4
2.2.1. El lema de Itô y ecuaciones diferenciales estocásticas	4
2.2.2. Volatilidad estocástica: el modelo de Heston y la rugosidad formal	5
2.2.3. Cambio de medida: el teorema de Girsanov y el primer teorema fundamental	6
2.2.4. La ecuación de Black–Scholes y la fórmula de Feynman–Kac	7
2.3. Ajuste Gamma por régimen de precios	8
2.4. Teoría de Matrices Aleatorias y la ley de Marchenko–Pastur	8
2.4.1. El Estimador Rotacionalmente Invariante (RIE) de Potters–Bouchaud	9
2.4.2. Movimiento browniano de Dyson y estadística de niveles	10
2.4.3. El criterio del cuarto momento (Nualart–Peccati)	10
2.5. Volatilidad realizada: Ornstein–Uhlenbeck	11
2.6. Modelos GARCH y GJR-GARCH	11
2.7. Teoría del Valor Extremo (EVT)	12
2.8. Teoría de Lamperti, autosimilitud y el exponente de Hurst	12
2.9. Modelos concretos para el proceso de Lévy subyacente	13
2.10. Multifractalidad: MFDFA	13
3. Revisión de la literatura	14
4. Hipótesis de investigación	14
5. Datos y metodología	14
6. Resultados	15
6.1. Estadística descriptiva	15
6.2. Ajuste Gamma por ciclo bursátil	16
6.3. Teoría de Matrices Aleatorias	16
6.3.1. RIE: portafolios de mínima varianza dentro y fuera de muestra	17

6.3.2. Estadística de niveles: Dyson y el surmise de Wigner	18
6.3.3. Normalidad asintótica: el criterio del cuarto momento	19
6.4. Exponente de Hurst: DFA vs. R/S	20
6.5. Multifractalidad: MFDFA	21
6.6. Procesos de Lévy: ajuste paramétrico	22
6.7. Volatilidad rugosa	23
6.8. GJR-GARCH y el efecto apalancamiento	24
6.9. Ornstein–Uhlenbeck: reversión a la media de la volatilidad	25
7. Teoría del Valor Extremo y validación de VaR	26
7.1. Verificación Monte Carlo no circular	29
8. Benchmark de Machine Learning: walk-forward	30
8.1. Optimización por algoritmo genético	32
9. Regresión Fama–French	33
10. Extensión comparativa: cinco mercados asiáticos adicionales	34
10.1. Lévy, MFDFA y volatilidad rugosa: cinco mercados	37
10.2. RMT, Dyson–Wigner, Peccati y RIE: Japón, Hong Kong y Corea	40
11. Extensión a mercados frontera: Argentina y Brasil	41
12. Pronósticos con Prophet	43
13. Discusión	45
14. Conclusiones	47

1. Introducción

¿Los precios bursátiles son ruido gaussiano incorporando información al instante, como postula la Hipótesis de los Mercados Eficientes (HME, Fama 1970), o cargan estructura –colas pesadas, memoria de largo plazo, factores de correlación genuínos– que la caminata aleatoria simplemente no puede producir? Este trabajo responde con tres décadas de datos diarios reales del IPC mexicano y del Dow Jones, sin apoyarse en cifras de estudios previos: cada número que se reporta en las Secciones 6 y 7 fue calculado directamente sobre las series de precios, con el código distribuido junto a este artículo (`scripts/01-07`).

Cuatro líneas de evidencia se examinan:

1. **Colas pesadas.** La curtosis en exceso de los rendimientos –incompatible con la Normal– se cuantifica y se traduce en un índice de cola $\alpha = 1/\hat{\xi}$ vía EVT (Sección 7).
2. **Heterocedasticidad condicional y apalancamiento.** Modelos GJR-GARCH estimados por máxima verosimilitud cuantifican si las caídas incrementan la volatilidad más que las subidas (Sección 2.6).
3. **Estructura factorial.** La Teoría de Matrices Aleatorias separa factores de correlación genuínos del ruido muestral en los componentes de ambos índices (Sección 2.4).
4. **Memoria de largo plazo.** El exponente de Hurst, estimado por dos métodos independientes (DFA y R/S), se conecta formalmente con los procesos de Lévy vía la Representación de Lamperti (Sección 2.8).

Un principio metodológico guía todo el trabajo: cuando dos métodos distintos para estimar la misma cantidad (aquí, el exponente de Hurst) discrepan, el desacuerdo se reporta explícitamente en vez de elegir el método que produce la conclusión más vistosa. La Sección 6.4 documenta un caso así para el DJI.

Organización del artículo

La Sección 2 construye los cimientos teóricos (martingalas, HME, cálculo estocástico en tiempo continuo –lema de Itô, modelo de Heston y cambio de medida de Girsanov–, distribución Gamma, RMT/Marchenko–Pastur, GJR-GARCH, Lamperti/Hurst, procesos de Lévy, MFDFA). La Sección 3 contextualiza la evidencia previa para México y mercados emergentes. La Sección 4 formaliza las hipótesis. La Sección 5 describe los datos. La Sección 6 presenta los resultados empíricos completos, incluyendo multifractalidad, ajuste de Lévy y volatilidad rugosa. La Sección 7 hace el backtesting de VaR y la verificación Monte Carlo no circular de RMT/EVT. La Sección 8 reporta el benchmark de Machine Learning y su optimización por algoritmo genético. La Sección 9 estima el modelo Fama–French. La Sección 10 extiende el análisis a cinco mercados asiáticos adicionales (China, Singapur, Japón, Hong Kong y Corea

del Sur), y la Sección 11 lo extiende además a dos mercados latinoamericanos (Argentina, Brasil). Las Secciones 13 y 14 discuten y concluyen.

2. Marco teórico

2.1. Filtraciones, martingalas y el juego justo

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad.

Definición 2.1 (Martingala). Un proceso $(X_t)_{t \geq 0}$ adaptado a una filtración $(\mathcal{F}_t)$ es una **martingala** si $\mathbb{E}[|X_t|] < \infty$ y $\mathbb{E}[X_t | \mathcal{F}_s] = X_s$ para todo $s \leq t$.

Definición 2.2 (Caminata aleatoria). Sea $(\xi_n)_{n \geq 1}$ i.i.d. con $\mathbb{E}[\xi_n] = 0$, $\text{Var}(\xi_n) = \sigma^2 < \infty$. El proceso $S_0 = 0$, $S_n = \sum_{k=1}^n \xi_k$ se denomina **caminata aleatoria**.

Proposición 2.3. *La caminata aleatoria es una martingala respecto a su filtración natural.*

Demostración. $\mathbb{E}[S_{n+1} | \mathcal{F}_n] = S_n + \mathbb{E}[\xi_{n+1} | \mathcal{F}_n] = S_n + \mathbb{E}[\xi_{n+1}] = S_n$, usando linealidad, $\mathcal{F}_n$ -medibilidad de S_n e independencia de ξ_{n+1} . $\square$

Teorema 2.4 (Donsker, 1951). *Bajo las hipótesis de la caminata aleatoria, $W_t^{(n)} = (\sigma\sqrt{n})^{-1}S_{\lfloor nt \rfloor}$ converge en distribución en $C([0, 1])$ al movimiento browniano estándar.*

Definición 2.5 (HME débil, Fama 1970). Un mercado es **débilmente eficiente** si los precios reflejan toda la información del historial de precios pasados, de modo que ninguna estrategia basada en dicho historial genera rendimientos anormales sistemáticos: $\mathbb{E}[r_t | \mathcal{F}_{t-1}] = \mu$ constante, y los residuos $\varepsilon_t = r_t - \mu$ son i.i.d.

2.2. Cálculo estocástico en tiempo continuo

El teorema de Donsker (arriba) muestra que la caminata aleatoria discreta que se prueba empíricamente en este artículo converge, a escala fina, a un movimiento browniano. Esta subsección formaliza el aparato de tiempo continuo que queda implícito en esa convergencia: el cálculo de Itô que sustenta al modelo log-normal de precios, la ecuación de la volatilidad estocástica que generaliza el ajuste de Ornstein–Uhlenbeck ya usado en la Sección 2.5, y el cambio de medida que le da al concepto de martingala (Definición 2.1) su justificación teórica en la valoración de activos sin arbitraje.

2.2.1. El lema de Itô y ecuaciones diferenciales estocásticas

Definición 2.6 (Movimiento browniano estándar). Un proceso $(W_t)_{t \geq 0}$ es un **movimiento browniano estándar** si $W_0 = 0$, tiene incrementos independientes y estacionarios, y $W_t -$

$W_s \sim N(0, t - s)$ para $s \leq t$. Su variación cuadrática satisface $\langle W \rangle_t = t$, resumida en el cálculo diferencial informal $(dW_t)^2 = dt$.

Teorema 2.7 (Fórmula de Itô, Itô 1951). Sea $dX_t = \mu_t dt + \sigma_t dW_t$ y $f \in C^{1,2}([0, \infty) \times \mathbb{R})$. Entonces

$$df(t, X_t) = \left(\partial_t f + \mu_t \partial_x f + \frac{1}{2} \sigma_t^2 \partial_{xx} f \right) dt + \sigma_t \partial_x f dW_t. \quad (1)$$

Idea de la prueba. Expansión de Taylor de f a segundo orden y sustitución de $(dX_t)^2 = \sigma_t^2 dt + o(dt)$ (que a su vez viene de $(dW_t)^2 = dt$, $dW_t dt = 0$, $(dt)^2 = 0$); el término de segundo orden en X , que se anularía en cálculo ordinario, sobrevive aquí porque la variación cuadrática de W es de orden dt y no $o(dt)$. $\square$

Ejemplo 2.8 (Movimiento browniano geométrico, GBM). Sea $dS_t = \mu S_t dt + \sigma S_t dW_t$ ($S_0 > 0$). Aplicando (1) a $f(x) = \log x$:

$$d \log S_t = \left(\mu - \frac{1}{2} \sigma^2 \right) dt + \sigma dW_t \implies S_t = S_0 \exp \left(\left(\mu - \frac{1}{2} \sigma^2 \right) t + \sigma W_t \right). \quad (2)$$

El GBM es exactamente el modelo cuya discretización $r_t = \log S_t - \log S_{t-1} \sim N(\mu - \sigma^2/2, \sigma^2)$ i.i.d. es la hipótesis nula implícita de la HME estricta: es la que la Sección 7 rechaza vía Kupiec, la que los ajustes de Lévy de la Sección 6.6 superan sistemáticamente por AIC, y la que la curtosis empírica (Tabla 2) contradice directamente —el GBM no tiene mecanismo interno para generar colas pesadas ni agrupamiento de volatilidad, que es precisamente lo que GARCH y EVT están diseñados para capturar.

Proposición 2.9 (Discretización exacta del proceso Ornstein–Uhlenbeck). Para $d\sigma_t = \kappa(\theta - \sigma_t) dt + \sigma_{\text{vol}} dW_t$ como en (14), la Proposición de la Sección 2.5 se sigue de aplicar (1) a $f(t, x) = e^{\kappa t} x$: $d(e^{\kappa t} \sigma_t) = \kappa \theta e^{\kappa t} dt + \sigma_{\text{vol}} e^{\kappa t} dW_t$; integrando entre t y $t + \Delta$ y despejando $\sigma_{t+\Delta}$ se obtiene la distribución condicional Gaussiana exacta citada ahí, sin aproximación de discretización (esquema de Euler-Maruyama u otro): la regresión lineal que ajusta `21_ornstein_uhlenbeck.py` recupera $(\kappa, \theta, \sigma_{\text{vol}})$ exactamente, no de forma aproximada.

2.2.2. Volatilidad estocástica: el modelo de Heston y la rugosidad formal

Definición 2.10 (Modelo de Heston, 1993).

$$dS_t = \mu S_t dt + \sqrt{v_t} S_t dW_t^{(1)}, \quad (3)$$

$$dv_t = \kappa(\theta - v_t) dt + \xi \sqrt{v_t} dW_t^{(2)}, \quad (4)$$

con $d\langle W^{(1)}, W^{(2)} \rangle_t = \rho dt$. La ecuación de varianza (4) es un proceso de Cox–Ingersoll–Ross (CIR 1985); la **condición de Feller** $2\kappa\theta \geq \xi^2$ garantiza $v_t > 0$ para todo t casi seguramente.

El proceso de varianza (4) tiene exactamente la forma de reversión a la media ya estimada en la Sección 6.9 (con κ, θ interpretados igual: velocidad y nivel de largo plazo de la volatilidad), pero con dos diferencias clave respecto al OU empíricamente ajustado ahí: (i) la difusión

$\xi\sqrt{v_t}$ depende del nivel (tipo CIR, evita $v_t < 0$), y (ii) el ruido $W_t^{(2)}$ es **markoviano y de rugosidad estándar** ($H = 1/2$). El hallazgo empírico de la Sección 6.7 $-\hat{H}(\log\text{-vol}) \approx 0.009$ usando $|r_t|$ diario sin traslape, muy por debajo de $1/2$ — es evidencia *en contra* de que un proceso markoviano tipo Heston/CIR sea el generador correcto de la volatilidad, y a favor de un modelo genuinamente **no markoviano y rugoso**: se reemplaza $W_t^{(2)}$ en (4) por un movimiento browniano fraccionario $W_t^{H,(2)}$ con $H < 1/2$ (rough Bergomi/rough Heston, Gatheral–Jaisson–Rosenbaum 2018, ya citado en la Sección 6.7), cuyas trayectorias son más irregulares que el browniano estándar en proporción directa a qué tan por debajo de $1/2$ cae H . Esta subsección no reajusta un modelo rough Bergomi a los datos —requeriría precios de opciones, no solo la serie de precios spot disponible aquí— sino que da el marco formal preciso al que apunta el hallazgo empírico ya reportado.

Extensión multifactor. El Heston de un solo factor (4) tiene una única escala de tiempo de reversión $1/\kappa$. El espectro MFDFA (Secciones 6.5 y 10.1), con $H(q)$ no constante y $\Delta\alpha \in [0.076, 0.47]$ según el mercado, es exactamente la firma que predice un proceso de volatilidad con **múltiples** escalas de tiempo, no una sola: las fluctuaciones grandes (momentos q altos) y las pequeñas (momentos q negativos) escalan distinto porque están dominadas por factores de volatilidad con velocidades de reversión distintas. El modelo de Heston de dos factores (Christoffersen–Heston–Jacobs 2009) reemplaza (4) por

$$v_t = v_{1,t} + v_{2,t}, \quad dv_{i,t} = \kappa_i(\theta_i - v_{i,t}) dt + \xi_i\sqrt{v_{i,t}} dW_t^{(i+1)}, \quad i = 1, 2, \quad (5)$$

con $\kappa_1 \gg \kappa_2$: un factor **rápido** que revierte en días/semanas y uno **lento** que revierte en meses. Bajo esta lectura, la vida media OU de 48–104 días ya estimada empíricamente en la Sección 6.9 (que ajusta un único factor a la volatilidad realizada de ventana de 21 días, un proxy que ya suaviza la variación de muy corto plazo) es más consistente con estar capturando predominantemente el factor *lento* $1/\kappa_2$ de una estructura latente de dos factores, que con ser la única escala de tiempo genuina de la volatilidad. Esta subsección no reajusta (5) a los datos —requeriría una estimación de volatilidad multiescala explícita o datos de opciones, fuera del alcance de este artículo— sino que conecta formalmente dos resultados ya computados independientemente (MFDFA y OU) bajo un mismo modelo candidato.

2.2.3. Cambio de medida: el teorema de Girsanov y el primer teorema fundamental

Teorema 2.11 (Girsanov, 1960). Sea $(W_t)_{t \leq T}$ browniano bajo $\mathbb{P}$ y $(\theta_t)_{t \leq T}$ un proceso adaptado que satisface la condición de Novikov $\mathbb{E}^{\mathbb{P}}[\exp(\frac{1}{2} \int_0^T \theta_t^2 dt)] < \infty$. Definiendo

$$\frac{d\mathbb{Q}}{d\mathbb{P}} \Big|_{\mathcal{F}_T} = \exp\left(-\int_0^T \theta_t dW_t - \frac{1}{2} \int_0^T \theta_t^2 dt\right), \quad (6)$$

el proceso $\tilde{W}_t = W_t + \int_0^t \theta_s ds$ es un movimiento browniano estándar bajo la medida $\mathbb{Q}$ (equivalente a $\mathbb{P}$).

Proposición 2.12 (Precio descontado como $\mathbb{Q}$ -martingala). *En el GBM (2) con tasa libre de riesgo r , tomando $\theta_t = (\mu - r)/\sigma$ (precio de mercado del riesgo) en el Teorema 2.11, el proceso descontado $\tilde{S}_t = e^{-rt} S_t$ satisface $d\tilde{S}_t = \sigma \tilde{S}_t d\tilde{W}_t$ bajo $\mathbb{Q}$: es una martingala en el sentido exacto de la Definición 2.1, ahora en tiempo continuo.*

Teorema 2.13 (Primer teorema fundamental de la valoración de activos, Harrison–Pliska 1981). *Un modelo de mercado (en tiempo discreto o continuo, bajo condiciones técnicas estándar de integrabilidad) admite **ausencia de arbitraje** si y solo si existe una medida $\mathbb{Q}$ equivalente a $\mathbb{P}$ bajo la cual el proceso de precios descontado es una $\mathbb{Q}$ -martingala.*

El Teorema 2.13 le da a la HME débil (Definición de Fama 1970, Sección 2.1) su contraparte teórica en la valoración de activos sin arbitraje: la HME afirma, bajo la medida física $\mathbb{P}$ –la que genera los datos que este artículo analiza– que $\mathbb{E}^{\mathbb{P}}[r_t \mid \mathcal{F}_{t-1}] = \mu$ constante (impredecibilidad estadística dado el historial de precios); el TFTVA afirma que la ausencia de arbitraje es equivalente a la *existencia* de alguna medida $\mathbb{Q}$ bajo la cual el precio descontado es exactamente una martingala. Son afirmaciones distintas –una estadística bajo $\mathbb{P}$, otra de existencia bajo $\mathbb{Q}$ – pero la segunda es la razón estructural, dada por el Teorema 2.11, de por qué “los precios deberían comportarse como una martingala” es la hipótesis nula correcta a contrastar en las Secciones 6–8, y no una convención estadística ad hoc.

2.2.4. La ecuación de Black–Scholes y la fórmula de Feynman–Kac

El Teorema 2.11 da existencia de $\mathbb{Q}$; esta subsección cierra el ciclo mostrando cómo esa medida convierte el cálculo de un precio esperado en la solución de una ecuación diferencial **determinista** –el otro pilar clásico del cálculo estocástico en finanzas, junto al lema de Itô de la Sección 2.2.1.

Proposición 2.14 (Ecuación de Black–Scholes, 1973). *Sea $V(t, S)$ el precio de un derivado europeo sobre el GBM (2) con tasa libre de riesgo r . Formando la cartera autofinanciada $\Pi_t = V(t, S_t) - \Delta_t S_t$ con $\Delta_t = \partial_S V(t, S_t)$ (cobertura delta) y aplicando el lema de Itô (1) a $V(t, S_t)$, el término en dW_t se cancela exactamente y Π_t queda libre de riesgo; por el Teorema 2.13 (ausencia de arbitraje) debe rendir la tasa libre de riesgo, $d\Pi_t = r\Pi_t dt$, lo que fuerza*

$$\partial_t V + \frac{1}{2} \sigma^2 S^2 \partial_{SS} V + r S \partial_S V - r V = 0, \quad V(T, S) = \Phi(S), \quad (7)$$

con Φ el pago terminal del derivado (p. ej. $\Phi(S) = (S - K)^+$ para una call europea).

Teorema 2.15 (Fórmula de Feynman–Kac). *Si V resuelve (7), entonces*

$$V(t, S) = e^{-r(T-t)} \mathbb{E}^{\mathbb{Q}}[\Phi(S_T) \mid S_t = S], \quad (8)$$

donde bajo $\mathbb{Q}$ (Teorema 2.11) el precio sigue $dS_t = rS_t dt + \sigma S_t d\tilde{W}_t$.

La fórmula (8) es la identidad exacta que cierra el ciclo de esta sección: una SDE (Itô, Sección 2.2.1) induce, vía cambio de medida (Girsanov), una EDP determinista (7) cuya solución es, de vuelta, una esperanza bajo la nueva medida. Para el Heston multifactor (5), la misma lógica de cobertura delta produce una EDP análoga pero en tres variables de estado (S, v_1, v_2) en vez de una sola (S) , sin solución cerrada en general –la razón estructural, no una limitación técnica evitable, por la que Heston (1993) resuelve su modelo vía función característica (transformada de Fourier) en vez de integrar la EDP directamente, y por la que la extensión multifactor de Christoffersen–Heston–Jacobs (2009) hace lo mismo. Finalmente, obsérvese que (7) es la ecuación cuya solución reproduce el precio de un derivado *si* el subyacente fuera exactamente el GBM (2) –el mismo modelo cuya hipótesis de incrementos i.i.d. Normales rechazan, con datos reales, las Secciones 6.1, 7 y 6.6 en los 7 mercados de este artículo.

2.3. Ajuste Gamma por régimen de precios

Si la HME estricta se cumple, la distribución de los *precios* dentro de un régimen suficientemente corto debería aproximarse a Normal (o lognormal en niveles). La alternativa empírica que se contrasta aquí es el ajuste de una distribución **Gamma** –de dos parámetros, soporte positivo, capaz de capturar asimetría– a los precios de cada ciclo bursátil, comparada contra la Normal vía AIC y la prueba de bondad de ajuste de Kolmogorov–Smirnov (Sección 6).

2.4. Teoría de Matrices Aleatorias y la ley de Marchenko–Pastur

La aplicación de la Teoría de Matrices Aleatorias (RMT) a las finanzas fue pionera por Laloux et al. (1999) y Plerou et al. (2002). Dada una matriz de correlación empírica $\hat{C}$ construida a partir de p activos y T observaciones, se espera que parte del espectro de $\hat{C}$ sea indistinguible de ruido puro.

Teorema 2.16 (Marchenko–Pastur, 1967). *Sea $\mathbf{X}$ una matriz $p \times T$ con entradas i.i.d. de media 0 y varianza σ^2 , con $q = p/T$ fijo cuando $p, T \rightarrow \infty$. Los eigenvalores de $\frac{1}{T}\mathbf{X}\mathbf{X}^\top$ convergen débilmente a la medida de Marchenko–Pastur con densidad*

$$\rho_{\text{MP}}(\lambda) = \frac{\sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}}{2\pi\sigma^2q\lambda}, \quad \lambda \in [\lambda_-, \lambda_+], \quad (9)$$

con bordes $\lambda_{\pm} = \sigma^2(1 \pm \sqrt{q})^2$.

Esquema. Se resuelve la ecuación funcional de la transformada de Stieltjes $G(z) = [z - \sigma^2(1 - q + qzG(z))]^{-1}$; véase Marchenko y Pastur (1967) y Bai y Silverstein (2010, Thm. 3.10). $\square$

Observación 2.17. Todo eigenvalor de $\hat{C}$ dentro de $[\lambda_-, \lambda_+]$ es estadísticamente indistinguible del ruido; los que superan λ_+ contienen información genuína de estructura de correlación

(factores comunes).

Teorema 2.18 (Transición BBP, Baik–Ben Arous–Péché 2005). *Bajo un modelo de picos $\Sigma = \mathbf{I}_p + (\ell - 1)\mathbf{u}\mathbf{u}^\top$ ($\ell > 1$ pico poblacional, $\mathbf{u}$ dirección del factor) con $p/T \rightarrow q$, el mayor eigenvalor muestral $\hat{\lambda}$ y su eigenvector $\hat{\mathbf{v}}$ satisfacen, c.s. cuando $\ell > 1 + \sqrt{q}$ (régimen supercrítico):*

$$\hat{\lambda} \rightarrow \varphi(\ell) := \ell + \frac{q\ell}{\ell - 1} > \lambda_+, \quad |\langle \hat{\mathbf{v}}, \mathbf{u} \rangle|^2 \rightarrow \frac{1 - q/(\ell - 1)^2}{1 + q/(\ell - 1)} > 0. \quad (10)$$

Si $1 < \ell \leq 1 + \sqrt{q}$ (subcrítico), $\hat{\lambda} \rightarrow \lambda_+$ y $|\langle \hat{\mathbf{v}}, \mathbf{u} \rangle|^2 \rightarrow 0$: el eigenvector muestral es asintóticamente ortogonal al factor poblacional verdadero.

Esquema. Se escribe la ecuación secular $\mathbf{u}^\top G_0(z)\mathbf{u} = -\ell/(z(\ell - 1))$ para el resolvente de la matriz de Wishart pura G_0 , se sustituye por su límite determinístico (transformada de Stieltjes de Marchenko–Pastur, delocalización de eigenvectores de Wishart) y se resuelve el cruce con la frontera λ_+ . Los detalles completos se encuentran en Baik, Ben Arous y Péché (2005) y Paul (2007, Teo. 1); véase también Bai y Silverstein (2010, Cap. 11). La fórmula del overlap se verifica de forma no circular por Monte Carlo en la Sección 7.1. $\square$

El filtrado estándar reemplaza los eigenvalores dentro de $[\lambda_-, \lambda_+]$ por su media, produciendo la matriz limpia $\hat{\mathbf{C}}_{\text{clean}} = \sum_{\lambda_i > \lambda_+} \lambda_i \mathbf{v}_i \mathbf{v}_i^\top + \bar{\lambda}_{\text{noise}} \sum_{\lambda_i \leq \lambda_+} \mathbf{v}_i \mathbf{v}_i^\top$.

2.4.1. El Estimador Rotacionalmente Invariante (RIE) de Potters–Bouchaud

El filtrado anterior es el método más simple posible: reemplaza el *ruido* pero deja los eigenvalores de *señal* intactos. Laloux, Cizeau, Bouchaud y Potters (1999) y, en su forma madura, Bun, Bouchaud y Potters (2017, *Physics Reports*) y Potters y Bouchaud (2020, Cap. 15) argumentan que incluso los eigenvalores de señal deben **encogerse**: el eigenvector muestral $\hat{\mathbf{v}}_k$ nunca coincide exactamente con la dirección poblacional verdadera $\mathbf{u}_k$, y usar λ_k sin ajustar sobreestima cuánto se puede confiar en esa dirección estimada.

Definición 2.19 (Estimador Rotacionalmente Invariante, Ledoit–Péché 2011). Entre todos los estimadores de la forma $\hat{\Sigma}_{\text{RIE}} = \sum_k \tilde{\zeta}_k \hat{\mathbf{v}}_k \hat{\mathbf{v}}_k^\top$ (misma base de eigenvectores muestral, eigenvalores $\tilde{\zeta}_k$ libres), el óptimo en norma de Frobenius esperada es

$$\tilde{\zeta}_k^{\text{oracle}} = \hat{\mathbf{v}}_k^\top \Sigma_{\text{true}} \hat{\mathbf{v}}_k. \quad (11)$$

Observación 2.20 (Fórmula práctica vía el overlap de BBP). Para un eigenvalor de señal, el oracle (11) tiene una forma cerrada expresable directamente en términos del overlap del Teorema 2.18: si ℓ_k es el pico poblacional recuperado invirtiendo φ (como en la Sección 7.1) y $|\langle \hat{\mathbf{v}}_k, \mathbf{u}_k \rangle|^2$ su overlap asociado,

$$\tilde{\zeta}_k \approx \lambda_k |\langle \hat{\mathbf{v}}_k, \mathbf{u}_k \rangle|^2 + \bar{\lambda}_{\text{noise}} (1 - |\langle \hat{\mathbf{v}}_k, \mathbf{u}_k \rangle|^2) : \quad (12)$$

un promedio ponderado entre el eigenvalor observado y el nivel de ruido, según qué tan fiable es la dirección estimada. Cuando el overlap $\rightarrow 1$ (factor muy por encima del umbral BBP), $\xi_k \rightarrow \lambda_k$ (sin encogimiento); cuando el overlap $\rightarrow 0$ (factor cerca del umbral), $\xi_k \rightarrow \bar{\lambda}_{\text{noise}}$ (se descarta como si fuera ruido). Los eigenvalores de ruido se tratan como en el filtrado estándar. Esta es precisamente la lógica de limpieza no lineal de Bun–Bouchaud–Potters (2017), expresada aquí con la misma cantidad –el overlap BBP– que ya se verificó de forma no circular en la Sección 7.1, en vez de introducir maquinaria adicional.

2.4.2. Movimiento browniano de Dyson y estadística de niveles

La ley de Marchenko–Pastur describe el comportamiento *macroscópico* del espectro (la forma de la densidad límite); la teoría de Dyson (1962) describe el comportamiento *microscópico*: cómo interactúan los eigenvalores individuales entre sí.

Teorema 2.21 (Movimiento browniano de Dyson, 1962). *Si las entradas de una matriz simétrica $p \times p$ evolucionan como movimientos brownianos independientes, los eigenvalores $\lambda_1(t) \geq \dots \geq \lambda_p(t)$ resultantes satisfacen el sistema de ecuaciones diferenciales estocásticas acopladas*

$$d\lambda_i = dW_i + \sum_{j \neq i} \frac{1}{\lambda_i - \lambda_j} dt, \quad i = 1, \dots, p, \quad (13)$$

con (W_i) movimientos brownianos independientes. El término de deriva es **repulsivo**: empuja a λ_i lejos de sus vecinos, como cargas eléctricas del mismo signo en un gas de Coulomb unidimensional confinado.

Observación 2.22. La consecuencia estática (estacionaria) de (13) para el ensemble gaussiano ortogonal (GOE) es el **surmise de Wigner**: la densidad de espaciamientos **normalizados** entre eigenvalores consecutivos (tras “desdoblar” el espectro a densidad local unitaria) es $P(s) = \frac{\pi s}{2} e^{-\pi s^2/4}$, con $P(0) = 0$ (repulsión de niveles: espaciamientos cercanos a cero son improbables) –en marcado contraste con eigenvalores independientes, que tendrían espaciamientos Poisson, $P(s) = e^{-s}$, con $P(0) = 1$ (aglomeración, no repulsión).

2.4.3. El criterio del cuarto momento (Nualart–Peccati)

Para juzgar si una estadística espectral *lineal* –por ejemplo, $N_+(t)$, el número de eigenvalores por encima de λ_+ en una ventana rodante, o $\lambda_1(t)$ mismo– se aproxima a una Normal cuando el tamaño de la matriz crece, el método de Malliavin–Stein ofrece un atajo drástico.

Teorema 2.23 (Teorema del cuarto momento, Nualart–Peccati 2005). *Sea (F_n) una sucesión de elementos de un caos de Wiener fijo de orden $q \geq 2$, normalizados a $\mathbb{E}[F_n^2] = 1$. Entonces $F_n \xrightarrow{d} N(0, 1)$ si y solo si $\mathbb{E}[F_n^4] \rightarrow 3$ (i.e., el exceso de curtosis converge a 0).*

Observación 2.24. La sorpresa del teorema es que **no hace falta verificar toda la sucesión de momentos** –como exigiría el método de momentos clásico– basta el cuarto. Bai y Yao (2005)

y Najim y Yao (2016) aplican esta maquinaria (estadísticas espectrales lineales de matrices aleatorias grandes viven en un caos de orden fijo) para obtener teoremas centrales del límite para funcionales del espectro de matrices de Wishart, exactamente la clase de estadísticas $(N_+(t), \lambda_1(t))$ que se examinan en la Sección 6.3.3.

2.5. Volatilidad realizada: Ornstein–Uhlenbeck

Definición 2.25 (Ornstein–Uhlenbeck, Uhlenbeck–Ornstein 1930).

$$d\sigma_t = \kappa(\theta - \sigma_t) dt + \sigma_{\text{vol}} dW_t, \quad (14)$$

con $\kappa > 0$ (velocidad de reversión), θ (nivel de largo plazo) y $\sigma_{\text{vol}} > 0$ (volatilidad del proceso).

Proposición 2.26 (MLE exacta vía discretización de Vasicek, 1977). *Bajo la discretización exacta del OU, $\sigma_{t+\Delta} \mid \sigma_t \sim N(\theta + (\sigma_t - \theta)e^{-\kappa\Delta}, \sigma_{\text{vol}}^2 \frac{1-e^{-2\kappa\Delta}}{2\kappa})$, por lo que $(\kappa, \theta, \sigma_{\text{vol}})$ se recuperan en forma cerrada de la regresión lineal $\sigma_{t+\Delta} = a + b\sigma_t + \epsilon_t$, con $b = e^{-\kappa\Delta}$.*

El parámetro interpretable directamente es la **vida media** de reversión $\tau_{1/2} = \ln 2 / \kappa$: el número de días en que un shock de volatilidad se disipa a la mitad. El OU se ajusta aquí a la **volatilidad realizada** (no a los rendimientos), como complemento al GJR-GARCH: el GARCH modela la varianza *condicional* día a día; el OU modela la reversión a la media de la volatilidad *realizada* como proceso continuo, dando una vida media directamente interpretable.

2.6. Modelos GARCH y GJR-GARCH

Definición 2.27 (GARCH(1,1), Bollerslev 1986). $r_t = \mu + \varepsilon_t$, $\varepsilon_t = \sqrt{h_t} z_t$, $z_t \stackrel{\text{iid}}{\sim} (0,1)$, con $h_t = \omega + \alpha\varepsilon_{t-1}^2 + \beta h_{t-1}$, $\omega > 0$, $\alpha, \beta \geq 0$, $\alpha + \beta < 1$.

Definición 2.28 (GJR-GARCH(1,1), Glosten–Jagannathan–Runkle 1993).

$$h_t = \omega + (\alpha + \gamma \mathbf{1}_{\varepsilon_{t-1} < 0}) \varepsilon_{t-1}^2 + \beta h_{t-1}, \quad (15)$$

donde $\gamma \geq 0$ captura el exceso de impacto de noticias negativas (*efecto apalancamiento*).

Proposición 2.29. *El GJR-GARCH(1,1) es estacionario en covarianza sii $\alpha + \frac{1}{2}\gamma + \beta < 1$.*

Demostración. Tomando esperanza incondicional en (15) con $\mathbb{E}[\mathbf{1}_{\varepsilon_{t-1} < 0}] = \frac{1}{2}$ por simetría de z_t : $\sigma^2 = \omega + (\alpha + \gamma/2 + \beta)\sigma^2$. $\square$

La **curva de impacto de noticias** (NIC, Engle–Ng 1993) es $\text{NIC}(\varepsilon) = \omega + \alpha\varepsilon^2 + \beta\sigma^2$ si $\varepsilon \geq 0$, y $\omega + (\alpha + \gamma)\varepsilon^2 + \beta\sigma^2$ si $\varepsilon < 0$: simétrica en el GARCH estándar, asimétrica en el GJR-GARCH cuando $\gamma > 0$.

2.7. Teoría del Valor Extremo (EVT)

Definición 2.30 (Distribución de Pareto Generalizada, GPD).

$$G_{\xi, \beta}(x) = \begin{cases} 1 - (1 + \xi x / \beta)^{-1/\xi}, & \xi \neq 0, \\ 1 - e^{-x/\beta}, & \xi = 0, \end{cases} \quad x \geq 0. \quad (16)$$

Teorema 2.31 (Pickands–Balkema–de Haan, 1974/1975). *Para una amplia clase de distribuciones (dominio de atracción de valores extremos), existe $\beta(u) > 0$ tal que $\lim_{u \rightarrow x_F} \sup_{0 \leq x < x_F - u} |F_u(x) - G_{\xi, \beta(u)}(x)| = 0$, donde $F_u(x) = P(X - u \leq x \mid X > u)$ es la distribución de excedencias sobre el umbral u .*

El teorema justifica el método *Peaks-Over-Threshold* (POT): fijar un umbral alto u , ajustar GPD a las excedencias por máxima verosimilitud, y usar la GPD ajustada para extrapolar cuantiles extremos (VaR) más allá de los datos observados. $\xi > 0$ implica colas tipo Pareto con índice de cola $\alpha = 1/\xi$.

2.8. Teoría de Lamperti, autosimilitud y el exponente de Hurst

Definición 2.32 (Proceso H -autosimilar). $(X_t)_{t \geq 0}$ es H -autosimilar si $(X_{at})_{t \geq 0} \stackrel{d}{=} (a^H X_t)_{t \geq 0}$ para todo $a > 0$. El movimiento browniano estándar es $\frac{1}{2}$ -autosimilar; el movimiento browniano fraccional B^H generaliza esto: persistencia si $H > \frac{1}{2}$, antipersistencia si $H < \frac{1}{2}$.

Teorema 2.33 (Lamperti, 1962). *Sea $(X_t)_{t \geq 0}$ un proceso H -autosimilar de Markov, con trayectorias càdlàg y $X_t > 0$ c.s. Entonces existe un único proceso de Lévy (ξ_s) tal que $X_t = e^{\xi_{\log t}}$, $t > 0$. Recíprocamente, todo proceso construido así a partir de un proceso de Lévy es H -autosimilar con $H = \mathbb{E}[\xi_1]$.*

Esquema. El cambio $\xi_s = \log X_{e^s}$ convierte autosimilitud en estacionariedad de incrementos; junto con la propiedad de Markov y trayectorias càdlàg, el teorema de Lévy–Itô caracteriza ξ como proceso de Lévy. Véase Kyprianou (2006, Cap. 13) y Bertoin (1996, Cap. III). *La hipótesis de Markov es esencial:* sin ella, el cambio de variable produce un proceso estacionario pero no necesariamente de incrementos independientes. $\square$

Observación 2.34. Interpretación financiera: $\log P_t = \xi_{\log t}$, i.e. el log-precio sigue un proceso de Lévy evaluado en tiempo logarítmico –generalización formal de Black–Scholes ($\xi_s = \sigma W_s + \mu s$) a procesos con saltos.

La conexión empírica con H se hace vía dos estimadores independientes:

Definición 2.35 (DFA). El **Análisis de Fluctuación sin Tendencia** calcula, para cada escala n , la fluctuación cuadrática media $F(n)$ de la caminata integrada tras remover tendencias locales por segmento. $F(n) \sim n^H$ identifica H como la pendiente de $\log F$ vs. $\log n$.

Definición 2.36 (R/S , Hurst 1951). Para ventanas de tamaño n , $R(n)/S(n)$ es el rango acumulado dividido entre la desviación estándar; $\mathbb{E}[R(n)/S(n)] \sim cn^H$.

Corolario 2.37. Si $\hat{H}$ difiere significativamente de $1/2$ (intervalo de confianza que excluye $1/2$), el proceso de Lévy subyacente ξ en la Representación de Lamperti no puede ser un movimiento browniano puro, y la HME débil en su forma gaussiana estricta queda rechazada para ese índice y método.

Ambos estimadores se aplican en la Sección 6.4, con un resultado que *no* es unánime entre métodos para el DJI.

2.9. Modelos concretos para el proceso de Lévy subyacente

El Teorema 2.33 garantiza *que* existe un proceso de Lévy ξ tal que $\log P_t = \xi_{\log t}$, pero no dice *cuál*. Tres familias paramétricas de incrementos de Lévy, todas con colas más pesadas que la Normal, se ajustan por máxima verosimilitud y se comparan por AIC en la Sección 6.6:

Definición 2.38 (Variance Gamma, Madan–Carr–Chang 1998). Proceso de Lévy puro salto obtenido al evaluar un movimiento browniano con deriva en un tiempo Gamma aleatorio: $X_t = \theta G_t + \sigma W_{G_t}$, con $G_t \sim \text{Gamma}(t/\nu, \nu)$. Densidad de incrementos en forma cerrada vía la función de Bessel modificada K_λ .

Definición 2.39 (Normal Inverse Gaussian, Barndorff-Nielsen 1997). Análogo con tiempo subordinado Inverso-Gaussiano en lugar de Gamma; parámetros $(\alpha, \beta, \mu, \delta)$ con $\alpha > |\beta|$ controlando forma, asimetría, ubicación y escala.

Definición 2.40 (Merton jump-diffusion, 1976). Movimiento browniano más un proceso compuesto de Poisson de saltos normales: $X_t = \sigma W_t + \sum_{i=1}^{N_t} J_i$, $N_t \sim \text{Poisson}(\lambda t)$, $J_i \stackrel{\text{iid}}{\sim} N(\mu_J, \sigma_J^2)$. Densidad de incrementos: mezcla de Poisson de normales.

2.10. Multifractalidad: MFDFA

Definición 2.41 (MFDFA, Kantelhardt et al. 2002). Generaliza el DFA calculando, para cada orden q , la fluctuación generalizada $F_q(n) = (\frac{1}{2N_s} \sum_v [F^2(v, n)]^{q/2})^{1/q}$ sobre los segmentos de tamaño n (con el caso $q = 0$ definido por continuidad como el promedio logarítmico). $F_q(n) \sim n^{H(q)}$ define el **exponente de Hurst generalizado** $H(q)$.

Observación 2.42. Un proceso **monofractal** (incluido el fBm) tiene $H(q) = H$ constante para todo q : el mismo exponente gobierna fluctuaciones grandes y pequeñas. Un proceso **multifractal** –la propuesta original de Mandelbrot (1963, 1975) para los mercados financieros– tiene $H(q)$ decreciente en q : las fluctuaciones grandes ($q > 0$, dominadas por eventos extremos) escalan con un exponente distinto de las pequeñas ($q < 0$). El ancho del espectro de singularidad $\Delta\alpha = \alpha_{\text{máx}} - \alpha_{\text{mín}}$, con $\alpha = H(q) + qH'(q)$, cuantifica el grado de multifractalidad: $\Delta\alpha = 0$ es monofractal.

3. Revisión de la literatura

Fama (1970, 1991) formaliza la HME. Mandelbrot (1963) documenta colas pesadas e intermitencia en series financieras, precursor de las finanzas fractales; Shiller (2000, 2003) documenta exceso de volatilidad y burbujas. Engle (1982) y Glosten, Jagannathan y Runkle (1993) introducen ARCH/GARCH y la asimetría de volatilidad. Laloux et al. (1999) y Plerou et al. (2002) aplican RMT a matrices de correlación bursátil. Para México: Mata (2008) discute técnicas fractales en el mercado accionario mexicano; Aguilar (2014) estima el coeficiente de Hurst y parámetros α -estables para el mercado cambiario; Lizarazu estudia el Hurst del IPC; Morales et al. (2022) documentan dependencia temporal en el S&P/BMV IPC. Este trabajo se distingue de esa literatura en un punto metodológico: todas las cifras –Hurst, GARCH, RMT, EVT– se recalculan sobre datos propios en vez de citarse de estudios previos, permitiendo comparación directa y consistente entre el IPC y el DJI bajo idéntica metodología.

4. Hipótesis de investigación

Hipótesis nula (H_0). Los rendimientos del IPC y del DJI son compatibles con la HME débil en su versión gaussiana estricta: no presentan colas más pesadas que la Normal, el exponente de Hurst no difiere de $1/2$, y el VaR gaussiano no es rechazado por el test de Kupiec.

Hipótesis alternativa (H_1). Al menos uno de los tres elementos anteriores falla en al menos uno de los dos índices, lo que constituye evidencia de recursividad/estructura no explicada por la HME estricta.

5. Datos y metodología

Los precios de cierre diarios del IPC ($\hat{MXX}$) y del DJI ($\hat{DJI}$) se obtuvieron de Yahoo Finance: IPC del 1991-11-11 al 2025-10-03 ($n = 8,490$ rendimientos log), DJI del 1992-01-03 al 2025-10-03 ($n = 8,499$). Los rendimientos log son $r_t = \log P_t - \log P_{t-1}$. Los componentes del IPC (20 tickers descargados, 17 con cobertura completa tras excluir FEMSA.MX, AMXL.MX y SITESB-1.MX, sin cotizaciones en la ventana) y del DJI (30 tickers, 28 con cobertura completa tras excluir WBA –sin datos– y DOW –listada solo a partir de 2019–) se usan para el análisis RMT (Sección 6.3).

Los ocho ciclos bursátiles (Tabla 1) se definen por fechas de episodios macrofinancieros documentados en la literatura y prensa financiera (crisis Tequila, burbuja *dot-com*, crisis hipotecaria de 2008, COVID-19), *no* se derivan algorítmicamente de picos/valles de la propia serie –evita sesgo de mirar-hacia-adelante en la definición de régimen.

Cuadro 1: Ciclos bursátiles usados en el análisis, con estadísticas básicas de rendimientos.

Ciclo	Ventana	Índice	n	Media	Desv. est.
Crisis Tequila	1994-11 – 1995-06	IPC	163	−0.00092	0.0261
		DJI	168	0.00091	0.0061
Boom pre dot-com	1996-01 – 1999-12	IPC	1,003	0.00094	0.0183
		DJI	1,011	0.00080	0.0107
Burbuja dot-com	2000-01 – 2002-12	IPC	749	−0.00020	0.0173
		DJI	752	−0.00043	0.0143
Expansión 2003–07	2003-01 – 2007-06	IPC	1,136	0.00143	0.0111
		DJI	1,131	0.00042	0.0076
Crisis hipotecaria	2007-07 – 2009-06	IPC	501	−0.00049	0.0207
		DJI	504	−0.00092	0.0202
Expansión post-GFC	2009-07 – 2019-12	IPC	2,630	0.00022	0.0092
		DJI	2,644	0.00046	0.0089
COVID-19	2020-01 – 2020-12	IPC	252	0.00005	0.0157
		DJI	253	0.00028	0.0233
Post-COVID	2021-01 – 2025-10	IPC	1,198	0.00029	0.0096
		DJI	1,194	0.00036	0.0094

6. Resultados

6.1. Estadística descriptiva

Cuadro 2: Estadística descriptiva de los rendimientos log diarios, muestra completa.

Índice	n	Media	Desv. est.	Asimetría	Curtosis exc.	Rango
IPC (1991–2025)	8,490	4.45×10^{-4}	0.01390	−0.013	6.80	[−0.143, 0.122]
DJI (1992–2025)	8,499	3.17×10^{-4}	0.01100	−0.385	13.00	[−0.138, 0.108]

Ambos índices exhiben curtosis en exceso muy superior a 0 (Normal): el DJI casi el doble que el IPC, y con asimetría negativa marcada (−0.385, más caídas extremas que subidas extremas), rasgo mucho más débil en el IPC (−0.013). Ambos rasgos son incompatibles con la versión gaussiana de la HME.

6.2. Ajuste Gamma por ciclo bursátil

Cuadro 3: Ajuste Gamma vs. Normal por ciclo (precios en nivel). “Gamma mejor” indica $AIC_{\Gamma} < AIC_N$.

Ciclo	Índice	n	KS- p (Γ)	KS- p (Normal)	Gamma mejor
Crisis Tequila (1994–95)	IPC	163	0.064	0.017	Sí
	DJI	168	0.004	0.004	Sí
Boom pre dot-com (1996–99)	IPC	1,003	< 0.001	< 0.001	Sí
	DJI	1,011	< 0.001	< 0.001	Sí
Burbuja dot-com (2000–02)	IPC	749	0.017	0.009	Sí
	DJI	752	< 0.001	< 0.001	No
Expansión 2003–07	IPC	1,136	< 0.001	< 0.001	Sí
	DJI	1,131	< 0.001	< 0.001	No
Crisis hipotecaria (2007–09)	IPC	501	< 0.001	< 0.001	No
	DJI	504	< 0.001	< 0.001	No
Expansión post-GFC (2009–19)	IPC	2,630	< 0.001	< 0.001	No
	DJI	2,644	< 0.001	< 0.001	Sí
COVID-19 (2020)	IPC	252	< 0.001	< 0.001	Sí
	DJI	253	0.004	0.010	No
Post-COVID (2021–25)	IPC	1,198	0.012	0.050	No
	DJI	1,194	< 0.001	< 0.001	Sí

El resultado es más matizado de lo que una narrativa limpia sugeriría: la Gamma mejora sobre la Normal por AIC en 9 de 16 casos, pero *ninguna* de las dos pasa la prueba KS con $p > 0.05$ en la mayoría de ciclos con n grande –consecuencia esperada de que KS es muy sensible con miles de observaciones, no evidencia de que ambas distribuciones sean “buenas”. La lectura honesta es que *ni* la Gamma *ni* la Normal describen completamente la distribución de precios dentro de un ciclo; la Gamma es consistentemente una mejor aproximación relativa (menor AIC) en los ciclos cortos y volátiles (Tequila, dot-com, COVID), no en las expansiones largas.

6.3. Teoría de Matrices Aleatorias

Cuadro 4: RMT estática: correlación entre componentes, muestra completa disponible.

Índice	p	T	$q = p/T$	λ_+	$\lambda_1, \dots, \lambda_5$	Factores gen.
IPC	17	4,364	0.0039	1.129	4.89, 1.29, 1.02, 0.97, 0.89	2
DJI	28	3,832	0.0073	1.178	12.27, 1.75, 1.33, 0.92, 0.83	3

En ambos mercados, solo 2–3 de los eigenvalores muestrales superan el umbral de ruido λ_+ : la gran mayoría de la varianza de correlación es indistinguible de ruido puro, y 63.7 %

(IPC) / 45.2 % (DJI) de la traza total del espectro cae dentro de la banda de ruido $[\lambda_-, \lambda_+]$. El primer eigenvalor –factor de mercado– es muy superior en el DJI (12.27) que en el IPC (4.89), consistente con una integración más fuerte entre las grandes tecnológicas/financieras estadounidenses que entre los componentes disponibles del IPC.

La RMT dinámica sobre el DJI (ventana rodante de 250 días, paso de 21 días, $p = 28$, $q = 0.112$, $\lambda_+^{\text{din}} = 1.781$) muestra que λ_1 **nunca** cae por debajo de λ_+^{din} en ninguna ventana de la muestra: el factor de mercado es siempre genuino, no solo durante crisis. Lo que sí varía fuertemente es su *magnitud*: percentil 10 = 6.69, mediana = 11.49, máximo = 18.55 el 2020-04-06 (pico de la caída por COVID-19), es decir, $2.8\times$ la mediana –el contagio se manifiesta como intensificación del factor único existente, no como su aparición repentina.

6.3.1. RIE: portafolios de mínima varianza dentro y fuera de muestra

Se construyen tres matrices de correlación limpias –muestral cruda, MP-clipped, y RIE vía la fórmula (12)– sobre el 80 % inicial de cada muestra de componentes, se calcula el portafolio de mínima varianza global (GMV, $\mathbf{w} = \Sigma^{-1}\mathbf{1}/(\mathbf{1}^\top \Sigma^{-1}\mathbf{1})$) para cada una, y se evalúa la varianza **realizada fuera de muestra** en el 20 % restante con esos pesos fijos –exactamente el ejercicio con el que Bouchaud, Potters y coautores demuestran empíricamente el valor de la limpieza RMT.

Cuadro 5: Portafolios GMV: varianza anualizada dentro/fuera de muestra, 3 matrices de limpieza.

Índice (p, q)	Método	Var. dentro	Var. fuera	Razón (infl.)
IPC ($p=17, q=0.0049$)	Muestral	0.02146	0.02240	1.044
	MP-clipped	0.02042	0.02229	1.092
	RIE	0.02050	0.02227	1.086
DJI ($p=28, q=0.0091$)	Muestral	0.01631	0.01695	1.039
	MP-clipped	0.01600	0.01845	1.153
	RIE	0.01595	0.01853	1.162

El resultado es **contrario a la expectativa textbook**, y se reporta así sin suavizarlo: en ambos mercados, la matriz limpia (MP-clipped o RIE) reduce la varianza *dentro* de muestra –como debe, por construcción, al regularizar la matriz– pero **no** reduce, e incluso empeora ligeramente, la varianza *fuera* de muestra frente al portafolio construido con la matriz cruda. La razón más plausible es el **régimen de q** : los estudios clásicos de Bouchaud, Potters y coautores (Laloux et al. 1999; Bun et al. 2017) limpian universos de $p \sim 100\text{--}500$ acciones con $q = p/T \sim 0.1\text{--}0.5$, donde hay sustancial ruido genuino que remover. Aquí, con solo $p = 17\text{--}28$ activos y varios miles de días de historia, q es *muchísimo* más pequeño (0.005–0.009): la matriz de correlación muestral ya es, en este régimen, un estimador razonablemente preciso de la verdadera, y encoger sus eigenvalores casi-de-ruido hacia la media del bulk –que en este régimen de q pequeño contienen algo más que ruido puro– introduce más sesgo de

especificación del que reduce varianza de estimación. Esto no contradice la literatura de Potters–Bouchaud: la *acota*, mostrando empíricamente que el beneficio de la limpieza RMT escala con q y puede revertirse en el régimen de pocos activos y mucha historia típico de índices (en vez de universos amplios de acciones individuales).




Figura 1: Razón de inflación de riesgo (varianza fuera/dentro de muestra) del portafolio GMV, 3 métodos de limpieza, IPC y DJI.

6.3.2. Estadística de niveles: Dyson y el surmise de Wigner

Se prueba el Teorema 2.21 sobre el espectro *completo* (no solo λ_1) de las matrices de correlación de componentes, desdoblado a densidad local unitaria.

Cuadro 6: Espaciamientos de eigenvalores desdoblados: KS vs. Wigner (GOE) y vs. Poisson.

Índice	p (espaciamientos)	KS-Wigner (p -valor)	KS-Poisson (p -valor)
IPC	16	0.221 (0.361)	0.416 (0.005)
DJI	26	0.150 (0.556)	0.260 (0.049)

Con solo 16 y 26 espaciamientos, la potencia estadística es baja –esto **no** es una confirmación fuerte de universalidad GOE– pero la dirección es la correcta y consistente en ambos índices: no se rechaza Wigner ($p = 0.36$, $p = 0.56$) y sí se rechaza Poisson ($p = 0.005$, $p = 0.049$), es decir, hay evidencia (moderada, no concluyente dado el tamaño muestral) de **repulsión de niveles** entre los eigenvalores de la matriz de correlación, cualitativamente consistente con la predicción de Dyson.




Figura 2: Histograma de espaciamientos desdoblados vs. surmise de Wigner (GOE) y densidad Poisson.

Como verificación adicional del componente *difusivo* de la SDE (13), se calcula cómo escala la varianza de los incrementos de $\lambda_1(t)$ (RMT dinámica del DJI, ventana rodante) al agregarlos en bloques de distinto tamaño: una difusión pura daría una pendiente log-log de 1. Se obtiene una pendiente de **1.285** –moderadamente por encima de 1–, indicando que $\lambda_1(t)$ tiene, además de una componente localmente difusiva compatible con Dyson, una persistencia adicional que la SDE de Dyson pura –sin términos exógenos– no captura: los saltos de régimen impulsados por crisis (COVID, GFC) son choques exógenos ausentes del modelo de Dyson, que describe la dinámica *local* del espectro, no los cambios de régimen macroeconómico.

6.3.3. Normalidad asintótica: el criterio del cuarto momento

Aplicando el Teorema 2.23 a $N_+(t)$ y $\lambda_1(t)$ de la RMT dinámica del DJI ($n = 171$ ventanas):

Cuadro 7: Criterio del cuarto momento (Nualart–Peccati) para estadísticas espectrales lineales.

Estadística	Curtosis exceso	IC95 % (bootstrap)	Shapiro p	Jarque–Bera p	¿Compatible
$N_+(t)$ (entero, discreto)	−1.171	[−1.377, −0.878]	< 0.0001	0.0042	No
$\lambda_1(t)$ (continuo)	−0.371	[−0.723, 0.079]	0.0004	0.2680	Sí

$N_+(t)$ –una variable entera con soporte pequeño (0–3)– falla claramente el criterio: su IC95 % de curtosis en exceso no contiene 0, y tanto Shapiro–Wilk como Jarque–Bera rechazan normalidad con contundencia. Es un resultado esperado: una variable discreta con pocos valores posibles no puede aproximarse bien a una Normal continua, independientemente de cualquier teorema del caos de Wiener. $\lambda_1(t)$, en cambio, *sí* es compatible con el criterio del cuarto momento –su IC95 % de curtosis en exceso incluye 0, y Jarque–Bera (que evalúa exac-

tamente asimetría y curtosis, el criterio relevante del Teorema 2.23) no rechaza normalidad ($p = 0.268$)—, aunque Shapiro–Wilk (un test omnibus más general) sí la rechaza ($p = 0.0004$). Esta tensión entre dos tests de normalidad no es una contradicción: mide cosas ligeramente distintas, y se reporta así —sin resolverla artificialmente— porque es exactamente lo que los datos muestran.




Figura 3: Histogramas de $N_+(t)$ y $\lambda_1(t)$ (RMT dinámica DJI) vs. densidad Normal ajustada.

6.4. Exponente de Hurst: DFA vs. R/S

Cuadro 8: Exponente de Hurst, dos estimadores independientes, IC 95 % por bloque-bootstrap ($n_{\text{boot}} = 200$, bloques de 250 días).

Índice	$\hat{H}_{\text{DFA}}$	IC95 %	$\hat{H}_{R/S}$	IC95 %	¿Excluye 1/2?
IPC	0.5036	[0.458, 0.512]	0.5460	[0.533, 0.577]	Solo R/S
DJI	0.4616	[0.414, 0.476]	0.5236	[0.508, 0.545]	Ambos (en direcciones opuestas de 1/2)

Este es el resultado empírico menos limpio —y más honesto— del artículo: los dos métodos *no* concuerdan para el DJI. El DFA —más robusto ante no estacionariedad y tendencias locales— estima **antipersistencia significativa** ($\hat{H} = 0.462 < 0.5$, IC excluye 0.5), mientras que R/S —conocido en la literatura por sesgarse al alza ante heterocedasticidad de corto plazo (Lo, 1991)— estima persistencia leve ($\hat{H} = 0.524 > 0.5$). Para el IPC, el DFA es esencialmente indistinguible de 1/2 (IC [0.458, 0.512] contiene 0.5), mientras que R/S vuelve a sugerir persistencia leve. La lectura más defendible, dado que el DFA es el estimador más robusto de los dos, es que **no hay evidencia sólida de memoria de largo plazo clásica (fBm) en ninguno de los dos índices**; la señal de persistencia de R/S es probablemente un artefacto de la heterocedasticidad condicional documentada en la Sección 6.8 (GARCH y R/S interactúan: Lo 1991), no evidencia independiente de fractalidad.




Figura 4: DFA y R/S (escala log-log) para IPC y DJI, con la pendiente estimada $\hat{H}$ indicada en la leyenda.

6.5. Multifractalidad: MFDFA

Cuadro 9: Espectro multifractal MFDFA: exponente de Hurst generalizado $H(q)$.

Índice	$H(q=-5)$	$H(q=2)$	$H(q=5)$	ΔH	$\Delta \alpha$
IPC	0.5610	0.4993	0.4484	0.1126	0.2538
DJI	0.5366	0.4557	0.3963	0.1403	0.2756

Ambos índices son claramente **multifractales**: $H(q)$ decrece de forma monótona con q en vez de permanecer constante (lo que descartaría un fBm monofractal simple como modelo completo), con $\Delta \alpha \approx 0.25\text{--}0.28$ –amplitud comparable a la reportada en la literatura para índices bursátiles desarrollados. Es notable que $H(q=2)$ del MFDFA (0.4993 IPC, 0.4557 DJI) coincide de cerca con el $\hat{H}_{\text{DFA}}$ estándar de la Tabla 8 (0.5036, 0.4616) –el DFA convencional es, en efecto, el caso particular $q = 2$ del MFDFA, y esta coincidencia numérica independiente sirve como verificación cruzada de ambas implementaciones. El DJI es más multifractal que el IPC ($\Delta \alpha$ y ΔH mayores), es decir, las fluctuaciones grandes y pequeñas del DJI escalan de forma más distinta entre sí que en el IPC –compatible con su mayor curtosis (Tabla 2) y su cola EVT más pesada (Tabla 14).




Figura 5: Izquierda: espectro de Hurst generalizado $H(q)$ (la pendiente no nula confirma multifractalidad). Derecha: espectro de singularidad $f(\alpha)$.

6.6. Procesos de Lévy: ajuste paramétrico

Cuadro 10: Comparación AIC de modelos de Lévy para los incrementos ξ_1 de la Representación de Lamperti (Teorema 2.33).

Índice	Normal	NIG	VG	Merton	Mejor
IPC	-48,512.8	-50,153.1	-49,533.9	-50,096.3	NIG
DJI	-52,535.0	-54,977.5	-55,497.7	-54,748.9	VG

Los tres modelos de Lévy superan ampliamente a la Normal por AIC en ambos índices –consistente con el rechazo del VaR gaussiano de la Tabla 15– pero el *ganador* difiere entre mercados: NIG para el IPC, VG para el DJI (aunque Merton queda muy cerca en ambos casos). Esto es evidencia concreta, no solo cualitativa, de que el proceso ξ de la Representación de Lamperti (Sección 2.8) no es un movimiento browniano: ambos ganadores son procesos de variación infinita (infinitos saltos pequeños en cualquier intervalo), por lo que el Corolario 2.37 aplica directamente con $\xi = \text{NIG/VG}$ en vez de permanecer como una posibilidad abstracta.




Figura 6: Histograma empírico (escala log) vs. densidades ajustadas Normal, NIG y VG: ambos modelos de Lévy siguen la masa de las colas mucho mejor que la Normal.

6.7. Volatilidad rugosa

En el espíritu de Gatheral, Jaisson y Rosenbaum (2018, “Volatility is Rough”), se estima el exponente de Hurst de la **log-volatilidad** (no del precio) vía el escalamiento de momentos $\mathbb{E}|\log \sigma_{t+\Delta} - \log \sigma_t|^q \sim \Delta^{qH}$.

Cuadro 11: Rugosidad de la log-volatilidad: dos proxies.

Índice	$\hat{H}$ (ventana rodante 21d)	$\hat{H}(r_t $ diario, sin traslape)
IPC	0.4895	0.0088
DJI	0.5063	0.0089

El contraste entre las dos columnas es en sí mismo el resultado metodológico relevante. La ventana rodante de 21 días –el proxy más común de “volatilidad realizada” con datos diarios– da $\hat{H} \approx 0.5$, aparentemente “no rugosa”; pero esto es un **artefacto del traslape**: ventanas consecutivas comparten 20 de 21 observaciones, induciendo autocorrelación espuria que *infla* $\hat{H}$ mecánicamente, independientemente de la rugosidad genuina del proceso subyacente. Usando $|r_t|$ diario –sin ventana, sin traslape– como proxy instantáneo de volatilidad, $\hat{H}$ colapsa a ≈ 0.009 en *ambos* índices: sustancialmente por debajo incluso del $H \approx 0.1$ que Gatheral–Jaisson–Rosenbaum reportan con datos *intradía* para acciones individuales. Dado que solo se dispone de precios de cierre diarios –no intradía–, esta cifra **no es una réplica directa** de su estimador de varianza cuadrática realizada, y debe leerse como evidencia direccional, no como una medición equivalente: ambos apuntan en la misma dirección (la volatilidad es muchísimo más rugosa que el precio, $H \ll 1/2$), consistente con los modelos de volatilidad estocástica fraccionaria (*rough Bergomi*, *rough Heston*) que la descomposición de Malliavin–Hoeffding de Alòs, León y Vives (2007) usa para explicar el sesgo a corto plazo (*skew*) de la volatilidad implícita observada en mercados de opciones.




Figura 7: Escalamiento $\hat{H} = \zeta(q)/q$ de la log-volatilidad: ventana rodante de 21 días (sesgada al alza por traslape, izquierda) vs. $|r_t|$ diario sin traslape (derecha). El colapso hacia $H \approx 0$ en el panel derecho es la firma de rugosidad.

6.8. GJR-GARCH y el efecto apalancamiento

Cuadro 12: GARCH(1,1) vs. GJR-GARCH(1,1), estimación por máxima verosimilitud (dist. t -Student), muestra completa y crisis 2008.

Índice	Periodo	$\hat{\alpha} + \hat{\beta}$ (GARCH)	$\hat{\alpha}$	$\hat{\gamma}$	$\hat{\beta}$	AIC (GARCH vs. GJR)
IPC	Completa (n=8,490)	0.9917	0.130	0.093	0.908	26,606.0 vs. 26,498.9
IPC	Crisis 2008 (n=501)	0.9878	0.148	0.144	0.922	2,020.1 vs. 2,006.1
DJI	Completa (n=8,499)	0.9905	0.166	0.161	0.896	21,610.6 vs. 21,414.2
DJI	Crisis 2008 (n=504)	0.9867	0.144	0.144	0.918	1,940.2 vs. 1,924.1

El GJR-GARCH domina al GARCH simétrico por AIC en los cuatro casos, y el parámetro de apalancamiento $\hat{\gamma}$ es positivo y sustancial en todos ellos (0.093–0.161): las caídas incrementan la volatilidad condicional más que las subidas de igual magnitud, en ambos mercados y tanto en muestra completa como en crisis. La persistencia total ($\hat{\alpha} + \hat{\gamma}/2 + \hat{\beta}$) es cercana a 1 en todos los casos (≥ 0.98), lo que indica memoria de volatilidad muy larga –compatible con la HME débil en media (los rendimientos no son predecibles) pero *incompatible* con la versión gaussiana homocedástica de la Sección 2.




Figura 8: Curva de impacto de noticias: GARCH(1,1) (simétrica, gris) vs. GJR-GARCH(1,1) (asimétrica, color), muestra completa.

6.9. Ornstein–Uhlenbeck: reversión a la media de la volatilidad

El modelo (14) se ajusta a la volatilidad realizada anualizada (ventana de 21 días) de los 4 mercados –incluyendo ya China y Singapur, introducidos formalmente en la Sección 10, para no repetir el ajuste allá.

Cuadro 13: Ajuste Ornstein–Uhlenbeck (MLE exacta) a la volatilidad realizada, 4 mercados.

Mercado	$\hat{\kappa}$	$\hat{\theta}$	$\hat{\sigma}_{vol}$	Vida media (días)	R^2
IPC	0.0092	0.193	0.0139	75.4	0.982
DJI	0.0066	0.148	0.0108	104.3	0.987
China	0.0117	0.204	0.0164	59.5	0.977
Singapur	0.0100	0.151	0.0129	69.6	0.981

Nota de interpretación: el $R^2 \approx 0.98$ en los cuatro mercados **no debe leerse como evidencia de que la volatilidad futura es casi perfectamente predecible** –está inflado mecánicamente por el mismo efecto de traslape de ventanas discutido en la Sección 6.7 para la rugosidad: la volatilidad realizada de ventana rodante en t y $t + 1$ comparte 20 de 21 observaciones, por lo que un alto R^2 día-a-día es esperable independientemente de la dinámica genuina de la volatilidad. La cantidad interpretable con cautela es la **vida media**: el DJI tiene la reversión más lenta (104 días) y la volatilidad de largo plazo $\hat{\theta}$ más baja (14.8 % anualizado); China tiene la reversión más rápida (60 días) y el $\hat{\theta}$ más alto (20.4 %) –consistente con un mercado más volátil pero que también disipa sus shocks de volatilidad más rápido, patrón opuesto a la interpretación ingenua de que “más volátil” implica “memoria de volatilidad más larga”.




Figura 9: Volatilidad realizada anualizada y nivel de largo plazo $\hat{\theta}$ ajustado (OU), 4 mercados.

7. Teoría del Valor Extremo y validación de VaR

Se aplica el método POT (Sección 2.7) con umbral en el percentil 95 de las pérdidas diarias $(-r_t)$.

Cuadro 14: Ajuste GPD sobre excedencias (POT, $u = p95$) y VaR 99 % comparado.

Índice	u	n_{exc}	$\hat{\xi}$	$\hat{\beta}$	$\alpha = 1/\hat{\xi}$
IPC	0.0208	425	0.1664	0.00939	6.01
DJI	0.0164	425	0.2229	0.00780	4.49

Ambos $\hat{\xi} > 0$ confirman colas tipo Pareto; el índice de cola del DJI ($\alpha \approx 4.5$) indica colas más pesadas que las del IPC ($\alpha \approx 6.0$) –resultado no trivial, pues es el mercado *desarrollado* el que exhibe la cola más pesada de los dos, al revés de lo que la intuición “emergente = más riesgoso” sugeriría; es consistente, sin embargo, con la mayor curtosis del DJI ya documentada en la Tabla 2.

Cuadro 15: Backtesting de VaR 99 % (test de proporción de fallas de Kupiec, 1995). Violaciones esperadas = $0.01n$.

Índice	Método	VaR 99 %	Violaciones	Esperadas	LR Kupiec	p -valor
IPC	Normal	0.0319	151	84.9	45.7	< 0.0001
IPC	Histórico	0.0390	85	84.9	0.00	0.9913
IPC	EVT/GPD	0.0381	91	84.9	0.43	0.5107
DJI	Normal	0.0253	146	85.0	40.4	< 0.0001
DJI	Histórico	0.0308	85	85.0	0.00	0.9991
DJI	EVT/GPD	0.0315	81	85.0	0.19	0.6611

El resultado es tajante: el VaR gaussiano es rechazado con $p < 0.0001$ en ambos mercados –subestima el riesgo sistemáticamente, produciendo casi el doble de violaciones de las esperadas. El VaR histórico y el VaR EVT/GPD no son rechazados ($p > 0.5$ en ambos casos). Esta es, junto con la curtosis de la Tabla 2, la evidencia más robusta e inequívoca del artículo en contra de la HME gaussiana estricta.




Figura 10: Pérdidas diarias y las tres estimaciones de VaR 99 %.




Figura 11: Espectro empírico de la matriz de correlación de componentes vs. densidad de Marchenko–Pastur, IPC ($p = 17$) y DJI ($p = 28$).




Figura 12: RMT dinámica del DJI: rendimientos diarios (arriba) y mayor eigenvalor λ_1 en ventana rodante de 250 días vs. umbral MP de la ventana (abajo). El pico del 2020-04-06 corresponde al colapso de correlaciones (contagio) durante COVID-19.




Figura 13: Función de exceso medio, IPC y DJI: la linealidad aproximada para u mayores confirma que la GPD es un modelo razonable de la cola.




Figura 14: Histograma de rendimientos (escala log) vs. densidad Normal ajustada: el exceso de masa en las colas es visible a simple vista en ambos índices.

7.1. Verificación Monte Carlo no circular

Dos resultados centrales del artículo –el umbral de factores genuínos en RMT (Sección 6.3) y la calibración del VaR EVT/GPD (Tabla 14)– se verifican por simulación de forma explícitamente **no circular**: los parámetros estimados de los propios datos se fijan como verdad *exógena* en una simulación independiente, evitando el error de invertir una fórmula y luego reaplicarla sobre los mismos datos (lo que siempre “cuadra” por construcción, sin decir nada sobre si el modelo es razonable).

(A) Transición BBP (Baik–Ben Arous–Péché, 2005). Los eigenvalores muestrales $\hat{\lambda}_1, \hat{\lambda}_2$ de la Tabla 4 se invierten vía la fórmula del outlier $\varphi(\ell) = \ell + q\ell/(\ell - 1)$ para recuperar picos poblacionales ℓ_1, ℓ_2 . Esos picos se fijan como verdad poblacional *exógena* en $M = 300$ réplicas Monte Carlo de un modelo de covarianza $\Sigma = I_p + (\ell - 1)uu^\top$ en las dimensiones p, T reales de cada índice, y se compara el eigenvalor muestral promedio simulado contra la

predicción $\varphi(\ell)$:

Cuadro 16: Verificación Monte Carlo no circular de la fórmula BBP ($M = 300$ réplicas).

Índice	Factor	ℓ (exógeno)	$\varphi(\ell)$ (pred.)	Simulado (media $\pm$ de)	Error rel.
IPC	Mercado	4.881	4.886	4.875 ± 0.096	0.23 %
IPC	Sectorial	1.275	1.293	1.294 ± 0.025	0.06 %
DJI	Mercado	12.263	12.271	12.259 ± 0.285	0.10 %
DJI	Sectorial	1.729	1.746	1.745 ± 0.040	0.02 %

El acuerdo es excelente en los cuatro casos (< 0.25 % de error), y ahora es una verificación genuína: la fórmula BBP predice, a partir únicamente de ℓ , p y T fijados de antemano en la simulación, el eigenvalor muestral que efectivamente se observa –sin haber usado $\hat{\lambda}$ observado en ningún paso de la simulación misma. *Nota técnica:* la verificación debe hacerse sobre la matriz de **covarianza** simulada, no sobre su versión re-estandarizada a correlación: para picos grandes ($\ell \gg 1$), re-estandarizar infla la varianza marginal de los activos correlacionados con el factor y encoge artificialmente el pico efectivo, produciendo errores espúreos de 30–40 % en una primera versión de este código que se corrigió antes de reportar la tabla anterior.

(B) Bootstrap paramétrico del ajuste GPD. Se simulan 500 muestras sintéticas del mismo tamaño que las excedencias observadas ($n_{\text{exc}} = 425$), generadas de la GPD ajustada ($\hat{\xi}, \hat{\beta}$ de la Tabla 14), y se reajusta GPD a cada una:

Cuadro 17: Bootstrap paramétrico de $\hat{\xi}$ (GPD), $M = 500$ réplicas.

Índice	$\hat{\xi}$ original	Media bootstrap	Sesgo	IC95 %
IPC	0.1664	0.1639	−0.0025	[0.043, 0.285]
DJI	0.2229	0.2205	−0.0024	[0.101, 0.347]

El sesgo es pequeño en ambos casos (< 0.003), pero el intervalo de confianza es amplio –reflejo honesto de que $n_{\text{exc}} = 425$ excedencias (el 5 % superior de $\sim 8,500$ observaciones) es una muestra modesta para estimar un parámetro de forma de cola. El punto estimado $\hat{\xi}$ es razonablemente estable, pero la incertidumbre alrededor de él es real y debe tenerse en cuenta al usar el VaR EVT para decisiones de capital regulatorio.

8. Benchmark de Machine Learning: walk-forward

Como contraste moderno a la evidencia clásica, se entrena una batería de cinco algoritmos –Random Forest, XGBoost, LightGBM, Gradient Boosting y regresión Ridge (vía clasificación lineal regularizada)– para predecir el **signo** del rendimiento del día siguiente, usando

únicamente información disponible hasta t : rezagos de rendimiento (1, 2, 3, 5, 10 días), volatilidad realizada rodante (10 y 21 días), momentum (5 y 21 días) y un RSI de 14 días. La validación es **walk-forward** estricta: entrenamiento expansivo desde 1,500 observaciones iniciales, evaluación en bloques de 250 días fuera de muestra, sin remezclar el orden temporal (27 bloques por índice, 6,750 predicciones evaluadas en cada uno).

Cuadro 18: Precisión direccional walk-forward (27 bloques de 250 días, $n = 6,750$ predicciones por índice).

Índice	Mayoría trivial	RF	XGBoost	LightGBM	GB	Ridge
IPC	0.5204	0.5265	0.5314	0.5274	0.5241	0.5249
DJI	0.5321	0.5241	0.5080	0.5083	0.5121	0.5283

El resultado es aleccionador y va *más allá* de la conclusión habitual de “ningún algoritmo supera 53–55 % de precisión”: para el **DJI**, los **cinco algoritmos de Machine Learning quedan por debajo del predictor trivial que siempre pronostica la clase mayoritaria del bloque** (53.21 %). Para el IPC, el mejor modelo (XGBoost, 53.14 %) apenas supera la mayoría trivial (52.04 %) por 1.1 puntos porcentuales –diferencia que, dado el tamaño de muestra, no es evidencia fuerte de señal explotable. Ninguno de los diez pares modelo-índice alcanza el 54 %. Esto corrobora, con métodos completamente distintos, la misma conclusión cualitativa de las Secciones anteriores: hay estructura estadística genuina en los precios (colas pesadas, apalancamiento GARCH, factores RMT), pero esa estructura no se traduce en predictibilidad direccional explotable día a día –ni siquiera para modelos no lineales con capacidad de capturar interacciones complejas entre las variables rezagadas.




Figura 15: Precisión direccional walk-forward por algoritmo, IPC y DJI, comparada contra el predictor de mayoría trivial y el azar (0.50).

8.1. Optimización por algoritmo genético

¿Puede un algoritmo genético (GA), buscando conjuntamente sobre selección de *features* e hiperparámetros de XGBoost, superar la rejilla fija de la Sección anterior? Se codifica un cromosoma de 13 genes (10 bits de selección de *features* + 3 genes enteros para *n_estimators*, *max_depth* y *learning_rate*), población de 12 individuos, 6 generaciones, selección por torneo, cruza de un punto ($p = 0.7$) y mutación ($p = 0.08$ por gen). El *fitness* –precisión walk-forward, *no* precisión de entrenamiento– usa una rejilla walk-forward reducida durante la búsqueda (para mantener el costo computacional manejable) y el mejor cromosoma final se reevalúa en la rejilla walk-forward **completa e idéntica** a la Tabla 18, para una comparación justa.

Cuadro 19: Mejor cromosoma GA vs. mejor modelo de rejilla fija (Tabla 18), walk-forward completo.

Índice	Features (GA)	Hiperparámetros	Acc. GA-XGB	Mejor rejilla fija	Mayoría trivial
IPC	r_lag1, r_lag3, rsi_14	$n=50, d=5, \eta=0.01$	0.5342	0.5314 (XGB)	0.5204
DJI	r_lag5, vol_21, mom_21, rsi_14	$n=50, d=2, \eta=0.01$	0.5323	0.5283 (Ridge)	0.5321

El GA mejora modestamente sobre el mejor modelo de rejilla fija en ambos índices (+0.28 puntos porcentuales IPC, +0.40 DJI), y de forma interesante, encuentra soluciones *más simples*: 3 y 4 de las 10 *features* disponibles, en vez de las 10 completas, con árboles poco profundos ($d \leq 5$) y tasas de aprendizaje bajas –consistente con la lectura de que la señal explotable, si existe, es débil y fácil de sobreajustar con modelos más complejos. Para el DJI, sin embargo, el 0.5323 del GA apenas supera el 0.5321 de la mayoría trivial por 0.02 puntos porcentuales –una diferencia dentro del ruido esperable para $n = 6,750$ predicciones, no evidencia convincente de que el GA haya encontrado señal genuína en el DJI. Para el IPC, la mejora sobre la mayoría trivial es mayor (+1.4pp) pero sigue siendo modesta. El GA *no* cambia la conclusión cualitativa de la Sección anterior; la refina, mostrando que ni siquiera una búsqueda evolutiva sobre *features* e hiperparámetros logra una mejora que resulte convincente frente al ruido muestral.




Figura 16: Evolución del algoritmo genético: mejor fitness y fitness promedio de la población por generación (rejilla walk-forward reducida usada durante la búsqueda).

9. Regresión Fama–French

Como último contraste –distinto en espíritu a las Secciones anteriores, pues no pregunta si los precios son aleatorios sino si sus rendimientos son explicados por factores de riesgo sistemático estándar– se estima el modelo de cinco factores de Fama y French (2015) $r_t - r_{f,t} = \alpha + \beta_1(\text{Mkt} - \text{RF})_t + \beta_2\text{SMB}_t + \beta_3\text{HML}_t + \beta_4\text{RMW}_t + \beta_5\text{CMA}_t + \varepsilon_t$, con errores estándar HAC (Newey–West).

Para el DJI se usan los factores diarios de EU de la librería de datos de Ken French (1990–2025). **Ken French no publica factores específicos de México**; para el IPC se usa el conjunto “Emerging Markets 5 Factors” (mensual) como *proxy* explícito del mercado emergente al que pertenece el IPC –no un factor mexicano genuino– y los rendimientos diarios se agregan a mensuales para emparejar la frecuencia; RMW y CMA se excluyen del modelo IPC por alta fracción de datos faltantes en la submuestra útil (queda un modelo de 3 factores).

Cuadro 20: Regresión Fama–French, errores HAC. IPC usa el proxy Emerging Markets (mensual, 3F); DJI usa factores EU (diario, 5F).

Índice	n	α anualizado	$p(\alpha)$	β_{Mkt}	β_{SMB}	β_{HML}	R^2
DJI (diario, 5F, EU)	8,499	−5.25 %	< 0.0001	0.965	−0.134	0.088	0.927
IPC (mensual, 3F, EM proxy)	408	+3.27 %	0.257	0.691	−0.525	0.081 (n.s.)	0.478

El DJI muestra un ajuste excelente ($R^2 = 0.927$) con beta de mercado ≈ 1 y exposiciones significativas a los cinco factores, como corresponde a un índice que es él mismo una cesta amplia de acciones estadounidenses. El α diario es **negativo y altamente significativo** (−5.25 % anualizado, $p < 0.0001$): el DJI, como índice *ponderado por precio* (no por capitalización de mercado, a diferencia del universo que subyace a los factores de Fama–French, que

es value-weighted), no es exactamente replicable por una combinación lineal de los cinco factores estándar –una discrepancia metodológica conocida en la literatura sobre índices ponderados por precio, no evidencia de “arbitraje” explotable (el DJI no es un portafolio que un inversionista pueda replicar y comparar directamente contra los factores sin asumir el mismo esquema de ponderación). Para el IPC, el ajuste es más modesto ($R^2 = 0.478$, esperable con una muestra mensual de solo $n = 408$ y un proxy regional en vez de un factor propiamente mexicano) y el α **no es significativo** ($p = 0.257$): no hay evidencia, bajo este modelo, de que el IPC genere rendimientos anormales sistemáticos respecto al mercado emergente –lectura compatible con la HME débil en un sentido distinto (ajustado por riesgo sistemático) al de las Secciones previas. Ambos índices muestran beta SMB negativo y significativo, esperable: son índices de las empresas más grandes de cada mercado, con sesgo estructural hacia *large-cap*.

10. Extensión comparativa: cinco mercados asiáticos adicionales

Para evaluar si las conclusiones anteriores son idiosincráticas de México/EU o se generalizan, se replica el núcleo del pipeline –estadística descriptiva, Hurst (DFA), GJR-GARCH, EVT/GPD con backtesting de Kupiec, y benchmark ML walk-forward– sobre cinco mercados asiáticos adicionales: el Índice Compuesto de Shanghai (SSE, China, 1997–2025), el Straits Times Index (STI, Singapur, 1987–2025), el Nikkei 225 (Japón, 1973–2025), el Hang Seng (Hong Kong, 1987–2025) y el KOSPI Composite (Corea del Sur, 1996–2025), todos truncados al 2025-10-03 para coincidir con la fecha de corte de IPC/DJI. *Nota de calidad de datos:* la serie cruda de Yahoo Finance para el Nikkei 225 repite una cotización inmóvil (3,187.62) durante 20 sesiones consecutivas en abril de 1972 –un dato defectuoso (*stale quote*), no un cierre real de la bolsa de Tokio– que se verificó es el único tramo así en toda la serie 1970–2025 y que, sin corregir, distorsiona específicamente los momentos muy negativos del espectro MFDFA (Sección 10.1) via el término $(\cdot)^{q/2}$ con $q \ll 0$; la serie de Japón se trunca por ello a partir de 1973-01-05 (se pierden ~ 2.5 años de 55, el tramo defectuoso queda excluido) y todos los números de Japón en esta sección usan la serie ya corregida. *Nota de alcance RMT:* para China y Singapur no se dispone de datos de componentes, por lo que **no** se replica el análisis RMT en esos dos índices; para Japón, Hong Kong y Corea sí se descargó una canasta de 14–19 componentes líquidos de gran capitalización cada uno (tras descartar los de alta fracción de datos faltantes por IPO tardía, mismo criterio que IPC/DJI en la Sección 5), lo que permite extender RMT, Dyson–Wigner, el criterio de Peccati y el RIE a esos tres mercados (Sección 10.2). El bloque-bootstrap de Hurst (200 réplicas, idéntico protocolo que la Tabla 8) se aplicó a los 5, ver Tabla 21.

Cuadro 21: Comparación de 7 mercados: estadística, Hurst (con IC95 % bootstrap), GARCH, EVT.

Mercado	n	Curt. exc.	$\hat{H}_{DFA}$	IC95 %	$\hat{\gamma}$ (GJR)	$\hat{\xi}$ (EVT)	Kupiec Norm./EVT
IPC (México)	8,490	6.80	0.504	[0.458, 0.512]	0.093	0.166	Rechaza / No
DJI (EU)	8,499	13.00	0.462	[0.414, 0.476]	0.161	0.223	Rechaza / No
China (SSE)	6,845	5.57	0.592	[0.499, 0.595]	0.032	0.122	Rechaza / No
Singapur (STI)	9,437	9.85	0.554	[0.508, 0.573]	0.087	0.188	Rechaza / No
Japón (N225)	12,972	9.37	0.481	[0.462, 0.519]	0.118	0.229	Rechaza / No
Hong Kong (HSI)	9,566	52.06	0.497	[0.472, 0.524]	0.070	0.302	Rechaza / No
Corea (KOSPI)	7,095	6.36	0.541	[0.479, 0.549]	0.075	0.092	Rechaza / No

Cuatro hallazgos destacan al ampliar de 4 a 7 mercados:

(1) El VaR gaussiano es rechazado universalmente, ahora en los 7. Los siete mercados rechazan a Normal por Kupiec ($p < 0.0001$ en los siete) y ninguno rechaza al VaR EVT/GPD –el resultado más robusto de todo el artículo (Sección 7) se sostiene sin excepción en una muestra aún más amplia y geográficamente diversa. Hong Kong exhibe la curtosis en exceso más alta de los 7 mercados por un margen enorme (52.06, cuatro veces la del DJI): su serie parte del 1987-01-02, apenas semanas antes del Lunes Negro de octubre de 1987, cuando el HSI cayó cerca de 33 % en una sola sesión –un evento de cola extremo que domina la curtosis muestral incluso en 38 años de datos.

(2) Singapur y DJI siguen siendo los únicos con Hurst significativamente distinto de 1/2; Hong Kong es, punto por punto, el más cercano a una caminata aleatoria pura de los 7. El IC95 % de Singapur ([0.508, 0.573]) excluye 0.5 por arriba (persistencia) y el del DJI ([0.414, 0.476]) lo excluye por abajo (antipersistencia); ningún otro mercado –ni siquiera China, con el punto estimado más alto de los 7 ($\hat{H} = 0.592$, IC95 % [0.499, 0.595], rozando 0.5 por el lado inferior)– logra significancia convencional. Ordenando los 7 por $|\hat{H}_{DFA} - 0.5|$: Hong Kong ($\hat{H} = 0.497$, distancia 0.003) e IPC ($\hat{H} = 0.504$, distancia 0.004) son los más cercanos a 0.5 exacto, seguidos de Japón ($\hat{H} = 0.481$, IC95 % [0.462, 0.519], distancia 0.019, intervalo casi simétrico alrededor de 0.5 pese a un punto estimado ya no tan pegado como en el pipeline sin corregir la serie), y luego DJI, Corea ($\hat{H} = 0.541$, IC95 % [0.479, 0.549], segundo punto estimado más alto tras China pero con IC95 % que también incluye 0.5 con amplio margen), Singapur y China en ese orden. Esto ilustra de nuevo la lección metodológica de la Sección 6.4: de los 7 puntos estimados, 5 sugerirían –leídos sin bootstrap– alguna forma de memoria; el bootstrap deja sobrevivir solo 2.

(3) El apalancamiento GARCH forma un espectro continuo, no un clúster asiático uniforme. Ordenando los 7 por $\hat{\gamma}$: China 0.032 < Hong Kong 0.070 < Corea 0.075 < Singapur 0.087 < IPC 0.093 < Japón 0.118 < DJI 0.161. China conserva el efecto apalancamiento más débil por un margen amplio, consistente con la lectura de participación estatal/restricciones a ventas en corto ya discutida; pero Japón –mercado desarrollado, sin esas restricciones estructurales– rompe la intuición de que “mercados asiáticos tienen apalancamiento débil”:

su $\hat{\gamma} = 0.118$ está muchísimo más cerca del DJI que de Hong Kong, Corea, China o Singapur (que ocupan el rango estrecho 0.032–0.087). El apalancamiento GARCH, entonces, no sigue una línea geográfica limpia Asia-vs-Occidente.

(4) El benchmark de ML confirma el patrón de las Secciones 8: la predictibilidad direccional explotable, cuando existe, es marginal y no universal. De los 7 mercados, DJI y Corea son los únicos donde *ningún* modelo supera la mayoría trivial (Corea: mejor modelo -1.18 pp bajo el baseline de 0.5367, el baseline más alto de los 7, reflejo de una asimetría direccional muy marcada en los rendimientos diarios del KOSPI). En los otros 5, la mejora máxima sobre el baseline nunca supera 1.5 puntos porcentuales (Japón: $+0.42$ pp; Hong Kong: $+0.11$ pp, apenas por encima del ruido; China: $+0.52$ pp; Singapur: $+0.53$ pp; IPC: $+1.1$ pp), ver Tabla 22.






Figura 17: Comparación de curtosis, Hurst (DFA), índice de cola EVT y apalancamiento GJR-GARCH, 7 mercados.

Cuadro 22: Benchmark ML walk-forward, 7 mercados (mismo protocolo: train_min=1,500, step=250).

Mercado	Mayoría trivial	RF	XGBoost	LightGBM	GB	Ridge
IPC	0.5204	0.5265	0.5314	0.5274	0.5241	0.5249
DJI	0.5321	0.5241	0.5080	0.5083	0.5121	0.5283
China	0.5274	0.5326	0.5322	0.5250	0.5192	0.5198
Singapur	0.5061	0.5107	0.5077	0.5093	0.5022	0.5114
Japón	0.5212	0.5254	0.5102	0.5132	0.5188	0.5132
Hong Kong	0.5140	0.5109	0.5151	0.5094	0.5074	0.5052
Corea	0.5367	0.5242	0.5018	0.5056	0.5142	0.5249

**Figura 18:** Precisión direccional walk-forward, 7 mercados, línea negra discontinua = mayoría trivial de cada mercado.**Figura 19:** Niveles (escala log) de Nikkei 225, Hang Seng y KOSPI Composite.

10.1. Lévy, MFDFA y volatilidad rugosa: cinco mercados

Se replica además el ajuste de procesos de Lévy (Sección 6.6), el espectro multifractal MFDFA (Sección 6.5), la rugosidad de $|r_t|$ diario sin traslape (Sección 6.7) y el ajuste Ornstein–Uhlenbeck de la volatilidad realizada (Sección 6.9) sobre los 5 mercados no primarios –esto

cierra, de paso, el hueco de alcance que China y Singapur tenían en las Secciones previas (solo contaban ahí con el pipeline base).

Cuadro 23: Lévy (mejor modelo por AIC), MFDFA y Ornstein–Uhlenbeck, 5 mercados.

Mercado	Mejor Lévy	$\Delta\alpha$ (MFDFA)	$H(q=2)$	$\hat{H}_{\text{DFA}}$	Vida media OU (d)
China	NIG	0.123	0.585	0.592	59.5
Singapur	VG	0.251	0.559	0.554	69.6
Japón	VG	0.230	0.484	0.481	72.9
Hong Kong	VG	0.467	0.494	0.497	48.4
Corea	NIG	0.076	0.550	0.541	103.0

Tres observaciones: **(i)** en los 5 mercados, $H(q=2)$ del espectro MFDFA reproduce el $\hat{H}_{\text{DFA}}$ de la Tabla 21 casi exactamente (diferencia máxima 0.011, Corea), el mismo autochequeo independiente ya documentado para IPC/DJI en la Sección 6.5, ahora verificado en 5 mercados adicionales. **(ii)** Un proceso de Lévy (NIG o VG) supera a la Normal por AIC en los 5, sin excepción –el mismo patrón universal que IPC/DJI. **(iii)** Hong Kong tiene el espectro multifractal más ancho de los 7 mercados del artículo ($\Delta\alpha = 0.467$, más del doble que Japón o Singapur), consistente con –aunque no una prueba directa de– la presencia del evento de cola extremo de 1987 ya discutido en el hallazgo (1): un mercado cuya dinámica incluye un colapso de un día de $\sim 33\%$ tiene razón de sobra para escalar de forma muy distinta entre fluctuaciones grandes y pequeñas. La vida media de reversión OU de la volatilidad va de 48 días (Hong Kong, reversión más rápida) a 103 días (Corea, la más lenta de los 7 mercados del artículo, incluyendo IPC/DJI).

Para $|r_t|$ diario sin traslape (proxy no sesgado de rugosidad de la Sección 6.7), los 5 mercados dan $\hat{H}(\log\text{-vol}) \in [0.0037, 0.0098]$ (Hong Kong mínimo, Singapur máximo) –órdenes de magnitud por debajo de 0.5 en los 5, replicando sin excepción el hallazgo de rugosidad extrema de IPC/DJI y reforzando directamente la discusión teórica de la Sección 2.2.2: un proceso de volatilidad markoviano tipo Heston/CIR ($H = 1/2$ por construcción) es incompatible con los 7 mercados del artículo, no solo con México/EU.




Figura 20: Ajuste de procesos de Lévy (NIG) vs. Normal, 5 mercados.




Figura 21: Espectro de Hurst generalizado $H(q)$, 5 mercados.




Figura 22: Rugosidad de $|r_t|$ diario sin traslape, $\hat{H} = \zeta(q)/q$, 5 mercados.




Figura 23: Ajuste Ornstein–Uhlenbeck de la volatilidad realizada, 5 mercados.

10.2. RMT, Dyson–Wigner, Peccati y RIE: Japón, Hong Kong y Corea

Replicando exactamente el protocolo de las Secciones 6.3, 6.3.3 y 6.3.1 sobre las canastas de componentes de Japón ($p = 19$), Hong Kong ($p = 14$) y Corea ($p = 16$):

Cuadro 24: RMT, Dyson–Wigner y RIE en Japón, Hong Kong y Corea.

Mercado	p	T	q	λ_+	λ_1	Factores	KS-Wigner p
Japón	19	4,934	0.0039	1.128	9.36	1	0.947
Hong Kong	14	4,420	0.0032	1.116	6.94	2	0.879
Corea	16	4,493	0.0036	1.123	5.78	3	0.784

Los tres mercados rechazan Poisson (KS-Poisson $p = 0.177$ Japón, 0.421 Hong Kong, 0.100 Corea) sin rechazar Wigner, replicando el hallazgo de repulsión de niveles de la Sección 6.3 en tres mercados adicionales, aunque con potencia baja dado el p pequeño (igual advertencia que la Sección 6.3 ya hace explícita para IPC/DJI). El criterio del cuarto momento (Peccati) sobre $\lambda_1(t)$ dinámico es compatible con normalidad asintótica en los tres (curtosis en exceso con IC95 % incluyendo 0: Japón $[-0.978, -0.522]$ –este único caso **no** incluye 0, evidencia de curtosis negativa persistente, posiblemente reflejo del bajo $p = 19$ –, Hong Kong $[-0.493, 0.357]$, Corea $[-0.753, 0.273]$).

Hallazgo RIE notable: en Japón, limpiar la matriz reduce la varianza fuera de muestra por debajo de 1, algo que no ocurre en ningún otro mercado del artículo. La razón de inflación (varianza fuera/dentro de muestra) es 0.730 (muestral) y 0.939 (RIE) en Japón –ambas por debajo de 1, es decir la varianza realizada fuera de muestra fue *menor* que la predicha dentro de muestra, y limpiar empeora la predicción al acercarla a 1 desde abajo.

Esto es la imagen especular exacta del hallazgo de la Sección 6.3.1 para IPC/DJI (limpiar *empeora* la varianza fuera de muestra, ahí por exceso): confirma, con signo opuesto, que el régimen de q pequeño ($q_{\text{Japn}} = p/T_{\text{train}} \approx 0.005$) sigue sin favorecer el encogimiento clásico de Bouchaud–Potters, en cualquier dirección del error. Hong Kong ($1.058 \rightarrow 1.166$) y Corea ($0.910 \rightarrow 0.903$, prácticamente sin cambio) se comportan más parecido al patrón de inflación por exceso de IPC/DJI/Hong-Kong ya reportado.




Figura 24: Espectro MP empírico vs. teórico: Japón, Hong Kong, Corea.




Figura 25: Razón de inflación de varianza GMV fuera de muestra, tres métodos de limpieza, Japón/Hong Kong/Corea.

11. Extensión a mercados frontera: Argentina y Brasil

Los 7 mercados anteriores cubren Norteamérica y Asia, pero ningún mercado latinoamericano distinto de México. Se replica aquí el pipeline base (estadística descriptiva, Hurst DFA con bootstrap de 200 réplicas, GJR-GARCH, EVT/GPD con Kupiec, ML walk-forward –el mismo alcance con el que empezó la Sección 10 para China/Singapur) sobre dos índices

adicionales: el Índice Merval (Argentina, 1996–2025) y el Índice Bovespa (Brasil, 1997–2025). *Nota de selección:* Vietnam y Nigeria –mencionados inicialmente como candidatos de mercado frontera– no tienen un índice accesible vía Yahoo Finance ($\hat{VNIINDEX}$ y $\hat{NGSEINDEX}$ devuelven 404); se sustituyeron por estos dos mercados latinoamericanos, con regímenes macroeconómicos deliberadamente distintos entre sí y del mexicano: Argentina, con inflación crónica y múltiples *defaults* soberanos (2001, 2014, 2020) dentro de la ventana muestral, y Brasil, el mayor mercado emergente de América Latina. *Nota de alcance:* al igual que China/Singapur en su momento, estos dos mercados reciben aquí solo el pipeline base –no RMT/Dyson/Peccati/RIE (sin datos de componentes) ni Lévy/MFDFA/roughvol/OU/Prophet (fuera del alcance de esta extensión)–, ver Tabla 25.

Cuadro 25: Argentina y Brasil: estadística, Hurst (IC95 % bootstrap), GARCH, EVT.

Mercado	n	Curt. exc.	$\hat{H}_{DFA}$	IC95 %	$\hat{\gamma}$ (GJR)	$\hat{\xi}$ (EVT)	Kupiec Norm./EVT
Argentina (Merval)	7,093	25.73	0.507	[0.481, 0.555]	0.064	0.244	Rechaza / No
Brasil (Bovespa)	7,123	14.93	0.507	[0.479, 0.540]	0.092	0.309	Rechaza / No

Tres observaciones, leídas junto con los 7 mercados anteriores (ahora 9 en total):

(1) El VaR gaussiano se rechaza y el EVT/GPD se sostiene, sin excepción, en los 9. Argentina y Brasil no rompen el patrón más robusto del artículo.

(2) Argentina tiene la segunda curtosis más alta de los 9 mercados (Hong Kong es la primera), pero por una razón estructural opuesta. La curtosis de Hong Kong (Sección 10) está dominada por un único evento extremo (el Lunes Negro de 1987); la de Argentina (25.73) refleja crisis recurrentes distribuidas a lo largo de toda la muestra (2001-02, 2018-19, 2023), consistente con su historial de inestabilidad macroeconómica crónica en vez de un choque puntual. Ninguno de los dos Hurst es significativo (ambos IC95 % incluyen 0.5), manteniendo en 2 de 9 (Singapur, DJI) el conteo de mercados con persistencia/antipersistencia significativa.

(3) El apalancamiento GARCH de Argentina es el segundo más débil de los 9 mercados (tras China), un resultado a primera vista contraintuitivo dado su historial de crisis. $\hat{\gamma} = 0.064$ para Argentina es notablemente bajo pese a ser el mercado con más episodios de crisis de la muestra. Una lectura plausible –no verificada aquí con datos adicionales, en el mismo espíritu que la discusión de China en la Sección 10– es que el efecto apalancamiento mide la asimetría *marginal* de la volatilidad condicional ante choques positivos vs. negativos, no el nivel absoluto de volatilidad: si la inestabilidad macroeconómica crónica de Argentina ya mantiene la volatilidad estructuralmente elevada en todo momento (no solo tras malas noticias), hay menos margen para una asimetría *adicional* que capture $\hat{\gamma}$. El benchmark ML confirma el patrón de ausencia de predictibilidad explotable ya establecido: en ambos mercados, *ningún* modelo supera la mayoría trivial (Argentina: mejor modelo –0.98pp bajo el baseline de 0.5425; Brasil: –0.65pp bajo 0.5238), sumándose a DJI y Corea para un total de

4 de 9 mercados sin predictibilidad direccional ML explotable de ningún tipo.




Figura 26: Niveles (escala log) del Merval (Argentina) y el Bovespa (Brasil).




Figura 27: Comparación de curtosis, Hurst (DFA), índice de cola EVT y apalancamiento GJR-GARCH, 9 mercados (incluye Argentina y Brasil).

12. Pronósticos con Prophet

Como último contraste –con una familia de modelos completamente distinta a las de las Secciones anteriores: descomposición Bayesiana de tendencia + estacionalidad, en vez de martingalas, RMT o árboles de decisión– se ajusta **Prophet** (Taylor y Letham, 2018, Meta/Facebook) al log-precio de los 7 índices, evaluado walk-forward: entrenamiento expansivo (idéntico a $\text{train_min} = 1,500$, $\text{step} = 250$ de las Secciones de ML y GA), pronóstico

a horizonte $h = 21$ días (un mes bursátil), reiniciado en cada bloque desde el valor observado real (para que errores de un bloque no contaminen el siguiente). Se compara el RMSE de Prophet contra el RMSE del pronóstico óptimo bajo HME estricta: “sin cambio” (caminata aleatoria).

Cuadro 26: Prophet vs. caminata aleatoria, pronóstico walk-forward a 21 días, 7 mercados.

Mercado	RMSE Prophet	RMSE caminata aleatoria	Razón	% bloques donde Prophet gana
IPC	0.1689	0.0371	4.6×	10.1 %
DJI	0.1132	0.0265	4.3×	12.8 %
China	0.2676	0.0402	6.7×	7.8 %
Singapur	0.1702	0.0310	5.5×	10.3 %
Japón	0.2095	0.0349	6.0×	7.9 %
Hong Kong	0.1890	0.0426	4.4×	9.9 %
Corea	0.1371	0.0317	4.3×	9.5 %

El resultado es el más contundente de todo el artículo, en cualquier dirección, y se sostiene sin excepción en los 7 mercados: Prophet es **4.3 a 6.7 veces peor** que asumir “sin cambio”, y solo gana en el 7.8–12.8 % de los bloques de 21 días evaluados –muy por debajo del 50 % que implicaría indiferencia, y muchísimo por debajo de lo que hace falta para ser útil. China seguido de Japón tienen la peor razón de las siete (6.7× y 6.0×); DJI y Corea la mejor (aún así 4.3× peor). La razón es estructural, no un problema de ajuste de hiperparámetros: Prophet está diseñado para extrapolar **tendencias y estacionalidad**, exactamente el tipo de estructura que la HME débil predice que *no* existe de forma explotable en los rendimientos (Sección 2.1). Cuando esa estructura no existe, extrapolarla activamente es peor que no hacer nada. Este resultado, obtenido con una herramienta y una lógica de modelado enteramente distintas a las del benchmark de ML (Sección 8) o al análisis de martingalas (Sección 2.1), converge exactamente en la misma dirección que ambos, ahora en 7 mercados: no hay predictibilidad explotable en el nivel de los precios, ni siquiera para modelos diseñados específicamente para extraer tendencias.




Figura 28: Izquierda: RMSE de Prophet vs. caminata aleatoria, 4 mercados. Derecha: porcentaje de bloques de 21 días donde Prophet supera a la caminata aleatoria (línea discontinua = empate).




Figura 29: RMSE de Prophet vs. caminata aleatoria, los 5 mercados no primarios (complementa la Figura 28, que cubre IPC/DJI).

13. Discusión

Cinco lentes independientes convergen en un mismo diagnóstico: el IPC y el DJI no son caminatas aleatorias gaussianas, pero la naturaleza precisa de la desviación es distinta según qué se mida, y no todas las desviaciones son igual de robustas.

Evidencia sólida e inequívoca. La curtosis en exceso (Tabla 2) y el rechazo tajante del VaR gaussiano por el test de Kupiec ($p < 0.0001$ en ambos mercados, Tabla 15) son la evidencia más fuerte del artículo: no dependen de elegir un método sobre otro, y el ajuste GPD (Sección 7) recupera exactamente la calibración que el VaR gaussiano pierde. El apalancamiento en volatilidad ($\hat{\gamma} > 0$ en las cuatro estimaciones GJR-GARCH, Tabla 12) es

igualmente consistente.

Evidencia genuina pero más sutil. La estructura factorial RMT es real –2–3 factores genuinos en cada mercado, muy por encima del ruido Marchenko–Pastur– pero su lectura no es “ruido en calma, señal en crisis”: el factor de mercado del DJI es *siempre* genuino; lo que cambia con las crisis es su magnitud relativa (Sección 6.3).

Evidencia ausente o dependiente del método. El exponente de Hurst –el pilar clásico de la “fractalidad de Mandelbrot” y de la Representación de Lamperti (Sección 2.8)– *no* produce un veredicto unánime: el estimador más robusto (DFA) no encuentra memoria de largo plazo significativa en el IPC y encuentra *antipersistencia* (no persistencia) en el DJI, mientras que R/S –sesgado por heterocedasticidad según Lo (1991)– sugiere lo contrario. Reportar este desacuerdo, en vez de citar solo el método que “confirma” la fractalidad, es en sí mismo un resultado: sugiere que buena parte de la persistencia que la literatura previa atribuye al Hurst clásico en el IPC (Aguilar 2014; Morales et al. 2022, $\hat{H} \approx 0.58\text{--}0.64$) podría ser, al menos parcialmente, un artefacto de la heterocedasticidad condicional ya documentada por el propio GARCH de este artículo, no memoria de largo plazo independiente. Distinguir ambas explicaciones formalmente (vía, por ejemplo, DFA sobre residuos GARCH-filtrados) queda como extensión natural de este trabajo.

Leyéndolo en conjunto vía el Corolario 2.37: el proceso de Lévy subyacente en la Representación de Lamperti no puede ser un movimiento browniano puro para ninguno de los dos índices –las colas pesadas y el VaR gaussiano rechazado bastan para eso– pero la evidencia *no* identifica de forma unánime si ese proceso tiene, además, autosimilitud con $H \neq 1/2$ en el sentido clásico del fBm. Los ajustes de Lévy (Sección 6.6) le dan a ζ un contenido concreto: NIG para el IPC, VG para el DJI, ambos de variación infinita.

Sobre las extensiones. El MFDFA (Sección 6.5) resuelve parcialmente la ambigüedad del Hurst clásico: ambos índices son multifractales ($H(q)$ no constante), lo que por sí mismo es incompatible con un fBm monofractal simple, independientemente de qué signo tenga la persistencia en $q = 2$. La rugosidad de la volatilidad (Sección 6.7, $\hat{H} \ll 1/2$ en la log-volatilidad diaria) es cualitativamente consistente con esta imagen –memoria débil o ausente en el *nivel* del precio, pero rugosidad marcada en su *volatilidad*–, aunque con datos diarios en vez de intradía el resultado es sugestivo y no una réplica exacta de Gatheral–Jaisson–Rosenbaum. La verificación Monte Carlo (Sección 7.1) confirma que ninguno de los resultados de RMT y EVT depende de un ajuste circular. La regresión Fama–French (Sección 9) agrega una capa distinta de evidencia: bajo un modelo de riesgo sistemático estándar, el IPC no muestra α significativo (HME débil ajustada por riesgo), mientras que el α negativo del DJI es más plausiblemente un artefacto de su ponderación por precio que evidencia de ineficiencia. Finalmente, la extensión a cinco mercados asiáticos adicionales (Sección 10) muestra que el hallazgo más robusto del artículo –rechazo universal del VaR gaussiano, ausencia de predictibilidad ML explotable, Prophet sistemáticamente peor que la caminata aleatoria– se sostiene sin excepción en los 7 mercados, mientras que la persistencia de Hurst (significativa solo en Singapur y DJI, con signos opuestos), el apalancamiento

GARCH (que forma un espectro continuo de 0.032 a 0.161 sin agruparse por geografía) y el hallazgo RIE de Japón (único mercado donde limpiar la matriz de correlación *reduce* la varianza fuera de muestra, en vez de aumentarla) son dimensiones donde los 7 mercados *sí* difieren de forma sustancial.

Sobre el aparato de cálculo estocástico (Sección 2.2). El lema de Itô formaliza el GBM cuya discretización i.i.d.-Normal es la hipótesis nula que este artículo rechaza empíricamente en los 7 mercados; el Teorema 2.13 (Harrison–Pliska) le da a esa hipótesis su justificación estructural en valoración de activos, vía el Teorema de Girsanov, en vez de dejarla como convención estadística ad hoc. Y el modelo de Heston, formalmente markoviano con $H = 1/2$ por construcción en su proceso de varianza, es incompatible con la rugosidad empírica $\hat{H} \ll 1/2$ documentada en los 7 mercados (Secciones 6.7 y 10.1): la volatilidad de estos índices exige, formalmente, un proceso de volatilidad no markoviano tipo rough Bergomi/rough Heston, no el Heston clásico. La extensión multifactor de Heston (Christoffersen–Heston–Jacobs 2009, Sección 2.2.2) conecta, bajo un mismo modelo candidato de dos factores de volatilidad, dos resultados empíricos computados por separado: el ancho del espectro MFDFA ($\Delta\alpha$, evidencia de múltiples escalas de tiempo) y la vida media OU de 48–104 días (Sección 6.9, más consistente con capturar el factor lento de esa estructura que con ser la única escala genuina). Y la fórmula de Feynman–Kac (Sección 2.2.4) cierra el ciclo teórico completo del artículo: SDE (Itô) $\rightarrow$ cambio de medida (Girsanov) $\rightarrow$ EDP determinista (Black–Scholes) $\rightarrow$ esperanza bajo la nueva medida –el mismo GBM cuya hipótesis de incrementos i.i.d. Normales las Secciones empíricas rechazan en los 7 mercados.

Sobre la motivación de política pública de ampliar a mercados emergentes/frontera. El Artículo 32.10 del T-MEC (la llamada “cláusula china”, en vigor desde 2020) restringe la capacidad de México para firmar un TLC con economías catalogadas como “no de mercado”. Independientemente de la valoración política de esa cláusula, el hecho estructural que motiva –en parte– ampliar este artículo más allá de México/EU es el mismo: entender cuantitativamente cómo se comportan mercados bursátiles fuera del eje tradicional EU–Europa –incluyendo China (Sección 10) y, en la Sección 11, dos mercados latinoamericanos con regímenes macroeconómicos muy distintos al mexicano (Argentina, con inflación crónica y múltiples *defaults* soberanos, y Brasil, el mayor mercado emergente de la región)– es un insumo analítico de valor independiente del uso que se le dé, no una posición sobre la negociación comercial en sí.

14. Conclusiones

Este artículo recalcula, sobre datos reales de tres décadas del IPC mexicano y del Dow Jones –extendido a cinco mercados asiáticos adicionales (China, Singapur, Japón, Hong Kong y Corea del Sur) en la Sección 10, y a dos mercados latinoamericanos adicionales (Argentina, Brasil) en la Sección 11–, diez marcos analíticos usualmente tratados por separado en la

literatura: martingalas/HME con su formalización en tiempo continuo (lema de Itô, modelo de Heston –incluyendo su extensión multifactor–, cambio de medida de Girsanov, el primer teorema fundamental de la valoración de activos y la fórmula de Feynman–Kac que conecta la EDP de Black–Scholes con la esperanza bajo la medida de riesgo neutral, Sección 2.2), ajuste Gamma por ciclo, RMT (con verificación Monte Carlo no circular de la transición BBP), Lamperti/Hurst, procesos de Lévy paramétricos, MFDFA, GJR-GARCH/EVT, volatilidad rugosa y regresión Fama–French, añadiendo un benchmark de Machine Learning (con optimización por algoritmo genético) y pronósticos Prophet como contraste moderno. Las conclusiones más robustas (curtosis, VaR gaussiano rechazado en los 9 mercados, apalancamiento GARCH positivo en los 9, multifractalidad MFDFA, Prophet sistemáticamente peor que la caminata aleatoria) se sostienen sin excepción: los mercados analizados se alejan claramente de la caminata aleatoria gaussiana. Una conclusión –la fractalidad clásica vía Hurst– se reporta como genuinamente incierta y depende del mercado (significativa solo en 2 de 9, con signos opuestos), en vez de resolverse artificialmente a favor de la narrativa más vistosa. Al ampliar de 2 a 9 mercados se encontró además un problema real de calidad de datos –una cotización inmóvil de 20 sesiones en la serie cruda del Nikkei 225 de abril de 1972, que distorsionaba específicamente los momentos negativos del espectro MFDFA– documentado y corregido en la fuente (Sección 10) en vez de dejarse pasar silenciosamente; esa misma disciplina de verificación es la que en la Sección 10.2 produjo el hallazgo, genuinamente inesperado, de que Japón es el único, de los 5 mercados con datos de componentes, donde limpiar la matriz de correlación RMT *reduce* en vez de aumentar la varianza de portafolio fuera de muestra. Esa honestidad metodológica –incluyendo reportar dónde los métodos discrepan y corregir en público los errores que el propio proceso de verificación expone– es, en sí misma, parte de la contribución del artículo.

Referencias

- [1] Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2), 383–417.
- [2] Fama, E. F. (1991). Efficient capital markets: II. *The Journal of Finance*, 46(5), 1575–1617.
- [3] Mandelbrot, B. (1963). The variation of certain speculative prices. *The Journal of Business*, 36(4), 394–419.
- [4] Shiller, R. J. (2000). *Irrational Exuberance*. Princeton University Press.
- [5] Shiller, R. J. (2003). From efficient markets theory to behavioral finance. *Journal of Economic Perspectives*, 17(1), 83–104.
- [6] Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.

- [7] Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- [8] Glosten, L. R., Jagannathan, R., & Runkle, D. E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *The Journal of Finance*, 48(5), 1779–1801.
- [9] Engle, R. F., & Ng, V. K. (1993). Measuring and testing the impact of news on volatility. *The Journal of Finance*, 48(5), 1749–1778.
- [10] Marchenko, V. A., & Pastur, L. A. (1967). Distribution of eigenvalues for some sets of random matrices. *Mathematics of the USSR-Sbornik*, 1(4), 457–483.
- [11] Bai, Z. D., & Silverstein, J. W. (2010). *Spectral Analysis of Large Dimensional Random Matrices* (2nd ed.). Springer.
- [12] Laloux, L., Cizeau, P., Bouchaud, J.-P., & Potters, M. (1999). Noise dressing of financial correlation matrices. *Physical Review Letters*, 83(7), 1467–1470.
- [13] Plerou, V., Gopikrishnan, P., Rosenow, B., Amaral, L. A. N., Guhr, T., & Stanley, H. E. (2002). Random matrix approach to cross correlations in financial data. *Physical Review E*, 65(6), 066126.
- [14] Lamperti, J. (1962). Semi-stable stochastic processes. *Transactions of the American Mathematical Society*, 104(1), 62–78.
- [15] Kyprianou, A. E. (2006). *Introductory Lectures on Fluctuations of Lévy Processes with Applications*. Springer.
- [16] Bertoin, J. (1996). *Lévy Processes*. Cambridge University Press.
- [17] Hurst, H. E. (1951). Long-term storage capacity of reservoirs. *Transactions of the American Society of Civil Engineers*, 116, 770–799.
- [18] Lo, A. W. (1991). Long-term memory in stock market prices. *Econometrica*, 59(5), 1279–1313.
- [19] Peng, C.-K., Buldyrev, S. V., Havlin, S., Simons, M., Stanley, H. E., & Goldberger, A. L. (1994). Mosaic organization of DNA nucleotides. *Physical Review E*, 49(2), 1685–1689.
- [20] Pickands, J. (1975). Statistical inference using extreme order statistics. *The Annals of Statistics*, 3(1), 119–131.
- [21] Balkema, A. A., & de Haan, L. (1974). Residual life time at great age. *The Annals of Probability*, 2(5), 792–804.
- [22] Kupiec, P. H. (1995). Techniques for verifying the accuracy of risk measurement models. *The Journal of Derivatives*, 3(2), 73–84.

- [23] McNeil, A. J., & Frey, R. (2000). Estimation of tail-related risk measures for heteroscedastic financial time series. *Journal of Empirical Finance*, 7(3–4), 271–300.
- [24] Mata, M. (2008). Uso de técnicas fractales en el análisis del mercado accionario mexicano. *Working paper*.
- [25] Aguilar, R. R. (2014). El coeficiente de Hurst y el parámetro α -estable para el análisis de series financieras. *Contaduría y Administración*, 59(1), 187–210.
- [26] Lizarazu, E. Comportamiento fractal del IPC y el tipo de cambio en México. *Working paper*.
- [27] Morales, R., et al. (2022). Memoria de los precios en acciones del sector de bienes de consumo frecuente del S&P/BMV IPC. *Working paper*.
- [28] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- [29] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of KDD 2016*, 785–794.
- [30] Ke, G., et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30.
- [31] Madan, D. B., Carr, P. P., & Chang, E. C. (1998). The variance gamma process and option pricing. *Review of Finance*, 2(1), 79–105.
- [32] Barndorff-Nielsen, O. E. (1997). Normal inverse Gaussian distributions and stochastic volatility modelling. *Scandinavian Journal of Statistics*, 24(1), 1–13.
- [33] Merton, R. C. (1976). Option pricing when underlying stock returns are discontinuous. *Journal of Financial Economics*, 3(1–2), 125–144.
- [34] Kantelhardt, J. W., et al. (2002). Multifractal detrended fluctuation analysis of nonstationary time series. *Physica A*, 316(1–4), 87–114.
- [35] Mandelbrot, B. B. (1975). *Les objets fractals: forme, hasard et dimension*. Paris: Flammarion.
- [36] Gatheral, J., Jaisson, T., & Rosenbaum, M. (2018). Volatility is rough. *Quantitative Finance*, 18(6), 933–949.
- [37] Alòs, E., León, J. A., & Vives, J. (2007). On the short-time behavior of the implied volatility for jump-diffusion models with stochastic volatility. *Finance and Stochastics*, 11(4), 571–589.
- [38] Baik, J., Ben Arous, G., & Pécché, S. (2005). Phase transition of the largest eigenvalue for nonnull complex sample covariance matrices. *The Annals of Probability*, 33(5), 1643–1697.
- [39] Fama, E. F., & French, K. R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1–22.

- [56] Black, F., & Scholes, M. (1973). The pricing of options and corporate liabilities. *Journal of Political Economy*, 81(3), 637–654.
- [57] Kac, M. (1949). On distributions of certain Wiener functionals. *Transactions of the American Mathematical Society*, 65(1), 1–13.
- [58] Christoffersen, P., Heston, S., & Jacobs, K. (2009). The shape and term structure of the index option smirk: Why multifactor stochastic volatility models work so well. *Management Science*, 55(12), 1914–1932.
- [59] *Agreement between the United States of America, the United Mexican States, and Canada (T-MEC/USMCA)*, Chapter 32, Article 32.10 “Non-Market Country FTA.” Signed 2018, in force since 2020.