

Sistema Integrado de Análisis Multirresolución y Desempeño Académico

Un índice de sentimiento con verificación estadística explícita de su eficiencia —y de sus límites—, vía embeddings y transformada wavelet

César Galindo López

Universidad Panamericana · Facultad de Empresariales, Ciudad UP

Gabriel Villafuerte C.

Facultad de Estudios Superiores Acatlán, UNAM · github.com/Gabriel44svg

2026

Resumen

Presentamos un sistema que combina la señal cuantitativa de un curso (calificaciones, parciales, estado de riesgo) con la señal cualitativa de una encuesta de retroalimentación abierta, produciendo para esta última un índice de sentimiento por alumno $\hat{\theta} \in (-1, 1)$: cada respuesta se convierte en una señal escalar indexada por posición de token (proyectando el embedding contextual de cada palabra sobre el embedding de oración), que se descompone con la transformada discreta de onduleta (DWT) en un componente de tendencia global y uno de fluctuación local. Acompañamos $\hat{\theta}$ de una verificación estadística explícita —información de Fisher y cota de Cramér–Rao bajo los modelos gaussiano y Laplaciano— y mostramos, con simulaciones, exactamente qué certifica esa verificación y qué no. No reportamos corridas sobre datos reales de curso: este es un artículo de método, acompañado de simulaciones ilustrativas explícitamente etiquetadas como tales, no un estudio de caso.

Palabras clave: analítica académica, alerta temprana, análisis de sentimiento, transformada wavelet, información de Fisher, cota de Cramér–Rao.

Metadato del código	Valor
Versión actual del código	v1.0
Enlace permanente al repositorio de esta versión	github.com/Gabriel44svg/...-SIAMDA
Licencia legal del código	MIT
Sistema de control de versiones usado	git
Lenguajes, herramientas y servicios usados	Python 3.11; Streamlit; sentence-transformers; Py-Wavelets; SciPy; pandas; Plotly; pytest
Requisitos de compilación, entornos y dependencias	Python ≥ 3.10 ; ver <code>requirements.txt</code> (ejecución) y <code>requirements-dev.txt</code> (pruebas)
Enlace a documentación de desarrollador/manual	<code>README.md</code> en el repositorio
Correo de soporte para preguntas	jcgalingo@up.edu.mx

Cuadro 1. Metadatos del código (formato estándar de *software papers*).

1. Motivación y relevancia

Un curso genera dos tipos de señal sobre el desempeño de un alumno: una *cuantitativa* (calificaciones parciales, tareas, exposición) y una *cualitativa* (lo que el alumno escribe en una encuesta de retroalimentación abierta). La señal cuantitativa es la que normalmente se usa para detectar riesgo académico; la cualitativa suele leerse de forma impresionista, sin métrica. Este trabajo propone una métrica para la segunda señal y pregunta si aporta información adicional sobre el riesgo académico, vía su correlación empírica con la calificación final.

La construcción de $\hat{\theta}$ combina dos ingredientes bien establecidos por separado: *embeddings* contextuales de oración obtenidos con redes tipo Siamese-BERT [8], y la transformada discreta de onduleta como herramienta de análisis multirresolución de señales [7]. Lo que el sistema añade es una capa de validación estadística explícita del estimador de sentimiento agregado del grupo, apoyada en la teoría clásica de eficiencia de estimadores [1, 2, 3], complementada con una prueba de normalidad [4] y una estimación de varianza por remuestreo [5]. La contribución de este artículo no es ninguno de esos ingredientes por separado, sino documentar con precisión qué certifica —y, sobre todo, qué *no* certifica— su combinación, algo que la primera versión de nuestra propia implementación afirmaba de forma imprecisa (sección 2.2.3).

2. Descripción del software

2.1. Arquitectura del software

El sistema se organiza en cuatro módulos:

1. **Ingesta y normalización** (`datos.py`): lectura de archivos de calificaciones (CSV/Excel) con detección automática de columnas (número de cuenta, nombre, parciales E1, E2, . . . , examen ponderado, tareas, exposición, validación), manejo de texto mixto en celdas no numéricas (“*te presentas a final*”, “*está en reposición*”, “*baja*”, etc.) y cómputo de una bandera binaria de riesgo.
2. **NLP y extracción wavelet** (`nlp_wavelet.py`): embeddings de oración y de token (*sentence-transformers* multilingüe) sobre las respuestas abiertas de la encuesta, y descomposición multirresolución de la señal posicional resultante vía DWT.
3. **Validación teórica** (`cramer_rao.py`): información de Fisher y cota de Cramér–Rao para el índice de sentimiento agregado, bajo los modelos gaussiano y Laplaciano, más prueba de normalidad (Shapiro–Wilk) y estimación bootstrap de la varianza del estimador.
4. **Visualización interactiva**: interfaz Streamlit con páginas para carga de datos, métricas del curso, análisis de sentimiento y validación teórica, con interpretaciones automáticas

en lenguaje natural para cada métrica.

2.2. Funcionalidades del software

2.2.1. Bandera de riesgo académico

Sea c_i la calificación final del alumno i y $e_i \in \{\text{Normal}, \dots\}$ su estado de validación (reposición, examen final, baja, etc.). El sistema define

$$r_i = \mathbf{1}\{c_i < 70\} \vee \mathbf{1}\{e_i \neq \text{Normal}\},$$

es decir, un alumno está en riesgo si su calificación cae por debajo del umbral aprobatorio (70) o si tiene un estado especial registrado, independientemente de la calificación numérica.

2.2.2. Índice de sentimiento por transformada wavelet

Para cada alumno i , el modelo de *sentence-transformers* multilingüe (`paraphrase-multilingual-MiniLM-L12-v2`, dimensión $d = 384$) [8] produce, en un solo *forward pass*: el embedding de oración $x_i \in \mathbb{R}^d$ (normalizado a norma unitaria) y, para cada token $t = 1, \dots, L_i$ de la respuesta, un embedding contextual $u_{i,t} \in \mathbb{R}^d$. A partir de estos se construye una señal escalar *indexada por posición del token en el texto* —un eje con adyacencia temporal genuina, a diferencia de las coordenadas del embedding—, proyectando cada token sobre la dirección semántica global de la respuesta:

$$s_i(t) = \langle u_{i,t}, x_i \rangle, \quad t = 1, \dots, L_i.$$

Sobre esta señal 1D se aplica la transformada discreta de onduleta [7] con familia Daubechies 4 y nivel de descomposición $J = 3$ por defecto, acotado en la práctica por `min(pywt.dwt_max_level(L_i, wavelet))` —la respuesta más corta del lote, no una dimensión fija—:

$$\text{wavedec}(s_i, J) = (c_A^{(i)}, c_{D,1}^{(i)}, \dots, c_{D,J}^{(i)}),$$

donde $c_A^{(i)}$ son los coeficientes de aproximación (tendencia global de la respuesta, de baja frecuencia *en la posición*) y $c_{D,j}^{(i)}$ los coeficientes de detalle en el nivel j (fluctuación local palabra a palabra, de alta frecuencia). Se definen las energías

$$E_i^{\text{apr}} = \|c_A^{(i)}\|_2^2, \quad E_i^{\text{det}} = \sum_{j=1}^J \|c_{D,j}^{(i)}\|_2^2,$$

y el índice de sentimiento del alumno i se define como

$$\hat{\theta}_i = \tanh\left(\frac{E_i^{\text{det}} - E_i^{\text{apr}}}{E_i^{\text{det}} + E_i^{\text{apr}} + \varepsilon}\right), \quad \varepsilon = 10^{-9},$$

de modo que $\hat{\theta}_i \in (-1, 1)$: valores cercanos a -1 indican energía concentrada en la aproximación (respuesta contextual, poca fluctuación local) y valores cercanos a $+1$ indican energía concentrada en los detalles (alta variabilidad local, interpretada aquí como carga emocional puntual).

Corrección de diseño

En una versión anterior de este pipeline, la DWT se aplicaba directamente sobre las 384 coordenadas de x_i , tratándolas como si fueran una señal temporal. Esas coordenadas son ejes de un espacio de características aprendido sin orden ni adyacencia intrínsecos: permutarlas no cambia el significado del texto, pero sí cambiaba E_i^{apr} y E_i^{det} bajo esa versión, de modo que la lectura “aproximación = contenido estable, detalle = emoción” no estaba justificada por la matemática de la transformada. La formulación de arriba —proyectar cada token sobre el embedding de oración y aplicar la DWT sobre la *posición del token*— usa un eje con estructura secuencial genuina, para el cual la separación de la DWT en tendencia global (aproximación) y fluctuación local (detalle) sí tiene el respaldo habitual de la teoría de wavelets [7]. Código: `processing/nlp_wavelet.py` (`obtener_embeddings_token`, `señal_por_posicion`, `aplicar_dwt_posicional`).

Una versión intermedia de `obtener_embeddings_token` —posterior a la corrección anterior— sí construía la señal posicional como aquí se describe, pero llamaba `modelo.encode()` *dos veces* (una para el embedding de oración, otra para los embeddings de token), es decir dos *forward passes*, mientras el docstring y una versión anterior de este párrafo afirmaban que ambas salidas provenían de “un solo forward pass”. Ambas cosas eran ciertas por separado y falsas juntas. La versión actual usa una sola llamada con `output_value=None`, que sentence-transformers documenta como forma de obtener todas las salidas (incluyendo `sentence_embedding` y `token_embeddings`) de un único *forward pass*, haciendo cierta la afirmación de arriba.

2.2.3. Validación estadística: información de Fisher y cota de Cramér–Rao

Sea $\hat{\theta} = (\hat{\theta}_1, \dots, \hat{\theta}_N)$ la muestra de índices de sentimiento del grupo (los datos, no estimadores individuales de nada), tratada como N observaciones i.i.d. de una distribución con parámetro de localización μ (el sentimiento promedio del grupo), y $\bar{\theta} = \frac{1}{N} \sum_i \hat{\theta}_i$ el estimador de media muestral de μ . La cota de Cramér–Rao [1, 2, 3] acota inferiormente la varianza de cualquier estimador insesgado de μ :

$$\text{Var}(\bar{\theta}) \geq \frac{1}{F(\mu)}, \quad F(\mu) = -\mathbb{E} \left[\frac{\partial^2}{\partial \mu^2} \ln p(X; \mu) \right],$$

donde $X = (\hat{\theta}_1, \dots, \hat{\theta}_N)$ denota la muestra completa (de modo que $p(X; \mu) = \prod_i p(\hat{\theta}_i; \mu)$) y $F(\mu)$ ya incorpora el factor N , como en las fórmulas explícitas de abajo).

Fórmulas clave

Modelo gaussiano. Bajo $\theta \sim \mathcal{N}(\mu, \sigma^2)$, con $\hat{\mu} = \bar{\theta}$ y $\hat{\sigma}^2$ la varianza muestral insesgada:

$$F(\mu) = \frac{N}{\hat{\sigma}^2}, \quad \text{CRB}_\mu = \frac{1}{F(\mu)} = \frac{\hat{\sigma}^2}{N}.$$

Modelo Laplaciano. Bajo $\theta \sim \text{Laplace}(\mu, b)$, con $\hat{\mu} = \text{mediana}(\hat{\theta})$ y $\hat{b} = \frac{1}{N} \sum_i |\hat{\theta}_i - \hat{\mu}|$:

$$F(\mu) = \frac{N}{\hat{b}^2}, \quad \text{CRB}_\mu = \frac{\hat{b}^2}{N}.$$

A diferencia del caso gaussiano, donde la media muestral alcanza la cota *exactamente* para todo N , la mediana muestral es el EMV de μ bajo el modelo Laplaciano y solo alcanza la cota *asintóticamente* ($N \rightarrow \infty$); para N finito su varianza puede exceder CRB_μ . **Eficiencia empírica del estimador (EES).** Con $\widehat{\text{Var}}(\bar{\theta})$ estimada por *bootstrap* [5] ($B = 500$ remuestreos con reemplazo):

$$\text{EES} = \min\left(\frac{\text{CRB}_\mu}{\widehat{\text{Var}}(\bar{\theta})}, 1\right).$$

El sistema complementa este cómputo con una prueba de normalidad de Shapiro–Wilk [4] sobre $\hat{\theta}$: si el valor p resultante es menor a 0.05, se recomienda reportar el modelo Laplaciano (más robusto a colas pesadas) en lugar del gaussiano, y usar la mediana muestral —el estimador óptimo bajo ese modelo— en vez de la media.

Observación 2.1. La cota de Cramér–Rao certifica algo preciso y limitado: qué tan cerca está la *media muestral* de $\hat{\theta}$ de ser un estimador óptimo de sí misma bajo un modelo paramétrico supuesto. No certifica que $\hat{\theta}$ mida “sentimiento real” correctamente, ni sustituye una validación externa (p. ej. contra anotación humana) del índice.

Hueco: qué NO certifica esta verificación

Bajo el modelo gaussiano con σ^2 desconocida y estimada por $\hat{\sigma}^2$, la media muestral es el estimador insesgado de varianza mínima de μ para *todo* N (Lehmann–Scheffé), con $\text{Var}(\bar{\theta}) = \sigma^2/N$ exactamente. Es decir, bajo ese modelo la eficiencia es 1 por construcción, no por mérito del pipeline NLP–wavelet: no hay ningún estimador alternativo de μ que pudiera ganarle a la media muestral. La comparación que hace el sistema — $\text{CRB}_\mu = \hat{\sigma}^2/N$ contra $\widehat{\text{Var}}(\bar{\theta})$ estimada por *bootstrap sobre la misma muestra*— es, en el límite de N grande, una comparación entre dos maneras de estimar la *misma* cantidad (σ^2/N) a partir de los *mismos* datos: la fórmula normal con $\hat{\sigma}^2$ plug-in, y el remuestreo. Que ambas coincidan ($\text{EES} \approx 1$) es entonces, en gran medida, una prueba de consistencia numérica entre bootstrap y la fórmula asintótica de la varianza de la media —algo que ocurre para casi cualquier muestra razonablemente grande, independientemente de qué tan bien el pipeline de embeddings y wavelets capture sentimiento real—, y *no* es evidencia de que el pipeline NLP–wavelet extraiga la máxima información posible del texto. Verificar eso último exigiría comparar $\hat{\theta}$

contra una pipeline de extracción de características alternativa (o contra anotación humana) sobre el mismo texto, no solo verificar que la media muestral de $\hat{\theta}$ es un buen estimador de sí misma. Sección 3 lo ilustra numéricamente: en la simulación, EES = 100 % a pesar de que $\hat{\theta}$ rechaza normalidad (Shapiro–Wilk $p < 10^{-3}$). Los textos de interpretación de la interfaz (`interpretar_crb` en `interpretacion.py`, y el “Marco Teórico” de `validacion.py`) sobreclamaban exactamente esto y ya fueron corregidos para reflejar el alcance real de la verificación.

2.2.4. Correlación con desempeño académico

Como paso final del análisis, el sistema calcula el coeficiente de correlación de Pearson r [6] entre $\hat{\theta}_i$ y la calificación c_i de cada alumno, junto con su valor p asociado y el tamaño de muestra N . Una correlación negativa significativa ($r < 0$, $p < 0.05$) se interpreta como evidencia de que mayor carga emocional en las respuestas se asocia con menor desempeño; una correlación positiva significativa se interpreta como posible motivación extrínseca. El sistema clasifica la fuerza de la asociación en umbrales ($|r| \geq 0.6$ fuerte, $|r| \geq 0.3$ moderada, $|r| < 0.3$ débil) y explícitamente reporta cuando la correlación no es significativa, sin forzar una narrativa de riesgo donde no hay evidencia estadística.

3. Ejemplo ilustrativo

Estas figuras son simulación, no datos de curso

Ningún dato de alumnos reales se usó para generar esta sección. Las señales, embeddings y calificaciones son sintéticas, construidas para ejercitar el código real de `processing/nlp_wavelet.py` y `processing/cramer_rao.py` —las mismas funciones que usa la aplicación— sobre entradas controladas, con el único fin de mostrar cómo se leen las gráficas que el sistema produce y de exhibir numéricamente el punto de la sección 2.2.3. La correlación de la figura 4 está impuesta por construcción en la simulación, no observada. Código de generación: `generar_figuras_articulo.py`.

Simulamos $N = 60$ respuestas de longitud variable (L_i entero uniforme en $\{12, \dots, 54\}$ tokens), cada una con una “intensidad emocional” $e_i \sim \text{Gamma}(2, 0.5)$ que controla la amplitud de ráfagas locales insertadas en una tendencia de caminata aleatoria (figura 1), y una calificación simulada $c_i = \text{clip}(92 - 9e_i + \eta_i, 40, 100)$ con $\eta_i \sim \mathcal{N}(0, 6^2)$, para poder ilustrar la lectura de una correlación negativa.




Figura 1. Dos señales posicionales simuladas $s_i(t)$: una con baja intensidad emocional impuesta (izquierda) y otra con ráfagas locales marcadas (derecha), que producen E^{det} bajo y alto respectivamente.




Figura 2. Distribución de $\hat{\theta}$ sobre el grupo simulado ($N = 60$). La asimetría visible es consistente con el rechazo de normalidad reportado en el texto (Shapiro–Wilk $p < 10^{-3}$).




Figura 3. Distribución bootstrap de $\bar{\theta}$ ($B = 500$) contra la banda $\bar{\theta} \pm \sqrt{\text{CRB}_\mu}$. En esta simulación $\text{EES} = 100\%$ a pesar de que $\hat{\theta}$ rechaza normalidad — el punto central de la sección 2.2.3: esta cifra no mide si el pipeline extrae información del texto.




Figura 4. Correlación simulada entre $\hat{\theta}$ y la calificación, impuesta por construcción (c_i se definió como función decreciente de la intensidad emocional simulada e_i) para ilustrar cómo se lee esta gráfica en la interfaz real.

3.1. Análisis de sensibilidad

Las secciones anteriores *afirman* que $\hat{\theta}$ depende del tamaño de la muestra, de la familia de onduleta y del nivel de descomposición, pero hasta aquí no lo mostraban con números. Esta subsección lo hace, ejecutando el mismo código real (`aplicar_dwt_posicional`, `calcular_indice_sentimiento`, `calcular_cramer_rao`) sobre variaciones controladas de la simulación anterior (`generar_figuras_sensibilidad.py`). Como el resto de esta sección, son simulaciones, no datos de curso.

Sensibilidad a N . Para $N \in \{8, 10, 15, 20, 30, 40, 60, 100, 150, 250\}$, con 20 réplicas independientes por valor de N , medimos el ancho del intervalo bootstrap $2\sqrt{\widehat{\text{Var}}(\hat{\theta})}$ y el EES (figura 5). El panel derecho confirma la afirmación de la sección 4: el ancho del intervalo decrece de forma consistente y su variabilidad entre réplicas es mucho mayor para $N < 30$ que para N grande. El panel izquierdo, en cambio, revela algo que la sección 2.2.3 ya anticipaba: el EES se mantiene entre 0.96 y 1.00 en *todo* el rango de N probado, sin una tendencia clara de mejora — consistente con que, bajo el modelo gaussiano, la eficiencia no mide qué tan bueno es el pipeline, sino una propiedad de la media muestral que se cumple casi siempre.




Figura 5. Sensibilidad a N (20 réplicas por valor de N). Izquierda: EES se mantiene alto independientemente de N . Derecha: el ancho del intervalo bootstrap sí decrece y se estabiliza con N , y es notablemente más disperso entre réplicas para $N < 30$.

Sensibilidad a la familia de onduleta. Sobre las mismas 60 señales simuladas, calculamos $\hat{\theta}$ con cada una de las seis familias que ofrece la interfaz real (`WAVELETS_DISPONIBLES` en `pages/sentimiento.py`): db4, db2, haar, sym4, coif2 y dmey (figura 6). En distribución agregada (mediana y dispersión), db4, sym4, coif2 y dmey se ven similares en la gráfica de caja, pero la correlación de Pearson punto a punto contra db4 —qué tan de acuerdo están dos familias sobre *cuál* alumno tiene un $\hat{\theta}$ alto o bajo, no solo sobre la forma de la distribución agregada— cuenta una historia más matizada: coif2 ($r = 0.80$) y dmey ($r = 0.72$) sí concuerdan de cerca con db4; sym4, a pesar de su distribución agregada visualmente parecida, concuerda más débilmente a nivel individual ($r = 0.59$, comparable a db2); db2 tiene una correlación moderada ($r = 0.77$) pero con una cola de valores atípicos positivos; **haar es cualitativamente distinta**: su mediana se acerca a cero y su rango intercuartílico cruza el signo, con la correlación más baja del grupo ($r = 0.50$). Esto

tiene una explicación directa para haar: es la familia con el filtro más corto (longitud 2), por lo que su separación aproximación/detalle captura una noción de “local” mucho más fina y ruidosa que las familias con filtros más largos. En la práctica, esto significa que la elección por defecto (db4) no es intercambiable con *todas* las opciones del menú: cambiar a haar puede cambiar el signo del índice reportado para el mismo texto, y aun familias con distribución agregada similar (sym4) pueden reordenar de forma no trivial qué alumnos quedan en los extremos.




Figura 6. Distribución de $\hat{\theta}$ para las seis familias de onduleta de la interfaz, sobre las mismas 60 señales simuladas. db4/sym4/coif2/dmey concuerdan de cerca; haar –el filtro más corto– es cualitativamente distinta.

Sensibilidad al nivel J : acotado por la respuesta más corta. Al variar $J \in \{1, \dots, 5\}$ sobre las mismas señales cortas (12–54 tokens) de esta sección, el nivel *efectivamente* usado quedó fijo en 1 para los cinco valores de J solicitados –`aplicar_dwt_posicional` acota el nivel por la respuesta más corta del lote (sección 2.2.2)–, de modo que $\hat{\theta}$ no cambió en absoluto al variar J (figura 7, panel izquierdo). Como control, repetimos el experimento con respuestas simuladas largas (150–400 tokens): ahí el nivel efectivo sí sube con J (1, 2, 3, 4, 4) y $\hat{\theta}$ se desplaza notablemente, con dispersión creciente en los niveles más altos (panel derecho).

Hallazgo: el parámetro J es efectivamente inútil para encuestas típicas

Con las longitudes de respuesta simuladas en esta sección (representativas de comentarios cortos de encuesta), el parámetro J que el usuario elige en la interfaz no tiene ningún efecto: basta una sola respuesta corta en el lote para que el nivel efectivo quede acotado en 1 independientemente de qué tan alto se pida J . El control deslizante “Nivel de descomposición J ” de `pages/sentimiento.py` solo importa, en la práctica, para encuestas con respuestas consistentemente largas. Agregamos una advertencia en la interfaz (`pages/sentimiento.py`) que avisa explícitamente cuando esto ocurre, en vez de dejar que el usuario suba J sin efecto visible y sin saber por qué.




Figura 7. Sensibilidad a J en dos regímenes: respuestas cortas (izquierda, nivel efectivo atorado en 1) y respuestas largas (derecha, nivel efectivo sube con J y $\hat{\theta}$ cambia de verdad).

4. Impacto

El sistema apunta a un problema genérico de docencia (no solo de un curso o institución): la señal cualitativa de una encuesta de retroalimentación abierta rara vez se analiza con la misma rigurosidad que la señal cuantitativa de calificaciones, a pesar de estar disponible en prácticamente cualquier curso. Al empaquetar embeddings de token, DWT y verificación Fisher/Cramér–Rao en un pipeline reproducible con interfaz interactiva, el sistema baja el costo de entrada para que un docente sin formación en NLP o teoría de la estimación pueda producir y —sobre todo— *interpretar correctamente* un índice de sentimiento agregado por grupo, incluyendo cuándo *no* confiar en él. Esa última parte es, en la práctica, el componente menos común en herramientas similares: la mayoría de los tableros de analítica educativa reportan una cifra sin decir qué garantiza matemáticamente esa cifra ni qué no.

El límite honesto al reuso inmediato es el que ya se documentó en las secciones anteriores: el índice $\hat{\theta}$ depende del modelo de embeddings elegido, de la familia y nivel de la wavelet, y del tamaño de la encuesta —cuantificado en el análisis de sensibilidad de la sección 3.1: la familia haar es cualitativamente distinta a las demás, y J no tiene efecto alguno para respuestas cortas—; con $N < 30$ las estimaciones bootstrap de varianza son inestables y el propio sistema advierte de ello en la interfaz. Las interpretaciones textuales que genera el módulo `interpretacion.py` son sugerencias de lectura, no conclusiones definitivas, y deben cotejarse con el criterio del docente y, cuando el caso lo amerite, con apoyo psicopedagógico institucional. Como se documentó en sección 2.2.3, la verificación de Cramér–Rao certifica la coherencia estadística de $\bar{\theta}$ bajo el modelo supuesto, no la calidad de $\hat{\theta}$ como medida de sentimiento; esa segunda pregunta —la que de verdad importaría validar para justificar adopción institucional— queda abierta y requeriría comparación externa (anotación humana, u otra pipeline de extracción) sobre datos reales de curso, algo que este artículo deliberadamente no reporta. Mientras esa validación no exista, el reuso responsable del sistema es como herramienta exploratoria y de apoyo, no como criterio único de decisión sobre un alumno.

Reuso

Código, datos de ejemplo, 22 pruebas automatizadas (`pytest`, ejecutadas en CI en cada *push*) y licencia MIT en github.com/Gabriel44svg/...-SIAMDA (véase también el cuadro 1). Los detalles de arquitectura y dependencias están en la sección 2.1.

5. Conclusiones

Este sistema integra dos señales de un curso —calificaciones y respuestas abiertas de encuesta— bajo un mismo tablero, y añade a la segunda una métrica reproducible ($\hat{\theta}$, vía embeddings de token, proyección posicional y DWT) junto con una verificación estadística de la coherencia de su media agregada (información de Fisher y cota de Cramér–Rao, bajo modelos gaussiano y Laplaciano). El resultado es un sistema de alerta temprana que hace explícito, en vez de impresionista, el vínculo entre el tono de las respuestas de un grupo y su desempeño, y que documenta honestamente qué certifica su capa estadística y qué no. Queda como trabajo futuro la validación de $\hat{\theta}$ contra anotación humana sobre datos reales de curso.

Declaración de conflicto de intereses

Los autores declaran no tener conflictos de interés conocidos que pudieran haber influido en el trabajo reportado en este artículo.

Referencias

- [1] R. A. Fisher, *On the mathematical foundations of theoretical statistics*, Philos. Trans. R. Soc. Lond. A **222** (1922), 309–368.
- [2] C. R. Rao, *Information and the accuracy attainable in the estimation of statistical parameters*, Bull. Calcutta Math. Soc. **37** (1945), 81–91.
- [3] H. Cramér, *Mathematical Methods of Statistics*, Princeton University Press, 1946.
- [4] S. S. Shapiro and M. B. Wilk, *An analysis of variance test for normality (complete samples)*, Biometrika **52** (1965), no. 3/4, 591–611.
- [5] B. Efron, *Bootstrap methods: another look at the jackknife*, Ann. Statist. **7** (1979), no. 1, 1–26.
- [6] K. Pearson, *Mathematical contributions to the theory of evolution. III. Regression, heredity, and panmixia*, Philos. Trans. R. Soc. Lond. A **187** (1896), 253–318.

- [7] S. G. Mallat, *A theory for multiresolution signal decomposition: the wavelet representation*, IEEE Trans. Pattern Anal. Mach. Intell. **11** (1989), no. 7, 674–693.
- [8] N. Reimers and I. Gurevych, *Sentence-BERT: sentence embeddings using Siamese BERT-networks*, in Proc. 2019 Conf. Empirical Methods in Natural Language Processing (EMNLP-IJCNLP), Hong Kong, 2019, pp. 3982–3992.