

Fundamentos de Econometría

Hoja de ejercicios: Mínimos Cuadrados Ordinarios (MCO)

César Galindo

Universidad Panamericana · Licenciatura en Finanzas · ECO515

Otoño 2026

Índice

1. Álgebra y deducción	6
2. Cálculo numérico	8
3. Interpretación y aplicaciones	10
4. Estilo examen CFA (opción múltiple)	12
5. Reto (opcional)	14

Idea central

Conjunto de ejercicios de práctica sobre MCO en la regresión lineal simple $y_i = \beta_0 + \beta_1 x_i + u_i$, complementario a las notas *Suma de variables aleatorias, varianza, covarianza, y la deducción de los estimadores de MCO*. Se agrupan en cinco bloques: (I) álgebra y deducción, (II) cálculo numérico, (III) interpretación y aplicaciones, (IV) preguntas de opción múltiple estilo examen CFA, (V) un reto opcional. Varios ejercicios incluyen solución completa; otros se dejan propuestos, algunos con sugerencia.

Recordatorio

Para toda la hoja, $\bar{x}$, $\bar{y}$ son las medias muestrales, $S_{xx} = \sum_i (x_i - \bar{x})^2$, $S_{yy} = \sum_i (y_i - \bar{y})^2$, $S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y})$, y los estimadores de MCO son

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}, \quad \hat{u}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i,$$

con $\sum_i \hat{u}_i = 0$ y $\sum_i x_i \hat{u}_i = 0$ (ecuaciones normales).

Deducción vía derivadas parciales

Un camino alternativo a las fórmulas de MCO, complementario al del Ejercicio 1.1 (que no usa cálculo diferencial): aquí se usa, y se muestra completo, paso a paso, con las **dos** formas usuales de resolver el sistema 2×2 resultante –por la inversa de la matriz y por la regla de Cramer– para que se vea que dan exactamente el mismo resultado.

Paso 1: la función a minimizar.

$$\text{SCR}(b_0, b_1) = \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2.$$

Paso 2: derivar cada término y sumar. Para un término genérico, por la regla de la cadena,

$$\frac{\partial}{\partial b_0} (y_i - b_0 - b_1 x_i)^2 = 2(y_i - b_0 - b_1 x_i)(-1), \quad \frac{\partial}{\partial b_1} (y_i - b_0 - b_1 x_i)^2 = 2(y_i - b_0 - b_1 x_i)(-x_i).$$

Sumando sobre $i = 1, \dots, n$ (derivar bajo el signo de suma es válido porque es una suma finita):

$$\frac{\partial \text{SCR}}{\partial b_0} = -2 \sum_i (y_i - b_0 - b_1 x_i), \quad \frac{\partial \text{SCR}}{\partial b_1} = -2 \sum_i x_i (y_i - b_0 - b_1 x_i).$$

Paso 3: condiciones de primer orden. Igualando ambas derivadas a cero en $(b_0, b_1) = (\hat{\beta}_0, \hat{\beta}_1)$ y dividiendo entre -2 :

$$\sum_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0, \quad \sum_i x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0.$$

Paso 4: distribuir la suma y agrupar las incógnitas a la izquierda. Distribuyendo cada suma y separando los términos con $\hat{\beta}_0, \hat{\beta}_1$ de los que no los tienen:

$$\sum_i y_i - n\hat{\beta}_0 - \hat{\beta}_1 \sum_i x_i = 0 \implies n\hat{\beta}_0 + \left(\sum_i x_i\right)\hat{\beta}_1 = \sum_i y_i,$$

$$\sum_i x_i y_i - \hat{\beta}_0 \sum_i x_i - \hat{\beta}_1 \sum_i x_i^2 = 0 \implies \left(\sum_i x_i\right)\hat{\beta}_0 + \left(\sum_i x_i^2\right)\hat{\beta}_1 = \sum_i x_i y_i.$$

Dos ecuaciones lineales en las dos incógnitas $\hat{\beta}_0, \hat{\beta}_1$.

Paso 5: forma matricial. Con $\mathbf{b} = (\hat{\beta}_0, \hat{\beta}_1)^\top$, el sistema del Paso 4 es $\mathbf{A}\mathbf{b} = \mathbf{c}$ con

$$\mathbf{A} = \begin{pmatrix} n & \sum_i x_i \\ \sum_i x_i & \sum_i x_i^2 \end{pmatrix}, \quad \mathbf{c} = \begin{pmatrix} \sum_i y_i \\ \sum_i x_i y_i \end{pmatrix}$$

($\mathbf{A}$ es simétrica: la entrada fuera de la diagonal, $\sum_i x_i$, es la misma arriba a la derecha y abajo a la izquierda, porque viene de la misma suma cruzada en ambas ecuaciones del Paso

4).

Paso 6: la identidad de suma de cuadrados, y det A. Antes de calcular $\det A$ conviene tener a mano la identidad que conecta la suma “cruda” $\sum_i x_i^2$ con S_{xx} . Partiendo de la definición $S_{xx} = \sum_i (x_i - \bar{x})^2$ y expandiendo el cuadrado:

$$S_{xx} = \sum_i (x_i - \bar{x})^2 = \sum_i (x_i^2 - 2x_i\bar{x} + \bar{x}^2) = \sum_i x_i^2 - 2\bar{x} \sum_i x_i + \sum_i \bar{x}^2.$$

El último término es $n\bar{x}^2$ ($\bar{x}^2$ sumado n veces, una por cada i), y como $\bar{x} = \frac{1}{n} \sum_i x_i$ se tiene $\sum_i x_i = n\bar{x}$, así que el término de en medio es $2\bar{x}(n\bar{x}) = 2n\bar{x}^2$. Sustituyendo ambos:

$$S_{xx} = \sum_i x_i^2 - 2n\bar{x}^2 + n\bar{x}^2 = \sum_i x_i^2 - n\bar{x}^2.$$

Falta escribir $n\bar{x}^2$ en términos de $\sum_i x_i$: sustituyendo $\bar{x} = \frac{1}{n} \sum_i x_i$,

$$n\bar{x}^2 = n\left(\frac{1}{n} \sum_i x_i\right)^2 = n \cdot \frac{1}{n^2} \left(\sum_i x_i\right)^2 = \frac{n}{n^2} \left(\sum_i x_i\right)^2 = \frac{1}{n} \left(\sum_i x_i\right)^2$$

(el factor n/n^2 se simplifica a $1/n$, cancelando una n arriba y abajo). Sustituyendo de vuelta:

$$S_{xx} = \sum_i x_i^2 - \frac{(\sum_i x_i)^2}{n}. \quad (\star)$$

Ahora sí, $\det A$: multiplicando *ambos lados* de $(\star)$ por n ,

$$nS_{xx} = n \sum_i x_i^2 - n \cdot \frac{(\sum_i x_i)^2}{n} = n \sum_i x_i^2 - \frac{n}{n} \left(\sum_i x_i\right)^2 = n \sum_i x_i^2 - \left(\sum_i x_i\right)^2$$

(de nuevo $n/n = 1$, así que ese factor simplemente desaparece). El lado derecho es exactamente $\det A = ps - qr$ para las entradas de A del Paso 5 ($p = n$, $s = \sum_i x_i^2$, $q = r = \sum_i x_i$), así que

$$\det A = n \sum_i x_i^2 - \left(\sum_i x_i\right)^2 = nS_{xx},$$

positivo siempre que $S_{xx} > 0$ (es decir, que x_i no sea constante –la misma condición que hace a A invertible). A partir de aquí, dos caminos igual de válidos para resolver $A\mathbf{b} = \mathbf{c}$.

Camino 1: por la inversa de la matriz. *Paso 7a: invertir A.* Con la fórmula de la inversa de una matriz 2×2 , $\begin{pmatrix} p & q \\ r & s \end{pmatrix}^{-1} = \frac{1}{ps - qr} \begin{pmatrix} s & -q \\ -r & p \end{pmatrix}$, y usando $\det A = nS_{xx}$ del Paso 6:

$$A^{-1} = \frac{1}{nS_{xx}} \begin{pmatrix} \sum_i x_i^2 & -\sum_i x_i \\ -\sum_i x_i & n \end{pmatrix}.$$

Paso 8a: $\mathbf{b} = A^{-1}\mathbf{c}$. Multiplicando la matriz por el vector $\mathbf{c}$ del Paso 5, entrada por entrada:

$$\begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} = A^{-1}\mathbf{c} = \frac{1}{n S_{xx}} \begin{pmatrix} \left(\sum_i x_i^2 \right) \left(\sum_i y_i \right) - \left(\sum_i x_i \right) \left(\sum_i x_i y_i \right) \\ n \sum_i x_i y_i - \left(\sum_i x_i \right) \left(\sum_i y_i \right) \end{pmatrix}.$$

Paso 9a: simplificar la segunda entrada, $\hat{\beta}_1$. Se necesita la identidad análoga a $(\star)$ del Paso 6, ahora para S_{xy} . Partiendo de $S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y})$ y expandiendo el producto:

$$S_{xy} = \sum_i (x_i y_i - x_i \bar{y} - \bar{x} y_i + \bar{x} \bar{y}) = \sum_i x_i y_i - \bar{y} \sum_i x_i - \bar{x} \sum_i y_i + n \bar{x} \bar{y}.$$

Con $\sum_i x_i = n\bar{x}$ y $\sum_i y_i = n\bar{y}$, los dos términos de en medio son $\bar{y}(n\bar{x}) = n\bar{x}\bar{y}$ y $\bar{x}(n\bar{y}) = n\bar{x}\bar{y}$; sumados al último término, $-n\bar{x}\bar{y} - n\bar{x}\bar{y} + n\bar{x}\bar{y} = -n\bar{x}\bar{y}$, así que

$$S_{xy} = \sum_i x_i y_i - n\bar{x}\bar{y}.$$

Sustituyendo $\bar{x} = \frac{1}{n} \sum_i x_i$, $\bar{y} = \frac{1}{n} \sum_i y_i$:

$$n\bar{x}\bar{y} = n \left(\frac{1}{n} \sum_i x_i \right) \left(\frac{1}{n} \sum_i y_i \right) = \frac{n}{n^2} \left(\sum_i x_i \right) \left(\sum_i y_i \right) = \frac{1}{n} \left(\sum_i x_i \right) \left(\sum_i y_i \right)$$

(otra vez $n/n^2 = 1/n$), de modo que

$$S_{xy} = \sum_i x_i y_i - \frac{(\sum_i x_i)(\sum_i y_i)}{n}. \quad (\star\star)$$

Multiplicando *ambos lados* de $(\star\star)$ por n :

$$n S_{xy} = n \sum_i x_i y_i - n \cdot \frac{(\sum_i x_i)(\sum_i y_i)}{n} = n \sum_i x_i y_i - \frac{n}{n} \left(\sum_i x_i \right) \left(\sum_i y_i \right) = n \sum_i x_i y_i - \left(\sum_i x_i \right) \left(\sum_i y_i \right)$$

(de nuevo $n/n = 1$). El lado derecho es exactamente el numerador de $\hat{\beta}_1$ del Paso 8a, así que ese numerador es $n S_{xy}$, y

$$\hat{\beta}_1 = \frac{n S_{xy}}{n S_{xx}} = \frac{n}{n} \cdot \frac{S_{xy}}{S_{xx}} = \frac{S_{xy}}{S_{xx}}$$

(el factor $n/n = 1$ se cancela una última vez, dejando el cociente familiar).

Paso 10a: simplificar la primera entrada, $\hat{\beta}_0$. Se suma y se resta $(\sum_i x_i)^2 / n$ dentro

del numerador, y se usan las mismas definiciones de S_{xx} y S_{xy} de los Pasos 6 y 9a:

$$\begin{aligned} \left(\sum_i y_i\right)S_{xx} - S_{xy}\left(\sum_i x_i\right) &= \left(\sum_i y_i\right)\left[\sum_i x_i^2 - \frac{(\sum_i x_i)^2}{n}\right] - \left[\sum_i x_i y_i - \frac{(\sum_i x_i)(\sum_i y_i)}{n}\right]\left(\sum_i x_i\right) \\ &= \left(\sum_i y_i\right)\left(\sum_i x_i^2\right) - \left(\sum_i x_i\right)\left(\sum_i x_i y_i\right) - \underbrace{\frac{(\sum_i x_i)^2(\sum_i y_i)}{n} + \frac{(\sum_i x_i)^2(\sum_i y_i)}{n}}_{=0} \\ &= \left(\sum_i x_i^2\right)\left(\sum_i y_i\right) - \left(\sum_i x_i\right)\left(\sum_i x_i y_i\right), \end{aligned}$$

es decir, el numerador de la primera entrada del Paso 8a es exactamente $(\sum_i y_i)S_{xx} - S_{xy}(\sum_i x_i)$. Dividiendo entre $\det A = n S_{xx}$ y separando la fracción en dos antes de simplificar:

$$\hat{\beta}_0 = \frac{(\sum_i y_i)S_{xx} - S_{xy}(\sum_i x_i)}{n S_{xx}} = \frac{(\sum_i y_i)S_{xx}}{n S_{xx}} - \frac{S_{xy}(\sum_i x_i)}{n S_{xx}}.$$

En el primer término $S_{xx}/S_{xx} = 1$ se cancela, dejando $(\sum_i y_i)/n = \bar{y}$; en el segundo se reagrupa $S_{xy}/S_{xx} = \hat{\beta}_1$ y queda $(\sum_i x_i)/n = \bar{x}$:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

Camino 2: por la regla de Cramer. *Paso 7b: enunciado de Cramer.* Para $A\mathbf{b} = \mathbf{c}$ con $\det A \neq 0$,

$$\hat{\beta}_0 = \frac{\det A_0}{\det A}, \quad \hat{\beta}_1 = \frac{\det A_1}{\det A},$$

donde A_0 es A con su *primera* columna (los coeficientes de $\hat{\beta}_0$) reemplazada por $\mathbf{c}$, y A_1 es A con su *segunda* columna reemplazada por $\mathbf{c}$:

$$A_0 = \begin{pmatrix} \sum_i y_i & \sum_i x_i \\ \sum_i x_i y_i & \sum_i x_i^2 \end{pmatrix}, \quad A_1 = \begin{pmatrix} n & \sum_i y_i \\ \sum_i x_i & \sum_i x_i y_i \end{pmatrix}.$$

Paso 8b: $\det A_0$ y $\det A_1$. Desarrollando cada determinante 2×2 por la fórmula usual ($ps - qr$):

$$\det A_0 = \left(\sum_i y_i\right)\left(\sum_i x_i^2\right) - \left(\sum_i x_i\right)\left(\sum_i x_i y_i\right), \quad \det A_1 = n \sum_i x_i y_i - \left(\sum_i x_i\right)\left(\sum_i y_i\right).$$

Éstas son, entrada por entrada, las mismas dos expresiones que aparecen en el numerador de $\mathbf{b} = A^{-1}\mathbf{c}$ del Paso 8a –no es casualidad: para una matriz 2×2 , la fórmula de la inversa y la regla de Cramer son algebraicamente la misma construcción, sólo organizada de otra manera.

Paso 9b: dividir entre $\det A$. Del Paso 9a, $\det A_1 = n S_{xy}$; del Paso 10a, $\det A_0 =$

$(\sum_i y_i)S_{xx} - S_{xy}(\sum_i x_i)$. Dividiendo cada uno entre $\det A = n S_{xx}$ (Paso 6):

$$\hat{\beta}_1 = \frac{\det A_1}{\det A} = \frac{n S_{xy}}{n S_{xx}} = \frac{n}{n} \cdot \frac{S_{xy}}{S_{xx}} = \frac{S_{xy}}{S_{xx}}$$

(el mismo factor $n/n = 1$ del Paso 9a). Para $\hat{\beta}_0$, se separa la fracción en dos antes de simplificar:

$$\hat{\beta}_0 = \frac{\det A_0}{\det A} = \frac{(\sum_i y_i)S_{xx} - S_{xy}(\sum_i x_i)}{n S_{xx}} = \frac{(\sum_i y_i)S_{xx}}{n S_{xx}} - \frac{S_{xy}(\sum_i x_i)}{n S_{xx}}.$$

En el primer término, $S_{xx}/S_{xx} = 1$ se cancela, dejando $(\sum_i y_i)/n = \bar{y}$; en el segundo, se reagrupa $S_{xy}/S_{xx} = \hat{\beta}_1$ y queda $(\sum_i x_i)/n = \bar{x}$:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

Conclusión. Los dos caminos –inversa de la matriz y regla de Cramer– recuperan exactamente $\hat{\beta}_1 = S_{xy}/S_{xx}$ y $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$, las mismas fórmulas que el Ejercicio 1.1 obtiene completando el cuadrado, sin usar cálculo. Los tres caminos son válidos exactamente bajo la misma condición, $S_{xx} > 0$ (equivalente a $\det A \neq 0$): la elección entre ellos es de conveniencia algebraica, no de contenido matemático distinto.

1. Álgebra y deducción

Ejercicio 1.1 (Deducción sin cálculo diferencial). Pruebe, **sin usar derivadas**, que $(\hat{\beta}_0, \hat{\beta}_1)$ minimiza $\text{SCR}(b_0, b_1) = \sum_i (y_i - b_0 - b_1 x_i)^2$, completando cuadrados en dos pasos:

- Para b_1 fijo, muestre que $b_0 = \overline{(y - b_1 x)}$ minimiza $\sum_i (y_i - b_1 x_i - b_0)^2$, usando la identidad $\sum_i (a_i - b_0)^2 = \sum_i (a_i - \bar{a})^2 + n(\bar{a} - b_0)^2$ con $a_i = y_i - b_1 x_i$.
- Sustituya ese b_0 óptimo de vuelta en SCR para obtener una función *sólo* de b_1 , exprese la como $S_{xx} b_1^2 - 2S_{xy} b_1 + S_{yy}$, y complete el cuadrado en b_1 para mostrar que se minimiza en $b_1 = S_{xy}/S_{xx}$.

Solución. (a) $\sum_i (a_i - b_0)^2 = \sum_i [(a_i - \bar{a}) + (\bar{a} - b_0)]^2 = \sum_i (a_i - \bar{a})^2 + 2(\bar{a} - b_0) \sum_i (a_i - \bar{a}) + n(\bar{a} - b_0)^2$. El término cruzado se anula porque $\sum_i (a_i - \bar{a}) = 0$ (suma de desviaciones respecto a la media). Queda $\sum_i (a_i - \bar{a})^2 + n(\bar{a} - b_0)^2$, suma de un término que no depende de b_0 más un cuadrado no negativo que se anula exactamente en $b_0 = \bar{a} = \overline{(y - b_1 x)} = \bar{y} - b_1 \bar{x}$.

- Sustituyendo $b_0 = \bar{y} - b_1 \bar{x}$, el residual se vuelve $y_i - b_0 - b_1 x_i = (y_i - \bar{y}) - b_1(x_i - \bar{x})$,

así que

$$\begin{aligned}\text{SCR}(b_1) &= \sum_i [(y_i - \bar{y}) - b_1(x_i - \bar{x})]^2 \\ &= \sum_i (y_i - \bar{y})^2 - 2b_1 \sum_i (x_i - \bar{x})(y_i - \bar{y}) + b_1^2 \sum_i (x_i - \bar{x})^2 \\ &= S_{yy} - 2S_{xy} b_1 + S_{xx} b_1^2.\end{aligned}$$

Completando el cuadrado en b_1 (posible porque $S_{xx} > 0$):

$$\text{SCR}(b_1) = S_{xx} \left(b_1 - \frac{S_{xy}}{S_{xx}} \right)^2 + \left(S_{yy} - \frac{S_{xy}^2}{S_{xx}} \right).$$

El segundo término no depende de b_1 ; el primero es S_{xx} (positivo) por un cuadrado, así que es mínimo exactamente cuando el cuadrado se anula: $b_1 = S_{xy}/S_{xx} = \hat{\beta}_1$. Esto recupera las fórmulas de los estimadores de MCO (Recordatorio anterior) sin usar cálculo diferencial en ningún paso –sólo la misma identidad de “completar el cuadrado” usada para probar la desigualdad de Cauchy–Schwarz. $\square$

Ejercicio 1.2 (Invarianza ante un cambio de escala en x). Sea $x'_i = a + bx_i$ ($b \neq 0$) un reescalamiento del regresor (por ejemplo, pasar de tasas en decimales a tasas en puntos porcentuales). Sean $\hat{\beta}_0, \hat{\beta}_1$ los estimadores de MCO de y sobre x , y $\hat{\beta}'_0, \hat{\beta}'_1$ los de y sobre x' . Demuestre que

$$\hat{\beta}'_1 = \frac{\hat{\beta}_1}{b}, \quad \hat{\beta}'_0 = \hat{\beta}_0 - \hat{\beta}_1 \frac{a}{b}.$$

Solución. Como $\bar{x}' = a + b\bar{x}$, se tiene $x'_i - \bar{x}' = b(x_i - \bar{x})$. Por tanto

$$\begin{aligned}S_{x'y} &= \sum_i (x'_i - \bar{x}')(y_i - \bar{y}) = b \sum_i (x_i - \bar{x})(y_i - \bar{y}) = b S_{xy}, \\ S_{x'x'} &= \sum_i (x'_i - \bar{x}')^2 = b^2 \sum_i (x_i - \bar{x})^2 = b^2 S_{xx}.\end{aligned}$$

Entonces $\hat{\beta}'_1 = S_{x'y}/S_{x'x'} = bS_{xy}/(b^2 S_{xx}) = \hat{\beta}_1/b$. Para el intercepto, $\hat{\beta}'_0 = \bar{y} - \hat{\beta}'_1 \bar{x}' = \bar{y} - \frac{\hat{\beta}_1}{b}(a + b\bar{x}) = \bar{y} - \hat{\beta}_1 \bar{x} - \hat{\beta}_1 \frac{a}{b} = \hat{\beta}_0 - \hat{\beta}_1 \frac{a}{b}$. $\square$

Ejercicio 1.3 (Invarianza ante un cambio de escala en y). Sea $y'_i = cy_i$ ($c \neq 0$; por ejemplo, pasar de pesos a miles de pesos). Demuestre que los estimadores de MCO de y' sobre el mismo x satisfacen $\hat{\beta}'_1 = c\hat{\beta}_1$ y $\hat{\beta}'_0 = c\hat{\beta}_0$. (Imite el argumento del Ejercicio 1.2.)

Solución. Como $\bar{y}' = c\bar{y}$, se tiene $y'_i - \bar{y}' = c(y_i - \bar{y})$, mientras que $x_i - \bar{x}$ no cambia. Por tanto

$$S_{xy'} = \sum_i (x_i - \bar{x})(y'_i - \bar{y}') = c \sum_i (x_i - \bar{x})(y_i - \bar{y}) = c S_{xy},$$

y S_{xx} no cambia. Entonces $\hat{\beta}'_1 = S_{xy'}/S_{xx} = c S_{xy}/S_{xx} = c\hat{\beta}_1$, y $\hat{\beta}'_0 = \bar{y}' - \hat{\beta}'_1 \bar{x} = c\bar{y} - c\hat{\beta}_1 \bar{x} = c(\bar{y} - \hat{\beta}_1 \bar{x}) = c\hat{\beta}_0$. $\square$

Ejercicio 1.4 (Cambio de escala simultáneo en x y y). Combine los Ejercicios 1.2 y 1.3 para mostrar que, si $x'_i = a + bx_i$ y $y'_i = cy_i$ simultáneamente ($b, c \neq 0$), entonces

$$\hat{\beta}'_1 = \frac{c}{b} \hat{\beta}_1, \quad \hat{\beta}'_0 = c \hat{\beta}_0 - \frac{ac}{b} \hat{\beta}_1 = c \hat{\beta}_0 - a \hat{\beta}'_1.$$

¿Qué le dice esto sobre por qué, al reportar una regresión, siempre hay que especificar las unidades de x y y ?

Solución. Como $x'_i - \bar{x}' = b(x_i - \bar{x})$ y $y'_i - \bar{y}' = c(y_i - \bar{y})$,

$$S_{x'y'} = \sum_i (x'_i - \bar{x}')(y'_i - \bar{y}') = bc S_{xy}, \quad S_{x'x'} = \sum_i (x'_i - \bar{x}')^2 = b^2 S_{xx},$$

así que $\hat{\beta}'_1 = S_{x'y'}/S_{x'x'} = bc S_{xy}/(b^2 S_{xx}) = (c/b) S_{xy}/S_{xx} = (c/b) \hat{\beta}_1$. Para el intercepto, con $\bar{x}' = a + b\bar{x}$ y $\bar{y}' = c\bar{y}$,

$$\hat{\beta}'_0 = \bar{y}' - \hat{\beta}'_1 \bar{x}' = c\bar{y} - \frac{c}{b} \hat{\beta}_1 (a + b\bar{x}) = c\bar{y} - \frac{ac}{b} \hat{\beta}_1 - c\hat{\beta}_1 \bar{x} = c(\bar{y} - \hat{\beta}_1 \bar{x}) - \frac{ac}{b} \hat{\beta}_1 = c \hat{\beta}_0 - \frac{ac}{b} \hat{\beta}_1,$$

que, usando $\hat{\beta}'_1 = (c/b) \hat{\beta}_1$, también se escribe $\hat{\beta}'_0 = c \hat{\beta}_0 - a \hat{\beta}'_1$. En palabras: reescalar x y y no cambia la forma de la recta ajustada, sólo sus coeficientes –por eso un $\hat{\beta}_1$ reportado sin unidades es ambiguo: el mismo fenómeno económico puede dar una pendiente de 0.7 o de 700 según se mida x en decimales o en puntos base. $\square$

Ejercicio 1.5 (Residuales y valores ajustados no están correlacionados). Demuestre que $\sum_i \hat{u}_i \hat{y}_i = 0$, donde $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ son los valores ajustados.

Solución.

$$\sum_i \hat{u}_i \hat{y}_i = \sum_i \hat{u}_i (\hat{\beta}_0 + \hat{\beta}_1 x_i) = \hat{\beta}_0 \sum_i \hat{u}_i + \hat{\beta}_1 \sum_i x_i \hat{u}_i = \hat{\beta}_0(0) + \hat{\beta}_1(0) = 0,$$

usando las dos ecuaciones normales. Junto con $\sum_i \hat{u}_i = 0$, esto dice que el vector de residuales es *ortogonal*, en el sentido usual del producto punto, tanto al vector constante como al vector de valores ajustados –la razón geométrica detrás de la descomposición $SST = SSE + SSR$ del Ejercicio 3.1. $\square$

2. Cálculo numérico

Ejercicio 2.1. Con la muestra $n = 6$:

i	1	2	3	4	5	6
x_i	2	4	6	8	10	12
y_i	3	5	6	8	7	10

calcule $\bar{x}, \bar{y}, S_{xy}, S_{xx}, S_{yy}$, los estimadores $\hat{\beta}_0, \hat{\beta}_1$, y la suma de cuadrados residuales en el mínimo, $\text{SCR}_{\min} = S_{yy} - S_{xy}^2/S_{xx}$.

Solución. $\bar{x} = 42/6 = 7, \bar{y} = 39/6 = 6.5$.

i	$x_i - \bar{x}$	$y_i - \bar{y}$	producto	$(x_i - \bar{x})^2$
1	-5	-3.5	17.5	25
2	-3	-1.5	4.5	9
3	-1	-0.5	0.5	1
4	1	1.5	1.5	1
5	3	0.5	1.5	9
6	5	3.5	17.5	25
Σ			$S_{xy} = 43$	$S_{xx} = 70$

$$S_{yy} = 3.5^2 + 1.5^2 + 0.5^2 + 1.5^2 + 0.5^2 + 3.5^2 = 12.25 + 2.25 + 0.25 + 2.25 + 0.25 + 12.25 = 29.5.$$

$$\hat{\beta}_1 = \frac{43}{70} \approx 0.6143, \quad \hat{\beta}_0 = 6.5 - 0.6143(7) = 6.5 - 4.3 = 2.2,$$

donde $0.6143 \times 7 = 43 \times 7/70 = 301/70 = 4.3$ exactamente. Finalmente,

$$\text{SCR}_{\min} = S_{yy} - \frac{S_{xy}^2}{S_{xx}} = 29.5 - \frac{43^2}{70} = 29.5 - \frac{1849}{70} \approx 29.5 - 26.414 \approx 3.086.$$

□

Ejercicio 2.2 (Sensibilidad a un dato atípico). Recuerde el ejemplo de las notas con $n = 5$: $x = (1, 2, 3, 4, 5)$, $y = (2, 3, 5, 4, 6)$, para el cual $\hat{\beta}_1 = 0.9$, $\hat{\beta}_0 = 1.3$. Sustituya el último punto por $(5, 20)$ –un dato atípico– y recalcule $\hat{\beta}_0, \hat{\beta}_1$. Compare con los valores originales y comente, en una o dos líneas, qué tan sensible es MCO a un solo dato extremo.

Solución. Con $y = (2, 3, 5, 4, 20)$: $\bar{y} = 34/5 = 6.8$ ($\bar{x} = 3$ no cambia, así que $S_{xx} = 10$ sigue igual). Las desviaciones de y son $(-4.8, -3.8, -1.8, -2.8, 13.2)$, y con $x - \bar{x} = (-2, -1, 0, 1, 2)$ los productos son 9.6, 3.8, 0, -2.8, 26.4, con suma $S_{xy} = 37$. Entonces

$$\hat{\beta}_1 = \frac{37}{10} = 3.7, \quad \hat{\beta}_0 = 6.8 - 3.7(3) = 6.8 - 11.1 = -4.3.$$

La pendiente pasó de 0.9 a 3.7 (más de cuatro veces mayor) y el intercepto de 1.3 a -4.3: un único punto atípico, con la misma x que los demás, basta para dominar por completo la recta ajustada. Esto ilustra por qué MCO no es robusto a valores atípicos –la función objetivo SCR penaliza el error al *cuadrado*, así que una observación lejana pesa desproporcionadamente en la suma. □

Ejercicio 2.3 (Practicar con desviaciones ya calculadas). Para una muestra de $n = 8$ se reportan únicamente las desviaciones respecto a la media: $\sum_i (x_i - \bar{x})(y_i - \bar{y}) = 54$,

$\sum_i (x_i - \bar{x})^2 = 36$, $\sum_i (y_i - \bar{y})^2 = 100$, $\bar{x} = 12$, $\bar{y} = 45$. Sin conocer los datos individuales, calcule $\hat{\beta}_0$, $\hat{\beta}_1$, la correlación muestral $\hat{\rho}_{xy}$, y R^2 .

Solución. $\hat{\beta}_1 = 54/36 = 1.5$. $\hat{\beta}_0 = 45 - 1.5(12) = 45 - 18 = 27$. $\hat{\rho}_{xy} = 54/\sqrt{36 \times 100} = 54/60 = 0.9$. Anticipando el Ejercicio 3.1, $R^2 = \hat{\rho}_{xy}^2 = 0.81$: el regresor explica el 81 % de la variación muestral de y . Nótese que las tres cantidades se obtienen sólo de S_{xy} , S_{xx} , S_{yy} , $\bar{x}$, $\bar{y}$, sin necesidad de los datos individuales –exactamente el mismo principio detrás de reportar una regresión mediante su tabla de resultados en vez de la base de datos completa. $\square$

3. Interpretación y aplicaciones

Ejercicio 3.1 (R^2 es la correlación muestral al cuadrado). Defina $SST = S_{yy}$, $SSE = \sum_i (\hat{y}_i - \bar{y})^2$ (suma de cuadrados explicada) y $SSR = \sum_i \hat{u}_i^2$ (suma de cuadrados residual), con $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$.

- Pruebe la descomposición $SST = SSE + SSR$, mostrando que el término cruzado en $\sum_i [(\hat{y}_i - \bar{y}) + \hat{u}_i]^2$ se anula usando las ecuaciones normales.
- Pruebe que $SSE = S_{xy}^2/S_{xx}$.
- Concluya que $R^2 := SSE/SST = \hat{\rho}_{xy}^2$, donde $\hat{\rho}_{xy} = S_{xy}/\sqrt{S_{xx}S_{yy}}$ es la correlación muestral.

Solución. (a) $y_i - \bar{y} = (\hat{y}_i - \bar{y}) + \hat{u}_i$, así que

$$SST = \sum_i (y_i - \bar{y})^2 = \sum_i (\hat{y}_i - \bar{y})^2 + 2 \sum_i (\hat{y}_i - \bar{y})\hat{u}_i + \sum_i \hat{u}_i^2.$$

El término cruzado es $\sum_i (\hat{y}_i - \bar{y})\hat{u}_i = \hat{\beta}_1 \sum_i (x_i - \bar{x})\hat{u}_i$ (pues $\hat{y}_i - \bar{y} = \hat{\beta}_1(x_i - \bar{x})$), y $\sum_i (x_i - \bar{x})\hat{u}_i = \sum_i x_i \hat{u}_i - \bar{x} \sum_i \hat{u}_i = 0 - 0 = 0$ por las dos ecuaciones normales. Luego $SST = SSE + SSR$.

- $\hat{y}_i - \bar{y} = \hat{\beta}_1(x_i - \bar{x})$, así que $SSE = \hat{\beta}_1^2 \sum_i (x_i - \bar{x})^2 = \hat{\beta}_1^2 S_{xx} = (S_{xy}/S_{xx})^2 S_{xx} = S_{xy}^2/S_{xx}$.

$$(c) R^2 = \frac{SSE}{SST} = \frac{S_{xy}^2/S_{xx}}{S_{yy}} = \frac{S_{xy}^2}{S_{xx}S_{yy}} = \hat{\rho}_{xy}^2. \quad \square$$

Ejercicio 3.2 (Regresión de y sobre x vs. de x sobre y). Sean $\hat{\beta}_{y|x} = S_{xy}/S_{xx}$ la pendiente de regresar y sobre x , y $\hat{\beta}_{x|y} = S_{xy}/S_{yy}$ la de regresar x sobre y (los papeles invertidos). Demuestre que

$$\hat{\beta}_{y|x} \cdot \hat{\beta}_{x|y} = \hat{\rho}_{xy}^2 \leq 1,$$

con igualdad si y sólo si $|\hat{\rho}_{xy}| = 1$ (correlación muestral perfecta). Explique por qué esto muestra que, en general, la recta de regresar y sobre x **no** es la misma que la de regresar x sobre y “despejada” para y .

Solución. $\hat{\beta}_{y|x}\hat{\beta}_{x|y} = \frac{S_{xy}}{S_{xx}} \cdot \frac{S_{xy}}{S_{yy}} = \frac{S_{xy}^2}{S_{xx}S_{yy}} = \hat{\rho}_{xy}^2$, y $\hat{\rho}_{xy}^2 \leq 1$ por la versión muestral de la desigualdad de Cauchy–Schwarz, con igualdad sólo si $|\hat{\rho}_{xy}| = 1$. Si despejar x de $\hat{y} = \hat{\beta}_0 + \hat{\beta}_{y|x}x$ diera la recta de regresar x sobre y , su pendiente (en y) sería $1/\hat{\beta}_{y|x}$; pero la pendiente real de esa segunda regresión es $\hat{\beta}_{x|y}$, y $1/\hat{\beta}_{y|x} = \hat{\beta}_{x|y}$ sólo cuando $\hat{\beta}_{y|x}\hat{\beta}_{x|y} = 1$, es decir, sólo en el caso extremo $|\hat{\rho}_{xy}| = 1$. Fuera de ese caso, las dos rectas de regresión son genuinamente distintas. $\square$

Ejercicio 3.3 (Aplicación: beta de un activo). Un analista corre la regresión $R_i - r_f = \alpha + \beta(R_m - r_f) + u$ (la ecuación de mercado del CAPM) con datos mensuales y obtiene $S_{xy} = 0.0056$, $S_{xx} = 0.0080$, $\overline{R_i - r_f} = 0.012$, $\overline{R_m - r_f} = 0.010$. Calcule $\hat{\beta}$ y $\hat{\alpha}$, e interprete ambos en el lenguaje del CAPM (¿el activo es más o menos volátil que el mercado? ¿hay evidencia de rendimiento anormal?).

Solución. $\hat{\beta} = 0.0056/0.0080 = 0.70$. Como $\hat{\beta} < 1$, el activo es –según esta muestra– menos volátil que el mercado (un movimiento de 1 % en el exceso de mercado se asocia, en promedio, con un movimiento de sólo 0.70 % en el exceso del activo). El intercepto es $\hat{\alpha} = 0.012 - 0.70(0.010) = 0.012 - 0.007 = 0.005$, es decir, un “alfa” positivo de 0.5 % mensual no explicado por el riesgo de mercado –potencial evidencia de rendimiento anormal, aunque una conclusión firme requeriría una prueba de hipótesis sobre $\hat{\alpha}$ (Sección 3 del syllabus), no sólo su signo. $\square$

Ejercicio 3.4 (MCO con un regresor binario: diferencia de medias). Suponga que $x_i \in \{0, 1\}$ es una variable *dummy* (por ejemplo, $x_i = 1$ si la empresa i paga dividendos, 0 si no), con n_1 observaciones en el grupo $x = 1$ y $n_0 = n - n_1$ en el grupo $x = 0$. Sean $\bar{y}_1$ y $\bar{y}_0$ las medias muestrales de y dentro de cada grupo. Demuestre que

$$\hat{\beta}_1 = \bar{y}_1 - \bar{y}_0, \quad \hat{\beta}_0 = \bar{y}_0.$$

Solución. Como $x_i \in \{0, 1\}$, $\bar{x} = n_1/n$, y $\bar{y} = (n_0\bar{y}_0 + n_1\bar{y}_1)/n$. Para las observaciones con $x_i = 1$, $x_i - \bar{x} = 1 - n_1/n = n_0/n$; para las de $x_i = 0$, $x_i - \bar{x} = -n_1/n$. Separando la suma S_{xy} por grupo,

$$\begin{aligned} S_{xy} &= \frac{n_0}{n} \sum_{i: x_i=1} (y_i - \bar{y}) - \frac{n_1}{n} \sum_{i: x_i=0} (y_i - \bar{y}) \\ &= \frac{n_0}{n} n_1(\bar{y}_1 - \bar{y}) - \frac{n_1}{n} n_0(\bar{y}_0 - \bar{y}) = \frac{n_0 n_1}{n} [(\bar{y}_1 - \bar{y}) - (\bar{y}_0 - \bar{y})] = \frac{n_0 n_1}{n} (\bar{y}_1 - \bar{y}_0). \end{aligned}$$

Análogamente, $S_{xx} = n_1(\frac{n_0}{n})^2 + n_0(\frac{n_1}{n})^2 = \frac{n_0 n_1 (n_0 + n_1)}{n^2} = \frac{n_0 n_1}{n}$. Por lo tanto

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{(n_0 n_1 / n)(\bar{y}_1 - \bar{y}_0)}{n_0 n_1 / n} = \bar{y}_1 - \bar{y}_0,$$

y $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$. Sustituyendo $\bar{y} = (n_0\bar{y}_0 + n_1\bar{y}_1)/n$ y $\bar{x} = n_1/n$:

$$\hat{\beta}_0 = \frac{n_0\bar{y}_0 + n_1\bar{y}_1}{n} - (\bar{y}_1 - \bar{y}_0) \frac{n_1}{n} = \frac{n_0\bar{y}_0 + n_1\bar{y}_1 - n_1\bar{y}_1 + n_1\bar{y}_0}{n} = \frac{(n_0 + n_1)\bar{y}_0}{n} = \bar{y}_0. \quad \square$$

Recordatorio

Regresar y sobre una dummy es, algebraicamente, exactamente lo mismo que comparar la media de y entre dos grupos: $\hat{\beta}_0$ es la media del grupo base ($x = 0$) y $\hat{\beta}_1$ es la diferencia de medias entre grupos. Ésta es la base de por qué, más adelante en el curso (Tema 4, variables cualitativas), MCO con variables dummy se usa para probar diferencias entre grupos con toda la maquinaria de inferencia de la regresión (Tema 3): una prueba t sobre $\hat{\beta}_1$ es, en este caso particular, una prueba de diferencia de medias.

4. Estilo examen CFA (opción múltiple)**Idea central**

Los exámenes CFA presentan la pendiente de MCO como $\hat{\beta}_1 = \text{Cov}(x, y) / \text{Var}(x)$, usando la covarianza y la varianza *muestrales estándar* (divididas entre $n - 1$), en vez de las sumas sin dividir S_{xy}, S_{xx} usadas en el resto de esta hoja. El primer ejercicio muestra que ambas notaciones dan exactamente el mismo número; los siguientes son preguntas de opción múltiple con el formato de tres alternativas (A/B/C) típico del examen.

Ejercicio 4.1 (De S_{xy}/S_{xx} a $\text{Cov}(x, y)/\text{Var}(x)$). La covarianza y varianza muestrales *estándar* son $\text{Cov}(x, y) = S_{xy}/(n - 1)$ y $\text{Var}(x) = S_{xx}/(n - 1)$. Demuestre que $\text{Cov}(x, y)/\text{Var}(x) = S_{xy}/S_{xx} = \hat{\beta}_1$, y explique por qué no importa si el software (o el examen) usa $n - 1$ o n en el denominador.

Solución.

$$\frac{\text{Cov}(x, y)}{\text{Var}(x)} = \frac{S_{xy}/(n - 1)}{S_{xx}/(n - 1)} = \frac{S_{xy}}{S_{xx}} = \hat{\beta}_1,$$

porque el factor $1/(n - 1)$ aparece igual en numerador y denominador y se cancela. El mismo argumento funciona con cualquier otro divisor común (por ejemplo n): $\hat{\beta}_1$ es un *cociente* de dos cantidades que se reescalan juntas, así que su valor no depende de la convención de normalización que use un paquete estadístico en particular –sólo debe usarse la **misma** convención en la covarianza y en la varianza a la vez. $\square$

Ejercicio 4.2 (Pendiente a partir de covarianza y varianza reportadas). Un analista de renta variable estima $R_{i,t} = \alpha + \beta R_{m,t} + u_t$ con 36 meses de datos y reporta $\text{Cov}(R_i, R_m) = 0.00186$ y $\text{Var}(R_m) = 0.00150$ (estadísticas estándar, ya divididas entre $n - 1 = 35$). ¿Cuál de las siguientes opciones está más cerca del valor de $\hat{\beta}$?

- (A) 0.81
- (B) 1.24
- (C) 1.55

Solución. $\hat{\beta} = \text{Cov}(R_i, R_m) / \text{Var}(R_m) = 0.00186 / 0.00150 = 1.24$. Respuesta (B). (Que Cov y Var ya estén divididas entre $n - 1$ no cambia nada, por el Ejercicio 4.1.) $\square$

Ejercicio 4.3 (Correlación y proporción de varianza no explicada). La correlación muestral entre el rendimiento de un fondo y el de su benchmark es $\hat{\rho} = 0.72$. Un cliente pregunta qué porcentaje de la variación del rendimiento del fondo **no** queda explicado por el benchmark. ¿Cuál de las siguientes opciones es la más cercana?

- (A) 28.0 %
- (B) 48.2 %
- (C) 51.8 %

Solución. $R^2 = \hat{\rho}^2 = 0.72^2 = 0.5184$ es la proporción *explicada* (51.8 %, opción (C) –una trampa clásica para quien confunde R^2 con la proporción no explicada). Lo no explicado es $1 - R^2 = 1 - 0.5184 = 0.4816 \approx 48.2\%$: respuesta (B). (La opción (A), 28 %, es la trampa de calcular $1 - \hat{\rho}$ en vez de $1 - \hat{\rho}^2$ –olvidar elevar al cuadrado la correlación antes de restar de 1.) $\square$

Ejercicio 4.4 (Pronóstico puntual con la recta estimada). Con el modelo estimado en el Ejercicio 2.1, $\hat{y} = 2.2 + 0.6143x$, ¿cuál es el valor pronosticado de y para $x = 9$, el más cercano a...

- (A) 7.7
- (B) 5.5
- (C) 8.9

Solución. $\hat{y} = 2.2 + 0.6143(9) = 2.2 + 5.5287 = 7.7287 \approx 7.7$. Respuesta (A). (La opción (B), 5.5, es la trampa de reportar sólo $0.6143 \times 9 \approx 5.5$, olvidando sumar el intercepto.) $\square$

Ejercicio 4.5 (Sensibilidad económica: crecimiento de ventas y PIB). Un analista regresa el crecimiento anual de las ventas de una empresa (y , en %) sobre el crecimiento del PIB (x , en %) y obtiene $\hat{\beta}_0 = -0.3$, $\hat{\beta}_1 = 1.8$. Si el consenso de mercado pronostica un crecimiento del PIB de 2.5 % el próximo año, ¿cuál de las siguientes opciones está más cerca del crecimiento de ventas pronosticado?

- (A) 4.2 %
- (B) 4.5 %
- (C) 4.8 %

Solución. $\hat{y} = -0.3 + 1.8(2.5) = -0.3 + 4.5 = 4.2\%$. Respuesta (A). (La opción (B) olvida el intercepto por completo; la (C) le cambia el signo, sumando 0.3 en vez de restarlo.) $\square$

Ejercicio 4.6 (Dummy: rendimiento promedio del grupo tratado). Un analista regresa el rendimiento anual de 50 fondos (y) sobre una variable dummy $D = 1$ si el fondo es de gestión activa y $D = 0$ si es pasivo (30 fondos activos, 20 pasivos), y obtiene $\hat{\beta}_0 = 4.5\%$,

$\hat{\beta}_1 = -0.8\%$. ¿Cuál de las siguientes opciones es la más cercana al rendimiento promedio de los fondos de gestión **activa**?

- (A) 4.5 %
- (B) 3.7 %
- (C) 5.3 %

Solución. Por el Ejercicio 3.4, $\hat{\beta}_0 = \bar{y}_0$ es la media del grupo *base* ($D = 0$, fondos pasivos) y $\hat{\beta}_1 = \bar{y}_1 - \bar{y}_0$ es la diferencia (activo menos pasivo). El rendimiento promedio del grupo activo ($D = 1$) es entonces $\bar{y}_1 = \hat{\beta}_0 + \hat{\beta}_1 = 4.5\% + (-0.8\%) = 3.7\%$. Respuesta (B). (La opción (A), 4.5 %, es la trampa de reportar $\hat{\beta}_0$ –el rendimiento del grupo *pasivo*, no del activo.) $\square$

5. Reto (opcional)

Ejercicio 5.1 (Por qué MCO y no otro estimador lineal). Considere estimadores *lineales* de la pendiente de la forma $\tilde{\beta}_1 = \sum_i c_i y_i$, con pesos c_i que dependen sólo de los x_i (no de y). Para que $\tilde{\beta}_1$ sea *insesgado* bajo $y_i = \beta_0 + \beta_1 x_i + u_i$ con $\mathbb{E}[u_i] = 0$, se requiere

$$\sum_i c_i = 0 \quad \text{y} \quad \sum_i c_i x_i = 1.$$

Suponiendo además que los errores son homocedásticos e incorrelacionados ($\text{Var}(u_i) = \sigma^2$, $\text{Cov}(u_i, u_j) = 0$ para $i \neq j$), se tiene $\text{Var}(\tilde{\beta}_1) = \sigma^2 \sum_i c_i^2$. Demuestre que, entre todos los pesos c_i que cumplen las dos restricciones de insesgamiento, la elección de MCO, $c_i = (x_i - \bar{x})/S_{xx}$, es la que **minimiza** $\sum_i c_i^2$ –es decir, MCO es el estimador lineal insesgado de mínima varianza (el teorema de Gauss–Markov, en el caso de la pendiente simple).

Escriba $c_i = \frac{x_i - \bar{x}}{S_{xx}} + d_i$ para pesos arbitrarios d_i que cumplen las restricciones, y muestre primero que las dos restricciones de insesgamiento fuerzan $\sum_i d_i = 0$ y $\sum_i d_i(x_i - \bar{x}) = 0$ (recuerde $\sum_i (x_i - \bar{x}) = 0$). Luego expanda $\sum_i c_i^2 = \sum_i \left(\frac{x_i - \bar{x}}{S_{xx}} + d_i \right)^2$ y muestre que el término cruzado se anula usando esas dos identidades, dejando $\sum_i c_i^2 = \frac{1}{S_{xx}} + \sum_i d_i^2 \geq \frac{1}{S_{xx}}$, con igualdad si y sólo si $d_i = 0$ para toda i –es decir, si y sólo si c_i son los pesos de MCO. (Este es, de nuevo, el mismo tipo de argumento de “completar el cuadrado” del Ejercicio 1.1, ahora en el espacio de los pesos c_i en vez de en b_1 .)