

Mis notas de Lineal

Facultad de Empresariales

Universidad Panamericana

César Galindo

2008

Índice

1. ¿En qué se usa el álgebra lineal todos los días?	3
1.1. Una visión panorámica	4
1.2. Cinco ejemplos empresariales desde el primer día	5
1.3. Inteligencia artificial	9
1.4. Business Analytics	9
1.5. Marketing	10
1.6. Finanzas	11
2. Introducción y filosofía estructural	12
2.1. El campo $\mathbb{K}$: qué es y por qué importa	13
3. Espacios vectoriales y subespacios	14
3.1. Definición formal y axiomas	14
3.2. Primeras imágenes mentales en $\mathbb{R}$	15
3.3. Subespacios	17
3.4. Contraejemplos: qué falla exactamente	20
4. Combinaciones lineales, span e independencia lineal	22

5. Bases, dimensión y el lema de intercambio	26
6. Suma, suma directa y cocientes	30
7. Transformaciones lineales	32
8. Teorema rango–nulidad y primer teorema de isomorfismo	35
9. Matrices y cambio de base	38
10. Espacios de columnas, filas y núcleos: el Teorema Fundamental del Álgebra Lineal	42
11. Determinantes	45
12. Polinomio característico, eigenvalores y eigenvectores	49
13. Diagonalización	52

Estas notas ofrecen una exposición rigurosa, pedagógica y muy visual de álgebra lineal de dimensión finita sobre un campo $\mathbb{K}$, pensada para la Facultad de Empresariales de la Universidad Panamericana. El principio rector es que los objetos fundamentales no son las matrices en sí mismas, sino los espacios vectoriales y las transformaciones lineales; las matrices aparecen como representaciones coordinadas de fenómenos invariantes. Se desarrollan con especial detalle los conceptos de espacio vectorial, subespacio, combinaciones lineales, bases, dimensión, suma directa, cocientes, transformaciones lineales, rango y nulidad, matrices, cambio de base, espacios de columnas y de filas, espacio nulo, el Teorema Fundamental del Álgebra Lineal, determinantes, eigenvalores y diagonalización. A lo largo del texto se incorporan figuras hechas en $\text{\LaTeX}$, cuadros sinópticos y ejemplos paso a paso tomados de costos, demanda, portafolios, segmentación y tableros de datos, para que cada resultado tenga una lectura matemática y otra aplicada.

Idea central

Estas notas pueden leerse en tres capas. La primera es *geométrica*: líneas, planos, proyecciones y descomposiciones ortogonales. La segunda es *álgebraica*: bases, coordenadas, matrices y ecuaciones lineales. La tercera es *estructural*: qué objetos no cambian cuando cambiamos de coordenadas. Esa tercera capa es la que da unidad al curso entero.

Qué conviene recordar

A lo largo del texto conviene mantener siempre presentes cuatro preguntas:

- (1) ¿qué depende de las coordenadas y qué es intrínseco?,
- (2) ¿qué espacio está siendo descrito?,
- (3) ¿qué aplicación lineal está actuando?,
- (4) ¿qué descomposición natural simplifica el problema?

Cuando se tiene claridad sobre estas cuatro cuestiones, la mayoría de los cálculos de álgebra lineal dejan de verse como recetas aisladas y pasan a ser manifestaciones de una misma arquitectura conceptual.

1. ¿En qué se usa el álgebra lineal todos los días?

Idea central

Aunque muchas veces se presenta como una teoría abstracta de vectores y matrices, el álgebra lineal aparece diariamente cada vez que organizamos datos, comprimimos información, hacemos predicciones, segmentamos clientes, medimos riesgo o entrenamos modelos de inteligencia artificial. En el fondo, casi toda aplicación moderna consiste en tres pasos: representar objetos como vectores, transformarlos linealmente y extraer estructura a partir de esas transformaciones.

Intuición geométrica

Una forma muy útil de pensar el tema es la siguiente: una tabla de datos ya es un objeto lineal. Si cada fila representa un cliente, un producto, una observación financiera o una imagen, entonces el problema práctico consiste en detectar direcciones importantes, relaciones entre variables, proyecciones relevantes o descomposiciones que simplifiquen la complejidad del sistema. Esa es exactamente la clase de preguntas que responde el álgebra lineal.

Qué conviene recordar

Ruta conceptual de la sección. Primero veremos una panorámica general; después, cinco ejemplos empresariales inmediatos —costos, demanda, portafolios, segmentación y tableros de datos—; luego, cuatro ámbitos concretos de uso cotidiano —inteligencia artificial, Business Analytics, Marketing y Finanzas—; finalmente, cerraremos con un cuadro sinóptico que conecte cada concepto lineal con una decisión real.


1.1. Una visión panorámica

El lenguaje lineal aparece cuando queremos responder preguntas como: ¿qué variables explican mejor un fenómeno?, ¿cómo reducir miles de características a unas pocas dimensiones interpretables?, ¿cómo medir similitud entre usuarios o productos?, ¿cómo separar señal y ruido?, ¿cómo asignar capital bajo restricciones?, ¿cómo propagar una entrada a través de una red neuronal?

Dicho de otro modo: cuando una situación real puede organizarse en una tabla de datos, en un sistema de ecuaciones o en una red de relaciones entre variables, casi siempre hay matrices, subespacios, proyecciones, eigenvalores o productos internos detrás de la operación concreta. El paso verdaderamente útil del álgebra lineal consiste en volver visible esa estructura.

Intuición geométrica

Una visión panorámica útil es la siguiente: primero la realidad produce *datos*; después elegimos una *representación vectorial*; enseguida aplicamos *herramientas lineales* para resumir, comparar o transformar; finalmente interpretamos el resultado como una *decisión*. Ese ciclo aparece una y otra vez en IA, analítica de negocios, marketing y finanzas.



Mapa conceptual

El álgebra lineal actúa como un puente entre los datos del mundo real y las decisiones.

Primero organiza la información en vectores y matrices; después la transforma mediante proyecciones, cambios de base y descomposiciones; finalmente la vuelve interpretable para comparar, predecir, segmentar u optimizar.

Qué conviene recordar

Idea sintética. En la práctica, el álgebra lineal convierte datos dispersos en estructura visible. Permite pasar de una colección de números a una geometría: direcciones dominantes, agrupamientos, correlaciones, proyecciones, descomposiciones y reglas de decisión.

1.2. Cinco ejemplos empresariales desde el primer día

Antes de entrar a la teoría formal, conviene ver cinco escenas muy concretas donde el lenguaje vectorial aparece de inmediato en Empresariales. La idea central es siempre la misma: una lista ordenada de números puede interpretarse como un vector, una tabla como una matriz y una regla de transformación como una aplicación lineal. A partir de ahí, los

cálculos dejan de ser solo aritmética y pasan a tener una estructura visible.

Ejemplo 1.1 (Costos de producción y combinación lineal). Supongamos que una empresa produce tres artículos: básico, premium y ejecutivo. Si el costo unitario de materiales y mano de obra viene dado por

$$c = \begin{pmatrix} 120 \\ 180 \\ 250 \end{pmatrix},$$

y en una semana se producen

$$q = \begin{pmatrix} 40 \\ 25 \\ 10 \end{pmatrix},$$

entonces el costo total puede escribirse como el producto interno

$$c \cdot q = 120(40) + 180(25) + 250(10).$$

Lo importante no es solo obtener un número, sino entender qué significa la operación: estamos agregando contribuciones de distintas líneas de negocio con una regla lineal. Si mañana cambian las cantidades producidas, el nuevo costo total se obtiene con la misma estructura. Si además se separan costos fijos y costos variables, el modelo completo toma la forma

$$C(q) = F + c \cdot q,$$

y ya aparece una de las ideas más importantes del curso: una parte afín o constante, y una parte lineal que describe cómo cambian los costos cuando cambia el vector de producción.

Ejemplo 1.2 (Demanda de varios productos y sistema lineal). Imaginemos dos productos cuyos niveles de demanda dependen del precio y de la publicidad. En una versión simplificada podríamos escribir

$$\begin{cases} q_1 = 500 - 8p_1 + 2a, \\ q_2 = 420 - 5p_2 + a, \end{cases}$$

donde p_1, p_2 son precios y a representa inversión publicitaria. Aunque aquí aparezcan términos constantes, la parte esencial puede organizarse en forma matricial. El beneficio de hacerlo así es que se puede estudiar el sistema completo a la vez: sensibilidad al precio, efecto de campañas, escenarios alternativos y comparación entre productos. En Business Analytics y en planeación comercial esto ocurre continuamente: varias variables se mueven al mismo tiempo y el álgebra lineal permite ver esa interacción

de manera compacta.

Ejemplo 1.3 (Portafolios y combinación de activos). Si una cartera reparte el capital entre tres activos con ponderaciones

$$w = \begin{pmatrix} 0.50 \\ 0.30 \\ 0.20 \end{pmatrix},$$

y los rendimientos esperados son

$$\mu = \begin{pmatrix} 0.10 \\ 0.14 \\ 0.08 \end{pmatrix},$$

el rendimiento esperado del portafolio es el producto interno

$$w^T \mu.$$

Aquí el vector w no es una lista cualquiera: representa una política de asignación. Cambiar el portafolio significa moverse a otro punto del espacio. Además, cuando se introduce la matriz de covarianzas Σ , el riesgo total se expresa como

$$w^T \Sigma w.$$

Esto muestra por qué el álgebra lineal es tan natural en finanzas: una cartera, un conjunto de riesgos y una regla de evaluación forman una geometría completa.

Ejemplo 1.4 (Segmentación de clientes y geometría de datos). Supongamos que cada cliente se describe por cuatro variables: frecuencia de compra, ticket promedio, antigüedad y tasa de respuesta a promociones. Entonces un cliente puede representarse como un vector de $\mathbb{R}^4$, por ejemplo

$$x = \begin{pmatrix} 12 \\ 850 \\ 18 \\ 0.32 \end{pmatrix}.$$

Otro cliente será otro vector del mismo espacio. La segmentación empieza cuando preguntamos qué tan cerca están dos clientes, en qué dirección difieren más, o si

existe un subgrupo con rasgos parecidos. Así, una campaña diferenciada para clientes de alto valor no nace solo de intuición comercial: nace de una estructura geométrica dentro de una nube de puntos. El lenguaje de distancias, centroides, proyecciones y componentes principales es, en el fondo, álgebra lineal aplicada al comportamiento del consumidor.


Ejemplo 1.5 (Tableros de datos y matrices ejecutivas). Un tablero directivo suele concentrar indicadores por sucursal, por semana o por canal. Si ponemos en filas las sucursales y en columnas variables como ventas, costo, margen, devoluciones y conversión, obtenemos una matriz

$$X = \begin{pmatrix} \text{ventas} & \text{costos} & \text{margen} & \text{devoluciones} & \text{conversión} \end{pmatrix}.$$

No hace falta escribir todos los números para ver la idea: el tablero es ya un objeto lineal. Comparar sucursales es comparar filas; analizar una variable es mirar columnas; construir un índice sintético de desempeño significa formar una combinación lineal de columnas; reducir cinco métricas a dos ejes visuales para un reporte ejecutivo significa proyectar la información sobre un subespacio de menor dimensión. En otras palabras, un buen tablero no solo muestra datos: organiza una geometría de decisiones.

Qué conviene recordar

Lectura estratégica de los cinco ejemplos. En costos aparece la idea de combinación lineal; en demanda aparece la organización matricial de relaciones simultáneas; en portafolios aparece la combinación de activos y el papel de las matrices de covarianza; en segmentación aparece la geometría de los clientes; en tableros aparece la matriz de datos como objeto central para resumir y decidir. Esa es la razón por la que el curso empieza con espacios vectoriales: porque allí vive el lenguaje que unifica todos estos escenarios.



Un tablero directivo puede leerse como una matriz coloreada: filas para unidades de negocio, columnas para métricas y combinaciones lineales para construir índices sintéticos.

1.3. Inteligencia artificial

En inteligencia artificial, casi todo se formula en términos de vectores y matrices. Una imagen puede verse como una matriz de píxeles; un texto puede convertirse en un vector de características o en un *embedding*; una capa de una red neuronal transforma una entrada $x \in \mathbb{R}^n$ mediante una expresión del tipo

$$y = \sigma(Wx + b),$$

donde W es una matriz de pesos y b es un vector de sesgos. Sin álgebra lineal no hay forma de describir de manera compacta esta propagación de información.

- Ejemplo 1.6** (Ejemplos cotidianos en IA). (1) **Recomendadores:** plataformas de streaming o comercio electrónico representan usuarios y productos como vectores; la cercanía entre ellos se mide con productos internos o similitudes angulares.
- (2) **Procesamiento de lenguaje:** palabras y oraciones se codifican como vectores de gran dimensión. La idea de que términos semánticamente cercanos ocupen regiones cercanas del espacio es puramente geométrica.
- (3) **Reducción de dimensión:** técnicas como PCA buscan las direcciones principales de variación para comprimir información, visualizar datos o eliminar ruido antes de entrenar un modelo.
- (4) **Visión computacional:** filtros, convoluciones, transformaciones lineales y descomposiciones matriciales aparecen en reconocimiento de imágenes, compresión y clasificación.

Método de trabajo

Cuando en IA se habla de *features*, *embeddings*, *weights*, *layers* o *latent factors*, casi siempre se está hablando en realidad de objetos de álgebra lineal: vectores, matrices, bases, proyecciones o cambios de coordenadas.

1.4. Business Analytics

Business Analytics trabaja casi siempre con una matriz de datos: filas que representan observaciones (clientes, sucursales, días, productos, regiones) y columnas que representan variables (ventas, costo, margen, tiempo, canal, inventario, conversión). Una gran parte del trabajo consiste en detectar patrones útiles dentro de esa matriz.

- Ejemplo 1.7** (Ejemplos concretos en Business Analytics). (1) **Pronóstico de demanda:** si se quiere anticipar ventas futuras, se construye una matriz con variables históricas y se ajusta un modelo lineal o multivariado para explicar la demanda en función de precio, estacionalidad, promociones y comportamiento pasado.
- (2) **Segmentación de clientes:** cada cliente se describe mediante un vector de atributos; después se comparan distancias o similitudes para agrupar perfiles parecidos y diseñar estrategias diferenciadas.
- (3) **Detección de variables clave:** con PCA o análisis factorial se identifican pocas combinaciones lineales que resumen mucha información, lo cual simplifica tableros ejecutivos y modelos de decisión.
- (4) **Optimización operativa:** problemas de asignación de recursos, mezcla de productos o planificación logística se formulan mediante sistemas lineales y matrices de restricciones.

1.5. Marketing


En marketing, el álgebra lineal aparece cuando se modela el comportamiento del consumidor, se estudia la afinidad entre productos y audiencias, o se mide el efecto conjunto de múltiples canales de campaña.

- Ejemplo 1.8** (Ejemplos concretos en Marketing). (1) **Sistemas de recomendación:** una matriz usuario–producto registra compras, clics o calificaciones. Al factorizar esa matriz, pueden descubrirse gustos latentes y sugerirse productos probables de interés.
- (2) **Segmentación por comportamiento:** variables como frecuencia de compra, ticket promedio, canal favorito y tasa de respuesta pueden verse como coordenadas de un vector cliente; esto permite agrupar audiencias con herramientas geométricas.
- (3) **Atribución multicanal:** cuando una conversión depende de email, redes sociales, anuncios pagos y tráfico orgánico, el efecto agregado puede estudiarse mediante modelos matriciales que separan contribuciones y relaciones entre variables.
- (4) **Análisis de percepción de marca:** encuestas y escalas pueden resumirse en matrices, y luego visualizarse en espacios de menor dimensión para detectar asociaciones entre atributos de marca y segmentos de consumidores.

1.6. Finanzas

Finanzas es uno de los terrenos naturales del álgebra lineal. Los rendimientos de varios activos se organizan en vectores y la dependencia entre ellos se resume en matrices de covarianza. A partir de ahí se calculan combinaciones eficientes, riesgos agregados y exposiciones a factores.

- Ejemplo 1.9** (Ejemplos concretos en Finanzas). (1) **Portafolios:** si $w \in \mathbb{R}^n$ es el vector de ponderaciones y Σ la matriz de covarianzas, el riesgo del portafolio se expresa como $w^\top \Sigma w$. Esta sola fórmula concentra una gran parte de la teoría moderna de portafolios.
- (2) **Cobertura y exposición:** una cartera puede escribirse como combinación lineal de factores de riesgo; el problema es entonces medir y ajustar la exposición en ciertas direcciones del espacio financiero.
- (3) **Modelos multifactoriales:** rendimientos, inflación, tasas, tipo de cambio y mercado pueden organizarse en matrices para estimar sensibilidades y descomponer fuentes de variación.
- (4) **Curvas y series múltiples:** al analizar muchos activos simultáneamente, las herramientas de autovalores y vectores propios ayudan a detectar factores comunes, regímenes dominantes o compresiones de dimensión.



Concepto lineal	Uso real	Ejemplo concreto
Vectores y productos internos	Medir similitud y cercanía	Comparar clientes, documentos o productos en sistemas de recomendación
Matrices de datos	Organizar información multivariada	Tablero con ventas, costos, conversión y márgenes por sucursal
Sistemas lineales	Resolver restricciones simultáneas	Asignar presupuesto o mezcla óptima de productos
Proyecciones y mínimos cuadrados	Ajustar modelos y pronósticos	Estimar demanda o respuesta a campañas
Autovalores y vectores propios	Detectar factores dominantes	Encontrar componentes principales en encuestas o rendimientos
Matrices de covarianza	Medir dependencia y riesgo conjunto	Construir portafolios y analizar exposición de activos

Cuadro sinóptico. Los conceptos centrales del curso reaparecen una y otra vez cuando los problemas reales se organizan como datos, restricciones y relaciones entre variables.

Qué conviene recordar

Mensaje final de esta sección. Estudiar álgebra lineal no solo sirve para resolver ejercicios con matrices. Sirve para aprender a pensar con estructura en problemas modernos: cómo organizar información, cómo reducir complejidad, cómo detectar relaciones ocultas y cómo transformar datos en decisiones.

2. Introducción y filosofía estructural

Idea central

En una primera lectura, conviene pensar que un espacio vectorial es un lugar donde tiene sentido sumar objetos del mismo tipo y multiplicarlos por números. En cursos posteriores esa idea se vuelve abstracta; aquí nos interesa que sea operativa y útil. Para una alumna o alumno de Empresariales, la intuición inicial correcta es *trabajar con listas de datos reales*, es decir, con vectores de $\mathbb{R}^n$.

Estas notas están pensadas para la **Facultad de Empresariales de la Universidad Panamericana**. Por ello, aunque mantendremos el lenguaje matemático correcto, daremos

prioridad a la interpretación, a la lectura geométrica y a ejemplos que conecten con datos, decisiones, restricciones y modelos. El objetivo no es memorizar fórmulas aisladas, sino reconocer cuándo una situación tiene estructura lineal.

Qué conviene recordar

Punto de partida recomendado. Al inicio del curso conviene trabajar casi siempre sobre $\mathbb{R}$:

- (1) porque los datos observados en economía, finanzas, marketing y analítica suelen representarse con números reales;
- (2) porque la geometría de rectas, planos, proyecciones y distancias se entiende de forma natural en $\mathbb{R}^2$ y $\mathbb{R}^3$;
- (3) porque muchas aplicaciones prácticas usan justamente matrices y vectores con entradas reales.

Más adelante aparecerá un campo general $\mathbb{K}$, pero al principio es sano pensar: *casi todo lo que estoy viendo ocurre primero en $\mathbb{R}$.*

2.1. El campo $\mathbb{K}$: qué es y por qué importa

En álgebra lineal no solo hay vectores; también hay *escalares*, es decir, los números con los que estiramos, comprimimos o cambiamos de signo a los vectores. El conjunto de escalares se denota por $\mathbb{K}$ y debe ser un *campo*. Esto significa, informalmente, que en $\mathbb{K}$ se puede sumar, restar, multiplicar y dividir entre elementos no nulos, y que esas operaciones se comportan bien.

Definición 2.1. Un *campo* $\mathbb{K}$ es un conjunto con dos operaciones, suma y multiplicación, en el que valen las reglas usuales de la aritmética: asociatividad, conmutatividad, existencia de 0 y 1, existencia de inversos aditivos para todos los elementos y de inversos multiplicativos para todos los elementos no nulos, además de la distributividad.

Ejemplo 2.2 (Campos que aparecen con frecuencia). (a) $\mathbb{R}$, el campo de los números reales. Es el más importante en un primer curso y el que usaremos por defecto en la mayor parte de los ejemplos.

(b) $\mathbb{C}$, el campo de los números complejos. Aparece mucho cuando se estudian eigenvalores y diagonalización, porque algunas matrices reales no tienen suficientes eigenvalores reales pero sí complejos.

(c) $\mathbb{Q}$, el campo de los números racionales. Es útil para ejemplos aritméticos, aunque geométricamente es más limitado que $\mathbb{R}$.

(d) $\mathbb{F}_p$, el campo finito con p elementos, donde p es primo. Estos campos aparecen en criptografía, teoría de códigos y combinatoria.

Error frecuente

El campo $\mathbb{K}$ *sí importa*. Un mismo conjunto puede ser espacio vectorial sobre un campo y no serlo sobre otro. Por ejemplo, $\mathbb{C}$ es un espacio vectorial sobre $\mathbb{R}$, pero no $\mathbb{R}^2$ sobre $\mathbb{C}$ con las operaciones usuales: faltaría definir de manera coherente cómo multiplicar un número complejo por un par real y permanecer dentro de $\mathbb{R}^2$.

Observación 2.3 (La convención práctica de estas notas). Siempre que no se diga otra cosa, puedes leer primero $\mathbb{K} = \mathbb{R}$. Después, una vez entendida la idea en $\mathbb{R}^n$, conviene volver a leer el mismo enunciado con $\mathbb{K}$ general y observar que el resultado no dependía de propiedades geométricas específicas de $\mathbb{R}$, sino solo de los axiomas del campo.

3. Espacios vectoriales y subespacios

Idea central

Esta sección fija las reglas del juego. Un espacio vectorial es un conjunto donde las combinaciones lineales tienen sentido. Todo lo demás —bases, coordenadas, matrices, sistemas lineales, proyecciones, modelos— nace de esta idea.

3.1. Definición formal y axiomas

Definición 3.1. Un *espacio vectorial* sobre un campo $\mathbb{K}$ es un conjunto V dotado de:

$$V \times V \rightarrow V, \quad (u, v) \mapsto u + v,$$

una operación de suma, y de

$$\mathbb{K} \times V \rightarrow V, \quad (\lambda, u) \mapsto \lambda u,$$

una operación de multiplicación por escalares, tales que para todos $u, v, w \in V$ y $\lambda, \mu \in \mathbb{K}$ se cumplen los axiomas siguientes.

Qué conviene recordar

Axiomas de espacio vectorial.

- (A1) **Asociatividad de la suma:** $(u + v) + w = u + (v + w)$.
- (A2) **Conmutatividad de la suma:** $u + v = v + u$.
- (A3) **Existencia del vector cero:** existe $0 \in V$ tal que $u + 0 = u$ para todo $u \in V$.
- (A4) **Existencia de opuesto:** para todo $u \in V$ existe $-u \in V$ con $u + (-u) = 0$.
- (A5) **Compatibilidad con el producto del campo:** $(\lambda\mu)u = \lambda(\mu u)$.
- (A6) **Acción del uno:** $1u = u$.
- (A7) **Distributividad respecto de la suma de vectores:** $\lambda(u + v) = \lambda u + \lambda v$.
- (A8) **Distributividad respecto de la suma de escalares:** $(\lambda + \mu)u = \lambda u + \mu u$.

Intuición geométrica

Estos axiomas dicen, en esencia, que podemos operar con vectores sin ambigüedades y con las mismas reglas formales con las que operamos en la aritmética ordinaria. La suma combina información del mismo tipo; la multiplicación por escalar cambia magnitud, signo o escala. Cuando estas reglas fallan, ya no estamos en un espacio vectorial.




Figura 1. La suma construye un paralelogramo; multiplicar por un escalar estira (o contrae, o invierte) la flecha. Estas dos operaciones deben satisfacer los ocho axiomas del espacio vectorial.

3.2. Primeras imágenes mentales en $\mathbb{R}$

La intuición más importante del inicio del curso ocurre en $\mathbb{R}$, $\mathbb{R}^2$ y $\mathbb{R}^3$:

- en $\mathbb{R}$, los vectores son simplemente números reales;

- en $\mathbb{R}^2$, los vectores se ven como flechas del plano o como pares ordenados (x, y) ;
- en $\mathbb{R}^3$, se interpretan como triples (x, y, z) , muy útiles para visualizar planos y direcciones.

Ejemplo 3.2 (Ejemplo base: $\mathbb{R}^n$). El conjunto $\mathbb{R}^n$ con la suma componente a componente y la multiplicación por escalares

$$(x_1, \dots, x_n) + (y_1, \dots, y_n) = (x_1 + y_1, \dots, x_n + y_n),$$

$$\lambda(x_1, \dots, x_n) = (\lambda x_1, \dots, \lambda x_n)$$

es un espacio vectorial sobre $\mathbb{R}$.

Lectura aplicada. Un vector de $\mathbb{R}^n$ puede representar, por ejemplo, ventas por producto, costos por unidad de negocio, retornos de n activos o el perfil de consumo de un cliente en n categorías. Sumar vectores significa agregar perfiles; multiplicar por un escalar significa reescalar esas cantidades.

Ejemplo 3.3 (Matrices como vectores). El conjunto $M_{m \times n}(\mathbb{R})$ de matrices reales de tamaño $m \times n$ es un espacio vectorial sobre $\mathbb{R}$. Se suman matrices entrada a entrada y se multiplican por escalares entrada a entrada.

Interpretación. Una matriz puede verse como una tabla de datos. Por ejemplo, una matriz de tamaño 12×5 puede registrar ventas mensuales de cinco líneas de producto. La estructura vectorial permite comparar tablas, combinarlas y construir promedios ponderados.

Ejemplo 3.4 (Polinomios). El conjunto $\mathbb{R}[X]$ de polinomios con coeficientes reales es un espacio vectorial sobre $\mathbb{R}$. También lo es el subconjunto $\mathbb{R}_n[X]$ de polinomios de grado a lo más n .

Interpretación. En modelación, los polinomios sirven para aproximar relaciones entre variables. Que formen un espacio vectorial significa que una combinación lineal de funciones polinomiales sigue siendo una función polinomial del mismo tipo.

Ejemplo 3.5 (Funciones). El conjunto de todas las funciones $f : \mathbb{R} \rightarrow \mathbb{R}$ es un espacio vectorial sobre $\mathbb{R}$ si definimos

$$(f + g)(x) = f(x) + g(x), \quad (\lambda f)(x) = \lambda f(x).$$

Idea importante. Aquí los vectores ya no son flechas ni listas finitas, sino funciones. Esto muestra que “vector” no significa necesariamente “flecha dibujable”, sino cualquier objeto sobre el que tenga sentido combinar linealmente.

3.3. Subespacios

Definición 3.6. Sea V un espacio vectorial sobre $\mathbb{K}$. Un subconjunto $W \subseteq V$ es un *subespacio vectorial* si, con las operaciones heredadas de V , también es espacio vectorial. En la práctica, basta verificar:

$$0 \in W, \quad x, y \in W \Rightarrow x + y \in W, \quad \lambda \in \mathbb{K}, x \in W \Rightarrow \lambda x \in W.$$

Qué conviene recordar

Prueba rápida de subespacio. Para decidir si $W \subseteq V$ es subespacio, revisa tres preguntas:

- (1) ¿contiene al vector cero?,
- (2) ¿es cerrado bajo suma?,
- (3) ¿es cerrado bajo multiplicación por escalares?

Si falla una sola, entonces W no es subespacio.




Figura 3. Izquierda: subespacio (recta por el origen). Derecha: recta desplazada, no es subespacio. La condición visual más fácil de recordar: *todo subespacio pasa por el origen*.

Ejercicio resuelto paso a paso

¿Es $W = \{(x, y, z) \in \mathbb{R}^3 : 2x - y + 3z = 0\}$ un subespacio?

Paso 1 — Vector cero. $2(0) - 0 + 3(0) = 0$. ✓ El vector cero pertenece a W .

Paso 2 — Cerradura bajo la suma. Sean $(x_1, y_1, z_1), (x_2, y_2, z_2) \in W$. Por

hipótesis $2x_i - y_i + 3z_i = 0$. Entonces:

$$2(x_1+x_2) - (y_1+y_2) + 3(z_1+z_2) = \underbrace{(2x_1 - y_1 + 3z_1)}_0 + \underbrace{(2x_2 - y_2 + 3z_2)}_0 = 0. \quad \checkmark$$

Paso 3 — Cerradura bajo escalar. Si $(x, y, z) \in W$ y $\lambda \in \mathbb{R}$:

$$2(\lambda x) - (\lambda y) + 3(\lambda z) = \lambda \underbrace{(2x - y + 3z)}_0 = 0. \quad \checkmark$$

Conclusión. W es un subespacio de $\mathbb{R}^3$.

Bonus — dimensión y generadores. Despejamos $y = 2x + 3z$:

$$(x, y, z) = x \underbrace{(1, 2, 0)}_{w_1} + z \underbrace{(0, 3, 1)}_{w_2}.$$

Como w_1 y w_2 son independientes: $\dim W = 2$. Geométricamente, W es un plano por el origen.

Para practicar

Decide si cada conjunto es subespacio de $\mathbb{R}^3$. Si lo es, halla una base y su dimensión.

- (a) $A = \{(x, y, z) : x + y = 0, y + z = 0\}$.
- (b) $B = \{(x, y, z) : x^2 + y^2 = 0\}$.
- (c) $C = \{(x, y, z) : x + y + z = 1\}$.
- (d) $D = \{(x, y, z) : x = 2y, z = 0\}$.

Respuestas: (a) sí, dim 1, generado por $(1, -1, 1)$; (b) sí, dim 1, eje z ; (c) no; (d) sí, dim 1, generado por $(2, 1, 0)$.

Ejemplo 3.7 (Subespacio dado por una ecuación lineal homogénea). En $\mathbb{R}^3$, el conjunto

$$W = \{(x, y, z) \in \mathbb{R}^3 : x + 2y - z = 0\}$$

es un subespacio.

Por qué. La ecuación es homogénea: el lado derecho es 0. Geométricamente, describe un plano que pasa por el origen. Algebraicamente, si dos vectores satisfacen la ecuación, su suma también la satisface; y si un vector la satisface, cualquier múltiplo escalar también.

Parametrización útil. De $x + 2y - z = 0$ obtenemos $x = -2y + z$, luego

$$(x, y, z) = y(-2, 1, 0) + z(1, 0, 1).$$

Así,

$$W = \text{span}((-2, 1, 0), (1, 0, 1)),$$

y se ve además que $\dim W = 2$.

Ejemplo 3.8 (Subespacio de matrices triangulares superiores). Dentro de $M_{2 \times 2}(\mathbb{R})$, el conjunto

$$W = \left\{ \begin{pmatrix} a & b \\ 0 & d \end{pmatrix} : a, b, d \in \mathbb{R} \right\}$$

es un subespacio.

Qué significa. Si sumamos dos matrices triangulares superiores, seguimos obteniendo una triangular superior; y si multiplicamos una de ellas por un número real, también. Es un ejemplo importante porque muestra que los subespacios no siempre son rectas o planos visibles: también pueden ser familias estructuradas de matrices.

Ejemplo 3.9 (Polinomios pares). Sea

$$W = \{p(X) \in \mathbb{R}[X] : p(-X) = p(X)\}.$$

Entonces W es un subespacio de $\mathbb{R}[X]$.

Interpretación. Son los polinomios simétricos respecto del eje vertical. La suma de dos polinomios pares sigue siendo par, y un múltiplo escalar de un polinomio par sigue siendo par.

Ejemplo 3.10 (Verificación paso a paso con datos de sucursales). Consideremos en $\mathbb{R}^3$ el conjunto

$$W = \{(u, v, w) \in \mathbb{R}^3 : u + v + w = 0\}.$$

Puede interpretarse como el conjunto de desviaciones de tres sucursales cuando la suma total de desviaciones es nula.

Paso 1: el vector cero pertenece a W , porque $0 + 0 + 0 = 0$.

Paso 2: si (u_1, v_1, w_1) y (u_2, v_2, w_2) están en W , entonces

$$(u_1 + u_2) + (v_1 + v_2) + (w_1 + w_2) = 0 + 0 = 0,$$

así que la suma también está en W .

Paso 3: si $\lambda \in \mathbb{R}$ y $(u, v, w) \in W$, entonces

$$\lambda u + \lambda v + \lambda w = \lambda(u + v + w) = \lambda \cdot 0 = 0,$$

de modo que $\lambda(u, v, w) \in W$.

Hemos verificado exactamente las tres propiedades clave. Por tanto W es subespacio. Además, despejando $w = -u - v$, obtenemos

$$(u, v, w) = u(1, 0, -1) + v(0, 1, -1),$$

por lo que W es un plano generado por dos direcciones independientes.

3.4. Contraejemplos: qué falla exactamente

Ejemplo 3.11 (Plano desplazado). El conjunto

$$A = \{(x, y, z) \in \mathbb{R}^3 : x + 2y - z = 1\}$$

no es un subespacio de $\mathbb{R}^3$.

Qué falla. No contiene al vector cero, porque $0 + 2 \cdot 0 - 0 \neq 1$. Geométricamente es un plano, sí, pero un plano desplazado, que no pasa por el origen. Ese desplazamiento rompe la estructura lineal.

Ejemplo 3.12 (Primer cuadrante). El conjunto

$$Q = \{(x, y) \in \mathbb{R}^2 : x \geq 0, y \geq 0\}$$

no es un subespacio de $\mathbb{R}^2$.

Qué falla. Aunque es cerrado bajo suma, no es cerrado bajo multiplicación por escalares negativos. Por ejemplo,

$$(1, 2) \in Q \quad \text{pero} \quad -1 \cdot (1, 2) = (-1, -2) \notin Q.$$

Este ejemplo es muy útil porque muestra que “verse estable” no basta: hay que revisar *todos* los escalares del campo.

Ejemplo 3.13 (Enteros con escalares reales). El conjunto $\mathbb{Z}$ de enteros no es un espacio vectorial sobre $\mathbb{R}$.

Qué falla. Si tomamos $1 \in \mathbb{Z}$ y el escalar $\frac{1}{2} \in \mathbb{R}$, entonces

$$\frac{1}{2} \cdot 1 = \frac{1}{2} \notin \mathbb{Z}.$$

Por tanto no hay cerradura bajo multiplicación por escalares reales.

Ejemplo 3.14 (Una operación “parecida” pero incorrecta). Consideremos $\mathbb{R}^2$ con la suma usual, pero definamos la multiplicación por escalares por

$$\lambda \odot (x, y) = (\lambda x, y).$$

Esto **no** da un espacio vectorial.

Qué falla. El axioma $0x = 0$ deja de cumplirse, porque

$$0 \odot (x, y) = (0, y),$$

que no es el vector cero salvo que $y = 0$. Este contraejemplo enseña que no basta tener una operación “similar” a la correcta: los axiomas deben cumplirse exactamente.

Proposición 3.15. *La intersección arbitraria de subespacios de un espacio vectorial V es un subespacio.*

Observación 3.16 (Qué significa este resultado). Este enunciado dice que las restricciones lineales compatibles pueden imponerse simultáneamente sin salir del mundo lineal. Por ejemplo, en $\mathbb{R}^3$ podemos intersectar dos planos que pasan por el origen y obtener una recta que también es subespacio; o intersectar varios conjuntos de soluciones de ecuaciones lineales homogéneas y seguir dentro de un subespacio. Es una de las razones por las que los sistemas lineales son tan manejables.

Ejemplo 3.17 (Intersección concreta). En $\mathbb{R}^3$, consideremos

$$W_1 = \{(x, y, z) : x + y + z = 0\}, \quad W_2 = \{(x, y, z) : x - z = 0\}.$$

Ambos son subespacios. Su intersección está dada por

$$x = z, \quad x + y + z = 0.$$

Sustituyendo $z = x$, queda $2x + y = 0$, es decir, $y = -2x$. Por tanto,

$$W_1 \cap W_2 = \{(x, -2x, x) : x \in \mathbb{R}\} = \text{span}((1, -2, 1)).$$

La intersección de dos planos lineales es aquí una recta lineal.

4. Combinaciones lineales, span e independencia lineal

Idea central

Una combinación lineal es la operación básica del curso. Con ella preguntamos dos cosas fundamentales: *qué puede construirse* a partir de ciertos vectores y *si hay redundancia* en lo que usamos para construirlo.

Definición 4.1. Si $v_1, \dots, v_r \in V$, una *combinación lineal* de estos vectores es toda expresión de la forma

$$a_1v_1 + \dots + a_rv_r, \quad a_1, \dots, a_r \in \mathbb{K}.$$

El *span* o *subespacio generado* por $v_1, \dots, v_r$ es el conjunto de todas sus combinaciones lineales y se denota por

$$\text{span}(v_1, \dots, v_r).$$

Definición 4.2. Una familia (v_i) es *linealmente independiente* si la única manera de obtener el vector cero como combinación lineal de ella es usando todos los coeficientes iguales a cero. En caso contrario, la familia es *linealmente dependiente*.

Intuición geométrica

Span responde a la pregunta “*qué puedo construir con estos vectores*”.

Independencia responde a la pregunta “*estoy usando direcciones realmente nuevas o algunas sobran*”.

La combinación de ambas ideas lleva directamente al concepto de base.

Ejemplo 4.3 (Span de dos vectores en $\mathbb{R}^2$). Sean

$$v_1 = (1, 0), \quad v_2 = (0, 1).$$

Entonces

$$\text{span}(v_1, v_2) = \mathbb{R}^2,$$

porque cualquier $(x, y) \in \mathbb{R}^2$ puede escribirse como

$$(x, y) = x(1, 0) + y(0, 1).$$

Lectura geométrica. Los vectores v_1 y v_2 proporcionan dos direcciones independientes y con ellas se alcanza todo el plano.

Ejemplo 4.4 (Span que solo produce una recta). Sean

$$v_1 = (1, 2), \quad v_2 = (2, 4).$$

Como $v_2 = 2v_1$, se tiene

$$\text{span}(v_1, v_2) = \text{span}(v_1) = \{(t, 2t) : t \in \mathbb{R}\}.$$

Qué pasa aquí. Aunque hay dos vectores escritos, en realidad solo hay una dirección nueva. El segundo no añade capacidad de generación.

Ejemplo 4.5 (Dependencia en datos de negocio). Imaginemos tres vectores de indicadores mensuales para una empresa:

$$v_1 = (1, 0, 1), \quad v_2 = (0, 1, 1), \quad v_3 = (1, 1, 2).$$

Se verifica que

$$v_3 = v_1 + v_2.$$

Por tanto la tercera columna no aporta información lineal nueva: es combinación exacta de las dos primeras. En un contexto de datos, esto significa redundancia perfecta.

Ejemplo 4.6 (Combinación lineal paso a paso en marketing). Supongamos que una campaña digital se resume con dos patrones básicos de respuesta:

$$v_1 = (100, 40), \quad v_2 = (30, 90),$$

donde la primera coordenada representa clics y la segunda conversiones ponderadas. Si una tercera campaña produce

$$w = (230, 220),$$

podemos preguntar si w es combinación lineal de v_1 y v_2 .

Buscamos escalares a, b tales que

$$a(100, 40) + b(30, 90) = (230, 220).$$

Esto equivale al sistema

$$100a + 30b = 230, \quad 40a + 90b = 220.$$

Dividiendo entre 10, queda

$$10a + 3b = 23, \quad 4a + 9b = 22.$$

Multiplicamos la primera por 3:

$$30a + 9b = 69.$$

Restando la segunda ecuación, obtenemos

$$26a = 47, \quad a = \frac{47}{26}.$$

Sustituyendo en $10a + 3b = 23$:

$$10 \cdot \frac{47}{26} + 3b = 23 \implies 3b = \frac{64}{13} \implies b = \frac{64}{39}.$$

Por tanto,

$$w = \frac{47}{26}v_1 + \frac{64}{39}v_2.$$

La interpretación es clara: el patrón observado puede reconstruirse como mezcla lineal de dos patrones base de comportamiento.

Ejemplo 4.7 (Independencia en polinomios). En $\mathbb{R}_2[X]$, los polinomios

$$1, X, X^2$$

son linealmente independientes. En efecto, si

$$a + bX + cX^2 = 0$$

como polinomio idénticamente nulo, entonces necesariamente $a = b = c = 0$.

Mensaje importante. La independencia no es solo un fenómeno geométrico; también existe en espacios de funciones, polinomios, matrices y series de datos.

Proposición 4.8. Sea $v_1, \dots, v_n \in V$. La familia $(v_1, \dots, v_n)$ es linealmente dependiente si y solo si alguno de los vectores pertenece al *span* de los anteriores.

Observación 4.9 (Cómo debe leerse este resultado). Este criterio permite detectar redundancia de manera conceptual. Una familia es dependiente exactamente cuando, en algún momento, uno de sus vectores ya estaba “contenido” en lo que habían generado los anteriores. En lenguaje de datos: aparece una variable que no añade una dirección nueva. En lenguaje geométrico: aparece un vector que cae en el subespacio

ya construido.

Ejemplo 4.10 (Aplicación inmediata del criterio). En $\mathbb{R}^3$, sea

$$v_1 = (1, 0, 0), \quad v_2 = (0, 1, 0), \quad v_3 = (1, 1, 0).$$

Como

$$v_3 = v_1 + v_2 \in \text{span}(v_1, v_2),$$

la familia es dependiente. Aquí el criterio evita resolver un sistema completo: basta observar que el tercer vector ya estaba generado por los dos primeros.




Figura 4. Dos vectores independientes generan el plano completo; un tercero que sea combinación lineal de ellos no añade ninguna dirección nueva.

Ejercicio resuelto paso a paso

Determinar si $v_1 = (1, 2, 0)$, $v_2 = (0, 1, 3)$, $v_3 = (2, 5, 3)$ **son linealmente independientes.**

Planteamos $\alpha v_1 + \beta v_2 + \gamma v_3 = 0$, que equivale al sistema:

$$\begin{pmatrix} 1 & 0 & 2 \\ 2 & 1 & 5 \\ 0 & 3 & 3 \end{pmatrix} \begin{pmatrix} \alpha \\ \beta \\ \gamma \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}.$$

Paso 1 — Eliminación gaussiana. $F_2 \leftarrow F_2 - 2F_1$:

$$\begin{pmatrix} 1 & 0 & 2 \\ 0 & 1 & 1 \\ 0 & 3 & 3 \end{pmatrix}.$$

$$F_3 \leftarrow F_3 - 3F_2:$$

$$\begin{pmatrix} 1 & 0 & 2 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \end{pmatrix}.$$

Paso 2 — Lectura del resultado. La última fila de ceros indica una ecuación redundante: el sistema tiene soluciones no triviales. Tomando $\gamma = t$ libre: $\beta = -t$, $\alpha = -2t$.

Paso 3 — Conclusión. Existe $t \neq 0$ con $-2tv_1 - tv_2 + tv_3 = 0$, es decir, $v_3 = 2v_1 + v_2$. La familia es **linealmente dependiente**. La tercera columna es redundante.

Conexión empresarial

En un modelo de datos, si v_1, v_2, v_3 fueran variables explicativas, la dependencia exacta $v_3 = 2v_1 + v_2$ indica **multicolinealidad perfecta**. Cualquier regresión que incluya las tres variables tendrá problemas de identificación.

Para practicar

- (a) ¿Son independientes $(1, 0, 1)$, $(0, 1, 1)$, $(1, 1, 2)$ en $\mathbb{R}^3$?
- (b) ¿Son independientes $1, X - 1, (X - 1)^2$ en $\mathbb{R}_2[X]$?
- (c) Si $w = av_1 + bv_2$ con v_1, v_2 independientes, ¿puede $\{v_1, v_2, w\}$ ser independiente?
- (d) En $M_{2 \times 2}(\mathbb{R})$, decide si $\left\{ \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}, \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}, \begin{pmatrix} 1 & 1 \\ 0 & 0 \end{pmatrix} \right\}$ es independiente.

Respuestas: (a) no; (b) sí; (c) no; (d) no.

5. Bases, dimensión y el lema de intercambio

Método de trabajo

Una base es una lista sin redundancia pero suficientemente rica para reconstruir todo el espacio. Esa idea es central en análisis de datos: elegir variables que basten para describir el fenómeno sin repetir información.

Definición 5.1. Una familia de vectores de V es una *base* si es linealmente independiente y además genera todo V .

Definición 5.2. Si V tiene una base con n elementos, diremos que V tiene *dimensión* n , y escribimos $\dim V = n$.

Ejemplo 5.3 (La base canónica de $\mathbb{R}^n$). En $\mathbb{R}^n$, la familia

$$e_1 = (1, 0, \dots, 0), \quad e_2 = (0, 1, \dots, 0), \quad \dots, \quad e_n = (0, 0, \dots, 1)$$

es una base.

Por qué es tan importante. Cada vector

$$(x_1, \dots, x_n)$$

se escribe de manera única como

$$(x_1, \dots, x_n) = x_1 e_1 + \dots + x_n e_n.$$

Las coordenadas no son otra cosa que los coeficientes de esta combinación lineal.

Ejemplo 5.4 (Base de polinomios). En $\mathbb{R}_n[X]$, la familia

$$1, X, X^2, \dots, X^n$$

es una base. Por ello,

$$\dim \mathbb{R}_n[X] = n + 1.$$

Interpretación. Para describir completamente un polinomio de grado a lo más n , basta conocer $n + 1$ coeficientes. Esos $n + 1$ números son las coordenadas del polinomio respecto de esta base natural.

Teorema 5.5 (Toda familia generadora finita contiene una base). *Si una familia finita genera un espacio vectorial de dimensión finita, entonces puede eliminarse la redundancia hasta obtener una base.*

Observación 5.6 (Qué significa). Este resultado dice que siempre es posible depurar una lista demasiado grande y quedarse con lo esencial. Si partimos de muchas variables, columnas o vectores que generan el fenómeno, podemos quitar las que están repetidas linealmente y conservar una familia mínima que siga describiéndolo todo. En aplicaciones, esto se relaciona con reducción de variables y eliminación de colinealidad exacta.

Teorema 5.7 (Toda familia independiente puede extenderse a una base). *Si una familia finita es linealmente independiente en un espacio vectorial de dimensión finita, entonces puede completarse agregando vectores hasta formar una base.*

Observación 5.8 (Qué significa). Este enunciado expresa la idea complementaria a la anterior: si ya tenemos información no redundante, pero todavía insuficiente, podemos añadir nuevas direcciones hasta obtener una descripción completa del espacio. En $\mathbb{R}^3$, por ejemplo, una recta generada por un vector no nulo puede completarse con otros dos vectores adecuados para formar una base del espacio.

Lema 5.9 (Lema de intercambio de Steinitz). *Sea V un espacio vectorial generado por n vectores. Entonces ninguna familia linealmente independiente de V puede tener más de n elementos. Más aún, los vectores independientes pueden intercambiarse por algunos de los generadores sin perder la capacidad de generar.*

Observación 5.10 (Lectura conceptual del lema). El lema de intercambio dice, en el fondo, que en un espacio generado por pocas direcciones no caben demasiadas direcciones independientes. También explica por qué la noción de dimensión es estable: si una familia genera con n vectores, cualquier familia independiente tiene a lo más n . Este es el mecanismo oculto detrás de casi todos los conteos de dimensión.

Teorema 5.11 (Invariancia de la dimensión). *Si V es un espacio vectorial de dimensión finita, cualesquiera dos bases de V tienen el mismo número de elementos.*

Observación 5.12 (Qué significa este resultado). Gracias a este teorema, la palabra *dimensión* está bien definida. No depende de la base elegida. En términos prácticos, la dimensión mide cuántas direcciones realmente independientes tiene el espacio. En $\mathbb{R}^2$ son dos; en $\mathbb{R}^3$ son tres; en el espacio de polinomios de grado a lo más dos, son tres; en el subespacio de matrices diagonales 2×2 , son dos.

Ejemplo 5.13 (Ejemplo detallado de extensión a base). Consideremos en $\mathbb{R}^3$ el vector

$$v = (1, 1, 0).$$

La familia (v) es independiente pero no genera todo $\mathbb{R}^3$. Podemos añadir

$$w_1 = (1, -1, 0), \quad w_2 = (0, 0, 1).$$

Entonces

$$((1, 1, 0), (1, -1, 0), (0, 0, 1))$$

forma una base de $\mathbb{R}^3$. El primer vector describe una dirección del plano xy , el segundo añade una nueva dirección en ese mismo plano, y el tercero incorpora la dirección vertical.

Ejemplo 5.14 (Ejemplo detallado de extracción de base). En $\mathbb{R}^3$, consideremos la familia generadora

$$(1, 0, 0), \quad (0, 1, 0), \quad (1, 1, 0), \quad (0, 0, 1).$$

Aquí el tercer vector es redundante porque

$$(1, 1, 0) = (1, 0, 0) + (0, 1, 0).$$

Si lo eliminamos, queda

$$(1, 0, 0), \quad (0, 1, 0), \quad (0, 0, 1),$$

que sigue generando $\mathbb{R}^3$ y además es independiente. Por tanto hemos extraído una base de una familia generadora más grande.

Ejercicio resuelto paso a paso

Hallar una base del subespacio $W = \{(x, y, z, w) \in \mathbb{R}^4 : x + y + z = 0, y + w = 0\}$.

Paso 1 — Expresar variables libres. Tenemos dos ecuaciones y cuatro incógnitas $\Rightarrow$ dos variables libres. Tomamos z y y como libres:

$$x = -y - z, \quad w = -y.$$

Paso 2 — Escribir la solución general.

$$(x, y, z, w) = y(-1, 1, 0, -1) + z(-1, 0, 1, 0).$$

Paso 3 — Identificar la base.

$$\mathcal{B} = \{(-1, 1, 0, -1), (-1, 0, 1, 0)\}.$$

Paso 4 — Verificar independencia. Ningún vector es múltiplo del otro (las terceras coordenadas son 0 y 1, distintas). Son independientes. ✓

Conclusión. $\dim W = 2$.

Conexión empresarial

Si (x, y, z, w) representara (ingresos, costos, margen, deuda) de cuatro unidades de negocio, las ecuaciones $x + y + z = 0$ y $y + w = 0$ serían restricciones contables. El subespacio W de dimensión 2 describe todas las combinaciones de cuatro variables que satisfacen simultáneamente esas dos restricciones.

Para practicar

- (a) Encuentra una base y la dimensión del subespacio de $\mathbb{R}^4$ definido por $x_1 - 2x_2 + x_3 = 0$.
- (b) ¿Cuántas bases tiene el espacio $\mathbb{R}_2[X]$ de polinomios de grado ≤ 2 ? (*Nota: infinitas; cualquier trio independiente que genere sirve.*)
- (c) Si $\dim V = 5$ y $W \subseteq V$ es subespacio con $\dim W = 3$, ¿qué valores puede tomar $\dim(V/W)$?
- (d) Prueba que $(1, 1)$ y $(1, -1)$ forman una base de $\mathbb{R}^2$ y halla las coordenadas de $(3, 7)$ en ella.

6. Suma, suma directa y cocientes

Idea central

La suma de subespacios permite combinar tipos de información; la suma directa garantiza que esa combinación no tenga ambigüedad; el cociente permite ignorar una parte del espacio y mirar solo lo que queda “modulo” esa parte.

Definición 6.1. Si $U, W \subseteq V$ son subespacios, su *suma* es

$$U + W = \{u + w : u \in U, w \in W\}.$$

Definición 6.2. Decimos que $V = U \oplus W$ es una *suma directa* si todo vector de V puede escribirse de manera única como $u + w$, con $u \in U$ y $w \in W$.

Proposición 6.3. Son equivalentes:

- (I) $V = U \oplus W$.
- (II) $V = U + W$ y $U \cap W = \{0\}$.

Observación 6.4 (Qué significa). La condición $U \cap W = \{0\}$ expresa que las componentes en U y en W no se confunden. Si hubiera un vector no nulo en la intersección, podría mover parte de la descomposición de un lado al otro y perderíamos unicidad. La suma directa es el lenguaje natural para separar un fenómeno en componentes independientes.

Ejemplo 6.5 (Descomposición concreta en $\mathbb{R}^2$). Sea

$$U = \text{span}((1, 0)), \quad W = \text{span}((0, 1)).$$

Entonces

$$\mathbb{R}^2 = U \oplus W.$$

En efecto, todo vector (a, b) se escribe como

$$(a, b) = (a, 0) + (0, b),$$

con $(a, 0) \in U$ y $(0, b) \in W$, y esta escritura es única.

Lectura aplicada. Esta descomposición separa naturalmente la información en dos coordenadas independientes: por ejemplo, costo fijo y costo variable; o retorno de dos factores básicos si se han elegido ejes adecuados.

Definición 6.6. Sea $W \subseteq V$ un subespacio. El *espacio cociente* V/W identifica dos vectores de V cuando difieren en un elemento de W . Sus elementos son clases de la forma

$$v + W = \{v + w : w \in W\}.$$

Proposición 6.7. Si V es de dimensión finita y $W \subseteq V$ es un subespacio, entonces

$$\dim(V/W) = \dim V - \dim W.$$

Observación 6.8 (Interpretación del cociente). El cociente V/W mide cuánta información queda después de declarar irrelevantes las direcciones contenidas en W . Si W representa una parte del fenómeno que queremos ignorar —por ejemplo, un componente sistemático ya conocido—, entonces V/W describe las clases de vectores una vez olvidada esa parte. La fórmula de dimensión dice exactamente cuánto “espacio libre” sobrevive.

7. Transformaciones lineales

Qué conviene recordar

Una transformación lineal se entiende bien si se conocen tres cosas: qué vectores anula, qué vectores produce y cómo actúa sobre una base. Núcleo, imagen y matriz son tres miradas complementarias del mismo objeto.

Definición 7.1. Sean V y W espacios vectoriales sobre $\mathbb{K}$. Una aplicación $T : V \rightarrow W$ es *lineal* si para todos $x, y \in V$ y todo $\lambda \in \mathbb{K}$,

$$T(x + y) = T(x) + T(y), \quad T(\lambda x) = \lambda T(x).$$

La linealidad significa exactamente que T preserva combinaciones lineales finitas:

$$T(a_1 v_1 + \cdots + a_r v_r) = a_1 T(v_1) + \cdots + a_r T(v_r).$$

Definición 7.2. Para una aplicación lineal $T : V \rightarrow W$, definimos el *núcleo* y la *imagen* por

$$\text{Ker}(T) = \{v \in V : T(v) = 0\}, \quad \text{Im}(T) = \{T(v) : v \in V\}.$$

Proposición 7.3. El núcleo y la imagen de una aplicación lineal son subespacios.

Demostración. Si $x, y \in \text{Ker}(T)$, entonces

$$T(x + y) = T(x) + T(y) = 0 + 0 = 0,$$

y para $\lambda \in \mathbb{K}$,

$$T(\lambda x) = \lambda T(x) = 0.$$

Por tanto $\text{Ker}(T)$ es subespacio. Para la imagen, si $u = T(x)$ y $v = T(y)$, entonces

$$u + v = T(x) + T(y) = T(x + y),$$

y si $\lambda \in \mathbb{K}$,

$$\lambda u = \lambda T(x) = T(\lambda x),$$

de modo que $\text{Im}(T)$ también es subespacio. □

Ejemplo 7.4 (Una transformación lineal concreta). Sea $T : \mathbb{R}^3 \rightarrow \mathbb{R}^2$ dada por

$$T(x, y, z) = (x - y, 2x + z).$$

Entonces T es lineal. Calculemos su núcleo:

$$T(x, y, z) = (0, 0) \iff x - y = 0, \quad 2x + z = 0.$$

De aquí,

$$y = x, \quad z = -2x,$$

y por tanto

$$\text{Ker}(T) = \{(t, t, -2t) : t \in \mathbb{R}\} = \text{span}((1, 1, -2)).$$

Así, $\dim \text{Ker}(T) = 1$.

La imagen se obtiene observando que

$$T(1, 0, 0) = (1, 2), \quad T(0, 1, 0) = (-1, 0), \quad T(0, 0, 1) = (0, 1).$$

Puesto que $(1, 2)$ y $(-1, 0)$ son linealmente independientes, $\text{Im}(T) = \mathbb{R}^2$, de modo que $\dim \text{Im}(T) = 2$.




Figura 6. Una transformación lineal “aplana” el núcleo (rojo) a cero y envía el resto del dominio sobre la imagen (verde). El teorema rango-nulidad contabiliza ambas partes.

Ejemplo 7.5 (Transformación lineal en un tablero de desempeño). Consideremos

$$T : \mathbb{R}^3 \rightarrow \mathbb{R}^2, \quad T(v_1, v_2, v_3) = (v_1 + v_2 + v_3, 2v_1 + v_2).$$

La primera coordenada resume el desempeño total y la segunda un índice ponderado que da más peso a la primera variable.

Si un vector es $(10, 5, 3)$, entonces

$$T(10, 5, 3) = (18, 25).$$

Es decir, del vector original de tres métricas pasamos a un tablero reducido de dos indicadores.

Para estudiar qué información se pierde, resolvemos

$$T(v_1, v_2, v_3) = (0, 0).$$

Esto equivale a

$$v_1 + v_2 + v_3 = 0, \quad 2v_1 + v_2 = 0.$$

De la segunda ecuación obtenemos $v_2 = -2v_1$, y sustituyendo en la primera resulta $v_3 = v_1$. Así,

$$\text{Ker}(T) = \text{span}((1, -2, 1)).$$

Este vector representa una combinación de cambios internos que el tablero resumido no distingue: produce indicadores finales iguales a cero y, por tanto, es invisible para el resumen.

Ejercicio resuelto paso a paso

Para $T : \mathbb{R}^4 \rightarrow \mathbb{R}^3$, $T(x_1, x_2, x_3, x_4) = (x_1 + x_2, x_2 + x_3, x_3 + x_4)$, **hallar** $\ker T$, $\text{Im } T$ **y verificar el teorema rango-nulidad.**

Paso 1 — Núcleo. Planteamos $T(x) = 0$:

$$x_1 + x_2 = 0, \quad x_2 + x_3 = 0, \quad x_3 + x_4 = 0.$$

De la primera: $x_1 = -x_2$. De la segunda: $x_3 = -x_2$. De la tercera: $x_4 = -x_3 = x_2$. Tomando $x_2 = t$ libre:

$$(x_1, x_2, x_3, x_4) = t(-1, 1, -1, 1).$$

$$\ker T = \text{span}((-1, 1, -1, 1)), \quad \dim \ker T = 1.$$

Paso 2 — Imagen. Calculamos T sobre la base canónica:

$$T(e_1) = (1, 0, 0), \quad T(e_2) = (1, 1, 0), \quad T(e_3) = (0, 1, 1), \quad T(e_4) = (0, 0, 1).$$

¿Son independientes $(1, 0, 0)$, $(1, 1, 0)$, $(0, 1, 1)$, $(0, 0, 1)$? Observamos que $(1, 1, 0) = (1, 0, 0) + (0, 1, 0)$, pero $(0, 1, 0) \notin \text{span}\{(1, 0, 0)\}$, así que hay que verificar el rango.

La matriz

$$\begin{pmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 \end{pmatrix}$$

tiene rango 3 (tres pivotes), luego $\dim \operatorname{Im} T = 3 = \dim \mathbb{R}^3$.

$$\operatorname{Im} T = \mathbb{R}^3.$$

Paso 3 — Verificar rango-nulidad.

$$\underbrace{\dim \ker T}_1 + \underbrace{\dim \operatorname{Im} T}_3 = 4 = \dim \mathbb{R}^4. \quad \checkmark$$

Conexión empresarial

En analítica, T puede interpretarse como una transformación que calcula *diferencias acumuladas* entre métricas consecutivas (ventas, margen, etc.). El núcleo—el vector $(-1, 1, -1, 1)$ —representa el patrón de cuatro métricas que se cancela por completo en las diferencias: el tablero de diferencias no lo detecta.

Para practicar

- (a) Para $T : \mathbb{R}^3 \rightarrow \mathbb{R}^3$, $T(x, y, z) = (x + y, y + z, x + z)$, calcula $\ker T$ e $\operatorname{Im} T$.
- (b) Si $T : \mathbb{R}^5 \rightarrow \mathbb{R}^3$ es lineal y $\dim \ker T = 3$, ¿qué valores puede tener $\dim \operatorname{Im} T$?
- (c) ¿Puede una aplicación lineal $T : \mathbb{R}^3 \rightarrow \mathbb{R}^4$ ser sobreyectiva? ¿E inyectiva?
- (d) Una empresa tiene $T : \mathbb{R}^4 \rightarrow \mathbb{R}^2$ que resume cuatro indicadores en dos. ¿Cuál es la nulidad mínima que garantiza el teorema rango-nulidad?

Respuestas: (a) $\ker = \{0\}$, $\operatorname{Im} = \mathbb{R}^3$; (b) solo $\dim \operatorname{Im} = 2$; (c) no sobreyectiva, sí inyectiva; (d) nulidad ≥ 2 .

8. Teorema rango–nulidad y primer teorema de isomorfismo

Idea central

Aquí aparece uno de los mensajes más profundos del curso: la dimensión del dominio se reparte entre las direcciones que desaparecen y las direcciones que sobreviven. El primer teorema de isomorfismo refina esa intuición al identificar exactamente el cociente por el núcleo con la imagen.

Teorema 8.1 (Rango–nulidad). *Sea $T : V \rightarrow W$ una aplicación lineal, con V de dimensión finita. Entonces*

$$\dim V = \dim \operatorname{Ker}(T) + \dim \operatorname{Im}(T).$$

Intuición geométrica

El teorema rango–nulidad puede leerse como una ley de conservación de dimensión. Toda dimensión del dominio termina o bien absorbida por el núcleo, o bien manifestándose en la imagen. No hay ninguna otra posibilidad.

Demostración. Sea $k_1, \dots, k_r$ una base de $\operatorname{Ker}(T)$, y extiéndase a una base de V :

$$k_1, \dots, k_r, v_{r+1}, \dots, v_n.$$

Afirmamos que

$$T(v_{r+1}), \dots, T(v_n)$$

forman una base de $\operatorname{Im}(T)$. Para ver que generan, sea $y \in \operatorname{Im}(T)$; entonces $y = T(v)$ para algún

$$v = a_1 k_1 + \dots + a_r k_r + a_{r+1} v_{r+1} + \dots + a_n v_n.$$

Por linealidad y porque $T(k_i) = 0$,

$$y = T(v) = a_{r+1} T(v_{r+1}) + \dots + a_n T(v_n).$$

Para la independencia lineal, si

$$a_{r+1} T(v_{r+1}) + \dots + a_n T(v_n) = 0,$$

entonces

$$T(a_{r+1} v_{r+1} + \dots + a_n v_n) = 0,$$

por lo que

$$a_{r+1} v_{r+1} + \dots + a_n v_n \in \operatorname{Ker}(T) = \operatorname{span}(k_1, \dots, k_r).$$

La independencia lineal de la base total de V obliga a $a_{r+1} = \dots = a_n = 0$. Concluimos que

$$\dim \operatorname{Im}(T) = n - r,$$

es decir,

$$\dim V = n = r + (n - r) = \dim \operatorname{Ker}(T) + \dim \operatorname{Im}(T).$$

□

Teorema 8.2 (Primer teorema de isomorfismo). *Sea $T : V \rightarrow W$ lineal. Entonces existe un isomorfismo natural*

$$\bar{T} : V/\text{Ker}(T) \xrightarrow{\sim} \text{Im}(T), \quad \bar{T}(v + \text{Ker}(T)) = T(v).$$

Demostración. Debemos mostrar primero que la aplicación está bien definida. Si

$$v + \text{Ker}(T) = v' + \text{Ker}(T),$$

entonces $v - v' \in \text{Ker}(T)$, es decir, $T(v - v') = 0$, y por tanto $T(v) = T(v')$. La linealidad es inmediata.

Es sobreyectiva por definición de la imagen. Es inyectiva porque

$$\bar{T}(v + \text{Ker}(T)) = 0 \iff T(v) = 0 \iff v \in \text{Ker}(T) \iff v + \text{Ker}(T) = \text{Ker}(T).$$

Luego $\bar{T}$ es un isomorfismo. □

$$\begin{array}{ccc} V & \xrightarrow{T} & \text{Im}(T) \\ \pi \downarrow & \nearrow \bar{T} & \\ V/\text{Ker}(T) & & \end{array}$$

Intuición geométrica

El diagrama anterior resume la situación completa: primero se colapsan todas las direcciones que T no distingue, es decir, las del núcleo; después, el operador resultante ya es fiel y describe exactamente la imagen. Esta es una de las primeras manifestaciones del principio universal “modulo el núcleo, una aplicación se vuelve inyectiva”.

Ejemplo 8.3 (Aplicación del teorema de isomorfismo). Para la transformación del ejemplo anterior,

$$T : \mathbb{R}^3 \rightarrow \mathbb{R}^2, \quad T(x, y, z) = (x - y, 2x + z),$$

tenemos

$$\mathbb{R}^3 / \text{span}((1, 1, -2)) \cong \mathbb{R}^2.$$

No se trata solo de una igualdad de dimensiones, sino de una identificación estructural: el espacio cociente por las direcciones “invisibles” para T se convierte exactamente en la imagen efectiva de la transformación.

9. Matrices y cambio de base

Error frecuente

Una matriz no es la transformación lineal; es su escritura en coordenadas. Cambiar de base cambia la matriz, pero no cambia la transformación. Toda vez que aparezca una fórmula matricial, hay que preguntarse cuál es su significado intrínseco.

Elegidas bases en el dominio y en el codominio, toda transformación lineal se representa mediante una matriz.

Definición 9.1. Sean V y W espacios vectoriales de dimensiones finitas n y m , respectivamente. Sea $\mathcal{B} = (e_1, \dots, e_n)$ una base de V , y $\mathcal{C} = (f_1, \dots, f_m)$ una base de W . La *matriz de $T : V \rightarrow W$ respecto de $\mathcal{B}$ y $\mathcal{C}$* es la matriz $[T]_{\mathcal{C} \leftarrow \mathcal{B}} \in \text{Mat}_{m \times n}(\mathbb{K})$ cuyas columnas son las coordenadas de $T(e_j)$ en la base $\mathcal{C}$.

Es decir, si

$$T(e_j) = a_{1j}f_1 + \dots + a_{mj}f_m,$$

entonces

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = (a_{ij})_{1 \leq i \leq m, 1 \leq j \leq n}.$$

Intuición geométrica

Leer una matriz por columnas es una habilidad central. La columna j no es un adorno: dice exactamente qué le hace la transformación al vector base e_j . Por eso, las columnas contienen la información operativa del mapa lineal.




Figura 9. Cada columna de A es la imagen del vector base correspondiente. El espacio de columnas es exactamente la imagen de la transformación lineal que representa A .

Ejercicio resuelto paso a paso

Para $T : \mathbb{R}^2 \rightarrow \mathbb{R}^2$, $T(x, y) = (3x + y, x + 2y)$, calcular la matriz en la base $\mathcal{B}' = \{(1, 1), (1, -1)\}$ y comparar con la base canónica.

Paso 1 — Matriz en base canónica $\mathcal{E}$.

$$T(e_1) = (3, 1), \quad T(e_2) = (1, 2) \Rightarrow [T]_{\mathcal{E}} = \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix}.$$

Paso 2 — Matriz de cambio de base P (de $\mathcal{B}'$ a $\mathcal{E}$).

$$P = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}, \quad \det(P) = -2, \quad P^{-1} = \frac{1}{-2} \begin{pmatrix} -1 & -1 \\ -1 & 1 \end{pmatrix} = \begin{pmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & -\frac{1}{2} \end{pmatrix}.$$

Paso 3 — Cambio de base.

$$[T]_{\mathcal{B}'} = P^{-1}[T]_{\mathcal{E}}P = \begin{pmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & -\frac{1}{2} \end{pmatrix} \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}.$$

Primero $[T]_{\mathcal{E}}P$:

$$\begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} = \begin{pmatrix} 4 & 2 \\ 3 & -1 \end{pmatrix}.$$

Luego P^{-1} por el resultado:

$$[T]_{\mathcal{B}'} = \begin{pmatrix} \frac{7}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{3}{2} \end{pmatrix}.$$

Verificación. $\det([T]_{\mathcal{B}'}) = \frac{7}{2} \cdot \frac{3}{2} - \frac{1}{2} \cdot \frac{1}{2} = \frac{21}{4} - \frac{1}{4} = 5$. Y $\det([T]_{\mathcal{E}}) = 3 \cdot 2 - 1 \cdot 1 = 5$. El determinante no cambia con el cambio de base. ✓

Conexión empresarial

En analítica, cambiar de base equivale a elegir un sistema de coordenadas adaptado al problema. Una base de eigenvectores hace que la matriz sea diagonal; una base de componentes principales (PCA) hace que las direcciones sean ortogonales y estén ordenadas de mayor a menor varianza explicada.

Para practicar

- Para $T : \mathbb{R}^2 \rightarrow \mathbb{R}^2$, $T(x, y) = (2x - y, x + 3y)$, calcula $[T]_{\mathcal{B}'}$ respecto de la base $\{(1, 0), (1, 1)\}$.
- Si $[T]_{\mathcal{B}} = \begin{pmatrix} 2 & 0 \\ 0 & 5 \end{pmatrix}$ (diagonal), ¿qué información da sobre T ?
- Dos analistas usan bases distintas para describir el mismo operador. Obtienen matrices diferentes. ¿Cuál tiene razón? ¿Cómo se relacionan sus matrices?

- (d) Calcula la traza y el determinante de $\begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix}$ en la base canónica y verifica que no cambian al cambiar de base.

Proposición 9.2. Si $S : U \rightarrow V$ y $T : V \rightarrow W$ son lineales, entonces la matriz de la composición satisface

$$[T \circ S] = [T] [S],$$

siempre que las bases elegidas sean compatibles.

Demostración. La columna j -ésima de $[S]$ contiene las coordenadas de $S(u_j)$ en la base de V . Al aplicar T , las coordenadas resultantes se obtienen multiplicando por $[T]$. La compatibilidad columna por columna produce la fórmula matricial usual. $\square$

Proposición 9.3 (Cambio de base). Sea $T : V \rightarrow V$, y sean $\mathcal{B}, \mathcal{B}'$ dos bases de V . Si P es la matriz de cambio de base de $\mathcal{B}'$ a $\mathcal{B}$, entonces

$$[T]_{\mathcal{B}'} = P^{-1} [T]_{\mathcal{B}} P.$$

Demostración. Si $[v]_{\mathcal{B}} = P[v]_{\mathcal{B}'}$, entonces

$$[T(v)]_{\mathcal{B}} = [T]_{\mathcal{B}} [v]_{\mathcal{B}} = [T]_{\mathcal{B}} P[v]_{\mathcal{B}'},$$

mientras que también

$$[T(v)]_{\mathcal{B}} = P[T(v)]_{\mathcal{B}'}.$$

Por tanto,

$$P[T(v)]_{\mathcal{B}'} = [T]_{\mathcal{B}} P[v]_{\mathcal{B}'},$$

y como esto vale para todo v , se concluye

$$[T]_{\mathcal{B}'} = P^{-1} [T]_{\mathcal{B}} P.$$

$\square$

$$\begin{array}{ccc} \mathbb{K}_{\mathcal{B}'}^n & \xrightarrow{[T]_{\mathcal{B}'}} & \mathbb{K}_{\mathcal{B}'}^n \\ P \downarrow & & \downarrow P \\ \mathbb{K}_{\mathcal{B}}^n & \xrightarrow{[T]_{\mathcal{B}}} & \mathbb{K}_{\mathcal{B}}^n \end{array}$$

Intuición geométrica

La semejanza expresa que cambiar de base no altera el operador, sino solo el sistema de coordenadas con el que lo observamos. En lenguaje geométrico, la información esencial del operador permanece intacta mientras que la rejilla con la que lo dibujamos cambia.

Observación 9.4. La relación anterior es la relación de *semejanza* entre matrices. Las matrices semejantes representan el mismo operador lineal en distintas coordenadas. Por ello, toda propiedad verdaderamente lineal debe ser invariante bajo semejanza.

Ejemplo 9.5 (Cálculo explícito de matriz). Sea $T : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ dada por

$$T(x, y) = (3x + y, x + 2y).$$

Respecto de la base canónica $\mathcal{E} = (e_1, e_2)$, tenemos

$$T(e_1) = (3, 1), \quad T(e_2) = (1, 2),$$

y por tanto

$$[T]_{\mathcal{E}} = \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix}.$$

Si ahora tomamos la base

$$\mathcal{B}' = ((1, 1), (1, -1)),$$

la matriz de cambio de base a la canónica es

$$P = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}.$$

Entonces

$$[T]_{\mathcal{B}'} = P^{-1}[T]_{\mathcal{E}}P.$$

Como

$$P^{-1} = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix},$$

se obtiene

$$[T]_{\mathcal{B}'} = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} = \begin{pmatrix} \frac{7}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{3}{2} \end{pmatrix}.$$

La transformación es la misma; solo ha cambiado su expresión matricial.

10. Espacios de columnas, filas y núcleos: el Teorema Fundamental del Álgebra Lineal

Idea central

Esta sección reúne varias de las intuiciones más importantes del curso. Cuando una matriz representa una transformación lineal, hay cuatro subespacios naturales que capturan toda la estructura: el espacio de columnas, el espacio de filas, el espacio nulo y el espacio nulo izquierdo. El Teorema Fundamental del Álgebra Lineal explica cómo se relacionan entre sí.

Definición 10.1. Sea $A \in \text{Mat}_{m \times n}(\mathbb{R})$.

- (I) El *espacio de columnas* de A , denotado $\text{Col}(A)$, es el subespacio de $\mathbb{R}^m$ generado por las columnas de A .
- (II) El *espacio de filas* de A , denotado $\text{Row}(A)$, es el subespacio de $\mathbb{R}^n$ generado por las filas de A .
- (III) El *espacio nulo* de A , denotado $\text{Null}(A)$, es

$$\text{Null}(A) = \{x \in \mathbb{R}^n : Ax = 0\}.$$

- (IV) El *espacio nulo izquierdo* de A es el espacio nulo de A^T , esto es,


$$\text{Null}(A^T) = \{y \in \mathbb{R}^m : A^T y = 0\}.$$

Qué conviene recordar

Dónde vive cada espacio.

$$\text{Col}(A), \text{Null}(A^T) \subseteq \mathbb{R}^m, \quad \text{Row}(A), \text{Null}(A) \subseteq \mathbb{R}^n.$$

Dos viven en el codominio matricial $\mathbb{R}^m$; dos viven en el dominio matricial $\mathbb{R}^n$. Esta sola observación evita muchísimas confusiones.



El teorema organiza el mundo matricial en dos pares ortogonales: filas versus espacio nulo en el dominio, y columnas versus nulo izquierdo en el codominio.

Teorema 10.2 (Teorema Fundamental del Álgebra Lineal). Si $A \in \text{Mat}_{m \times n}(\mathbb{R})$, entonces:

- (a) $\dim \text{Col}(A) = \dim \text{Row}(A) = \text{rk}(A)$.
- (b) $\dim \text{Null}(A) = n - \text{rk}(A)$.
- (c) $\dim \text{Null}(A^T) = m - \text{rk}(A)$.
- (d) $\text{Row}(A)^\perp = \text{Null}(A)$ en $\mathbb{R}^n$.
- (e) $\text{Col}(A)^\perp = \text{Null}(A^T)$ en $\mathbb{R}^m$.

Observación 10.3 (Cómo debe leerse el teorema). La primera igualdad dice que el número de columnas informativamente nuevas coincide con el número de filas informativamente nuevas. Las dos fórmulas de nulidad dicen cuánta libertad queda en el dominio y en el codominio después de fijar el rango. Las relaciones de ortogonalidad dicen algo todavía más fino: las restricciones invisibles de una matriz aparecen exactamente como direcciones perpendiculares a la información efectiva.

Ejemplo 10.4 (Ejemplo completo paso a paso). Consideremos

$$A = \begin{pmatrix} 1 & 0 & 2 \\ 0 & 1 & 1 \\ 1 & 1 & 3 \end{pmatrix}.$$

Las columnas son

$$c_1 = (1, 0, 1), \quad c_2 = (0, 1, 1), \quad c_3 = (2, 1, 3).$$

Observamos inmediatamente que

$$c_3 = 2c_1 + c_2.$$

Por tanto,

$$\text{Col}(A) = \text{span}(c_1, c_2), \quad \dim \text{Col}(A) = 2.$$

Las filas son

$$r_1 = (1, 0, 2), \quad r_2 = (0, 1, 1), \quad r_3 = (1, 1, 3),$$

y también satisfacen

$$r_3 = r_1 + r_2.$$

De modo que

$$\text{Row}(A) = \text{span}(r_1, r_2), \quad \dim \text{Row}(A) = 2.$$

Esto ya muestra que $\text{rk}(A) = 2$.

Ahora calculemos el espacio nulo. Buscamos $x = (x_1, x_2, x_3)$ tal que $Ax = 0$. El sistema es

$$x_1 + 2x_3 = 0, \quad x_2 + x_3 = 0, \quad x_1 + x_2 + 3x_3 = 0.$$

La tercera ecuación es redundante. Tomando $x_3 = t$, obtenemos

$$x_1 = -2t, \quad x_2 = -t.$$

Por tanto,

$$\text{Null}(A) = \text{span}((-2, -1, 1)), \quad \dim \text{Null}(A) = 1 = n - \text{rk}(A) = 3 - 2.$$

Para el nulo izquierdo resolvemos $A^T y = 0$, es decir,

$$\begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 2 & 1 & 3 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix} = 0.$$

Las ecuaciones son

$$y_1 + y_3 = 0, \quad y_2 + y_3 = 0, \quad 2y_1 + y_2 + 3y_3 = 0.$$

De nuevo, la tercera es redundante. Si $y_3 = -t$, entonces $y_1 = t$ y $y_2 = t$, de modo que

$$\text{Null}(A^T) = \text{span}((1, 1, -1)), \quad \dim \text{Null}(A^T) = 1 = m - \text{rk}(A) = 3 - 2.$$

Este ejemplo deja ver todo el teorema en una sola matriz: dos direcciones útiles en columnas, dos en filas, una libertad interna en el dominio y una restricción ortogonal en el codominio.

Ejemplo 10.5 (Lectura empresarial del espacio de columnas). Si una matriz A tiene columnas que representan métricas como ventas, margen y ticket promedio, entonces $\text{Col}(A)$ contiene todas las combinaciones observables de esas métricas en el espacio de resultados. Si una columna resulta ser combinación lineal de otras, entonces no aporta una dirección nueva de información: puede ser relevante gerencialmente, pero linealmente es redundante.

Ejemplo 10.6 (Lectura empresarial del espacio nulo). Si $Ax = 0$, el vector x describe una combinación de decisiones internas que deja intactos ciertos indicadores agregados. En analítica, esto significa que varios ajustes distintos pueden producir exactamente el mismo resumen final. El espacio nulo mide, por tanto, cuánta ambigüedad interna no detecta el tablero o modelo lineal que se está usando.

Qué conviene recordar

Resumen operativo.

- (1) Las **columnas** explican qué resultados puede producir la matriz.
- (2) Las **filas** explican qué combinaciones del dominio realmente se están leyendo.
- (3) El **espacio nulo** describe lo que la matriz no distingue.
- (4) El **nulo izquierdo** describe restricciones ocultas en el codominio.

Cuando se entiende esta tabla mental, la matriz deja de ser un rectángulo de números y se convierte en un mapa geométrico completo.

11. Determinantes

Qué conviene recordar

El determinante mide, simultáneamente, un fenómeno algebraico y uno geométrico: algebraicamente detecta invertibilidad; geométricamente registra el factor de escala orientado del volumen. Es importante ver ambas lecturas a la vez.

El determinante puede introducirse de varias formas. Conceptualmente, es la forma multilineal alternante normalizada por $\det(I_n) = 1$.

Definición 11.1. El *determinante* es la única aplicación

$$\det : \text{Mat}_n(\mathbb{K}) \rightarrow \mathbb{K}$$

que satisface:

- (I) es multilinear en las filas;
- (II) es alternante (si dos filas coinciden, el determinante es cero);
- (III) $\det(I_n) = 1$.

Teorema 11.2 (Fórmula de Leibniz). Para $A = (a_{ij}) \in \text{Mat}_n(\mathbb{K})$,

$$\det(A) = \sum_{\sigma \in S_n} \text{sgn}(\sigma) a_{1\sigma(1)} \cdots a_{n\sigma(n)}.$$

Intuición geométrica

La suma sobre permutaciones codifica todas las maneras posibles de escoger una entrada por fila y por columna. El signo $\text{sgn}(\sigma)$ corrige la orientación: permutaciones pares conservan orientación y permutaciones impares la invierten. Esa es la razón profunda por la que el determinante sabe detectar cambios de volumen orientado.

Observación 11.3. Aunque esta fórmula es explícita, no siempre es el modo más conceptual ni más eficiente de calcular determinantes. Las operaciones elementales y las descomposiciones triangulares suelen ser superiores para el cálculo efectivo.

Proposición 11.4. Para matrices cuadradas $A, B \in \text{Mat}_n(\mathbb{K})$, se tiene

$$\det(AB) = \det(A) \det(B).$$

En particular, A es invertible si y solo si $\det(A) \neq 0$.

Demostración. La función $B \mapsto \det(AB)$ es multilinear alternante en las filas de B . Por unicidad de la caracterización del determinante, debe ser un múltiplo escalar de $\det(B)$. Evaluando en $B = I_n$, el múltiplo resulta ser $\det(A)$. Así,

$$\det(AB) = \det(A) \det(B).$$

Si A es invertible, entonces

$$1 = \det(I_n) = \det(A) \det(A^{-1}),$$

luego $\det(A) \neq 0$. Recíprocamente, si $\det(A) \neq 0$, las filas de A son linealmente independientes, y por tanto A es invertible. $\square$

Ejemplo 11.5 (Un determinante por eliminación). Consideremos

$$A = \begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & 3 \\ 2 & 1 & 1 \end{pmatrix}.$$

Restando dos veces la primera fila a la tercera, obtenemos

$$\begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & 3 \\ 0 & -3 & 1 \end{pmatrix}.$$

Estas operaciones no cambian el determinante. Luego sumando tres veces la segunda fila a la tercera,

$$\begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & 3 \\ 0 & 0 & 10 \end{pmatrix}.$$

El determinante de una matriz triangular es el producto de la diagonal, de modo que

$$\det(A) = 1 \cdot 1 \cdot 10 = 10.$$




Figura 7. Pipeline de eliminación gaussiana para calcular el determinante. Las operaciones de fila no cambian el determinante (salvo intercambios de filas que multiplican por -1).

Ejercicio resuelto paso a paso

Calcular $\det(B)$ para $B = \begin{pmatrix} 2 & 1 & -1 \\ 0 & 3 & 2 \\ 4 & -1 & 1 \end{pmatrix}$, y decidir si B es invertible.

Paso 1 — Eliminar la columna 1. $F_3 \leftarrow F_3 - 2F_1$:

$$\begin{pmatrix} 2 & 1 & -1 \\ 0 & 3 & 2 \\ 0 & -3 & 3 \end{pmatrix}.$$

Paso 2 — Eliminar la columna 2. $F_3 \leftarrow F_3 + F_2$:

$$\begin{pmatrix} 2 & 1 & -1 \\ 0 & 3 & 2 \\ 0 & 0 & 5 \end{pmatrix}.$$

Paso 3 — Producto de la diagonal.

$$\det(B) = 2 \cdot 3 \cdot 5 = 30.$$

Conclusión. Como $\det(B) = 30 \neq 0$, la matriz B es **invertible**. El rango es 3.

Conexión empresarial

En finanzas, el determinante de una matriz de covarianza mide el *volumen generalizado* del riesgo del portafolio. Si $\det(\Sigma) = 0$, las variables de riesgo son perfectamente colineales y el modelo queda sobredeterminado.

Para practicar

(a) Calcula $\det \begin{pmatrix} 3 & 0 & 1 \\ 2 & -1 & 4 \\ 0 & 2 & 1 \end{pmatrix}$.

(b) Si $\det(A) = 5$ y $\det(B) = 3$, ¿cuánto vale $\det(2AB^{-1})$ para matrices 3×3 ?

(c) ¿Para qué valores de k es $\begin{pmatrix} k & 2 \\ 3 & k \end{pmatrix}$ no invertible?

(d) Una empresa tiene una matriz de transformación M con $\det(M) = 0$. ¿Qué implica eso para el rango de M ?

Respuestas: (a) -17 ; (b) $8^3 \cdot 5/3 = \frac{1280}{3}$; wait, $\det(2AB^{-1}) = 2^3 \det(A)/\det(B) = 8 \cdot 5/3 = 40/3$; (c) $k = \pm\sqrt{6}$; (d) *rango* $< n$, no es invertible, hay información redundante.

12. Polinomio característico, eigenvalores y eigenvectores

Idea central

Los eigenvectores son direcciones privilegiadas: el operador no las mezcla con otras, solo las estira, contrae o rota por un factor escalar. Encontrar estas direcciones suele transformar un problema complicado en varios problemas unidimensionales.

Definición 12.1. Sea $T : V \rightarrow V$ un endomorfismo, con $\dim V = n$. El *polinomio característico* de T es

$$\chi_T(\lambda) = \det(\lambda I - [T]_{\mathcal{B}}),$$

donde $\mathcal{B}$ es cualquier base de V .

Observación 12.2. La definición no depende de la base elegida, porque matrices semejantes tienen el mismo polinomio característico:

$$\det(\lambda I - P^{-1}AP) = \det(P^{-1}(\lambda I - A)P) = \det(\lambda I - A).$$

Definición 12.3. Un escalar $\lambda \in \mathbb{K}$ es un *eigenvalor* de T si existe un vector no nulo $v \in V$ tal que

$$T(v) = \lambda v.$$

El vector v se llama *eigenvector* asociado a λ .

Proposición 12.4. λ es eigenvalor de T si y solo si

$$\det(\lambda I - T) = 0.$$

Equivalente: los eigenvalores son exactamente las raíces del polinomio característico.

Demostración. La condición $T(v) = \lambda v$ para algún $v \neq 0$ equivale a

$$(\lambda I - T)(v) = 0$$

con $v \neq 0$, es decir, a que $\lambda I - T$ no sea inyectiva. En dimensión finita, eso equivale a no ser invertible; y una matriz cuadrada no es invertible si y solo si su determinante es cero. $\square$

Ejemplo 12.5 (Cálculo completo de eigenvalores). Sea

$$A = \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix}.$$

Entonces

$$\chi_A(\lambda) = \det \begin{pmatrix} \lambda - 3 & -1 \\ -1 & \lambda - 2 \end{pmatrix} = (\lambda - 3)(\lambda - 2) - 1 = \lambda^2 - 5\lambda + 5.$$

Sus raíces son

$$\lambda_{\pm} = \frac{5 \pm \sqrt{5}}{2}.$$

Para $\lambda_+ = \frac{5+\sqrt{5}}{2}$, resolvemos

$$(A - \lambda_+ I)v = 0.$$

La primera ecuación es

$$\left(3 - \frac{5 + \sqrt{5}}{2}\right)x + y = 0 \iff \frac{1 - \sqrt{5}}{2}x + y = 0,$$

por lo que podemos tomar

$$v_+ = \left(1, \frac{\sqrt{5} - 1}{2}\right).$$

Análogamente, para λ_- , un eigenvector es

$$v_- = \left(1, -\frac{1 + \sqrt{5}}{2}\right).$$

Ejercicio resuelto paso a paso

Encontrar los eigenvalores y eigenvectores de $A = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$ e interpretar geométricamente.

Paso 1 — Polinomio característico.

$$\chi_A(\lambda) = \det \begin{pmatrix} \lambda - 1 & -2 \\ -2 & \lambda - 1 \end{pmatrix} = (\lambda - 1)^2 - 4 = \lambda^2 - 2\lambda - 3 = (\lambda - 3)(\lambda + 1).$$

Eigenvalores: $\lambda_1 = 3$ y $\lambda_2 = -1$.

Paso 2 — Eigenvector para $\lambda_1 = 3$.

$$(A - 3I)v = 0 : \quad \begin{pmatrix} -2 & 2 \\ 2 & -2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = 0 \Rightarrow x = y.$$

$v_1 = (1, 1)/\sqrt{2}$ (normalizado). La transformación *estira* en esta dirección por factor 3.

Paso 3 — Eigenvector para $\lambda_2 = -1$.


$$(A + I)v = 0 : \quad \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = 0 \Rightarrow x = -y.$$

$v_2 = (1, -1)/\sqrt{2}$ (normalizado). La transformación *invierte* en esta dirección (factor -1).

Paso 4 — Interpretación geométrica.

La transformación A es una *simetría + escala*: estira la diagonal principal (dirección $(1, 1)$) por 3 e invierte la diagonal secundaria (dirección $(1, -1)$). Matricialmente:

$$A = P \begin{pmatrix} 3 & 0 \\ 0 & -1 \end{pmatrix} P^{-1}, \quad P = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}.$$

**Conexión empresarial**

En finanzas, si A fuera la matriz de covarianzas de dos activos, sus eigenvectores $(1, 1)/\sqrt{2}$ y $(1, -1)/\sqrt{2}$ serían la cartera “long-long” y la cartera “long-short”. Los eigenvalores indican la varianza de cada cartera. La de mayor eigenvalor ($\lambda = 3$) concentra más riesgo; la de menor eigenvalor ($\lambda = -1$)... ¡negativo! indicaría que la parametrización no es válida para una covarianza (las matrices de covarianza deben ser semidefinidas positivas).

Para practicar

- (a) Halla los eigenvalores de $\begin{pmatrix} 0 & 1 \\ -2 & 3 \end{pmatrix}$ y decide si es diagonalizable.
- (b) Para una matriz simétrica 2×2 con eigenvalores 5 y 2, ¿cuánto vale $\text{tr}(A)$ y $\det(A)$?
- (c) Si λ es eigenvalor de A , ¿es λ^2 eigenvalor de A^2 ? Demuéstralo o da un contraejemplo.
- (d) Una cadena de Markov tiene matriz de transición $M = \begin{pmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{pmatrix}$. Verifica que $\lambda = 1$ es siempre eigenvalor de cualquier matriz de Markov y halla el eigenvector correspondiente (distribución estacionaria).

Respuestas: (a) $\lambda = 1, 2$, sí diagonalizable; (b) $\text{tr} = 7$, $\det = 10$; (c) sí: $Av = \lambda v \Rightarrow A^2v = \lambda^2v$; (d) distribución estacionaria $(4/7, 3/7)$.

13. Diagonalización

Método de trabajo

Diagonalizar significa encontrar coordenadas adaptadas al operador. En esa base especial, el operador actúa independientemente sobre cada dirección coordinada. Por eso, una matriz diagonal es el análogo lineal de una forma “normal”.

Error frecuente

No basta con que una matriz tenga eigenvalores: para diagonalizar hace falta disponer de suficientes eigenvectores linealmente independientes. La verdadera condición es que la suma de dimensiones de los espacios propios sea toda la dimensión del espacio.

Definición 13.1. Un endomorfismo $T : V \rightarrow V$ es *diagonalizable* si existe una base de V formada por eigenvectores de T . Equivalente: si en alguna base su matriz es diagonal.

Proposición 13.2. *Eigenvectores asociados a eigenvalores distintos son linealmente independientes.*

Demostración. Sea $v_1, \dots, v_r$ con

$$T(v_i) = \lambda_i v_i, \quad \lambda_i \neq \lambda_j \text{ si } i \neq j.$$

Procedemos por inducción. Para $r = 1$ no hay nada que probar. Supongamos una relación

$$a_1 v_1 + \dots + a_r v_r = 0.$$

Aplicando T ,

$$a_1 \lambda_1 v_1 + \dots + a_r \lambda_r v_r = 0.$$

Multiplicando la primera relación por λ_r y restando, obtenemos

$$a_1(\lambda_1 - \lambda_r)v_1 + \dots + a_{r-1}(\lambda_{r-1} - \lambda_r)v_{r-1} = 0.$$

Por hipótesis inductiva, $a_1 = \dots = a_{r-1} = 0$, y entonces también $a_r = 0$. $\square$

Teorema 13.3. *Sea $T : V \rightarrow V$ con $\dim V = n$. Si el polinomio característico de T se separa en factores lineales y la suma de las dimensiones de los autoespacios es n , entonces T es diagonalizable.*

Demostración. Sea $\lambda_1, \dots, \lambda_s$ la lista de eigenvalores distintos, y sea

$$E_{\lambda_i} = \text{Ker}(T - \lambda_i I)$$

el autoespacio correspondiente. Por la proposición anterior, la suma de estos autoespacios es directa. Si la suma de sus dimensiones es n , su suma directa tiene dimensión n , luego coincide con V . Tomando una base en cada autoespacio y uniéndolas, obtenemos una base de V formada por eigenvectores. $\square$

Corolario 13.4. *Si un endomorfismo de dimensión n tiene n eigenvalores distintos en $\mathbb{K}$, entonces es diagonalizable.*

Ejemplo 13.5 (Diagonalización completa). Sea

$$A = \begin{pmatrix} 4 & 0 & 0 \\ 0 & 2 & 1 \\ 0 & 1 & 2 \end{pmatrix}.$$

El bloque inferior tiene polinomio característico

$$(\lambda - 2)^2 - 1 = (\lambda - 1)(\lambda - 3),$$

de modo que los eigenvalores de A son 4, 3, 1, todos distintos. Luego A es diagonalizable. Calculemos eigenvectores:

- Para $\lambda = 4$, un eigenvector es $(1, 0, 0)$.
- Para $\lambda = 3$, el bloque inferior satisface

$$\begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} y \\ z \end{pmatrix} = 0,$$

luego $y = z$, y un eigenvector es $(0, 1, 1)$.

- Para $\lambda = 1$,

$$\begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} y \\ z \end{pmatrix} = 0,$$

luego $y = -z$, y un eigenvector es $(0, 1, -1)$.

Si


$$P = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & -1 \end{pmatrix},$$

entonces

$$P^{-1}AP = \text{diag}(4, 3, 1).$$

Matriz original

Base de eigenvectores



Cada eigenvector: dirección propia del operador

Figura 8. Diagonalizar es elegir una base de eigenvectores. En esa base, el operador actúa de forma completamente desacoplada: estira o contrae cada dirección por su eigenvalor.

Ejercicio resuelto paso a paso

Diagonalizar completamente $M = \begin{pmatrix} 5 & 2 \\ 1 & 4 \end{pmatrix}$.

Paso 1 — Polinomio característico.

$$\chi_M(\lambda) = \det(\lambda I - M) = (\lambda - 5)(\lambda - 4) - 2 = \lambda^2 - 9\lambda + 18 = (\lambda - 3)(\lambda - 6).$$

Eigenvalores: $\lambda_1 = 3$, $\lambda_2 = 6$.

Paso 2 — Eigenvectores para $\lambda_1 = 3$.

$$(M - 3I)v = 0 : \quad \begin{pmatrix} 2 & 2 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = 0 \Rightarrow x = -y.$$

Eigenvector: $v_1 = (-1, 1)$ (o cualquier múltiplo no nulo).

Paso 3 — Eigenvectores para $\lambda_2 = 6$.

$$(M - 6I)v = 0 : \quad \begin{pmatrix} -1 & 2 \\ 1 & -2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = 0 \Rightarrow x = 2y.$$

Eigenvector: $v_2 = (2, 1)$.

Paso 4 — Construir P y verificar.

$$P = \begin{pmatrix} -1 & 2 \\ 1 & 1 \end{pmatrix}, \quad P^{-1} = \frac{1}{-3} \begin{pmatrix} 1 & -2 \\ -1 & -1 \end{pmatrix}.$$

$$P^{-1}MP = \begin{pmatrix} 3 & 0 \\ 0 & 6 \end{pmatrix} = D. \quad \checkmark$$

Aplicación — potencias de M . Una vez diagonalizada, $M^k = PD^kP^{-1}$, con $D^k = \text{diag}(3^k, 6^k)$. En modelos de crecimiento o cadenas de Markov, esto permite calcular el estado tras k pasos sin hacer k multiplicaciones de matrices.

Conexión empresarial

En economía, una matriz de insumo-producto M diagonalizable permite descomponer el crecimiento de un sistema en modos independientes. El eigenvalor de Perron-Frobenius (el mayor) determina la tasa de crecimiento de largo plazo; los demás eigenvalores gobiernan las oscilaciones transitorias.

Para practicar

- (a) Diagonaliza $\begin{pmatrix} 1 & 3 \\ 3 & 1 \end{pmatrix}$ y encuentra sus eigenvalores y eigenvectores.
- (b) ¿Es $\begin{pmatrix} 2 & 1 \\ 0 & 2 \end{pmatrix}$ diagonalizable? Justifica.
- (c) Si A es diagonalizable con eigenvalores $2, -1, 3$, calcula $\det(A)$, $\text{tr}(A)$ y $\det(A^3)$.
- (d) Una analista de riesgo tiene una matriz de covarianzas 3×3 diagonalizable. ¿Qué información dan sus eigenvalores sobre el portafolio?

Respuestas: (a) $\lambda = 4, -2$, eigenvectores $(1, 1)$ y $(1, -1)$; (b) no, solo un eigenvalor $\lambda = 2$ con espacio propio de dim 1; (c) $\det = -6$, $\text{tr} = 4$, $\det(A^3) = -216$; (d) los eigenvalores son las varianzas en las direcciones principales (componentes principales), la dirección del mayor eigenvalor es la de mayor riesgo.

Qué conviene recordar

Hoja de ruta del curso — conceptos y su conexión.

Concepto	Qué mide o describe	Ejemplo empresarial
Espacio vectorial	Universo donde combinamos linealmente	Perfiles de clientes en $\mathbb{R}^n$
Subespacio	Restricción lineal homogénea	Variables sujetas a una restricción contable
Span / base	Mínima información para generar todo	Variables no redundantes en un modelo
Dimensión	Grado de libertad del espacio	Número de factores explicativos independientes
Transformación lineal	Regla que respeta la estructura	Modelo lineal, filtro, proyección
Núcleo	Información invisible para la transformación	Patrones que el tablero no detecta
Imagen / rango	Información que sí produce la transformación	Espacio de predicciones posibles
Determinante	Escala de volumen orientado	Invertibilidad de un sistema de precios
Eigenvalores	Factores de escala en direcciones propias	Tasas de crecimiento en modelos dinámicos
Diagonalización	Cambio a base de eigenvectores	Componentes principales, factores de riesgo