

Cadenas de Markov Finitas (Tiempo Discreto):

Notas estilo IHES

con prerequisites, demostraciones completas y ejercicios resueltos

Contents

1	Preliminares y prerequisites usados en las demostraciones	2
1.1	Probabilidad en espacios finitos	2
1.2	Propiedad de Markov fuerte y tiempos de paro	2
1.3	Álgebra lineal y matrices estocásticas	3
1.4	Lema de Doeblin (minoración) y contracción	4
2	Definiciones básicas y álgebra de la matriz de transición	5
2.1	Propiedad de Markov y matriz de transición	5
2.2	Potencias, Chapman–Kolmogórov y forma operatorial	6
3	Comunicación, clases y descomposición	6
3.1	Accesibilidad y clases comunicantes	6
3.2	Conjuntos cerrados y clases cerradas	7
4	Periodicidad	8
5	Análisis de primer paso: probabilidades y tiempos de llegada	8
5.1	Probabilidades de llegada como funciones armónicas	8
5.2	Tiempos esperados de llegada	9
6	Recurrencia, transiencia y función de Green	9
7	Distribuciones estacionarias e invariancia	11
8	Convergencia al equilibrio y teoremas ergódicos	12
8.1	Caso aperiódico: convergencia de P^n	12
8.2	Caso periódico: convergencia de Cesàro	13
8.3	Teorema ergódico (promedios temporales)	14
9	Fórmula de Kac y tiempos de retorno	15
10	Cadenas absorbentes y matriz fundamental	15

11 Reversibilidad (opcional, pero estándar)	16
12 Ejercicios con soluciones	17

1 Preliminares y prerrequisitos usados en las demostraciones

Esta sección reúne los hechos de probabilidad, álgebra lineal y teoría de matrices que usaremos repetidamente. Todo se formula para espacios finitos, lo cual simplifica varias justificaciones (convergencia de series, intercambio suma/esperanza, etc.).

1.1 Probabilidad en espacios finitos

Definición 1.1 (Variables aleatorias y esperanza). Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad y $Y : \Omega \rightarrow \mathbb{R}$ una variable aleatoria integrable. La esperanza se define por $\mathbb{E}[Y] = \sum_y y \mathbb{P}(Y = y)$ cuando Y toma valores en un conjunto finito o numerable.

Lema 1.2 (Linealidad y acotación básica). Si Y, Z son integrables y $a, b \in \mathbb{R}$, entonces $\mathbb{E}[aY + bZ] = a\mathbb{E}[Y] + b\mathbb{E}[Z]$. Si $|Y| \leq M$ c.s. entonces $|\mathbb{E}[Y]| \leq M$.

Proof. Linealidad: se verifica directamente expandiendo la suma de la definición. Acotación: $|\mathbb{E}[Y]| \leq \mathbb{E}[|Y|] \leq \mathbb{E}[M] = M$. $\square$

Lema 1.3 (Convergencia monótona (versión discreta)). Si $(Y_n)_{n \geq 1}$ es una sucesión de variables aleatorias no negativas con $Y_n(\omega) \uparrow Y(\omega)$ para todo ω , entonces $\mathbb{E}[Y_n] \uparrow \mathbb{E}[Y]$ (posiblemente infinita).

Proof. En espacios discretos se puede escribir $Y_n = \sum_k a_{n,k} \mathbf{1}_{A_k}$ con particiones finitas, y el resultado se reduce al hecho elemental de que si $a_{n,k} \uparrow a_k$ con $a_{n,k} \geq 0$, entonces $\sum_k a_{n,k} \mathbb{P}(A_k) \uparrow \sum_k a_k \mathbb{P}(A_k)$ por convergencia monótona de series de términos no negativos. $\square$

Lema 1.4 (Fórmula de la cola). Si T es una variable aleatoria con valores en $\mathbb{N} \cup \{\infty\}$, entonces

$$\mathbb{E}[T] = \sum_{n=0}^{\infty} \mathbb{P}(T > n) \quad (\text{posiblemente } = \infty).$$

Proof. Observe que $T(\omega) = \sum_{n=0}^{\infty} \mathbf{1}_{\{T(\omega) > n\}}$ para cada ω (pues si $T = t$, la suma contiene exactamente t unos). Tomando esperanza e intercambiando suma/esperanza por convergencia monótona,

$$\mathbb{E}[T] = \mathbb{E}\left[\sum_{n \geq 0} \mathbf{1}_{\{T > n\}}\right] = \sum_{n \geq 0} \mathbb{E}[\mathbf{1}_{\{T > n\}}] = \sum_{n \geq 0} \mathbb{P}(T > n).$$

$\square$

1.2 Propiedad de Markov fuerte y tiempos de paro

Definición 1.5 (Tiempo de paro). Un tiempo aleatorio $\tau : \Omega \rightarrow \mathbb{N} \cup \{\infty\}$ es un *tiempo de paro* (respecto a la filtración natural $\mathcal{F}_n = \sigma(X_0, \dots, X_n)$) si para todo n el evento $\{\tau \leq n\}$ pertenece a $\mathcal{F}_n$.

Teorema 1.6 (Propiedad de Markov fuerte (caso finito, tiempo discreto)). Sea $(X_n)_{n \geq 0}$ una cadena de Markov homogénea con matriz de transición P . Si τ es un tiempo de paro con $\mathbb{P}(\tau < \infty) = 1$, entonces condicionalmente a $\mathcal{F}_\tau$, la evolución futura $(X_{\tau+n})_{n \geq 0}$ es una cadena de Markov con la misma matriz P y estado inicial X_τ . En particular, para toda función acotada f y todo $n \geq 0$,

$$\mathbb{E}[f(X_{\tau+n}) \mid \mathcal{F}_\tau] = (P^n f)(X_\tau).$$

Proof. Se prueba primero para tiempos de paro acotados (por ejemplo, $\tau \leq M$ c.s.) expandiendo por partición

$$\{\tau = 0\} \cup \{\tau = 1\} \cup \cdots \cup \{\tau = M\}$$

y usando la propiedad de Markov ordinaria en cada evento $\{\tau = k\}$: en dicho evento, $X_\tau = X_k$ y el futuro depende del pasado sólo vía X_k .

Para tiempos de paro generales con $\mathbb{P}(\tau < \infty) = 1$, se aproxima por $\tau_M = \min(\tau, M)$, aplicando el caso acotado a τ_M y pasando al límite $M \rightarrow \infty$: como f es acotada, las esperanzas condicionales convergen y se obtiene la identidad deseada. La afirmación cualitativa (el futuro es una copia fresca desde X_τ) es equivalente a la identidad para todas las funciones indicadoras $f = \mathbf{1}_{\{j\}}$. $\square$

1.3 Álgebra lineal y matrices estocásticas

Definición 1.7 (Simplejo de probabilidades). Sea $S = \{1, \dots, m\}$. El conjunto

$$\Delta = \left\{ x \in \mathbb{R}^m : x_i \geq 0, \sum_{i=1}^m x_i = 1 \right\}$$

se llama el *simplejo* de vectores de probabilidad.

Lema 1.8 (Compacidad del simplejo). Δ es compacto y convexo en $\mathbb{R}^m$.

Proof. Δ es cerrado (por continuidad de las coordenadas y de la suma) y acotado (todas las coordenadas están en $[0, 1]$), luego es compacto por Heine–Borel en dimensión finita. La convexidad es inmediata. $\square$

Definición 1.9 (Norma de variación total en espacio finito). Para dos probabilidades α, β en S , definimos

$$\|\alpha - \beta\|_{\text{TV}} := \frac{1}{2} \sum_{i \in S} |\alpha(i) - \beta(i)|.$$

Lema 1.10 (Dualidad de la variación total (finito)). Para probabilidades α, β en S ,

$$\|\alpha - \beta\|_{\text{TV}} = \max_{A \subset S} |\alpha(A) - \beta(A)| = \frac{1}{2} \max_{\|f\|_\infty \leq 1} \left| \sum_{i \in S} f(i) (\alpha(i) - \beta(i)) \right|.$$

Proof. En espacio finito se usa el conjunto $A = \{i : \alpha(i) \geq \beta(i)\}$. Entonces $\sum_i (\alpha(i) - \beta(i)) = 0$ implica

$$\sum_{i \in A} (\alpha(i) - \beta(i)) = - \sum_{i \notin A} (\alpha(i) - \beta(i)) = \frac{1}{2} \sum_i |\alpha(i) - \beta(i)|.$$

De ahí se obtiene la igualdad con el máximo en conjuntos. La forma dual se obtiene tomando $f = \mathbf{1}_A - \mathbf{1}_{A^c}$ (que tiene norma supremo ≤ 1) y verificando que alcanza el máximo. $\square$

Lema 1.11 (Un kernel estocástico no aumenta la variación total). Sea K una matriz estocástica (kernel) en S . Entonces para probabilidades α, β ,

$$\|\alpha K - \beta K\|_{\text{TV}} \leq \|\alpha - \beta\|_{\text{TV}}.$$

Proof. Usamos la dualidad:

$$\|\alpha K - \beta K\|_{\text{TV}} = \frac{1}{2} \max_{\|f\|_{\infty} \leq 1} \left| \sum_j f(j) [(\alpha K)(j) - (\beta K)(j)] \right|.$$

Pero

$$\sum_j f(j) (\alpha K)(j) = \sum_j f(j) \sum_i \alpha(i) K(i, j) = \sum_i \alpha(i) \sum_j K(i, j) f(j) = \sum_i \alpha(i) (Kf)(i).$$

Entonces

$$\sum_j f(j) [(\alpha K)(j) - (\beta K)(j)] = \sum_i (\alpha(i) - \beta(i)) (Kf)(i).$$

Como K es estocástica, $(Kf)(i)$ es combinación convexa de valores de f , así que $\|Kf\|_{\infty} \leq \|f\|_{\infty} \leq 1$. Por lo tanto el máximo sobre f no puede exceder el máximo correspondiente para $\alpha - \beta$, y se concluye. $\square$

1.4 Lema de Doeblin (minoración) y contracción

Lema 1.12 (Minoración de Doeblin $\Rightarrow$ contracción estricta). Sea K una matriz estocástica en S . Supongamos que existen una probabilidad ρ en S y $\varepsilon \in (0, 1]$ tales que

$$K(i, j) \geq \varepsilon \rho(j) \quad \forall i, j \in S.$$

Entonces para cualesquiera probabilidades α, β en S ,

$$\|\alpha K - \beta K\|_{\text{TV}} \leq (1 - \varepsilon) \|\alpha - \beta\|_{\text{TV}}.$$

Proof. Definimos

$$\widetilde{K}(i, j) := \frac{K(i, j) - \varepsilon \rho(j)}{1 - \varepsilon} \quad (\varepsilon < 1),$$

y si $\varepsilon = 1$ el resultado es trivial pues $K(i, \cdot) \equiv \rho$ para todo i . Por hipótesis, $\widetilde{K}(i, j) \geq 0$. Además,

$$\sum_j \widetilde{K}(i, j) = \frac{\sum_j K(i, j) - \varepsilon \sum_j \rho(j)}{1 - \varepsilon} = \frac{1 - \varepsilon}{1 - \varepsilon} = 1,$$

luego $\widetilde{K}$ es estocástica. Tenemos la descomposición convexa

$$K = \varepsilon(\mathbf{1}\rho) + (1 - \varepsilon)\widetilde{K},$$

donde $(\mathbf{1}\rho)(i, \cdot) = \rho(\cdot)$ para todo i . Entonces

$$\alpha K - \beta K = \varepsilon(\alpha - \beta)(\mathbf{1}\rho) + (1 - \varepsilon)(\alpha \widetilde{K} - \beta \widetilde{K}).$$

Como $\sum_i (\alpha(i) - \beta(i)) = 0$, el primer término se anula:

$$[(\alpha - \beta)(\mathbf{1}\rho)](j) = \sum_i (\alpha(i) - \beta(i)) \rho(j) = 0.$$

Por tanto,

$$\alpha K - \beta K = (1 - \varepsilon)(\alpha \widetilde{K} - \beta \widetilde{K}).$$

Aplicando el lema anterior (no aumento de $\|\cdot\|_{\text{TV}}$) a $\widetilde{K}$, obtenemos

$$\|\alpha K - \beta K\|_{\text{TV}} = (1 - \varepsilon)\|\alpha \widetilde{K} - \beta \widetilde{K}\|_{\text{TV}} \leq (1 - \varepsilon)\|\alpha - \beta\|_{\text{TV}}.$$

□

2 Definiciones básicas y álgebra de la matriz de transición

2.1 Propiedad de Markov y matriz de transición

Definición 2.1 (Cadena de Markov finita). Sea $S = \{1, \dots, m\}$ un conjunto finito. Un proceso estocástico $(X_n)_{n \geq 0}$ con valores en S es una *cadena de Markov homogénea* si para todo $n \geq 0$ y todo $i_0, \dots, i_n, j \in S$ con $\mathbb{P}(X_0 = i_0, \dots, X_n = i_n) > 0$ se cumple

$$\mathbb{P}(X_{n+1} = j \mid X_n = i_n, \dots, X_0 = i_0) = \mathbb{P}(X_{n+1} = j \mid X_n = i_n).$$

Definición 2.2 (Matriz de transición). Definimos

$$P(i, j) := \mathbb{P}(X_{n+1} = j \mid X_n = i) \quad (i, j \in S).$$

Por homogeneidad, no depende de n . La matriz $P = (P(i, j))$ es estocástica por filas: $P(i, j) \geq 0$ y $\sum_{j \in S} P(i, j) = 1$ para cada i .

Definición 2.3 (Ley inicial y notación $\mathbb{P}_\mu, \mathbb{P}_i$). Sea μ una probabilidad en S . Denotamos por $\mathbb{P}_\mu$ la ley de la cadena con $\mathbb{P}_\mu(X_0 = i) = \mu(i)$. Si $\mu = \delta_i$ (masa puntual), escribimos $\mathbb{P}_i$ y $\mathbb{E}_i$.

Proposición 2.4 (Distribuciones finito-dimensionales a partir de (μ, P)). Dados μ en S y una matriz estocástica P , existe una cadena de Markov $(X_n)_{n \geq 0}$ con $X_0 \sim \mu$ y transición P , única en ley. Además, para $n \geq 0$ e $(i_0, \dots, i_n) \in S^{n+1}$,

$$\mathbb{P}_\mu(X_0 = i_0, \dots, X_n = i_n) = \mu(i_0) \prod_{k=0}^{n-1} P(i_k, i_{k+1}).$$

Proof. (Construcción) Definimos una probabilidad sobre cilindros $[i_0, \dots, i_n]$ por la fórmula dada. Verificamos consistencia: al marginalizar en i_n ,

$$\sum_{i_n \in S} \mu(i_0) \prod_{k=0}^{n-2} P(i_k, i_{k+1}) P(i_{n-1}, i_n) = \mu(i_0) \prod_{k=0}^{n-2} P(i_k, i_{k+1}) \sum_{i_n} P(i_{n-1}, i_n) = \mu(i_0) \prod_{k=0}^{n-2} P(i_k, i_{k+1}),$$

pues cada fila de P suma 1. En espacio de estados finito, esta consistencia es suficiente para definir una medida en $S^\mathbb{N}$ (vía extensión por álgebra de cilindros). (*Markov*) Para historia $X_0 = i_0, \dots, X_n = i$ con probabilidad positiva,

$$\mathbb{P}_\mu(X_{n+1} = j \mid X_0 = i_0, \dots, X_n = i) = \frac{\mathbb{P}_\mu(X_0 = i_0, \dots, X_n = i, X_{n+1} = j)}{\mathbb{P}_\mu(X_0 = i_0, \dots, X_n = i)} = \frac{\mu(i_0) \prod_{k=0}^{n-1} P(i_k, i_{k+1}) P(i, j)}{\mu(i_0) \prod_{k=0}^{n-1} P(i_k, i_{k+1})} =$$

(*Unicidad*) La ley está determinada por todas las distribuciones finito-dimensionales, las cuales fija la fórmula. □

2.2 Potencias, Chapman–Kolmogórov y forma operatorial

Definición 2.5 (n -pasos). Definimos P^n por multiplicación matricial, con $P^0 = I$.

Proposición 2.6 (Chapman–Kolmogórov). Para todo $m, n \geq 0$ y $i, j \in S$,

$$P^{m+n}(i, j) = \sum_{k \in S} P^m(i, k) P^n(k, j).$$

Proof. Es exactamente la fórmula del producto matricial: $P^{m+n} = P^m P^n$ y $(AB)(i, j) = \sum_k A(i, k) B(k, j)$. $\square$

Proposición 2.7 (Evolución de distribuciones). Si $X_0 \sim \mu$, entonces la distribución μ_n de X_n satisface

$$\mu_n = \mu P^n, \quad \mu_n(j) = \sum_{i \in S} \mu(i) P^n(i, j).$$

Proof. Por inducción. Para $n = 0$ es trivial. Si vale para n , entonces

$$\mu_{n+1}(j) = \mathbb{P}_\mu(X_{n+1} = j) = \sum_{i \in S} \mathbb{P}_\mu(X_n = i, X_{n+1} = j) = \sum_i \mathbb{P}_\mu(X_n = i) \mathbb{P}_\mu(X_{n+1} = j \mid X_n = i) = \sum_i \mu_n(i) P(i, j)$$

de donde $\mu_{n+1} = \mu_n P = \mu P^{n+1}$. $\square$

Definición 2.8 (Operador de Markov). Para $f : S \rightarrow \mathbb{R}$, definimos

$$(Pf)(i) := \sum_{j \in S} P(i, j) f(j).$$

Proposición 2.9 (Esperanza condicional). Para toda f acotada y todo $n \geq 0$,

$$\mathbb{E}[f(X_{n+1}) \mid X_n] = (Pf)(X_n), \quad \mathbb{E}_i[f(X_n)] = (P^n f)(i).$$

Proof. Para la primera identidad, sobre el evento $\{X_n = i\}$,

$$\mathbb{E}[f(X_{n+1}) \mid X_n = i] = \sum_{j \in S} f(j) \mathbb{P}(X_{n+1} = j \mid X_n = i) = \sum_j P(i, j) f(j) = (Pf)(i).$$

Luego $\mathbb{E}[f(X_{n+1}) \mid X_n] = (Pf)(X_n)$.

Para la segunda, por inducción:

$$\mathbb{E}_i[f(X_{n+1})] = \mathbb{E}_i(\mathbb{E}[f(X_{n+1}) \mid X_n]) = \mathbb{E}_i[(Pf)(X_n)] = (P^n(Pf))(i) = (P^{n+1}f)(i).$$

$\square$

3 Comunicación, clases y descomposición

3.1 Accesibilidad y clases comunicantes

Definición 3.1 (Accesibilidad y comunicación). Para $i, j \in S$, escribimos $i \rightarrow j$ si existe $n \geq 0$ con $P^n(i, j) > 0$. Escribimos $i \leftrightarrow j$ si $i \rightarrow j$ y $j \rightarrow i$.

Proposición 3.2 (La comunicación es relación de equivalencia). La relación $\leftrightarrow$ es una relación de equivalencia en S . Sus clases se llaman clases comunicantes.

Proof. Reflexiva: $P^0(i, i) = 1 > 0$, luego $i \rightarrow i$.

Simétrica: por definición.

Transitiva: si $i \leftrightarrow j$ y $j \leftrightarrow k$, entonces existen m, n con $P^m(i, j) > 0$ y $P^n(j, k) > 0$. Por Chapman–Kolmogórov,

$$P^{m+n}(i, k) \geq P^m(i, j)P^n(j, k) > 0,$$

así $i \rightarrow k$. De forma análoga $k \rightarrow i$. Luego $i \leftrightarrow k$. $\square$

Definición 3.3 (Irreducibilidad). La cadena (o P) es *irreducible* si $i \leftrightarrow j$ para todo $i, j \in S$.

3.2 Conjuntos cerrados y clases cerradas

Definición 3.4 (Conjunto cerrado). Un subconjunto $C \subset S$ es *cerrado* si $P(i, C) = 1$ para todo $i \in C$. Una clase comunicante C es *cerrada* si es cerrada como conjunto.

Lema 3.5 (No se puede salir de un conjunto cerrado). Si C es cerrado y $X_0 \in C$, entonces $\mathbb{P}(X_n \in C \ \forall n \geq 0) = 1$.

Proof. Para cada n , en el evento $\{X_n \in C\}$ se tiene $\mathbb{P}(X_{n+1} \in C \mid X_n) = 1$ por cerradura. Inductivamente, $\mathbb{P}(X_k \in C \ \forall 0 \leq k \leq n) = 1$ para todo n , y por intersección numerable concluimos. $\square$

Proposición 3.6 (Existencia de clases comunicantes cerradas). Toda cadena de Markov en espacio finito tiene al menos una clase comunicante cerrada.

Proof. Consideramos el grafo dirigido con vértices S y arista $i \rightarrow j$ si $P(i, j) > 0$. El grafo de componentes fuertemente conexas (condensación) es un DAG finito, por tanto posee un vértice sumidero. La componente correspondiente no tiene aristas salientes hacia otras componentes, lo que equivale a que la clase comunicante es cerrada. $\square$

Definición 3.7 (Tiempos de llegada y retorno). Para $A \subset S$:

$$\tau_A := \inf\{n \geq 0 : X_n \in A\}, \quad \tau_i := \tau_{\{i\}}.$$

El tiempo de retorno a i :

$$T_i := \inf\{n \geq 1 : X_n = i\}.$$

Teorema 3.8 (En espacio finito, la cadena entra a alguna clase cerrada a.s.). Sean $\mathcal{C}_1, \dots, \mathcal{C}_r$ las clases comunicantes cerradas de una cadena finita. Entonces para todo estado inicial i ,

$$\mathbb{P}_i(\exists k \in \{1, \dots, r\} : \tau_{\mathcal{C}_k} < \infty) = 1.$$

Además, una vez que entra a $\mathcal{C}_k$, no sale de ella.

Proof. La segunda afirmación es el lema anterior (no salir de cerrado).

Para la primera: supongamos por contradicción que existe i tal que con probabilidad positiva la cadena nunca visita $\cup_k \mathcal{C}_k$. En ese evento, la cadena vive para siempre en el conjunto finito $S \setminus (\cup_k \mathcal{C}_k)$. Por el principio del palomar, existe al menos un estado v que es visitado infinitamente muchas veces. Sea V el conjunto de estados visitados infinitamente muchas veces en ese evento; entonces $V \neq \emptyset$.

Afirmamos que V es una clase comunicante cerrada (lo cual contradice que $\mathcal{C}_1, \dots, \mathcal{C}_r$ sean todas las clases cerradas).

- *Cerradura:* si $v \in V$ y $P(v, w) > 0$, entonces cada vez que la cadena visita v tiene probabilidad $P(v, w)$ de ir a w al siguiente paso. Como v se visita infinitamente a menudo, por repetición independiente-condicional (propiedad de Markov fuerte en tiempos de visita a v), la transición $v \rightarrow w$ ocurre infinitamente muchas veces con probabilidad 1 sobre el evento en cuestión. Luego w se visita infinitamente a menudo y $w \in V$.
- *Comunicación:* si $v, v' \in V$, como ambas ocurren infinitamente muchas veces a lo largo de una misma trayectoria, existen tiempos $n < m$ con $X_n = v$ y $X_m = v'$, lo que implica $v \rightarrow v'$. Simétricamente $v' \rightarrow v$.

Concluimos que V es una clase comunicante cerrada disjunta de $\cup_k \mathcal{C}_k$, contradicción. $\square$

4 Periodicidad

Definición 4.1 (Periodo). Para $i \in S$ definimos

$$d(i) := \gcd\{n \geq 1 : P^n(i, i) > 0\}.$$

Si $d(i) = 1$ decimos que i es *aperiódico*.

Proposición 4.2 (El periodo es constante en una clase comunicante). Si $i \leftrightarrow j$, entonces $d(i) = d(j)$.

Proof. Como $i \leftrightarrow j$, existen $m, n \geq 1$ con $P^m(i, j) > 0$ y $P^n(j, i) > 0$. Sea $t \geq 1$ tal que $P^t(j, j) > 0$. Entonces por Chapman–Kolmogórov,

$$P^{m+t+n}(i, i) \geq P^m(i, j)P^t(j, j)P^n(j, i) > 0,$$

así $m+t+n$ pertenece al conjunto de retornos de i . Esto muestra que todo t con $P^t(j, j) > 0$ produce un retorno de i al sumar la constante $m+n$. En particular, $d(i)$ divide $m+n+t$ para todo t en el conjunto de j . Por lo tanto $d(i)$ divide cualquier combinación lineal entera de tales tiempos, y en particular divide $d(j)$. Intercambiando el papel de i y j se obtiene también $d(j) \mid d(i)$, por lo que $d(i) = d(j)$. $\square$

Definición 4.3 (Cadena aperiódica). Una cadena irreducible es *aperiódica* si (equivalentemente) algún (y entonces todo) estado tiene periodo 1.

5 Análisis de primer paso: probabilidades y tiempos de llegada

5.1 Probabilidades de llegada como funciones armónicas

Proposición 5.1 (Ecuación de primer paso para probabilidades de llegada). Sea $A \subset S$ no vacío y $h(i) := \mathbb{P}_i(\tau_A < \infty)$. Entonces h satisface

$$h(i) = 1 \quad (i \in A), \quad h(i) = \sum_{j \in S} P(i, j)h(j) \quad (i \notin A),$$

y es la mínima solución no negativa de ese problema de frontera.

Proof. Si $i \in A$, entonces $\tau_A = 0$ y $h(i) = 1$.

Si $i \notin A$, descomponemos por el primer paso:

$$h(i) = \mathbb{P}_i(\tau_A < \infty) = \sum_{j \in S} \mathbb{P}_i(X_1 = j) \mathbb{P}_i(\tau_A < \infty \mid X_1 = j).$$

Por Markov fuerte en $\tau = 1$ (o Markov ordinaria), condicionalmente a $X_1 = j$ el futuro desde tiempo 1 es una copia de la cadena iniciada en j , así $\mathbb{P}_i(\tau_A < \infty \mid X_1 = j) = \mathbb{P}_j(\tau_A < \infty) = h(j)$. Luego

$$h(i) = \sum_j P(i, j) h(j).$$

Minimalidad. Sea $g \geq 0$ otra solución. Definimos $h_n(i) := \mathbb{P}_i(\tau_A \leq n)$. Entonces $h_0 = \mathbf{1}_A$ y para $i \notin A$:

$$h_{n+1}(i) = \sum_j P(i, j) h_n(j),$$

pues para llegar a A en $\leq n+1$ pasos, primero se va a j y luego se llega en $\leq n$ pasos desde j . Por inducción en n se verifica $h_n \leq g$ (usando que g satisface la misma ecuación y que $h_0 \leq g$). Finalmente $h_n(i) \uparrow h(i)$ cuando $n \rightarrow \infty$ y por convergencia monótona concluimos $h \leq g$. $\square$

5.2 Tiempos esperados de llegada

Proposición 5.2 (Ecuación de primer paso para tiempos esperados). *Supongamos que $\mathbb{P}_i(\tau_A < \infty) = 1$ para todo i (por ejemplo, cuando A intersecta todas las clases cerradas). Definimos $u(i) := \mathbb{E}_i[\tau_A]$ (posiblemente infinita en general, finita en muchos casos finitos). Entonces*

$$u(i) = 0 \quad (i \in A), \quad u(i) = 1 + \sum_{j \in S} P(i, j) u(j) \quad (i \notin A),$$

y entre las soluciones no negativas es la mínima.

Proof. Si $i \in A$, $\tau_A = 0$ y $u(i) = 0$. Si $i \notin A$, entonces $\tau_A = 1 + \tau_A \circ \theta_1$, donde θ_1 es el corrimiento del camino. Condicionando por X_1 y usando Markov fuerte en tiempo 1:

$$u(i) = \mathbb{E}_i[\tau_A] = \mathbb{E}_i[1 + \tau_A \circ \theta_1] = 1 + \sum_{j \in S} \mathbb{P}_i(X_1 = j) \mathbb{E}_i[\tau_A \circ \theta_1 \mid X_1 = j] = 1 + \sum_j P(i, j) \mathbb{E}_j[\tau_A] = 1 + \sum_j P(i, j) u(j)$$

Minimalidad: sea $v \geq 0$ solución. Definimos $u^{(n)}(i) = \mathbb{E}_i[\tau_A \wedge n]$. Estas funciones satisfacen una ecuación de tipo primer paso con término de error no negativo; se prueba por inducción que $u^{(n)} \leq v$ para todo n . Luego $u^{(n)} \uparrow u$ y por convergencia monótona $u \leq v$. $\square$

6 Recurrencia, transiencia y función de Green

Definición 6.1 (Recurrencia y transiencia). Un estado i es *recurrente* si $\mathbb{P}_i(T_i < \infty) = 1$ y *transiente* si $\mathbb{P}_i(T_i < \infty) < 1$.

Definición 6.2 (Función de Green). Para $i, j \in S$ definimos

$$G(i, j) := \sum_{n=0}^{\infty} P^n(i, j) \in [0, \infty].$$

Proposición 6.3 (Interpretación de Green: número esperado de visitas). Sea $N_j := \sum_{n=0}^{\infty} \mathbf{1}_{\{X_n=j\}}$. Entonces

$$G(i, j) = \mathbb{E}_i[N_j].$$

Proof. Como $N_j = \sum_{n \geq 0} \mathbf{1}_{\{X_n=j\}}$ es suma no negativa, aplicamos convergencia monótona:

$$\mathbb{E}_i[N_j] = \sum_{n \geq 0} \mathbb{E}_i[\mathbf{1}_{\{X_n=j\}}] = \sum_{n \geq 0} \mathbb{P}_i(X_n = j) = \sum_{n \geq 0} P^n(i, j) = G(i, j).$$

□

Proposición 6.4 (Criterio de recurrencia mediante Green). Para $i \in S$, se tiene:

$$i \text{ recurrente} \iff G(i, i) = \infty, \quad i \text{ transiente} \iff G(i, i) < \infty.$$

Proof. Sea $r := \mathbb{P}_i(T_i < \infty)$. Al iniciar en i , la cadena está en i en tiempo 0. Luego, el número de *retornos* a i (visitas posteriores a tiempo 0) tiene estructura de renovación: cada vez que la cadena retorna a i , por Markov fuerte el proceso se reinicia desde i , con la misma probabilidad r de volver a retornar en el futuro. Así, el número de retornos K es geométrico con parámetro $1 - r$:

$$\mathbb{P}_i(K = k) = (1 - r)r^k, \quad k \geq 0.$$

El número total de visitas es $N_i = 1 + K$. Entonces

$$\mathbb{E}_i[N_i] = \begin{cases} 1 + \frac{r}{1 - r} = \frac{1}{1 - r} < \infty, & r < 1, \\ \infty, & r = 1, \end{cases}$$

y como $G(i, i) = \mathbb{E}_i[N_i]$, obtenemos la equivalencia. □

Teorema 6.5 (En espacio finito no hay recurrencia nula). En una cadena de Markov con espacio de estados finito, todo estado recurrente es positivamente recurrente:

$$\mathbb{P}_i(T_i < \infty) = 1 \implies \mathbb{E}_i[T_i] < \infty.$$

En particular, si la cadena es irreducible y finita, todos los estados son positivamente recurrentes.

Proof. Damos una prueba sin invocar aún la distribución estacionaria.

Sea i recurrente. Como S es finito, existe $n_0 \geq 1$ tal que $P^{n_0}(i, i) > 0$: en efecto, la recurrencia implica que existe algún retorno posible en algún tiempo n con probabilidad positiva. Tomemos $\alpha := P^{n_0}(i, i) > 0$.

Consideremos los tiempos múltiples de n_0 . Para $k \geq 1$, por la propiedad de Markov en el tiempo $(k - 1)n_0$,

$$\mathbb{P}_i(X_{kn_0} = i \mid X_{(k-1)n_0} = i) = P^{n_0}(i, i) = \alpha.$$

En particular, en cada bloque de longitud n_0 , si estamos en i al inicio del bloque, hay probabilidad al menos α de volver a estar en i al final del bloque. Esto sugiere una cota geométrica para la cola de T_i .

Formalizamos con un argumento de dominación: definimos el evento $A_k = \{T_i > kn_0\}$. En A_{k-1} , hasta el tiempo $(k - 1)n_0$ no se ha retornado a i . Ahora, incluso sin saber dónde

está la cadena en el tiempo $(k-1)n_0$, podemos usar finitud para obtener una *minoración uniforme*: como el estado i es recurrente y la cadena vive en un conjunto finito, existe m_0 tal que

$$\beta := \min_{x \in S} P^{m_0}(x, i) > 0$$

(siendo cuidadosos: esta propiedad es automática si la cadena es irreducible; si no lo es, se restringe a la clase cerrada que contiene a i , donde irreducibilidad se cumple). En la clase cerrada que contiene a i , como es finita e irreducible, tal $\beta > 0$ existe. Entonces, en bloques de tamaño m_0 , desde cualquier estado hay probabilidad al menos β de estar en i al final del bloque. De aquí se obtiene

$$\mathbb{P}_i(T_i > km_0) \leq (1 - \beta)^k.$$

Aplicando la fórmula de la cola,

$$\mathbb{E}_i[T_i] = \sum_{n \geq 0} \mathbb{P}_i(T_i > n) \leq m_0 \sum_{k \geq 0} \mathbb{P}_i(T_i > km_0) \leq m_0 \sum_{k \geq 0} (1 - \beta)^k < \infty.$$

Concluimos positividad de la recurrencia. En el caso irreducible finito, todo estado es recurrente (pues la única clase cerrada es S) y por tanto positivamente recurrente. $\square$

7 Distribuciones estacionarias e invariancia

Definición 7.1 (Distribución estacionaria). Una probabilidad π en S es *estacionaria* si

$$\pi = \pi P, \quad \text{es decir} \quad \pi(j) = \sum_{i \in S} \pi(i)P(i, j) \quad \forall j.$$

Proposición 7.2 (Invarianza en el tiempo). Si $X_0 \sim \pi$ y π es estacionaria, entonces $X_n \sim \pi$ para todo $n \geq 0$.

Proof. Por evolución de distribuciones, $X_n \sim \pi P^n$. Como $\pi = \pi P$, multiplicando por P^{n-1} se obtiene $\pi = \pi P^n$ para todo n , luego $X_n \sim \pi$. $\square$

Teorema 7.3 (Existencia de distribución estacionaria (espacio finito)). Toda matriz estocástica P en un espacio finito admite al menos una distribución estacionaria π .

Proof. Consideramos el simplejo compacto Δ de probabilidades y el mapa continuo $T : \Delta \rightarrow \Delta$ dado por $T(x) = xP$. Por el teorema de Brouwer, T tiene un punto fijo π , i.e. $\pi = \pi P$. $\square$

Teorema 7.4 (Unicidad y positividad en el caso irreducible finito). Si P es irreducible en un espacio finito, existe una única distribución estacionaria π y satisface $\pi(i) > 0$ para todo $i \in S$.

Proof. Positividad. Sea π estacionaria. Definimos $A = \{i : \pi(i) > 0\}$, no vacío. Si $i \in A$ y $P(i, j) > 0$, entonces

$$\pi(j) = \sum_k \pi(k)P(k, j) \geq \pi(i)P(i, j) > 0,$$

luego $j \in A$. Esto implica que A es cerrado (no hay probabilidad de salir de A desde A). Por irreducibilidad, el único subconjunto no vacío cerrado es S mismo, así $A = S$ y $\pi > 0$.

Unicidad. Sea π y ν estacionarias. Primero, en una cadena irreducible finita existe N tal que la matriz promedio

$$\bar{P}_N := \frac{1}{N} \sum_{t=0}^{N-1} P^t$$

tiene entradas estrictamente positivas: para cada par (i, j) existe algún $t(i, j)$ con $P^{t(i, j)}(i, j) > 0$ (por accesibilidad), y escogiendo $N > \max_{i, j} t(i, j)$ garantizamos que el promedio incluye al menos un término positivo para cada (i, j) , por lo que $\bar{P}_N(i, j) > 0$.

Sea $\varepsilon := \min_{i, j} \bar{P}_N(i, j) > 0$ y sea ρ la uniforme en S : $\rho(j) = 1/m$. Entonces $\bar{P}_N(i, j) \geq \varepsilon = m\varepsilon\rho(j)$, es decir,

$$\bar{P}_N(i, \cdot) \geq \delta \rho(\cdot) \quad \text{con} \quad \delta = m\varepsilon \in (0, 1].$$

Por el lema de Doeblin, $\bar{P}_N$ es una contracción estricta en $\|\cdot\|_{\text{TV}}$:

$$\|\alpha \bar{P}_N - \beta \bar{P}_N\|_{\text{TV}} \leq (1 - \delta) \|\alpha - \beta\|_{\text{TV}}.$$

Como $\pi = \pi P$ y $\nu = \nu P$, también $\pi = \pi \bar{P}_N$ y $\nu = \nu \bar{P}_N$ (pues $\bar{P}_N$ es combinación convexa de potencias de P). Luego

$$\|\pi - \nu\|_{\text{TV}} = \|\pi \bar{P}_N - \nu \bar{P}_N\|_{\text{TV}} \leq (1 - \delta) \|\pi - \nu\|_{\text{TV}}.$$

Dado que $1 - \delta < 1$, esto fuerza $\|\pi - \nu\|_{\text{TV}} = 0$, por lo que $\pi = \nu$. $\square$

8 Convergencia al equilibrio y teoremas ergódicos

8.1 Caso aperiódico: convergencia de P^n

Teorema 8.1 (Convergencia al equilibrio (finito, irreducible y aperiódico)). *Supongamos S finito y P irreducible y aperiódico. Sea π la única distribución estacionaria. Entonces para todo $i, j \in S$,*

$$\lim_{n \rightarrow \infty} P^n(i, j) = \pi(j),$$

y para toda distribución inicial μ , $\mu P^n \rightarrow \pi$ en variación total.

Proof. En espacio finito, irreducible + aperiódico implica que P es *primitiva*: existe n_0 tal que $P^{n_0}(i, j) > 0$ para todo i, j . Damos un argumento explícito:

Como P es irreducible, para cada i, j existe $n(i, j)$ con $P^{n(i, j)}(i, j) > 0$. Fijamos un estado a . Por irreducibilidad, para cada i existe r_i con $P^{r_i}(i, a) > 0$ y para cada j existe s_j con $P^{s_j}(a, j) > 0$. Entonces

$$P^{r_i + s_j}(i, j) \geq P^{r_i}(i, a) P^{s_j}(a, j) > 0.$$

Esto da positividad para una colección de tiempos que dependen de (i, j) . La aperiodicidad permite sincronizar los tiempos a uno común: existe L tal que desde a se puede volver a a en tiempos que generan $\text{gcd} = 1$, y por tanto (teoría clásica de semigrupos numéricos) existe M tal que todo entero $n \geq M$ es combinación de esos tiempos de retorno; así se obtiene un n_0 grande con retornos suficientes para ajustar paridades y concluir que $P^{n_0}(i, j) > 0$ para todos los pares. (En un curso, esta sincronización suele presentarse como un lema estándar: irreducible + aperiódico $\Rightarrow$ existe n_0 con $P^{n_0} > 0$.)

Tomemos tal n_0 y sea $\varepsilon = \min_{i,j} P^{n_0}(i,j) > 0$. Con ρ uniforme, tenemos la minoración

$$P^{n_0}(i,j) \geq \varepsilon = m\varepsilon \rho(j),$$

o sea Doeblin con $\delta = m\varepsilon$. Entonces, para distribuciones μ, ν ,

$$\|\mu P^{n_0} - \nu P^{n_0}\|_{\text{TV}} \leq (1 - \delta)\|\mu - \nu\|_{\text{TV}}.$$

Iterando,

$$\|\mu P^{kn_0} - \nu P^{kn_0}\|_{\text{TV}} \leq (1 - \delta)^k \|\mu - \nu\|_{\text{TV}} \xrightarrow{k \rightarrow \infty} 0.$$

Tomando $\nu = \pi$ y usando $\pi P^{kn_0} = \pi$ se obtiene $\mu P^{kn_0} \rightarrow \pi$. Para tiempos intermedios $kn_0 + r$:

$$\|\mu P^{kn_0+r} - \pi\|_{\text{TV}} = \|(\mu P^{kn_0})P^r - \pi P^r\|_{\text{TV}} \leq \|\mu P^{kn_0} - \pi\|_{\text{TV}} \rightarrow 0$$

por el lema de no aumento de $\|\cdot\|_{\text{TV}}$. Así $\mu P^n \rightarrow \pi$ y en particular $P^n(i, \cdot) \rightarrow \pi$, lo que da $P^n(i, j) \rightarrow \pi(j)$. $\square$

8.2 Caso periódico: convergencia de Cesàro

Teorema 8.2 (Convergencia de Cesàro (finito e irreducible)). *Si S es finito y P irreducible (posiblemente periódico), con estacionaria única π , entonces para todo i, j ,*

$$\frac{1}{N} \sum_{n=0}^{N-1} P^n(i, j) \xrightarrow{N \rightarrow \infty} \pi(j).$$

Proof. Sea $\bar{P}_N = \frac{1}{N} \sum_{n=0}^{N-1} P^n$. Como antes, para N grande $\bar{P}_N$ tiene entradas estrictamente positivas (irreducibilidad). Entonces $\bar{P}_N$ es una Doeblin-kernel y es contracción estricta en $\|\cdot\|_{\text{TV}}$.

Ahora, toda subsucesión $\mu \bar{P}_{N_k}$ tiene un punto límite (compactitud de Δ). Sea ν un punto límite. Mostramos que ν es estacionaria: observamos la identidad

$$\bar{P}_N P = \bar{P}_N + \frac{1}{N}(P^N - I),$$

que se verifica expandiendo:

$$\bar{P}_N P = \frac{1}{N} \sum_{n=0}^{N-1} P^{n+1} = \frac{1}{N} \left(\sum_{n=0}^{N-1} P^n + (P^N - I) \right) = \bar{P}_N + \frac{1}{N}(P^N - I).$$

Multiplicando por μ a la izquierda y tomando norma $\|\cdot\|_{\text{TV}}$,

$$\|\mu \bar{P}_N P - \mu \bar{P}_N\|_{\text{TV}} \leq \frac{1}{N} \|\mu(P^N - I)\|_{\text{TV}} \leq \frac{2}{N} \rightarrow 0,$$

pues $\|\cdot\|_{\text{TV}}$ entre dos probabilidades es ≤ 1 , y entre una probabilidad y sí misma es 0; en todo caso la diferencia está acotada por 2 en norma ℓ^1 y por 1 en $\|\cdot\|_{\text{TV}}$. Por lo tanto, en el límite $N_k \rightarrow \infty$,

$$\nu P = \nu.$$

Así ν es estacionaria, y por unicidad en el caso irreducible, $\nu = \pi$. Como todo punto límite es π , la sucesión completa converge a π . $\square$

8.3 Teorema ergódico (promedios temporales)

Teorema 8.3 (Ley fuerte tipo ergódica para cadenas finitas irreducibles). *Si S es finito y P irreducible, con estacionaria π , entonces para toda $f : S \rightarrow \mathbb{R}$,*

$$\frac{1}{N} \sum_{n=0}^{N-1} f(X_n) \xrightarrow[N \rightarrow \infty]{c.s.} \sum_{j \in S} \pi(j) f(j),$$

para cualquier distribución inicial.

Proof. Damos una prueba completa por regeneración (excursiones).

Fijamos un estado $a \in S$. Por irreducibilidad y finitud, el retorno a a tiene esperanza finita: $\mathbb{E}_a[T_a] < \infty$ (recurrencia positiva). Definimos tiempos de retorno sucesivos:

$$\sigma_0 = 0, \quad \sigma_{k+1} = \inf\{n > \sigma_k : X_n = a\}.$$

Cada σ_k es tiempo de paro. Por Markov fuerte, los segmentos de trayectoria entre σ_k y σ_{k+1} son i.i.d. bajo $\mathbb{P}_a$.

Definimos

$$L_k = \sigma_{k+1} - \sigma_k, \quad Y_k = \sum_{n=\sigma_k}^{\sigma_{k+1}-1} f(X_n).$$

Entonces $(Y_k, L_k)_{k \geq 0}$ son i.i.d. y $\mathbb{E}_a[|Y_0|] < \infty$ (porque S finito implica f acotada) y $\mathbb{E}_a[L_0] = \mathbb{E}_a[T_a] < \infty$. Por la ley fuerte para i.i.d.,

$$\frac{\sum_{k=0}^{K-1} Y_k}{K} \rightarrow \mathbb{E}_a[Y_0], \quad \frac{\sum_{k=0}^{K-1} L_k}{K} \rightarrow \mathbb{E}_a[L_0] \quad \text{c.s.}$$

Dividiendo,

$$\frac{\sum_{k=0}^{K-1} Y_k}{\sum_{k=0}^{K-1} L_k} \rightarrow \frac{\mathbb{E}_a[Y_0]}{\mathbb{E}_a[L_0]} \quad \text{c.s.}$$

Pero $\sum_{k=0}^{K-1} Y_k = \sum_{n=0}^{\sigma_K-1} f(X_n)$ y $\sum_{k=0}^{K-1} L_k = \sigma_K$. Así,

$$\frac{1}{\sigma_K} \sum_{n=0}^{\sigma_K-1} f(X_n) \rightarrow c := \frac{\mathbb{E}_a[Y_0]}{\mathbb{E}_a[L_0]} \quad \text{c.s.}$$

Pasamos de la subsucesión σ_K a todo N : para $\sigma_K \leq N < \sigma_{K+1}$,

$$\left| \frac{1}{N} \sum_{n=0}^{N-1} f(X_n) - \frac{1}{\sigma_K} \sum_{n=0}^{\sigma_K-1} f(X_n) \right| \leq \frac{1}{\sigma_K} \sum_{n=\sigma_K}^{\sigma_{K+1}-1} |f(X_n)| \leq \frac{\|f\|_\infty L_K}{\sigma_K}.$$

Como $\sigma_K = \sum_{k=0}^{K-1} L_k$ y L_K tiene media finita, se tiene $\sigma_K \rightarrow \infty$ y además $L_K/\sigma_K \rightarrow 0$ c.s. (por ejemplo, porque σ_K crece linealmente en K mientras L_K no). Concluimos que la diferencia anterior tiende a 0, así el límite existe para todo N y vale c .

Falta identificar c con $\sum_j \pi(j) f(j)$. Para ello, aplicamos el argumento a $f = \mathbf{1}_{\{j\}}$. El límite c_j es la fracción de tiempo asintótica en el estado j . El vector $c = (c_j)_j$ es una probabilidad, y es estacionaria: intuitivamente, en el régimen de largo tiempo, la frecuencia de transiciones respeta $\pi = \pi P$. Formalmente, usando que $\frac{1}{N} \sum_{n=0}^{N-1} \mathbf{1}_{\{X_n=i, X_{n+1}=j\}} \rightarrow c_i P(i, j)$ y sumando en i se obtiene $c_j = \sum_i c_i P(i, j)$. Por unicidad de estacionaria (irreducible), $c = \pi$. Por linealidad, para f general se obtiene $c = \sum_j \pi(j) f(j)$. Finalmente, para distribución inicial arbitraria, se acopla/espera hasta el primer hitting de a y se usa Markov fuerte para reducir al caso $\mathbb{P}_a$. $\square$

9 Fórmula de Kac y tiempos de retorno

Teorema 9.1 (Fórmula de Kac (finito irreducible)). *Sea S finito, P irreducible y π la estacionaria única. Entonces para todo $i \in S$,*

$$\mathbb{E}_i[T_i] = \frac{1}{\pi(i)}.$$

Proof. Aplicamos el teorema ergódico a $f = \mathbf{1}_{\{i\}}$ iniciando desde i :

$$\frac{1}{N} \sum_{n=0}^{N-1} \mathbf{1}_{\{X_n=i\}} \rightarrow \pi(i) \quad \text{c.s.}$$

Ahora describimos la izquierda mediante renovaciones. Sea $0 = N_1 < N_2 < \dots$ la sucesión de tiempos de visita a i (incluyendo $N_1 = 0$). Entonces los incrementos $N_{k+1} - N_k$ son i.i.d. con la misma ley que T_i bajo $\mathbb{P}_i$, por Markov fuerte en N_k . Por la ley fuerte i.i.d.,

$$\frac{N_k}{k} \rightarrow \mathbb{E}_i[T_i] \quad \text{c.s.}$$

El número de visitas a i antes de N es aproximadamente el mayor k con $N_k \leq N$, y asintóticamente $k \sim N/\mathbb{E}_i[T_i]$. Por tanto,

$$\frac{1}{N} \sum_{n=0}^{N-1} \mathbf{1}_{\{X_n=i\}} = \frac{\#\{0 \leq n \leq N-1 : X_n=i\}}{N} \rightarrow \frac{1}{\mathbb{E}_i[T_i]} \quad \text{c.s.}$$

Comparando con el límite $\pi(i)$ concluimos $\pi(i) = 1/\mathbb{E}_i[T_i]$. □

10 Cadenas absorbentes y matriz fundamental

Definición 10.1 (Conjunto absorbente y estados transientes). Un subconjunto $A \subset S$ es *absorbente* si es cerrado y además cada $a \in A$ es absorbente: $P(a, a) = 1$. Los estados en $T = S \setminus A$ se llaman *transientes* (para esta cadena absorbente).

Proposición 10.2 (Forma canónica). *Ordenando los estados como (T, A) , la matriz P tiene la forma*

$$P = \begin{pmatrix} Q & R \\ 0 & I \end{pmatrix}.$$

Proof. Si $t \in T$, puede ir a T (bloque Q) o a A (bloque R). Si $a \in A$, como $P(a, a) = 1$ y no sale de A , su fila tiene un 1 en la diagonal del bloque I y ceros fuera. □

Teorema 10.3 (Matriz fundamental y estadísticas de absorción). *Supongamos que desde todo $t \in T$ se tiene $\mathbb{P}_t(\tau_A < \infty) = 1$. Entonces la serie $\sum_{n \geq 0} Q^n$ converge entrada a entrada y*

$$N := (I - Q)^{-1} = \sum_{n=0}^{\infty} Q^n.$$

Además, para $t, t' \in T$,

$$N(t, t') = \mathbb{E}_t \left[\sum_{n=0}^{\tau_A-1} \mathbf{1}_{\{X_n=t'\}} \right].$$

El tiempo esperado de absorción $u(t) = \mathbb{E}_t[\tau_A]$ satisface $u = N\mathbf{1}$, y las probabilidades de absorción en $a \in A$ están dadas por $B = NR$:

$$B(t, a) = \mathbb{P}_t(X_{\tau_A} = a).$$

Proof. Como $\tau_A < \infty$ a.s. desde T , el proceso restringido a T es transiente: para cada t' , el número de visitas a t' antes de absorberse tiene esperanza finita. Pero

$$\mathbb{P}_t(X_n = t', n < \tau_A) = Q^n(t, t'),$$

por definición del bloque Q como la transición dentro de T sin absorberse. Así

$$\sum_{n=0}^{\infty} Q^n(t, t') = \sum_{n=0}^{\infty} \mathbb{P}_t(X_n = t', n < \tau_A) = \mathbb{E}_t \left[\sum_{n=0}^{\infty} \mathbf{1}_{\{X_n = t', n < \tau_A\}} \right] = \mathbb{E}_t \left[\sum_{n=0}^{\tau_A-1} \mathbf{1}_{\{X_n = t'\}} \right],$$

donde usamos convergencia monótona para intercambiar suma y esperanza.

La identidad $N = (I - Q)^{-1}$ se obtiene por telescopio:

$$(I - Q) \sum_{n=0}^{\infty} Q^n = \sum_{n=0}^{\infty} Q^n - \sum_{n=0}^{\infty} Q^{n+1} = I,$$

justificado entrada a entrada por convergencia de series no negativas.

Para el tiempo esperado:

$$u(t) = \mathbb{E}_t[\tau_A] = \mathbb{E}_t \left[\sum_{n=0}^{\tau_A-1} 1 \right] = \sum_{t' \in T} \mathbb{E}_t \left[\sum_{n=0}^{\tau_A-1} \mathbf{1}_{\{X_n = t'\}} \right] = \sum_{t' \in T} N(t, t') = (N\mathbf{1})(t).$$

Para $B(t, a)$, descomponemos por el último paso antes de absorberse:

$$\mathbb{P}_t(X_{\tau_A} = a) = \sum_{n \geq 1} \sum_{t' \in T} \mathbb{P}_t(X_{n-1} = t', \tau_A = n) P(t', a).$$

El evento $\{\tau_A = n\}$ equivale a “no absorberse antes de n y entrar a A en n ”. Luego

$$\mathbb{P}_t(X_{n-1} = t', \tau_A = n) = \mathbb{P}_t(X_{n-1} = t', n-1 < \tau_A),$$

y ese término es $Q^{n-1}(t, t')$. Así

$$\mathbb{P}_t(X_{\tau_A} = a) = \sum_{n \geq 1} \sum_{t' \in T} Q^{n-1}(t, t') R(t', a) = \sum_{t' \in T} \left(\sum_{k \geq 0} Q^k(t, t') \right) R(t', a) = (NR)(t, a).$$

□

11 Reversibilidad (opcional, pero estándar)

Definición 11.1 (Reversibilidad y balance detallado). Una distribución estacionaria π hace a P *reversible* si para todo $i, j \in S$,

$$\pi(i)P(i, j) = \pi(j)P(j, i).$$

Proposición 11.2 (Balance detallado $\Rightarrow$ estacionariedad). Si π satisface balance detallado, entonces π es estacionaria.

Proof. Fijado j ,

$$\sum_{i \in S} \pi(i)P(i, j) = \sum_{i \in S} \pi(j)P(j, i) = \pi(j) \sum_{i \in S} P(j, i) = \pi(j).$$

Por tanto $\pi = \pi P$.

□

12 Ejercicios con soluciones

Instrucciones

Todos los ejercicios son en espacios finitos. Se resuelven con: (i) análisis de primer paso; (ii) resolver $\pi = \pi P$; (iii) matriz fundamental en cadenas absorbentes.

Ejercicio 12.1 (Cadena de dos estados: estacionaria y límite). Sea $S = \{0, 1\}$ y

$$P = \begin{pmatrix} 1-a & a \\ b & 1-b \end{pmatrix} \quad (a, b \in (0, 1)).$$

Halle la distribución estacionaria π y compute $\lim_{n \rightarrow \infty} P^n$.

Solución. Sea $\pi = (\pi_0, \pi_1)$ con $\pi = \pi P$ y $\pi_0 + \pi_1 = 1$. La ecuación $\pi = \pi P$ en la coordenada 0 da

$$\pi_0 = \pi_0(1-a) + \pi_1 b \iff \pi_0 a = \pi_1 b.$$

Con $\pi_1 = 1 - \pi_0$, obtenemos $\pi_0 a = (1 - \pi_0)b$, así $\pi_0(a+b) = b$, i.e.

$$\pi_0 = \frac{b}{a+b}, \quad \pi_1 = \frac{a}{a+b}.$$

Como $P(0,0) > 0$ y $P(1,1) > 0$, la cadena es aperiódica; además es irreducible pues $a, b > 0$. Por convergencia al equilibrio,

$$P^n(i, \cdot) \rightarrow \pi(\cdot) \implies \lim_{n \rightarrow \infty} P^n = \begin{pmatrix} \pi_0 & \pi_1 \\ \pi_0 & \pi_1 \end{pmatrix}.$$

□

Ejercicio 12.2 (Periodo en un ciclo determinista). Sea $S = \mathbb{Z}/m\mathbb{Z}$ y $X_{n+1} = X_n + 1 \pmod{m}$ determinísticamente. Compute el periodo y describa todas las distribuciones estacionarias.

Solución. Aquí $P(i, i+1) = 1$. Entonces $P^n(i, i) = 1$ sii $n \equiv 0 \pmod{m}$. Así $\{n \geq 1 : P^n(i, i) > 0\} = \{m, 2m, 3m, \dots\}$ y $d(i) = m$. La ecuación estacionaria $\pi = \pi P$ implica $\pi(j) = \pi(j-1)$ para todo j , por lo que π es uniforme: $\pi(j) = 1/m$. □

Ejercicio 12.3 (Ruina del jugador: probabilidad de absorción en N). En $\{0, 1, \dots, N\}$ con 0 y N absorbentes, para $1 \leq i \leq N-1$ sea $P(i, i+1) = p$, $P(i, i-1) = q = 1-p$. Calcule $h(i) = \mathbb{P}_i(\tau_N < \tau_0)$.

Solución. Condiciones de frontera: $h(0) = 0$, $h(N) = 1$. Para $1 \leq i \leq N-1$,

$$h(i) = ph(i+1) + qh(i-1).$$

Si $p = q = 1/2$, entonces h es afín y $h(i) = i/N$. Si $p \neq q$, la ecuación característica de $p\lambda^2 - \lambda + q = 0$ tiene raíces 1 y q/p . Así $h(i) = A + B(q/p)^i$. Con $h(0) = 0$ se tiene $A = -B$ y

$$h(i) = A(1 - (q/p)^i).$$

Con $h(N) = 1$ resulta $A = (1 - (q/p)^N)^{-1}$ y

$$h(i) = \frac{1 - (q/p)^i}{1 - (q/p)^N}.$$

□

Ejercicio 12.4 (Ruina del jugador: tiempo esperado (caso justo)). En el ejercicio anterior, suponga $p = q = 1/2$. Calcule $u(i) = \mathbb{E}_i[\tau_{\{0,N\}}]$.

Solución. Sea $\tau = \tau_0 \wedge \tau_N$. Entonces $u(0) = u(N) = 0$ y para $1 \leq i \leq N-1$,

$$u(i) = 1 + \frac{1}{2}u(i+1) + \frac{1}{2}u(i-1),$$

equivalentemente

$$u(i+1) - 2u(i) + u(i-1) = -2.$$

Buscamos $u(i) = ai^2 + bi + c$. La segunda diferencia de i^2 es 2, por lo que $2a = -2$ y $a = -1$. Con $u(0) = 0$ se obtiene $c = 0$. Con $u(N) = 0$ se obtiene $-N^2 + bN = 0$, o sea $b = N$. Luego

$$u(i) = i(N-i).$$

□

Ejercicio 12.5 (Caminata aleatoria en grafo no dirigido con pesos). Sea $G = (V, E)$ finito, no dirigido, con pesos simétricos $w_{ij} = w_{ji} \geq 0$ y $w_{ij} > 0 \Leftrightarrow \{i, j\} \in E$. Defina

$$P(i, j) = \frac{w_{ij}}{\sum_{k \in V} w_{ik}}.$$

Demuestre reversibilidad y encuentre π .

Solución. Sea $d(i) = \sum_k w_{ik}$ y defina $\pi(i) = d(i) / \sum_\ell d(\ell)$. Entonces

$$\pi(i)P(i, j) = \frac{d(i)}{\sum_\ell d(\ell)} \cdot \frac{w_{ij}}{d(i)} = \frac{w_{ij}}{\sum_\ell d(\ell)} = \frac{w_{ji}}{\sum_\ell d(\ell)} = \pi(j)P(j, i).$$

Luego hay balance detallado; por tanto la cadena es reversible y π es estacionaria. □

Ejercicio 12.6 (Matriz fundamental en una cadena absorbente de 3 estados). Sea $S = \{1, 2, 3\}$, 3 absorbente, y

$$P = \begin{pmatrix} 1/2 & 1/4 & 1/4 \\ 1/4 & 1/2 & 1/4 \\ 0 & 0 & 1 \end{pmatrix}.$$

Calcule: (i) $\mathbb{E}_1[\tau_{\{3\}}]$; (ii) $\mathbb{P}_2(X_{\tau_{\{3\}}} = 3)$.

Solución. $T = \{1, 2\}$, $A = \{3\}$.

$$Q = \begin{pmatrix} 1/2 & 1/4 \\ 1/4 & 1/2 \end{pmatrix}, \quad R = \begin{pmatrix} 1/4 \\ 1/4 \end{pmatrix}.$$

$$I - Q = \begin{pmatrix} 1/2 & -1/4 \\ -1/4 & 1/2 \end{pmatrix}, \quad \det(I - Q) = \frac{1}{4} - \frac{1}{16} = \frac{3}{16}.$$

Entonces

$$N = (I - Q)^{-1} = \frac{16}{3} \begin{pmatrix} 1/2 & 1/4 \\ 1/4 & 1/2 \end{pmatrix} = \begin{pmatrix} 8/3 & 4/3 \\ 4/3 & 8/3 \end{pmatrix}.$$

(i) $u = N\mathbf{1}$ da $u(1) = 8/3 + 4/3 = 4$, así $\mathbb{E}_1[\tau_{\{3\}}] = 4$. (ii) $B = NR$:

$$B = \begin{pmatrix} 8/3 & 4/3 \\ 4/3 & 8/3 \end{pmatrix} \begin{pmatrix} 1/4 \\ 1/4 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix},$$

luego la absorción en 3 ocurre con probabilidad 1 desde 2. □

Ejercicio 12.7 (Sistema lineal de tiempos esperados). Sea $S = \{1, 2, 3, 4\}$, 4 absorbente, y para $i \in \{1, 2, 3\}$:

$$P(i, i) = \frac{1}{2}, \quad P(i, 4) = \frac{1}{4}, \quad P(i, j) = \frac{1}{8} \text{ si } j \in \{1, 2, 3\}, j \neq i.$$

Calcule $u(i) = \mathbb{E}_i[\tau_4]$ para $i = 1, 2, 3$.

Solución. Por simetría $u(1) = u(2) = u(3) =: u$, y $u(4) = 0$. La ecuación de primer paso:

$$u = 1 + \frac{1}{2}u + \frac{1}{8}(2u) + \frac{1}{4} \cdot 0 = 1 + \frac{1}{2}u + \frac{1}{4}u = 1 + \frac{3}{4}u.$$

Entonces $u = 4$. □

Ejercicio 12.8 (Estacionaria y periodicidad). Sea

$$P = \begin{pmatrix} 0 & 1 & 0 \\ 1/2 & 0 & 1/2 \\ 0 & 1 & 0 \end{pmatrix}.$$

Encuentre π y decida si $P^n(i, \cdot)$ converge.

Solución. Sea $\pi = (x, y, z)$ con $x + y + z = 1$ y $\pi = \pi P$:

$$x = \frac{1}{2}y, \quad y = x + z, \quad z = \frac{1}{2}y.$$

Luego $x = z = \frac{1}{2}y$ y $x + y + z = 2y = 1$, así $y = \frac{1}{2}$ y $x = z = \frac{1}{4}$. La cadena es irreducible pero tiene periodo 2 (alternancia entre 2 y $\{1, 3\}$), así $P^n(i, \cdot)$ no converge (oscila), aunque los promedios de Cesàro sí convergen a π . □

Ejercicio 12.9 (Verificación de Kac en dos estados). Para la cadena de dos estados del primer ejercicio, calcule $\mathbb{E}_0[T_0]$ directamente y verifique que coincide con $1/\pi(0)$.

Solución. Desde 0, con probabilidad $1-a$ regresamos en un paso ($T_0 = 1$). Con probabilidad a vamos a 1 y el tiempo para volver a 0 desde 1 es geométrico con parámetro b , de media $1/b$. Luego

$$\mathbb{E}_0[T_0] = (1-a) \cdot 1 + a \cdot \left(1 + \frac{1}{b}\right) = 1 + \frac{a}{b}.$$

Como $\pi(0) = \frac{b}{a+b}$, se tiene $1/\pi(0) = (a+b)/b = 1 + a/b$, coincide. □

Ejercicio 12.10 (Cota geométrica de mezcla por Doeblin (cadena primitiva)). Sea P irreducible y aperiódica en S finito. Demuestre que existen n_0 y $\delta > 0$ tales que para toda μ, ν :

$$\|\mu P^{kn_0} - \nu P^{kn_0}\|_{\text{TV}} \leq (1 - \delta)^k.$$

Solución. Por primitividad existe n_0 con $P^{n_0}(i, j) > 0$ para todo i, j . Sea $\varepsilon = \min_{i,j} P^{n_0}(i, j) > 0$ y ρ uniforme. Entonces $P^{n_0}(i, j) \geq m\varepsilon\rho(j)$, i.e. Doeblin con $\delta = m\varepsilon$. Aplicando el lema de Doeblin y iterando k veces se obtiene la cota. □