

Notas de teoría de la medida

De la construcción en $\mathbb{R}$ a la integral de Lebesgue, con orientación hacia probabilidad y procesos estocásticos

Resumen

Estas notas desarrollan, de manera gradual, la construcción de la medida de Lebesgue sobre la recta real, la noción de función medible, la integral de Lebesgue y su interpretación probabilística como esperanza. El énfasis está puesto en la transición conceptual desde longitud y área hacia probabilidad, distribución, independencia, teoremas de convergencia y esperanza condicional. La notación adoptada escribe las medidas en la forma $\mu(dx)$, $\lambda(dx)$, $\mathbb{P}(d\omega)$ y $\mathbb{P}_X(dx)$, de modo que las integrales conserven explícitamente el espacio sobre el cual se promedia.

Índice

1.	La pregunta inicial: ¿qué significa medir?	3
2.	Álgebras, σ -álgebras e información observable	4
3.	La σ -álgebra de Borel en la recta real	5
4.	Medidas: tamaño, masa y probabilidad	5
5.	Medida exterior de Lebesgue	7
6.	Medibilidad de Carathéodory	8
7.	Conjuntos nulos y afirmaciones casi en todas partes	9
8.	Completación de medidas y el papel de los conjuntos nulos	10
9.	Funciones medibles	10
10.	Leyes de variables aleatorias	11
11.	Funciones simples	13
12.	Integral de Lebesgue para funciones no negativas	14
13.	Funciones con signo e integrabilidad	15
14.	Riemann y Lebesgue	16
15.	Teoremas de convergencia	16
16.	Espacios L^p	18
17.	Esperanza como integral	18
18.	Medida producto e independencia	20
19.	Tonelli, Fubini y fórmulas de cola	20

20. Esperanza condicional	21
Ejercicios de consolidación	24

1. La pregunta inicial: ¿qué significa medir?

La teoría de la medida comienza con una pregunta que parece elemental: ¿cómo asignar un tamaño a un subconjunto de la recta real? Para intervalos no hay misterio. Si $a < b$, la longitud esperada de $[a, b]$, (a, b) , $[a, b)$ y $(a, b]$ es $b - a$. Esta convención viene de la geometría elemental, pero pronto se convierte en un problema analítico profundo.

El siglo XIX obligó a refinar la intuición geométrica. Las series de Fourier, las funciones discontinuas en conjuntos densos, los límites de sucesiones de funciones y los conjuntos contruidos por procesos infinitos mostraron que no basta medir intervalos o figuras simples. La integral de Riemann, aunque poderosa, no es suficientemente estable bajo límites. Lebesgue propuso separar dos problemas que antes estaban mezclados: primero medir conjuntos y después integrar funciones a partir de esa medición.

Definición 1.1. La medida de Lebesgue de un intervalo se normaliza mediante

$$\lambda((a, b)) = \lambda([a, b]) = \lambda([a, b)) = \lambda((a, b]) = b - a.$$

Esta igualdad debe entenderse como el punto de partida, no como la definición completa de λ en conjuntos generales.

Ejemplo 1.2 (Intervalos disjuntos). Si

$$A = (0, 2) \cup (5, 7),$$

entonces la longitud natural es

$$\lambda(A) = 2 + 2 = 4.$$

Aquí sólo se usa aditividad finita: dos piezas disjuntas aportan longitudes que se suman.

Ejemplo 1.3 (Un punto). La longitud de un punto debe ser cero. En efecto, si $a \in \mathbb{R}$, el punto $\{a\}$ puede cubrirse por intervalos arbitrariamente pequeños. Es natural exigir

$$\lambda(\{a\}) = 0.$$

Esto será compatible con la construcción rigurosa de la medida exterior.

Ejemplo 1.4 (Conjuntos finitos). Si $A = \{a_1, \dots, a_n\}$, entonces

$$\lambda(A) = 0.$$

La suma finita de ceros sigue siendo cero. Esta observación es elemental, pero prepara una idea crucial: un conjunto puede tener muchos puntos y, aun así, ser invisible para la longitud.

Nota histórica 1.5. En la integral de Riemann se divide el dominio en subintervalos y se comparan sumas superiores e inferiores. Lebesgue cambió el punto de vista: en lugar de partir primero el eje horizontal, conviene medir los conjuntos donde la función toma determinados rangos de valores. Para que esa idea funcione, la teoría de los conjuntos medibles debe preceder a la teoría de la integral.

Observación 1.6. En probabilidad, la misma pregunta reaparece con otra terminología. En vez de preguntar por la longitud de $A \subset \mathbb{R}$, preguntamos por la probabilidad de un evento $A \subset \Omega$. La teoría será formalmente la misma: una probabilidad es una medida con masa total igual a uno.

2. Álgebras, σ -álgebras e información observable

Antes de asignar tamaños a conjuntos, debemos decidir cuáles conjuntos son admisibles. En probabilidad elemental se dice que un evento es un subconjunto del espacio muestral. En contextos finitos esto no causa problemas. En espacios continuos, sin embargo, permitir todos los subconjuntos puede destruir la posibilidad de tener una medida razonable.

La solución consiste en fijar una colección de conjuntos estable bajo las operaciones lógicas y bajo límites numerables. Esta colección es una σ -álgebra.

Definición 2.1. Sea Ω un conjunto. Una colección $\mathcal{F} \subseteq \mathcal{P}(\Omega)$ es una σ -álgebra si cumple:

1. $\Omega \in \mathcal{F}$;
2. si $A \in \mathcal{F}$, entonces $A^c \in \mathcal{F}$;
3. si $A_1, A_2, \dots \in \mathcal{F}$, entonces $\bigcup_{n \geq 1} A_n \in \mathcal{F}$.

El par $(\Omega, \mathcal{F})$ se llama espacio medible.

Observación 2.2. La clausura bajo uniones numerables implica clausura bajo intersecciones numerables, porque

$$\bigcap_{n \geq 1} A_n = \left(\bigcup_{n \geq 1} A_n^c \right)^c.$$

Por eso una σ -álgebra es estable bajo los conectivos lógicos que se requieren para manejar sucesiones de eventos.

Ejemplo 2.3 (Dado con información completa). Sea $\Omega = \{1, 2, 3, 4, 5, 6\}$. Si observamos el resultado exacto, la σ -álgebra natural es

$$\mathcal{F} = \mathcal{P}(\Omega).$$

En ella pertenecen eventos como $\{2\}$, $\{1, 3, 5\}$ y $\{4, 5, 6\}$.

Ejemplo 2.4 (Dado con información parcial). Si sólo observamos la paridad del dado, la colección observable es

$$\mathcal{G} = \{\emptyset, \{1, 3, 5\}, \{2, 4, 6\}, \Omega\}.$$

Esta σ -álgebra distingue entre par e impar, pero no distingue entre los tres resultados impares ni entre los tres resultados pares.

Ejemplo 2.5 (Moneda dos veces). Sea

$$\Omega = \{HH, HT, TH, TT\}.$$

Si sólo observamos el primer lanzamiento, la información disponible está dada por

$$\mathcal{G} = \{\emptyset, \{HH, HT\}, \{TH, TT\}, \Omega\}.$$

Un evento como “salieron exactamente dos caras” es $\{HH\}$, pero no pertenece a $\mathcal{G}$. No es observable si sólo conocemos el primer lanzamiento.

Observación 2.6 (La interpretación probabilística). Una σ -álgebra representa información. Cuando escribimos $A \in \mathcal{F}$, estamos diciendo que el evento A puede ser observado, preguntado o medido dentro del modelo. Esta interpretación será decisiva al definir esperanza condicional: condicionar significa restringirse a una sub- σ -álgebra de información disponible.

3. La σ -álgebra de Borel en la recta real

La recta real trae una estructura adicional: la topología. Sabemos qué significa que un conjunto sea abierto, qué significa convergencia de sucesiones y qué significa continuidad. Por eso la primera familia natural de conjuntos medibles en $\mathbb{R}$ se obtiene a partir de los abiertos.

Definición 3.1. La σ -álgebra de Borel de $\mathbb{R}$, denotada $\mathcal{B}(\mathbb{R})$, es la menor σ -álgebra que contiene todos los conjuntos abiertos de $\mathbb{R}$. Sus elementos se llaman conjuntos borelianos.

Proposición 3.2. La σ -álgebra $\mathcal{B}(\mathbb{R})$ también es generada por cualquiera de las siguientes familias:

$$\{(a, b) : a < b\}, \quad \{(-\infty, x) : x \in \mathbb{R}\}, \quad \{(-\infty, x] : x \in \mathbb{R}\}.$$

Idea de la prueba. Los abiertos de $\mathbb{R}$ son uniones numerables de intervalos abiertos con extremos racionales. A su vez, los intervalos abiertos pueden escribirse mediante operaciones numerables a partir de semirrectas. Así, las σ -álgebras generadas coinciden. $\square$

Ejemplo 3.3 (Puntos). Para cada $a \in \mathbb{R}$,

$$\{a\} = \bigcap_{n \geq 1} \left(a - \frac{1}{n}, a + \frac{1}{n} \right).$$

Por tanto, $\{a\} \in \mathcal{B}(\mathbb{R})$.

Ejemplo 3.4 (Racionales). Como $\mathbb{Q}$ es numerable, puede escribirse como $\mathbb{Q} = \{q_1, q_2, \dots\}$. Entonces

$$\mathbb{Q} = \bigcup_{n \geq 1} \{q_n\}.$$

Cada punto es boreliano y las uniones numerables de borelianos son borelianas. Así, $\mathbb{Q} \in \mathcal{B}(\mathbb{R})$.

Ejemplo 3.5 (Irracionales). El conjunto de irracionales es el complemento de $\mathbb{Q}$. Como las σ -álgebras son cerradas bajo complementos,

$$\mathbb{R} \setminus \mathbb{Q} \in \mathcal{B}(\mathbb{R}).$$

Ejemplo 3.6 (Conjunto de Cantor). El conjunto ternario de Cantor es cerrado. Todo cerrado es boreliano, porque es complemento de un abierto. Por tanto el conjunto de Cantor pertenece a $\mathcal{B}(\mathbb{R})$.

Observación 3.7. Los conjuntos borelianos son suficientes para gran parte del análisis y la probabilidad. Sin embargo, la medida de Lebesgue completa contiene también subconjuntos de conjuntos borelianos de medida cero que no son necesariamente borelianos. Esta distinción es técnica, pero importante cuando se trabaja con igualdad casi en todas partes.

4. Medidas: tamaño, masa y probabilidad

Una medida asigna un tamaño no negativo a cada conjunto medible. La propiedad central no es la aditividad finita, sino la aditividad numerable. Esa exigencia es la que permite compatibilidad con límites.

Definición 4.1. Sea $(\Omega, \mathcal{F})$ un espacio medible. Una medida es una función

$$\mu : \mathcal{F} \rightarrow [0, \infty]$$

tal que $\mu(\emptyset) = 0$ y, para toda sucesión $(A_n)_{n \geq 1}$ de conjuntos disjuntos dos a dos en $\mathcal{F}$,

$$\mu \left(\bigcup_{n \geq 1} A_n \right) = \sum_{n \geq 1} \mu(A_n).$$

El triple $(\Omega, \mathcal{F}, \mu)$ se llama espacio de medida.

Definición 4.2. Una probabilidad es una medida $\mathbb{P}$ con masa total igual a uno:

$$\mathbb{P}(\Omega) = 1.$$

El triple $(\Omega, \mathcal{F}, \mathbb{P})$ se llama espacio de probabilidad.

Ejemplo 4.3 (Medida de conteo). En $\mathbb{N}$, la medida de conteo se define por

$$\mu(A) = \#A,$$

con el valor ∞ si A es infinito. Entonces $\mu(\{2, 4, 6\}) = 3$.

Ejemplo 4.4 (Probabilidad uniforme finita). Si $\Omega = \{1, 2, 3, 4, 5, 6\}$ y el dado es justo, entonces

$$\mathbb{P}(A) = \frac{\#A}{6}.$$

En particular, $\mathbb{P}(\{2, 4, 6\}) = 1/2$.

Ejemplo 4.5 (Medida de Dirac). Para $a \in \mathbb{R}$, la medida de Dirac en a se define por

$$\delta_a(B) = \begin{cases} 1, & a \in B, \\ 0, & a \notin B. \end{cases}$$

Es una probabilidad concentrada en un solo punto. En notación integral,

$$\int_{\mathbb{R}} f(x) \delta_a(dx) = f(a)$$

para toda función medible no negativa, y también para toda función integrable respecto de δ_a .

Ejemplo 4.6 (Medida con densidad). Si $g : \mathbb{R} \rightarrow [0, \infty)$ es boreliana y

$$\int_{\mathbb{R}} g(x) \lambda(dx) < \infty,$$

podemos definir una medida μ por

$$\mu(A) = \int_A g(x) \lambda(dx).$$

Cuando la integral total de g es uno, μ es una probabilidad y escribimos informalmente

$$\mu(dx) = g(x) \lambda(dx).$$

Observación 4.7 (Continuidad desde abajo). Si $A_1 \subseteq A_2 \subseteq \dots$, entonces

$$\mu \left(\bigcup_{n \geq 1} A_n \right) = \lim_{n \rightarrow \infty} \mu(A_n).$$

Esta propiedad se deduce de la σ -aditividad y es indispensable para argumentos por aproximación.

Observación 4.8 (Continuidad desde arriba). Si $A_1 \supseteq A_2 \supseteq \dots$ y $\mu(A_1) < \infty$, entonces

$$\mu \left(\bigcap_{n \geq 1} A_n \right) = \lim_{n \rightarrow \infty} \mu(A_n).$$

La hipótesis $\mu(A_1) < \infty$ no es decorativa; sin ella la conclusión puede fallar.

5. Medida exterior de Lebesgue

La construcción de Lebesgue comienza con un procedimiento robusto: cubrir un conjunto arbitrario por intervalos abiertos y tomar la menor longitud total posible. Esta idea permite definir un tamaño externo para todo subconjunto de $\mathbb{R}$, incluso antes de saber si será medible.

Definición 5.1. Para $A \subseteq \mathbb{R}$, la medida exterior de Lebesgue se define como

$$\lambda^*(A) = \inf \left\{ \sum_{n \geq 1} |I_n| : A \subseteq \bigcup_{n \geq 1} I_n, I_n \text{ intervalos abiertos} \right\}.$$

Aquí $|I_n|$ denota la longitud del intervalo I_n .

Observación 5.2. La palabra exterior indica que se mide A desde afuera, mediante cubiertas. Si A es irregular, no se intenta partirlo directamente. Se lo cubre por objetos simples y se optimiza la longitud total de la cubierta.

Proposición 5.3. La medida exterior λ^* satisface:

1. $\lambda^*(\emptyset) = 0$;
2. si $A \subseteq B$, entonces $\lambda^*(A) \leq \lambda^*(B)$;
3. para cualquier sucesión $(A_n)_{n \geq 1}$,

$$\lambda^* \left(\bigcup_{n \geq 1} A_n \right) \leq \sum_{n \geq 1} \lambda^*(A_n).$$

Ejemplo 5.4 (Un punto). Si $A = \{a\}$, entonces para cada $\varepsilon > 0$ el intervalo

$$\left(a - \frac{\varepsilon}{2}, a + \frac{\varepsilon}{2} \right)$$

cubre a A y tiene longitud ε . Por tanto $\lambda^*(\{a\}) \leq \varepsilon$. Como $\varepsilon > 0$ es arbitrario, $\lambda^*(\{a\}) = 0$.

Ejemplo 5.5 (Conjunto numerable). Sea $A = \{a_1, a_2, \dots\}$. Dado $\varepsilon > 0$, cubrimos a_n con un intervalo I_n de longitud $\varepsilon 2^{-n}$. Entonces

$$\sum_{n \geq 1} |I_n| = \varepsilon.$$

Así, $\lambda^*(A) = 0$. En particular, $\lambda^*(\mathbb{Q}) = 0$.

Ejemplo 5.6 (Los racionales en el intervalo unitario). La enumeración de $\mathbb{Q} \cap [0, 1]$ permite cubrir sus puntos con longitud total arbitrariamente pequeña. Entonces

$$\lambda^*(\mathbb{Q} \cap [0, 1]) = 0.$$

Este resultado no contradice que $\mathbb{Q} \cap [0, 1]$ sea denso en $[0, 1]$. Densidad topológica y tamaño medido son nociones distintas.

Ejemplo 5.7 (El intervalo unitario). Se tiene

$$\lambda^*([0, 1]) = 1.$$

La desigualdad $\lambda^*([0, 1]) \leq 1$ se obtiene cubriendo $[0, 1]$ por intervalos abiertos con longitud total tan cercana a uno como se quiera. La desigualdad contraria usa compacidad: toda cubierta abierta de $[0, 1]$ admite una subcubierta finita, y ninguna colección finita de intervalos abiertos que cubra $[0, 1]$ puede tener longitud total menor que uno.

Advertencia 5.8. La medida exterior está definida sobre todos los subconjuntos de $\mathbb{R}$, pero no es aditiva sobre todos ellos. La etapa siguiente consiste en seleccionar los conjuntos para los cuales la medida exterior se comporta como una medida auténtica.

6. Medibilidad de Carathéodory

Carathéodory dio un criterio elegante para separar los conjuntos bien medibles de los conjuntos patológicos. La idea es que un conjunto medible debe cortar cualquier otro conjunto sin alterar la contabilidad de la medida exterior.

Definición 6.1. Un conjunto $E \subseteq \mathbb{R}$ es Lebesgue medible si para todo $A \subseteq \mathbb{R}$,

$$\lambda^*(A) = \lambda^*(A \cap E) + \lambda^*(A \cap E^c).$$

La colección de todos los conjuntos Lebesgue medibles se denota por $\mathcal{L}(\mathbb{R})$.

Teorema 6.2 (Carathéodory). *La familia $\mathcal{L}(\mathbb{R})$ es una σ -álgebra. Además, la restricción de λ^* a $\mathcal{L}(\mathbb{R})$ es una medida. Esta medida se llama medida de Lebesgue y se denota λ .*

Observación 6.3. La condición de Carathéodory expresa que E no crea masa artificial ni destruye masa al separar un conjunto A en dos piezas. Para conjuntos medibles, la medida exterior recupera aditividad exacta.

Proposición 6.4. *Todo conjunto boreliano es Lebesgue medible. En símbolos,*

$$\mathcal{B}(\mathbb{R}) \subseteq \mathcal{L}(\mathbb{R}).$$

Ejemplo 6.5 (Intervalos). Los intervalos abiertos, cerrados y semiabiertos son Lebesgue medibles. En todos los casos,

$$\lambda((a, b)) = \lambda([a, b]) = \lambda((a, b]) = \lambda([a, b)) = b - a.$$

Ejemplo 6.6 (Abiertos). Todo abierto de $\mathbb{R}$ es una unión numerable disjunta de intervalos abiertos. Por tanto es boreliano y, en consecuencia, Lebesgue medible.

Ejemplo 6.7 (Cerrados). Todo cerrado es complemento de un abierto. Por la estabilidad de las σ -álgebras bajo complementos, todo cerrado es boreliano y por tanto Lebesgue medible.

Ejemplo 6.8 (Conjunto de Cantor). El conjunto ternario de Cantor C es cerrado y, por tanto, Lebesgue medible. Su medida es cero. El cálculo se obtiene observando que en la construcción se retiran intervalos cuya longitud total es

$$\frac{1}{3} + \frac{2}{3^2} + \frac{2^2}{3^3} + \cdots = 1.$$

Como el intervalo inicial tiene longitud uno, queda $\lambda(C) = 0$.

Observación 6.9 (Complejidad). La medida de Lebesgue es completa: si $N \in \mathcal{L}(\mathbb{R})$ y $\lambda(N) = 0$, entonces todo subconjunto de N es Lebesgue medible. Esta propiedad no la tiene, en general, la medida de Lebesgue restringida a $\mathcal{B}(\mathbb{R})$.

7. Conjuntos nulos y afirmaciones casi en todas partes

Una de las grandes virtudes de la teoría de medida es que permite ignorar sistemáticamente conjuntos de medida cero. En análisis esto da lugar a la noción de igualdad casi en todas partes; en probabilidad, a la noción de igualdad casi seguramente.

Definición 7.1. Un conjunto medible N es nulo si $\lambda(N) = 0$. Una propiedad $P(x)$ se cumple λ -casi en todas partes si el conjunto donde falla es nulo.

Definición 7.2. En un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$, una propiedad se cumple $\mathbb{P}$ -casi seguramente si el evento donde falla tiene probabilidad cero.

Ejemplo 7.3 (Racionales). Se cumple

$$\lambda(\mathbb{Q} \cap [0, 1]) = 0.$$

Por tanto,

$$\mathbf{1}_{\mathbb{Q} \cap [0, 1]}(x) = 0 \quad \lambda\text{-c.t.p. en } [0, 1].$$

La función indicadora no es idénticamente cero punto por punto, pero sí es cero casi en todas partes.

Ejemplo 7.4 (Irracionales). En $[0, 1]$,

$$\lambda([0, 1] \setminus \mathbb{Q}) = 1.$$

Así,

$$\mathbf{1}_{[0, 1] \setminus \mathbb{Q}}(x) = 1 \quad \lambda\text{-c.t.p.}$$

Esta función difiere de la función constante uno únicamente sobre $\mathbb{Q} \cap [0, 1]$.

Ejemplo 7.5 (Variables iguales casi seguramente). Si X, Y son variables aleatorias y

$$\mathbb{P}(\{\omega : X(\omega) = Y(\omega)\}) = 1,$$

entonces escribimos $X = Y$, $\mathbb{P}$ -c.s. En espacios L^p , ambas variables representan el mismo elemento.

Ejemplo 7.6 (Un tiempo fijo y una trayectoria). Si $(W_t)_{t \geq 0}$ es un movimiento Browniano estándar y $t > 0$, entonces W_t tiene distribución normal $N(0, t)$. En particular,

$$\mathbb{P}(W_t = 0) = 0.$$

Esto no significa que la trayectoria browniana no toque cero. De hecho, la afirmación sobre un tiempo fijo y la afirmación sobre todos los tiempos pertenecen a niveles medibles distintos.

Observación 7.7. La frase “casi seguramente” no significa “seguramente en el sentido coloquial”. Significa que el conjunto excepcional tiene probabilidad cero. En modelos continuos, muchos eventos individuales tienen probabilidad cero, pero eso no implica imposibilidad lógica.

8. Completación de medidas y el papel de los conjuntos nulos

La completación de una medida consiste en añadir todos los subconjuntos de conjuntos nulos. Esta operación es natural porque, si un conjunto tiene tamaño cero, cualquier subconjunto suyo debería también tener tamaño cero.

Definición 8.1. Sea $(\Omega, \mathcal{F}, \mu)$ un espacio de medida. La medida μ es completa si, siempre que $N \in \mathcal{F}$, $\mu(N) = 0$ y $A \subseteq N$, se tiene $A \in \mathcal{F}$ y $\mu(A) = 0$.

Proposición 8.2. Toda medida admite una completación. La completación de $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \lambda)$ es precisamente el espacio de Lebesgue $(\mathbb{R}, \mathcal{L}(\mathbb{R}), \lambda)$.

Ejemplo 8.3 (Subconjuntos de racionales). Todo subconjunto de $\mathbb{Q}$ es Lebesgue medible y tiene medida cero. No todo subconjunto de $\mathbb{Q}$ necesita ser boreliano. La completación permite incorporar estos conjuntos sin cambiar la medida de los conjuntos ya medidos.

Ejemplo 8.4 (Igualdad en clases). En L^p , no se trabaja con funciones punto a punto, sino con clases de equivalencia bajo igualdad casi en todas partes. Si $f = g$ fuera de un conjunto nulo, entonces f y g son el mismo elemento de L^p .

Observación 8.5 (Procesos estocásticos). En procesos estocásticos, la completación puede ser delicada porque también se trabaja con filtraciones $(\mathcal{F}_t)$. Una filtración suele completarse y hacerse continua por la derecha para evitar patologías en tiempos de paro y versiones de procesos. Aunque estos temas aparecen más adelante, el origen técnico está en el tratamiento correcto de los conjuntos nulos.

9. Funciones medibles

Una vez fijados los conjuntos medibles, debemos decidir qué funciones son compatibles con ellos. La idea es sencilla: una función es medible si la preimagen de todo conjunto medible del codominio es medible en el dominio.

Definición 9.1. Sean $(\Omega, \mathcal{F})$ y $(S, \mathcal{S})$ espacios medibles. Una función $X : \Omega \rightarrow S$ es medible si

$$X^{-1}(B) \in \mathcal{F}$$

para todo $B \in \mathcal{S}$.

Cuando $S = \mathbb{R}$ y $\mathcal{S} = \mathcal{B}(\mathbb{R})$, una función real X es medible si $\{\omega : X(\omega) \in B\} \in \mathcal{F}$ para todo boreliano B .

Proposición 9.2. Para una función $X : \Omega \rightarrow \mathbb{R}$, son equivalentes:

1. X es $\mathcal{F}/\mathcal{B}(\mathbb{R})$ -medible;
2. $\{X \leq x\} \in \mathcal{F}$ para todo $x \in \mathbb{R}$;
3. $\{X < x\} \in \mathcal{F}$ para todo $x \in \mathbb{R}$;
4. $\{X > x\} \in \mathcal{F}$ para todo $x \in \mathbb{R}$.

Ejemplo 9.3 (Indicadoras). Si $A \in \mathcal{F}$, entonces $\mathbf{1}_A$ es medible. En efecto,

$$\{\mathbf{1}_A = 1\} = A, \quad \{\mathbf{1}_A = 0\} = A^c.$$

Ejemplo 9.4 (Funciones continuas). Toda función continua $f : \mathbb{R} \rightarrow \mathbb{R}$ es boreliana medible. Esto se debe a que la preimagen de un abierto bajo una función continua es abierta.

Ejemplo 9.5 (Funciones escalón). La función

$$f(x) = 2\mathbf{1}_{[0,1]}(x) - 3\mathbf{1}_{(1,2]}(x) + 5\mathbf{1}_{(2,4)}(x)$$

es boreliana medible, porque los conjuntos $[0, 1]$, $(1, 2]$ y $(2, 4)$ son borelianos.

Ejemplo 9.6 (Límites de funciones medibles). Si (f_n) es una sucesión de funciones medibles, entonces las funciones

$$\sup_n f_n, \quad \inf_n f_n, \quad \limsup_{n \rightarrow \infty} f_n, \quad \liminf_{n \rightarrow \infty} f_n$$

son medibles. En particular, si $f_n(x)$ converge para todo x , el límite puntual es medible.

Observación 9.7 (Variables aleatorias). En probabilidad, una variable aleatoria real es una función medible

$$X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R})).$$

La medibilidad garantiza que eventos como $\{X \leq x\}$, $\{a < X \leq b\}$ y $\{X \in B\}$ tienen probabilidad bien definida.

10. Leyes de variables aleatorias

Una variable aleatoria transforma la probabilidad original sobre Ω en una probabilidad sobre $\mathbb{R}$. Esa probabilidad transformada es su ley.

Definición 10.1. Sea $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ una variable aleatoria. Su ley, o distribución, es la medida $\mathbb{P}_X$ definida por

$$\mathbb{P}_X(B) = \mathbb{P}(\{\omega : X(\omega) \in B\}), \quad B \in \mathcal{B}(\mathbb{R}).$$

La función de distribución acumulada es

$$F_X(x) = \mathbb{P}(X \leq x).$$

Observación 10.2. La ley $\mathbb{P}_X$ contiene toda la información necesaria para calcular esperanzas de funciones de X . La variable X vive en Ω ; su ley vive en $\mathbb{R}$.

Ejemplo 10.3 (Bernoulli). Si $X \sim \text{Bernoulli}(p)$, entonces

$$\mathbb{P}_X(dx) = (1-p)\delta_0(dx) + p\delta_1(dx).$$

Para toda φ integrable respecto de $\mathbb{P}_X$,

$$\int_{\mathbb{R}} \varphi(x) \mathbb{P}_X(dx) = (1-p)\varphi(0) + p\varphi(1).$$

Ejemplo 10.4 (Normal estándar). Si $X \sim N(0, 1)$, entonces

$$\mathbb{P}_X(dx) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2} \lambda(dx).$$

Por tanto,

$$\int_{\mathbb{R}} \varphi(x) \mathbb{P}_X(dx) = \int_{\mathbb{R}} \varphi(x) \frac{1}{\sqrt{2\pi}} e^{-x^2/2} \lambda(dx).$$

Ejemplo 10.5 (Distribución mixta). La medida

$$\mathbb{P}_X(dx) = \frac{1}{2}\delta_0(dx) + \frac{1}{2}\mathbf{1}_{[0,1]}(x) \lambda(dx)$$

es una distribución mixta: tiene una masa puntual en cero y una parte continua uniforme en $[0, 1]$, con peso total $1/2$ en cada parte.

Ejemplo 10.6 (Tiempo fijo de un proceso). Si $(X_t)_{t \geq 0}$ es un proceso estocástico, cada X_t tiene su ley $\mathbb{P}_{X_t}$. Si (W_t) es Browniano estándar, entonces

$$\mathbb{P}_{W_t}(dx) = \frac{1}{\sqrt{2\pi t}} e^{-x^2/(2t)} \lambda(dx), \quad t > 0.$$

Observación 10.7 (Distribuciones finito-dimensionales). Para un proceso $(X_t)_{t \geq 0}$, no basta conocer las leyes individuales $\mathbb{P}_{X_t}$. También importan las leyes conjuntas de $(X_{t_1}, \dots, X_{t_n})$. Estas distribuciones finito-dimensionales codifican correlaciones, independencia de incrementos y estructura temporal.

11. Funciones simples

La integral de Lebesgue se define primero para funciones simples. Estas funciones son combinaciones finitas de indicadoras y representan el análogo medible de una función escalonada.

Definición 11.1. Una función simple no negativa sobre $(\Omega, \mathcal{F})$ es una función de la forma

$$s(\omega) = \sum_{k=1}^n a_k \mathbf{1}_{A_k}(\omega),$$

donde $a_k \geq 0$ y $A_k \in \mathcal{F}$. Si μ es una medida, se define

$$\int_{\Omega} s(\omega) \mu(d\omega) = \sum_{k=1}^n a_k \mu(A_k),$$

cuando la representación se toma con conjuntos disjuntos o se interpreta mediante una refinación común.

Ejemplo 11.2 (Indicadora). Para $s = \mathbf{1}_A$,

$$\int_{\Omega} \mathbf{1}_A(\omega) \mu(d\omega) = \mu(A).$$

En probabilidad,

$$\mathbb{E}[\mathbf{1}_A] = \mathbb{P}(A).$$

Ejemplo 11.3 (Dado justo). Sea X el resultado de un dado justo. Entonces

$$X = \sum_{k=1}^6 k \mathbf{1}_{\{X=k\}}.$$

Así,

$$\mathbb{E}[X] = \sum_{k=1}^6 k \mathbb{P}(X = k) = \frac{7}{2}.$$

Ejemplo 11.4 (Pago de una apuesta). Supongamos que una apuesta paga 100 si ocurre A , paga 20 si ocurre B , y paga 0 fuera de $A \cup B$, donde $A \cap B = \emptyset$. El pago es

$$Y = 100\mathbf{1}_A + 20\mathbf{1}_B.$$

Su valor esperado es

$$\mathbb{E}[Y] = 100\mathbb{P}(A) + 20\mathbb{P}(B).$$

Ejemplo 11.5 (Variable simple con partición). Si $\Omega = A_1 \cup \dots \cup A_n$, los conjuntos A_i son disjuntos y $s = \sum_{i=1}^n a_i \mathbf{1}_{A_i}$, entonces la integral pondera cada valor a_i por la masa de la región donde se toma ese valor.

Observación 11.6. La identidad $\mathbb{E}[\mathbf{1}_A] = \mathbb{P}(A)$ es más que una curiosidad. Permite pasar de probabilidades de eventos a esperanzas de variables, y viceversa. Muchos argumentos en probabilidad consisten en escribir eventos mediante indicadoras e integrar.

12. Integral de Lebesgue para funciones no negativas

La integral de una función medible no negativa se define como el supremo de las integrales de funciones simples que están por debajo de ella. La construcción es ordenada, monotónica y compatible con límites crecientes.

Definición 12.1. Sea $f : \Omega \rightarrow [0, \infty]$ medible. Se define

$$\int_{\Omega} f(\omega) \mu(d\omega) = \sup \left\{ \int_{\Omega} s(\omega) \mu(d\omega) : 0 \leq s \leq f, \text{ } s \text{ simple} \right\}.$$

Observación 12.2. La integral se construye desde abajo. Esto evita tener que controlar oscilaciones de la función sobre intervalos pequeños, como en Riemann. En Lebesgue, las funciones simples medibles forman la base de aproximación.

Ejemplo 12.3 (Función escalonada). Sea

$$f(x) = \mathbf{1}_{[0,1)}(x) + 3\mathbf{1}_{[1,2)}(x) + 4\mathbf{1}_{[2,3)}(x).$$

Entonces

$$\int_{\mathbb{R}} f(x) \lambda(dx) = 1 \cdot 1 + 3 \cdot 1 + 4 \cdot 1 = 8.$$

Ejemplo 12.4 (Función no acotada integrable). La función

$$f(x) = x^{-1/2} \mathbf{1}_{(0,1]}(x)$$

es no acotada cerca de cero, pero

$$\int_{\mathbb{R}} f(x) \lambda(dx) = \int_0^1 x^{-1/2} \lambda(dx) = 2.$$

La integral de Lebesgue no exige acotación.

Ejemplo 12.5 (Función no negativa con integral infinita). Para

$$g(x) = x^{-1} \mathbf{1}_{(0,1]}(x),$$

se tiene

$$\int_{\mathbb{R}} g(x) \lambda(dx) = \infty.$$

La teoría permite integrales infinitas para funciones no negativas.

Ejemplo 12.6 (Esperanza de una exponencial). Si $X \sim \text{Exp}(\theta)$, con $\theta > 0$, entonces

$$\mathbb{P}_X(dx) = \theta e^{-\theta x} \mathbf{1}_{[0,\infty)}(x) \lambda(dx).$$

Por tanto,

$$\mathbb{E}[X] = \int_{\mathbb{R}} x \mathbb{P}_X(dx) = \int_0^{\infty} x \theta e^{-\theta x} \lambda(dx) = \frac{1}{\theta}.$$

Proposición 12.7 (Linealidad positiva). Si $f, g \geq 0$ son medibles y $a, b \geq 0$, entonces

$$\int (af + bg)(\omega) \mu(d\omega) = a \int f(\omega) \mu(d\omega) + b \int g(\omega) \mu(d\omega),$$

con la convención usual para valores infinitos.

13. Funciones con signo e integrabilidad

Para integrar funciones que pueden tomar valores negativos, se separan las partes positiva y negativa. La integral sólo está bien definida como número real finito cuando ambas contribuciones no producen una indeterminación del tipo infinito menos infinito.

Definición 13.1. Para una función medible $f : \Omega \rightarrow \mathbb{R}$, definimos

$$f^+(\omega) = \max\{f(\omega), 0\}, \quad f^-(\omega) = \max\{-f(\omega), 0\}.$$

Entonces

$$f = f^+ - f^-, \quad |f| = f^+ + f^-.$$

Se dice que f es integrable si

$$\int_{\Omega} |f(\omega)| \mu(d\omega) < \infty.$$

En ese caso,

$$\int_{\Omega} f(\omega) \mu(d\omega) = \int_{\Omega} f^+(\omega) \mu(d\omega) - \int_{\Omega} f^-(\omega) \mu(d\omega).$$

Ejemplo 13.2 (Función con dos niveles). Sea

$$f(x) = 2\mathbf{1}_{[0,1]}(x) - 3\mathbf{1}_{(1,2]}(x).$$

Entonces

$$f^+ = 2\mathbf{1}_{[0,1]}, \quad f^- = 3\mathbf{1}_{(1,2]}.$$

Por tanto,

$$\int_{\mathbb{R}} f(x) \lambda(dx) = 2 - 3 = -1.$$

Ejemplo 13.3 (Variable con dos valores). Si $\mathbb{P}(X = 1) = 0,7$ y $\mathbb{P}(X = -2) = 0,3$, entonces

$$\mathbb{P}_X(dx) = 0,7\delta_1(dx) + 0,3\delta_{-2}(dx),$$

y

$$\mathbb{E}[X] = \int_{\mathbb{R}} x \mathbb{P}_X(dx) = 0,7 - 0,6 = 0,1.$$

Ejemplo 13.4 (Cauchy). Si X tiene distribución de Cauchy estándar,

$$\mathbb{P}_X(dx) = \frac{1}{\pi(1+x^2)} \lambda(dx),$$

entonces

$$\int_{\mathbb{R}} |x| \mathbb{P}_X(dx) = \infty.$$

Por tanto, X no tiene esperanza finita. No es correcto asignarle esperanza cero sólo por simetría si se exige integrabilidad absoluta.

Observación 13.5 (Integrabilidad absoluta). La condición $\int |f| \mu(dx) < \infty$ garantiza que la integral no dependa de cancelaciones artificiales entre colas positivas y negativas. En probabilidad, esta condición permite manipular esperanzas de manera segura.

14. Riemann y Lebesgue

La integral de Riemann y la integral de Lebesgue coinciden en muchas funciones clásicas, pero responden a principios distintos. Riemann controla oscilaciones sobre particiones del dominio. Lebesgue mide el tamaño de los conjuntos donde la función toma ciertos valores.

Teorema 14.1 (Criterio de Lebesgue para integrabilidad de Riemann). *Una función acotada $f : [a, b] \rightarrow \mathbb{R}$ es Riemann integrable si y sólo si el conjunto de sus discontinuidades tiene medida de Lebesgue cero.*

Ejemplo 14.2 (Función de Dirichlet). Sea

$$f(x) = \mathbf{1}_{\mathbb{Q} \cap [0,1]}(x).$$

Esta función es discontinua en todo punto de $[0, 1]$, por lo que no es Riemann integrable. Sin embargo,

$$\int_{[0,1]} f(x) \lambda(dx) = \lambda(\mathbb{Q} \cap [0, 1]) = 0.$$

Ejemplo 14.3 (Indicadora de irracionales). La función

$$g(x) = \mathbf{1}_{[0,1] \setminus \mathbb{Q}}(x)$$

tampoco es Riemann integrable, pero

$$\int_{[0,1]} g(x) \lambda(dx) = 1.$$

Ejemplo 14.4 (Una discontinuidad). La función $\mathbf{1}_{[0,1]}$, considerada sobre $[-1, 2]$, es Riemann integrable y Lebesgue integrable. Ambas integrales valen uno. El conjunto de discontinuidades es $\{0, 1\}$, que tiene medida cero.

Ejemplo 14.5 (Función de Thomae). La función de Thomae en $[0, 1]$, definida por $f(x) = 0$ si x es irracional y $f(p/q) = 1/q$ para p/q en forma reducida, es discontinua en los racionales y continua en los irracionales. Como los racionales tienen medida cero, la función es Riemann integrable y su integral es cero. También es Lebesgue integrable con integral cero.

Observación 14.6 (Por qué esto importa en probabilidad). La integral de Lebesgue permite tratar en una misma notación distribuciones discretas, continuas, mixtas y singulares. En probabilidad moderna no se quiere cambiar de teoría cada vez que cambia el tipo de distribución. La fórmula estable es

$$\mathbb{E}[\varphi(X)] = \int_{\mathbb{R}} \varphi(x) \mathbb{P}_X(dx).$$

15. Teoremas de convergencia

El poder de la integral de Lebesgue aparece con los teoremas de convergencia. Estos resultados permiten intercambiar límites e integrales bajo hipótesis naturales, algo esencial en probabilidad, estadística, análisis funcional y procesos estocásticos.

Teorema 15.1 (Convergencia monótona). Si $0 \leq f_1 \leq f_2 \leq \dots$ y $f_n(\omega) \uparrow f(\omega)$, entonces

$$\int f_n(\omega) \mu(d\omega) \uparrow \int f(\omega) \mu(d\omega).$$

Ejemplo 15.2 (Indicadoras crecientes). Sea $A_n = [0, 1 - 1/n]$. Entonces $\mathbf{1}_{A_n} \uparrow \mathbf{1}_{[0,1]}$. Por convergencia monótona,

$$\lambda(A_n) = \int \mathbf{1}_{A_n}(x) \lambda(dx)$$

crece hacia

$$\int \mathbf{1}_{[0,1]}(x) \lambda(dx) = 1.$$

Ejemplo 15.3 (Truncaciones). Si $X \geq 0$, definimos $X_n = \min\{X, n\}$. Entonces $X_n \uparrow X$, y

$$\mathbb{E}[X_n] \uparrow \mathbb{E}[X].$$

Esto permite estudiar variables no negativas mediante variables acotadas.

Teorema 15.4 (Lema de Fatou). Si $f_n \geq 0$, entonces

$$\liminf_{n \rightarrow \infty} \int f_n(\omega) \mu(d\omega) \leq \int \liminf_{n \rightarrow \infty} f_n(\omega) \mu(d\omega).$$

Ejemplo 15.5 (Masa que escapa). Sea $f_n(x) = \mathbf{1}_{[n, n+1]}(x)$. Para cada x , $f_n(x)$ tiende a cero. Sin embargo,

$$\int f_n(x) \lambda(dx) = 1$$

para todo n . Fatou da $0 \leq 1$, y revela que la masa no desaparece localmente: se desplaza hacia el infinito.

Teorema 15.6 (Convergencia dominada). Supongamos que $f_n \rightarrow f$ casi en todas partes y que existe $g \in L^1(\mu)$ tal que $|f_n| \leq g$ para todo n . Entonces

$$\int f_n(\omega) \mu(d\omega) \rightarrow \int f(\omega) \mu(d\omega).$$

Ejemplo 15.7 (Potencias en el intervalo unitario). Sea $f_n(x) = x^n$. Entonces $f_n(x) \rightarrow 0$ para $0 \leq x < 1$, y $f_n(1) = 1$. El límite es cero casi en todas partes. Además $|f_n| \leq 1$, y 1 es integrable en $[0, 1]$. Por convergencia dominada,

$$\int_0^1 x^n \lambda(dx) \rightarrow 0.$$

Ejemplo 15.8 (Esperanzas). Si $X_n \rightarrow X$, $\mathbb{P}$ -c.s., y $|X_n| \leq Y$ con $\mathbb{E}[Y] < \infty$, entonces

$$\mathbb{E}[X_n] \rightarrow \mathbb{E}[X].$$

Este es uno de los argumentos más usados para justificar límites de esperanzas.

Observación 15.9. Convergencia monótona no requiere dominación, pero sí monotonía y no negatividad. Fatou no exige convergencia puntual completa, sólo controla el límite inferior. Convergencia dominada exige una cota integrable común. Cada resultado tiene un papel diferente.

16. Espacios L^p

Los espacios L^p organizan funciones de acuerdo con la integrabilidad de sus potencias. En probabilidad, estos espacios clasifican variables aleatorias según sus momentos.

Definición 16.1. Para $1 \leq p < \infty$, se define

$$L^p(\Omega, \mathcal{F}, \mu) = \left\{ f : \Omega \rightarrow \mathbb{R} : f \text{ medible y } \int_{\Omega} |f(\omega)|^p \mu(d\omega) < \infty \right\},$$

identificando funciones iguales casi en todas partes. La norma es

$$\|f\|_p = \left(\int_{\Omega} |f(\omega)|^p \mu(d\omega) \right)^{1/p}.$$

Definición 16.2. El espacio L^∞ consiste en las funciones esencialmente acotadas. Su norma es

$$\|f\|_\infty = \text{ess sup } |f|.$$

Teorema 16.3. Para $1 \leq p \leq \infty$, L^p es un espacio de Banach. En particular, toda sucesión de Cauchy en norma L^p converge a un elemento de L^p .

Ejemplo 16.4 (Normal). Si $X \sim N(0, 1)$, entonces $X \in L^p(\mathbb{P})$ para todo $p < \infty$. Todos sus momentos absolutos finitos existen.

Ejemplo 16.5 (Cauchy). Si X es Cauchy estándar, entonces $X \notin L^1(\mathbb{P})$. Mucho menos pertenece a $L^2(\mathbb{P})$.

Ejemplo 16.6 (Colas de Pareto). Si X tiene cola $\mathbb{P}(X > x) = x^{-\alpha}$ para $x \geq 1$, entonces $X \in L^p$ exactamente para $p < \alpha$. Este criterio conecta integrabilidad con grosor de colas, algo esencial en riesgo financiero.

Observación 16.7 (El caso L^2). El espacio $L^2(\mathbb{P})$ es un espacio de Hilbert con producto interno

$$\langle X, Y \rangle = \mathbb{E}[XY] = \int_{\Omega} X(\omega)Y(\omega) \mathbb{P}(d\omega).$$

Esta estructura geométrica permite interpretar la esperanza condicional como proyección ortogonal.

Ejemplo 16.8 (Varianza). Si $X \in L^2$, entonces

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \|X - \mathbb{E}[X]\|_2^2.$$

La varianza mide distancia cuadrática de X a las constantes.

Observación 16.9 (Inclusiones en probabilidad). Si $\mathbb{P}(\Omega) = 1$ y $q > p$, entonces $L^q(\mathbb{P}) \subseteq L^p(\mathbb{P})$. En particular, segundo momento finito implica primer momento finito.

17. Esperanza como integral

La esperanza es la integral de una variable aleatoria respecto a la medida de probabilidad. Esta identificación es el punto donde la teoría de la medida se convierte en probabilidad moderna.

Definición 17.1. Si $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$, su esperanza se define por

$$\mathbb{E}[X] = \int_{\Omega} X(\omega) \mathbb{P}(d\omega).$$

Si $X \geq 0$, la esperanza puede tomar el valor ∞ .

Proposición 17.2 (Cambio a la ley). *Si X es una variable aleatoria real y φ es boreliana no negativa o integrable respecto de $\mathbb{P}_X$, entonces*

$$\mathbb{E}[\varphi(X)] = \int_{\mathbb{R}} \varphi(x) \mathbb{P}_X(dx).$$

Ejemplo 17.3 (Discreta). Si $\mathbb{P}(X = x_k) = p_k$, entonces

$$\mathbb{P}_X(dx) = \sum_k p_k \delta_{x_k}(dx),$$

y

$$\mathbb{E}[\varphi(X)] = \sum_k \varphi(x_k) p_k.$$

Ejemplo 17.4 (Continua con densidad). Si $\mathbb{P}_X(dx) = f_X(x) \lambda(dx)$, entonces

$$\mathbb{E}[\varphi(X)] = \int_{\mathbb{R}} \varphi(x) f_X(x) \lambda(dx).$$

Ejemplo 17.5 (Mixta). Si

$$\mathbb{P}_X(dx) = \frac{1}{2} \delta_0(dx) + \frac{1}{2} \mathbf{1}_{[0,1]}(x) \lambda(dx),$$

entonces

$$\mathbb{E}[\varphi(X)] = \frac{1}{2} \varphi(0) + \frac{1}{2} \int_0^1 \varphi(x) \lambda(dx).$$

Ejemplo 17.6 (Indicadoras). Para todo evento $A \in \mathcal{F}$,

$$\mathbb{E}[\mathbf{1}_A] = \int_{\Omega} \mathbf{1}_A(\omega) \mathbb{P}(d\omega) = \mathbb{P}(A).$$

Esta identidad es la traducción elemental entre eventos y variables aleatorias.

Observación 17.7 (Momentos). El momento de orden p se escribe

$$\mathbb{E}[|X|^p] = \int_{\mathbb{R}} |x|^p \mathbb{P}_X(dx).$$

La existencia de momentos es una propiedad de la ley de X , no de la representación particular de X sobre un espacio Ω .

18. Medida producto e independencia

Para estudiar vectores aleatorios, pares de variables e incrementos de procesos, se necesitan medidas producto. La independencia se expresa como una factorización de la ley conjunta.

Definición 18.1. Sean $(\Omega_1, \mathcal{F}_1, \mu_1)$ y $(\Omega_2, \mathcal{F}_2, \mu_2)$ espacios de medida σ -finitos. La σ -álgebra producto $\mathcal{F}_1 \otimes \mathcal{F}_2$ es la generada por los rectángulos medibles $A_1 \times A_2$. La medida producto $\mu_1 \otimes \mu_2$ es la medida caracterizada por

$$(\mu_1 \otimes \mu_2)(A_1 \times A_2) = \mu_1(A_1)\mu_2(A_2).$$

Definición 18.2. Si X, Y son variables aleatorias reales, su ley conjunta es la medida $\mathbb{P}_{(X,Y)}$ sobre $\mathbb{R}^2$. Decimos que X y Y son independientes si

$$\mathbb{P}_{(X,Y)} = \mathbb{P}_X \otimes \mathbb{P}_Y.$$

Ejemplo 18.3 (Dos dados). Si X y Y son dos dados justos independientes, entonces

$$\mathbb{P}(X = i, Y = j) = \frac{1}{36}$$

para $i, j \in \{1, \dots, 6\}$. La ley conjunta factoriza porque $1/36 = (1/6)(1/6)$.

Ejemplo 18.4 (Normales independientes). Si $X, Y \sim N(0, 1)$ son independientes, entonces

$$\mathbb{P}_{(X,Y)}(dx dy) = \frac{1}{2\pi} e^{-(x^2+y^2)/2} \lambda_2(dx dy),$$

donde λ_2 es la medida de Lebesgue en $\mathbb{R}^2$. La densidad conjunta es producto de las densidades marginales.

Ejemplo 18.5 (Dependencia perfecta). Si $Y = X$, la ley conjunta de (X, Y) está concentrada en la diagonal $\{(x, y) : x = y\}$. En general no coincide con $\mathbb{P}_X \otimes \mathbb{P}_Y$. La igualdad $Y = X$ codifica dependencia máxima.

Ejemplo 18.6 (Incrementos independientes). En un proceso Browniano, los incrementos $W_{t_2} - W_{t_1}$, $W_{t_3} - W_{t_2}$, ..., sobre intervalos disjuntos son independientes. Esto significa que su ley conjunta factoriza como producto de las leyes marginales gaussianas correspondientes.

Observación 18.7. La independencia no significa ausencia de relación visual en una muestra finita, sino una propiedad exacta de factorización de medidas. Esta formulación es la que sobrevive en dimensiones altas, procesos y espacios funcionales.

19. Tonelli, Fubini y fórmulas de cola

Los teoremas de Tonelli y Fubini justifican integrar por etapas. En probabilidad, estos resultados permiten calcular esperanzas condicionales, marginales, colas y momentos mediante integrales iteradas.

Teorema 19.1 (Tonelli). Si $f : \Omega_1 \times \Omega_2 \rightarrow [0, \infty]$ es medible, entonces

$$\int_{\Omega_1 \times \Omega_2} f(\omega_1, \omega_2) (\mu_1 \otimes \mu_2)(d\omega_1 d\omega_2) = \int_{\Omega_1} \left[\int_{\Omega_2} f(\omega_1, \omega_2) \mu_2(d\omega_2) \right] \mu_1(d\omega_1),$$

y la integral iterada con el orden opuesto tiene el mismo valor.

Teorema 19.2 (Fubini). *Si f es integrable respecto de $\mu_1 \otimes \mu_2$, entonces las integrales iteradas existen casi en todas partes, son integrables y coinciden con la integral sobre el producto.*

Ejemplo 19.3 (Rectángulo). Para

$$f(x, y) = \mathbf{1}_{[0,2] \times [0,3]}(x, y),$$

se obtiene

$$\int_{\mathbb{R}^2} f(x, y) \lambda_2(dx dy) = 6.$$

La integral iterada primero en y y luego en x da

$$\int_0^2 \left[\int_0^3 \mathbf{1} \lambda(dy) \right] \lambda(dx) = \int_0^2 3 \lambda(dx) = 6.$$

Ejemplo 19.4 (Producto de esperanzas). Si X y Y son independientes, y las integrales existen, entonces

$$\mathbb{E}[g(X)h(Y)] = \left(\int_{\mathbb{R}} g(x) \mathbb{P}_X(dx) \right) \left(\int_{\mathbb{R}} h(y) \mathbb{P}_Y(dy) \right).$$

Este resultado es una aplicación directa de Fubini y de la factorización $\mathbb{P}_{(X,Y)} = \mathbb{P}_X \otimes \mathbb{P}_Y$.

Proposición 19.5 (Fórmula de cola). *Si $X \geq 0$, entonces*

$$\mathbb{E}[X] = \int_0^\infty \mathbb{P}(X > t) \lambda(dt).$$

Demostración. Para cada ω ,

$$X(\omega) = \int_0^\infty \mathbf{1}_{\{X(\omega) > t\}} \lambda(dt).$$

Tonelli permite integrar primero en ω y después en t :

$$\mathbb{E}[X] = \int_{\Omega} \int_0^\infty \mathbf{1}_{\{X(\omega) > t\}} \lambda(dt) \mathbb{P}(d\omega) = \int_0^\infty \mathbb{P}(X > t) \lambda(dt).$$

□

Ejemplo 19.6 (Exponencial por colas). Si $X \sim \text{Exp}(\theta)$, entonces $\mathbb{P}(X > t) = e^{-\theta t}$. Por la fórmula de cola,

$$\mathbb{E}[X] = \int_0^\infty e^{-\theta t} \lambda(dt) = \frac{1}{\theta}.$$

Ejemplo 19.7 (Colas pesadas). Si $\mathbb{P}(X > t) \sim Ct^{-\alpha}$, entonces la finitud de $\mathbb{E}[X]$ depende de si $\alpha > 1$. La fórmula de cola vuelve visible la relación entre esperanza y decaimiento de colas.

20. Esperanza condicional

La esperanza condicional es el punto en el que la teoría de la medida se convierte en teoría de la información. Condicionar no significa simplemente sustituir una variable por un valor; significa restringir la información disponible.

En probabilidad elemental se escribe $\mathbb{E}[X \mid Y = y]$. Esta notación es intuitiva, pero puede ser peligrosa cuando $\mathbb{P}(Y = y) = 0$, como ocurre con variables continuas. La formulación rigurosa condiciona respecto a una sub- σ -álgebra.

Definición 20.1. Sea $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ y sea $\mathcal{G} \subseteq \mathcal{F}$ una sub- σ -álgebra. Una versión de la esperanza condicional de X dada $\mathcal{G}$ es una variable aleatoria $\mathcal{G}$ -medible, denotada $\mathbb{E}[X \mid \mathcal{G}]$, tal que para todo $G \in \mathcal{G}$,

$$\int_G \mathbb{E}[X \mid \mathcal{G}](\omega) \mathbb{P}(d\omega) = \int_G X(\omega) \mathbb{P}(d\omega).$$

Teorema 20.2 (Existencia y unicidad). Si $X \in L^1(\mathbb{P})$, entonces $\mathbb{E}[X \mid \mathcal{G}]$ existe y es única salvo igualdad $\mathbb{P}$ -casi seguramente.

Idea de la prueba. Para $X \geq 0$, la medida $\nu(G) = \int_G X(\omega) \mathbb{P}(d\omega)$ es absolutamente continua respecto de $\mathbb{P}$ restringida a $\mathcal{G}$. El teorema de Radon–Nikodym produce una densidad $\mathcal{G}$ -medible. Para $X \in L^1$, se aplica la construcción a X^+ y X^- . $\square$

Observación 20.3 (Interpretación). La variable $\mathbb{E}[X \mid \mathcal{G}]$ es el mejor resumen integrable de X que sólo usa la información de $\mathcal{G}$. No necesariamente es un número; es una nueva variable aleatoria, constante sobre los bloques de información que $\mathcal{G}$ no puede distinguir.

Ejemplo 20.4 (Información trivial). Si $\mathcal{G} = \{\emptyset, \Omega\}$, entonces toda variable $\mathcal{G}$ -medible es constante. Por tanto,

$$\mathbb{E}[X \mid \mathcal{G}] = \mathbb{E}[X]$$

como variable constante. Sin información, la mejor predicción es la media.

Ejemplo 20.5 (Información completa). Si $\mathcal{G} = \mathcal{F}$, entonces

$$\mathbb{E}[X \mid \mathcal{F}] = X.$$

Con información completa, no hay nada que promediar: se conoce la variable misma.

Ejemplo 20.6 (Dado y paridad). Sea $\Omega = \{1, 2, 3, 4, 5, 6\}$ con probabilidad uniforme y $X(\omega) = \omega$. Si $\mathcal{G}$ sólo distingue paridad,

$$\mathcal{G} = \{\emptyset, \{1, 3, 5\}, \{2, 4, 6\}, \Omega\},$$

entonces

$$\mathbb{E}[X \mid \mathcal{G}] = 3\mathbf{1}_{\{1,3,5\}} + 4\mathbf{1}_{\{2,4,6\}}.$$

La variable condicionada es constante en cada bloque de información.

Ejemplo 20.7 (Condicionar respecto a una variable discreta). Si Y toma valores $y_1, y_2, \dots$, entonces

$$\mathbb{E}[X \mid Y] = \sum_k \mathbb{E}[X \mid Y = y_k] \mathbf{1}_{\{Y=y_k\}},$$

siempre que los términos estén bien definidos. Rigurosamente, $\mathbb{E}[X \mid Y]$ significa $\mathbb{E}[X \mid \sigma(Y)]$.

Ejemplo 20.8 (Independencia). Si $X \in L^1$ es independiente de $\mathcal{G}$, entonces

$$\mathbb{E}[X \mid \mathcal{G}] = \mathbb{E}[X]$$

$\mathbb{P}$ -c.s. La información de $\mathcal{G}$ no mejora la predicción de X .

Ejemplo 20.9 (Sacar lo conocido). Si Z es $\mathcal{G}$ -medible y acotada, y $X \in L^1$, entonces

$$\mathbb{E}[ZX \mid \mathcal{G}] = Z\mathbb{E}[X \mid \mathcal{G}].$$

La variable Z ya es conocida al nivel de información $\mathcal{G}$, por lo que puede salir de la esperanza condicional.

Teorema 20.10 (Proyección en L^2). Si $X \in L^2(\mathbb{P})$, entonces $\mathbb{E}[X \mid \mathcal{G}]$ es la proyección ortogonal de X sobre el subespacio cerrado

$$L^2(\mathcal{G}) = \{Y \in L^2(\mathbb{P}) : Y \text{ es } \mathcal{G}\text{-medible}\}.$$

Equivalente, para todo $Y \in L^2(\mathcal{G})$,

$$\mathbb{E}[(X - \mathbb{E}[X \mid \mathcal{G}])Y] = 0.$$

Observación 20.11 (Procesos estocásticos). Si $(\mathcal{F}_t)_{t \geq 0}$ es una filtración, $\mathcal{F}_t$ representa la información disponible hasta el tiempo t . La condición de martingala

$$\mathbb{E}[M_t \mid \mathcal{F}_s] = M_s, \quad s \leq t,$$

dice que, con la información disponible en s , la mejor predicción integrable de M_t es M_s . Esta frase descansa completamente en la construcción medida-teórica de la esperanza condicional.

Observación 20.12 (Cierre). Hasta este punto, la teoría ha construido un lenguaje común para longitud, masa y probabilidad. La medida de Lebesgue permite medir subconjuntos de $\mathbb{R}$; la integral de Lebesgue permite promediar funciones medibles; la ley de una variable aleatoria traslada la probabilidad a espacios de valores; la esperanza condicional formaliza la idea de predicción bajo información parcial. Estos son los cimientos sobre los que se construyen martingalas, tiempos de paro, Browniano, integración de Itô, cambios de medida y procesos de Lévy.

Ejercicios de consolidación

Ejercicio 20.13. Demuestra que si $A \subseteq B$, entonces $\lambda^*(A) \leq \lambda^*(B)$.

Ejercicio 20.14. Sea $A \subset \mathbb{R}$ numerable. Escribe una prueba completa de $\lambda^*(A) = 0$ usando cubiertas por intervalos de longitud total menor que ε .

Ejercicio 20.15. Prueba que si $X : \Omega \rightarrow \mathbb{R}$ satisface $\{X \leq x\} \in \mathcal{F}$ para todo $x \in \mathbb{R}$, entonces X es medible.

Ejercicio 20.16. Sea $X \sim \text{Bernoulli}(p)$. Calcula $\mathbb{E}[X]$, $\mathbb{E}[X^2]$ y $\text{Var}(X)$ usando la ley $\mathbb{P}_X(dx) = (1-p)\delta_0(dx) + p\delta_1(dx)$.

Ejercicio 20.17. Da un ejemplo de una sucesión (f_n) que converge puntualmente a cero, pero cuyas integrales no convergen a cero. Explica por qué no se puede aplicar convergencia dominada.

Ejercicio 20.18. Sea $X \geq 0$. Usa Tonelli para demostrar la fórmula de cola

$$\mathbb{E}[X] = \int_0^\infty \mathbb{P}(X > t) \lambda(dt).$$

Ejercicio 20.19. En el dado justo, sea $X(\omega) = \omega^2$ y sea $\mathcal{G}$ la σ -álgebra que sólo distingue paridad. Calcula $\mathbb{E}[X \mid \mathcal{G}]$.

Ejercicio 20.20. Supón que $X \in L^2$. Explica por qué $\mathbb{E}[X \mid \mathcal{G}]$ minimiza

$$\mathbb{E}[(X - Y)^2]$$

entre todas las variables $Y \in L^2(\mathcal{G})$.

Referencias

- [1] P. Billingsley, *Probability and Measure*, Wiley.
- [2] R. Durrett, *Probability: Theory and Examples*, Cambridge University Press.
- [3] G. B. Folland, *Real Analysis: Modern Techniques and Their Applications*, Wiley.
- [4] O. Kallenberg, *Foundations of Modern Probability*, Springer.
- [5] H. L. Royden and P. Fitzpatrick, *Real Analysis*, Pearson.
- [6] D. Williams, *Probability with Martingales*, Cambridge University Press.