

Homología persistente aplicada a datos actuariales

Una introducción rigurosa, con ejemplos y una lectura crítica

Julio César Galindo López

CONAC

Universidad Panamericana, Ciudad UP

9 de septiembre de 2026

Agenda

1. ¿Por qué topología en datos actuariales?
2. Fundamentos de homología persistente
3. Un ejemplo completo, calculado a mano
4. Diccionario actuarial-topológico
5. Caso de estudio: superficies de mortalidad
6. Caso de estudio: riesgo de mercado y de crédito
7. Un panorama honesto: qué existe y qué no
8. Herramientas y cómo empezar un piloto
9. Conclusiones

¿Por qué topología en datos actuariales?

- Los datos actuariales rara vez son una nube homogénea: hay **cohortes**, **regímenes**, **choques** (pandemias, crisis financieras, catástrofes) y **ciclos**.
- Los modelos habituales (GLM, Lee–Carter, cópulas, triángulos de reserva) suponen una forma funcional y luego prueban ajuste.
- La pregunta topológica es distinta: *¿qué forma tiene la nube de datos, y esa forma se mantiene al cambiar la escala de resolución con la que la miro?*
- Homología persistente da una respuesta **cuantificable** y **estable ante ruido** (más adelante, con teorema).

Lo que esto no es

No sustituye al modelado actuarial estándar. Es una herramienta exploratoria y de detección de estructura, complementaria al GLM, a Lee–Carter o al triángulo de reserva de siempre.

Un ejemplo para tener en mente

- Una superficie de mortalidad ($\text{edad} \times \text{año}$) tiene *forma*: las cohortes dejan diagonales, las pandemias dejan valles y picos.
- Un mercado en crisis tiene *forma*: co-movimientos que normalmente son “ruido” se organizan en *ciclos* antes de un colapso.
- En ambos casos, lo interesante no es un punto aislado sino una **estructura que persiste** en un rango de escalas.
- Ese es exactamente el objeto que la homología persistente está diseñada para medir.

Para medirlo con precisión necesitamos tres ingredientes: una nube de puntos, una escala que crece, y una noción de qué nace y qué muere en el camino.

Nubes de puntos y complejos simpliciales

Sea (X, d) un espacio métrico finito: $X = \{x_1, \dots, x_n\}$ (observaciones: pólizas, celdas edad-año, ventanas de tiempo, series).

Complejo de Vietoris–Rips, $VR_\varepsilon(X)$

Un subconjunto $\sigma = \{x_{i_0}, \dots, x_{i_k}\} \subseteq X$ es un símplex de $VR_\varepsilon(X)$ si y solo si $d(x_i, x_j) \leq \varepsilon$ para **todo par** $x_i, x_j \in \sigma$.

- Condición puramente *pareada*: fácil de calcular a partir de una sola matriz de distancias (o de disimilitud actuarial).
- Alternativa clásica: el **complejo de Čech**, que exige que las n bolas cerradas de radio $\varepsilon/2$ tengan intersección común no vacía. Por el lema del nervio (Borsuk), en $\mathbb{R}^m$ el complejo de Čech es homotópicamente equivalente a la unión de esas bolas.
- Cota clásica (Vietoris–Rips vs. Čech, de Silva–Ghrist):
 $\mathcal{C}ech_\varepsilon(X) \subseteq VR_\varepsilon(X) \subseteq \mathcal{C}ech_{\sqrt{2}\varepsilon}(X)$ en $\mathbb{R}^m$ euclidiano.

- Si $\varepsilon \leq \varepsilon'$ entonces $VR_\varepsilon(X) \subseteq VR_{\varepsilon'}(X)$: una familia **anidada** de complejos, la **filtración**.
- Para cada ε calculamos los grupos de homología simplicial $H_k(VR_\varepsilon(X); \mathbb{F})$ sobre un campo $\mathbb{F}$ (usualmente $\mathbb{F}_2$).
- Sus rangos son los **números de Betti** $\beta_k(\varepsilon)$:
 - β_0 : número de componentes conexas.
 - β_1 : número de ciclos independientes (“agujeros” 1D).
 - β_2 : número de cavidades 2D independientes.
- Las inclusiones inducen mapas lineales $H_k(VR_\varepsilon) \rightarrow H_k(VR_{\varepsilon'})$: esto es un **módulo de persistencia**.

Teorema de estructura (Zomorodian–Carlsson, 2005)

Sobre un campo, y para un complejo finito, todo módulo de persistencia se descompone como suma directa de **módulos de intervalo** $[b, d)$: cada uno es una clase de homología que *nace* en $\varepsilon = b$ y *muer*e en $\varepsilon = d$.

- El **código de barras** dibuja cada intervalo $[b, d)$ como una barra horizontal sobre el eje ε .
- El **diagrama de persistencia** Dgm_k dibuja cada intervalo como el punto (b, d) en el plano, con $b \leq d$.
- Puntos cerca de la diagonal $b = d$: nacen y mueren casi de inmediato $\Rightarrow$ ruido. Puntos lejos de la diagonal: rasgos **persistentes** $\Rightarrow$ estructura real.

Estabilidad: por qué esto sirve con datos ruidosos

Teorema de estabilidad (Cohen-Steiner–Edelsbrunner–Harer, 2007)

Si $f, g : X \rightarrow \mathbb{R}$ son funciones *tame* sobre un mismo espacio (p.ej. dos filtraciones comparables), entonces

$$d_B(\mathrm{Dgm}(f), \mathrm{Dgm}(g)) \leq \|f - g\|_\infty,$$

donde d_B es la **distancia bottleneck** entre diagramas.



- Versión para nubes de puntos (Chazal–Cohen-Steiner–Guibas–Mémoli–Oudot, 2009): si dos nubes están cerca en distancia de Gromov–Hausdorff, sus diagramas están cerca en d_B .
- **Consecuencia actuarial:** una perturbación pequeña de los datos (ruido de medición, redondeo, un año atípico) no puede mover mucho un rasgo topológico verdaderamente persistente.

Con esa garantía en mano, veamos el mecanismo completo en un ejemplo pequeño que se puede verificar a mano.

Un ejemplo completo, calculado a mano

Seis puntos en un hexágono regular de radio 2 (ángulos $0^\circ, 60^\circ, \dots, 300^\circ$). Distancias posibles entre pares:

- vecinos adyacentes (60°): $d = 2$
- salto uno (120°): $d = 2\sqrt{3} \approx 3,46$
- opuestos (180°): $d = 4$



$\varepsilon = 2$: hexágono, $\beta_1 = 1$ $\varepsilon \geq 4$: símlice completo, contraíble

Los tres umbrales exactos


Por la simetría del hexágono, las tres distancias son también los tres *umbrales de la filtración*:

- $\varepsilon < 2$: solo vértices sueltos. $\beta_0 = 6$, todo lo demás 0.
- $\varepsilon = 2$: aparecen las 6 aristas del hexágono a la vez. β_0 baja de 6 a 1; nace **un** ciclo, $\beta_1 = 1$.
- $\varepsilon = 2\sqrt{3} \approx 3,46$: aparecen las 6 aristas “salto uno” **y** 8 triángulos a la vez. El complejo es combinatoriamente la frontera de un octaedro ($\simeq S^2$): el ciclo 1D **muere** ($\beta_1 = 0$) pero nace una cavidad 2D ($\beta_2 = 1$).
- $\varepsilon = 4$: aparecen las 3 aristas opuestas; el complejo es el símplex completo en 6 vértices (contraíble). β_2 muere.

Nota de cautela

A escala intermedia nace una cavidad 2D que **no corresponde a ninguna estructura real**: es un artefacto de muestrear un círculo con puntos regularmente espaciados. Con estacionalidad (mortalidad anual, siniestros estacionales) puede aparecer un efecto análogo, y **debe contrastarse contra un modelo nulo** antes de interpretarse.

El mismo ejemplo: código de barras y diagrama



código de barras




diagrama de persistencia

Ambos puntos H_1 y H_2 están lejos de la diagonal: en este ejemplo *ambos* son “persistentes”, aunque ya vimos que uno de los dos (H_2) es un artefacto de muestreo — la persistencia mide duración en la escala, no “realidad”. Ese vocabulario es el que ahora traducimos al lenguaje del actuario.

Diccionario actuarial–topológico

Objeto topológico	Lectura actuarial
Punto de la nube	Observación: póliza, celda edad–año, ventana temporal
Métrica d	Disimilitud actuarial: Mahalanobis, 1–correlación, distancia en log-retornos
Componente conexa (β_0)	Segmento o subpoblación homogénea
Ciclo 1D (β_1)	Régimen cíclico, recurrencia, co-movimiento antes de un choque
Persistencia (longitud de barra)	Robustez de la estructura frente a la escala de agregación
Cerca de la diagonal	Ruido de muestreo, no evidencia de estructura

Veamos este diccionario funcionando en dos terrenos donde ya hay literatura publicada: mortalidad y mercados financieros.

Caso de estudio: superficies de mortalidad

- Existe trabajo publicado reciente que aplica homología persistente y el algoritmo **Mapper** a datos semanales de mortalidad de los CDC (EE. UU.), de enero de 2020 a septiembre de 2023, para estudiar la pandemia de COVID-19 (*Topological Data Analysis of Mortality Patterns During the COVID-19 Pandemic*, arXiv:2510.15066, 2025).
- La idea metodológica común (compartida con el caso financiero que sigue): construir una nube de puntos vía **embedding de retraso** (Takens) de la serie de mortalidad, y seguir su diagrama de persistencia ventana por ventana en el tiempo.
- Lectura para nuestra práctica: un cambio topológico persistente (aparición de un ciclo, cambio brusco en el diagrama) es candidato a señal de **cambio de régimen de mortalidad**, en el mismo espíritu que Lee–Carter detecta cambios de tendencia, pero sin suponer de entrada una forma funcional.

Honestidad metodológica

Esta es un área de investigación activa. No es (todavía) un método estándar de la práctica biométrica actuarial.

Gidea–Katz (2018), *Physica A*, arXiv:1703.04385

Con ventanas deslizantes sobre los log-retornos diarios de cuatro índices (S&P 500, DJIA, NASDAQ, Russell 2000), construyen una nube de puntos por ventana y calculan su **paisaje de persistencia** (Bubenik, 2015).

- Hallazgo: la norma L^p del paisaje de persistencia muestra un **ascenso sostenido** en los ~ 250 días de bolsa previos a la quiebra de Lehman Brothers (2008).
- Lectura actuarial: relevante para pruebas de estrés y gestión de riesgo de mercado en reservas ligadas a inversión (seguros de vida con componente de inversión, *unit-linked*), donde el interés no es predecir el nivel del mercado sino detectar un cambio de *régimen* en su estructura de co-movimiento.

Caso de estudio: riesgo de crédito

- Trabajo exploratorio de Oxford (*Topological Analysis of Credit Data: Preliminary Findings*) usa homología persistente para describir la estructura de similitud entre deudores en datos de crédito.
- Es, como dice su propio título, un resultado **preliminar**: no un método ya validado en producción.
- Relevancia para el actuario de fianzas o de riesgo de crédito de cartera de inversión: una alternativa exploratoria a la segmentación por *scoring* tradicional, útil para **detectar subgrupos** que la segmentación lineal no separa.

Estos tres casos son reales, pero no agotan el mapa. Falta decir, con la misma honestidad, dónde termina lo publicado y dónde empieza el terreno abierto.

Un panorama honesto: qué existe y qué no

Ya hay literatura

- Mortalidad y COVID-19
- Crisis de mercado (Gidea–Katz)
- Similitud de crédito (exploratorio)
- Reclamaciones de salud negadas indebidamente, vía Mapper (mencionado en revisiones del algoritmo Mapper, arXiv:2504.09042)

Todavía abierto

- Reservas de siniestros (*loss reserving*) vía homología persistente: no encontré literatura arbitrada específica.
- Detección de fraude en seguros de daños o de vida por esta vía: igual, dirección abierta, no método establecido.

Un hueco en la literatura no es una debilidad del método: es, más bien, la lista de proyectos piloto que todavía nadie ha corrido.

- **Costo computacional:** el número de símlices de VR_ε crece exponencialmente con el tamaño de la nube y con ε ; en la práctica se trunca la dimensión homológica calculada (usualmente H_0, H_1, H_2).
- **Elección de métrica:** la distancia actuarial correcta (Mahalanobis, correlación, alguna cópula) no es única y cambia el diagrama resultante.
- **Artefactos de muestreo:** ya lo vimos en el ejemplo del hexágono — una cavidad “fantasma” puede nacer solo por la geometría del muestreo, no por señal real.
- **Interpretabilidad regulatoria:** ante un regulador (CNSF, Solvencia II), un diagrama de persistencia por sí solo no es una explicación; hay que traducirlo a una covariable o una prueba de hipótesis explícita.

Ninguno de estos retos es motivo para no empezar: son, más bien, la lista de precauciones para el primer piloto.

Herramientas y cómo empezar un piloto

Software

- R: paquetes TDA (Fasy et al.) y TDAstats.
- Python: `ripser.py`, GUDHI, `giotto-tda`.

Flujo sugerido para un piloto

1. Elegir la variable y la métrica de disimilitud actuarial.
2. Construir la nube de puntos (observaciones directas, o embedding de retraso si es serie de tiempo).
3. Calcular el diagrama de persistencia (H_0 , H_1 , quizá H_2).
4. Comparar contra una nube nula (permutación o *bootstrap*) para descartar artefactos como el del hexágono.
5. Vectorizar los rasgos robustos (paisajes de persistencia) y usarlos como covariable dentro de un GLM o un modelo de aprendizaje supervisado ya establecido.

Conclusiones

- La homología persistente no reemplaza el arsenal actuarial: le añade un lente sobre la **forma global** de los datos.
- Viene con una garantía matemática poco común en herramientas exploratorias: el **teorema de estabilidad**.
- Ya existe evidencia publicada en mortalidad y en riesgo de mercado; en reservas y fraude, el terreno está abierto.
- El paso natural siguiente no es “sustituir” nada, sino correr un piloto acotado, contrastado contra un modelo nulo, sobre una pregunta actuarial concreta.

Gracias.

Referencias (I)

- Carlsson, G. (2009). Topology and data. *Bull. Amer. Math. Soc.*, 46(2), 255–308.
- Zomorodian, A., Carlsson, G. (2005). Computing persistent homology. *Discrete Comput. Geom.*, 33(2), 249–274.
- Cohen-Steiner, D., Edelsbrunner, H., Harer, J. (2007). Stability of persistence diagrams. *Discrete Comput. Geom.*, 37(1), 103–120.
- Chazal, F., Cohen-Steiner, D., Guibas, L., Méholi, F., Oudot, S. (2009). Gromov–Hausdorff stable signatures for shapes using persistence. *Comput. Graph. Forum*, 28(5), 1393–1403.
- Ghrist, R. (2008). Barcodes: The persistent topology of data. *Bull. Amer. Math. Soc.*, 45(1), 61–75.
- Bubenik, P. (2015). Statistical topological data analysis using persistence landscapes. *J. Mach. Learn. Res.*, 16(1), 77–102.
- Edelsbrunner, H., Harer, J. (2010). *Computational Topology: An Introduction*. AMS.

Referencias (II)

- Gidea, M., Katz, Y. (2018). Topological data analysis of financial time series: Landscapes of crashes. *Physica A*, 491, 820–834. arXiv:1703.04385.
- Topological Data Analysis of Mortality Patterns During the COVID-19 Pandemic. arXiv:2510.15066 (2025).
- Topological Analysis of Credit Data: Preliminary Findings. University of Oxford (working paper).
- A Comprehensive Review of the Mapper Algorithm, a Topological Data Analysis Technique, and Its Applications Across Various Fields (2007–2025). arXiv:2504.09042.
- Chazal, F., Michel, B. (2021). An introduction to topological data analysis: fundamental and practical aspects for data scientists. *Front. Artif. Intell.*, 4, 667963.