

Fundamentos de Econometría

Suma de variables aleatorias, varianza, covarianza,
y la deducción de los estimadores de MCO

César Galindo

Universidad Panamericana · Licenciatura en Finanzas · ECO515

Otoño 2026

Idea central

Este documento es material complementario al Tema 2 del syllabus (Introducción al Modelo de Regresión Lineal): repasa, con demostraciones completas, las propiedades del valor esperado y la varianza de sumas de variables aleatorias, la covarianza y sus propiedades algebraicas, y usa exactamente esas herramientas –nada más– para deducir, desde cero, las fórmulas cerradas de los estimadores de Mínimos Cuadrados Ordinarios $\hat{\beta}_0$ y $\hat{\beta}_1$ en la regresión lineal simple. Incluye un ejemplo numérico completo y ejercicios resueltos y propuestos en cada sección.

Índice

1. Suma de variables aleatorias	2
1.1. Valor esperado y linealidad	2
1.2. Ejemplo: rendimiento de un portafolio	3
1.3. Ejercicios	4
2. Varianza y covarianza	4
2.1. Definiciones y primeras propiedades	4
2.2. Varianza de una suma: el teorema clave	6
2.3. Correlación y la desigualdad de Cauchy–Schwarz	7
2.4. Ejemplo: varianza de un portafolio de dos activos	7
2.5. Ejercicios	8
3. Regresión lineal simple: deducción de MCO	9

3.1. Planteamiento	9
3.2. Condiciones de primer orden	9
3.3. Fórmulas cerradas: dónde entran la varianza y la covarianza	10
3.4. Condición de segundo orden	11
3.5. Consecuencias algebraicas inmediatas	11
3.6. Ejemplo numérico completo	12
3.7. Ejercicios	12

1. Suma de variables aleatorias

1.1. Valor esperado y linealidad

Todo lo que sigue –varianza, covarianza, y a la postre MCO– descansa en una sola propiedad del valor esperado: es un operador *lineal*. Esto es tan simple que suele pasarse por alto, pero es, literalmente, el único ingrediente algebraico detrás de la fórmula de la pendiente de MCO que deduciremos en la Sección 3.

Definición 1.1 (Valor esperado). Si X es una variable aleatoria discreta con valores $x_1, \dots, x_k$ y probabilidades $p_1, \dots, p_k$, su *valor esperado* es

$$\mathbb{E}[X] = \sum_{j=1}^k x_j p_j.$$

(Si X es continua con densidad f_X , se reemplaza la suma por $\int x f_X(x) dx$; todas las propiedades de esta sección valen igual en ambos casos, porque tanto la suma como la integral son operadores lineales.)

Proposición 1.2 (Linealidad del valor esperado). Para variables aleatorias X, Y y constantes $a, b, c \in \mathbb{R}$,

$$\mathbb{E}[aX + bY + c] = a \mathbb{E}[X] + b \mathbb{E}[Y] + c.$$

Demostración. Basta probarlo para el caso discreto conjunto: si (X, Y) toma el valor

(x_i, y_j) con probabilidad p_{ij} , entonces

$$\begin{aligned}
 \mathbb{E}[aX + bY + c] &= \sum_i \sum_j (ax_i + by_j + c) p_{ij} \\
 &= a \sum_i \sum_j x_i p_{ij} + b \sum_i \sum_j y_j p_{ij} + c \sum_i \sum_j p_{ij} \\
 &= a \sum_i x_i \left(\sum_j p_{ij} \right) + b \sum_j y_j \left(\sum_i p_{ij} \right) + c \cdot 1 \\
 &= a \sum_i x_i p_i + b \sum_j y_j p_j + c = a \mathbb{E}[X] + b \mathbb{E}[Y] + c,
 \end{aligned}$$

donde $p_i = \sum_j p_{ij}$ y $p_j = \sum_i p_{ij}$ son las marginales de X y Y , y usamos que $\sum_i \sum_j p_{ij} = 1$. El paso decisivo es puramente algebraico: reagrupar una suma doble en dos sumas simples, sin usar en ningún momento que X y Y sean independientes. La linealidad de $\mathbb{E}$ no requiere independencia. $\square$

Corolario 1.3. Para $X_1, \dots, X_n$ variables aleatorias cualesquiera y constantes $a_1, \dots, a_n, c$,

$$\mathbb{E} \left[\sum_{i=1}^n a_i X_i + c \right] = \sum_{i=1}^n a_i \mathbb{E}[X_i] + c.$$

Demostración. Inducción en n sobre la Proposición 1.2: el caso $n = 2$ (con $c = 0$) es exactamente la proposición; si vale para $n - 1$ términos, se aplica la proposición una vez más a $(\sum_{i=1}^{n-1} a_i X_i) + a_n X_n$ para obtener el caso n . $\square$

Error frecuente

La linealidad de $\mathbb{E}$ es **gratuita**: vale siempre, sin importar si X y Y están correlacionadas, son independientes o no. Lo que **sí** depende de la relación entre X y Y es la varianza de la suma, que se estudia en la Sección 2.

1.2. Ejemplo: rendimiento de un portafolio

Ejemplo 1.4 (Rendimiento esperado de un portafolio). Un portafolio invierte una fracción w de la riqueza en un activo con rendimiento aleatorio R_1 y el resto, $1 - w$, en un activo con rendimiento R_2 . El rendimiento del portafolio es la variable aleatoria

$$R_p = wR_1 + (1 - w)R_2.$$

Por la Proposición 1.2 (con $a = w$, $b = 1 - w$, $c = 0$),

$$\mathbb{E}[R_p] = w \mathbb{E}[R_1] + (1 - w) \mathbb{E}[R_2],$$

es decir, el rendimiento *esperado* del portafolio es simplemente el promedio ponderado de los rendimientos esperados individuales –sin importar qué tan correlacionados estén R_1

y R_2 . Esa independencia respecto a la correlación se pierde en cuanto se pregunta por el *riesgo* (la varianza) del portafolio: véase el Ejemplo 2.9.

1.3. Ejercicios

Ejercicio 1.5. Sea X el número de clientes que llegan a una sucursal bancaria en una hora, con $\mathbb{E}[X] = 40$. Si cada cliente deja, en promedio, un depósito de \$3,000, y el banco cobra una comisión fija de \$500 por sucursal independientemente del número de clientes, escriba el ingreso total I como función lineal de X y calcule $\mathbb{E}[I]$.

Solución. Si cada cliente deposita en promedio \$3,000 y el banco cobra γ por depósito (supóngase una comisión de 1 % sobre cada depósito promedio, es decir \$30 por cliente, más el cargo fijo), un modelo lineal razonable es $I = 30X + 500$. Entonces, por la Proposición 1.2, $\mathbb{E}[I] = 30 \mathbb{E}[X] + 500 = 30(40) + 500 = \$1,700$. (La respuesta numérica depende de los supuestos sobre la comisión; lo que importa es identificar I como *afín* en X y aplicar linealidad, no una fórmula memorizada.) $\square$

Ejercicio 1.6. Un portafolio de tres activos tiene pesos w_1, w_2, w_3 con $w_1 + w_2 + w_3 = 1$ y rendimientos esperados $\mathbb{E}[R_1] = 8\%$, $\mathbb{E}[R_2] = 12\%$, $\mathbb{E}[R_3] = 5\%$. Si $w_1 = 0.5$, $w_2 = 0.3$, calcule w_3 y $\mathbb{E}[R_p]$.

Solución. $w_3 = 1 - 0.5 - 0.3 = 0.2$. Por el Corolario 1.3,

$$\mathbb{E}[R_p] = 0.5(8\%) + 0.3(12\%) + 0.2(5\%) = 4\% + 3.6\% + 1\% = 8.6\%.$$

$\square$

Ejercicio 1.7. Demuestre, usando sólo la Proposición 1.2 (no la definición de varianza), que si $Y = a + bX$ con $b \neq 0$, entonces $\mathbb{E}[X] = \frac{\mathbb{E}[Y] - a}{b}$.

Ejercicio 1.8 (Propuesto). Un fondo cobra una comisión de administración del 1.5 % anual sobre el valor final del portafolio, más una comisión fija de \$200. Si V es el valor final del portafolio (aleatorio) y $\mathbb{E}[V] = \$120,000$, escriba la comisión total C como función afín de V y calcule $\mathbb{E}[C]$.

2. Varianza y covarianza

2.1. Definiciones y primeras propiedades

La varianza mide qué tan lejos, en promedio al cuadrado, se dispersa una variable aleatoria respecto a su media. La covarianza extiende esa idea a *dos* variables: mide si se mueven juntas o en direcciones opuestas.

Definición 2.1 (Varianza). La *varianza* de una variable aleatoria X es

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2].$$

La *desviación estándar* es $\sigma_X = \sqrt{\text{Var}(X)}$.

Definición 2.2 (Covarianza). La *covarianza* entre X y Y es

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

Nótese que $\text{Cov}(X, X) = \text{Var}(X)$: la varianza es un caso particular de la covarianza.

Proposición 2.3 (Fórmulas de cómputo).

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2, \quad \text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

Demostración. Sea $\mu_X = \mathbb{E}[X]$, $\mu_Y = \mathbb{E}[Y]$ (constantes, no aleatorias). Expandiendo el cuadrado y usando linealidad (Proposición 1.2) con μ_X tratada como constante:

$$\begin{aligned} \text{Var}(X) &= \mathbb{E}[(X - \mu_X)^2] = \mathbb{E}[X^2 - 2\mu_X X + \mu_X^2] \\ &= \mathbb{E}[X^2] - 2\mu_X \mathbb{E}[X] + \mu_X^2 = \mathbb{E}[X^2] - 2\mu_X^2 + \mu_X^2 = \mathbb{E}[X^2] - \mu_X^2. \end{aligned}$$

Para la covarianza, el mismo argumento con dos variables:

$$\begin{aligned} \text{Cov}(X, Y) &= \mathbb{E}[(X - \mu_X)(Y - \mu_Y)] = \mathbb{E}[XY - \mu_X Y - \mu_Y X + \mu_X \mu_Y] \\ &= \mathbb{E}[XY] - \mu_X \mathbb{E}[Y] - \mu_Y \mathbb{E}[X] + \mu_X \mu_Y \\ &= \mathbb{E}[XY] - \mu_X \mu_Y - \mu_Y \mu_X + \mu_X \mu_Y = \mathbb{E}[XY] - \mu_X \mu_Y. \end{aligned} \quad \square$$

Proposición 2.4 (Bilinealidad de la covarianza). Para constantes a, b, c, d y variables aleatorias X, Y, Z, W :

- (I) $\text{Cov}(X, Y) = \text{Cov}(Y, X)$ (*simetría*);
- (II) $\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y)$;
- (III) $\text{Cov}(X + Z, Y) = \text{Cov}(X, Y) + \text{Cov}(Z, Y)$ (*aditividad*).

Demostración. (i) es inmediata de la definición: el producto $(X - \mu_X)(Y - \mu_Y)$ es simétrico en X, Y . Para (ii), $aX + b$ tiene media $a\mu_X + b$, así que $(aX + b) - (a\mu_X + b) = a(X - \mu_X)$; análogamente para $cY + d$. Entonces

$$\text{Cov}(aX + b, cY + d) = \mathbb{E}[a(X - \mu_X) \cdot c(Y - \mu_Y)] = ac \mathbb{E}[(X - \mu_X)(Y - \mu_Y)] = ac \text{Cov}(X, Y),$$

usando linealidad de $\mathbb{E}$ para sacar la constante ac . Para (iii), sea $\mu_Z = \mathbb{E}[Z]$; entonces $(X + Z) - (\mu_X + \mu_Z) = (X - \mu_X) + (Z - \mu_Z)$, y

$$\begin{aligned} \text{Cov}(X + Z, Y) &= \mathbb{E}[(X - \mu_X + Z - \mu_Z)(Y - \mu_Y)] \\ &= \mathbb{E}[(X - \mu_X)(Y - \mu_Y)] + \mathbb{E}[(Z - \mu_Z)(Y - \mu_Y)] = \text{Cov}(X, Y) + \text{Cov}(Z, Y), \end{aligned}$$

de nuevo por linealidad de $\mathbb{E}$ aplicada a la suma de dos productos. $\square$

2.2. Varianza de una suma: el teorema clave

Teorema 2.5 (Varianza de una combinación lineal). *Para variables aleatorias X, Y y constantes a, b ,*

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y).$$

En particular, si X y Y son independientes (o simplemente $\text{Cov}(X, Y) = 0$, condición más débil llamada incorrelación),

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y).$$

Demostración. Como $\text{Var}(Z) = \text{Cov}(Z, Z)$ para cualquier Z , y por bilinealidad (Proposición 2.4, aplicando (ii)–(iii) dos veces):

$$\begin{aligned} \text{Var}(aX + bY) &= \text{Cov}(aX + bY, aX + bY) \\ &= \text{Cov}(aX, aX) + \text{Cov}(aX, bY) + \text{Cov}(bY, aX) + \text{Cov}(bY, bY) \\ &= a^2 \text{Cov}(X, X) + ab \text{Cov}(X, Y) + ab \text{Cov}(Y, X) + b^2 \text{Cov}(Y, Y) \\ &= a^2 \text{Var}(X) + 2ab \text{Cov}(X, Y) + b^2 \text{Var}(Y), \end{aligned}$$

donde en el último paso usamos $\text{Cov}(X, Y) = \text{Cov}(Y, X)$. El caso independiente se sigue de que la independencia implica $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$ y, por la Proposición 2.3, $\text{Cov}(X, Y) = 0$. $\square$

Error frecuente

El error más común en este punto es tratar Var como si fuera lineal, escribiendo $\text{Var}(aX + bY) = a \text{Var}(X) + b \text{Var}(Y)$. Eso es **falso** en general: la varianza es *cuadrática*, no lineal, y aparece un término cruzado de covarianza a menos que X y Y sean incorrelacionadas. Contraste esto con la Proposición 1.2: el valor esperado *sí* es lineal siempre; la varianza no.

Corolario 2.6 (Caso general de n variables). *Para $X_1, \dots, X_n$ y constantes $a_1, \dots, a_n$,*

$$\text{Var}\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i^2 \text{Var}(X_i) + 2 \sum_{i < j} a_i a_j \text{Cov}(X_i, X_j).$$

Demostración. Igual que en el Teorema 2.5, expandiendo $\text{Cov}(\sum_i a_i X_i, \sum_j a_j X_j)$ por bilinealidad en las n^2 parejas (i, j) , separando los n términos diagonales ($i = j$, que dan $a_i^2 \text{Var}(X_i)$) de los $n^2 - n$ términos fuera de la diagonal, que se agrupan por pares (i, j) y (j, i) –iguales entre sí por simetría– en $2 \sum_{i < j} a_i a_j \text{Cov}(X_i, X_j)$. $\square$

2.3. Correlación y la desigualdad de Cauchy–Schwarz

La covarianza tiene un defecto práctico: su magnitud depende de las unidades de X y Y (si X se mide en pesos en vez de miles de pesos, $\text{Cov}(X, Y)$ se multiplica por mil). El *coeficiente de correlación* corrige esto.

Definición 2.7 (Correlación).

$$\text{Corr}(X, Y) = \rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}, \quad \sigma_X, \sigma_Y > 0.$$

Proposición 2.8 ($|\rho_{XY}| \leq 1$). Para cualesquiera X, Y con varianza finita positiva, $-1 \leq \rho_{XY} \leq 1$.

Demostración. Para todo $t \in \mathbb{R}$, por el Teorema 2.5 (con $a = 1$, $b = -t$),

$$0 \leq \text{Var}(X - tY) = \text{Var}(X) - 2t \text{Cov}(X, Y) + t^2 \text{Var}(Y) =: g(t),$$

usando que la varianza de cualquier variable aleatoria es no negativa. $g(t)$ es un polinomio cuadrático en t con coeficiente principal $\text{Var}(Y) > 0$ que nunca es negativo; por lo tanto su discriminante no puede ser positivo (si lo fuera, g tendría dos raíces reales distintas y sería negativo entre ellas). Así,

$$(2 \text{Cov}(X, Y))^2 - 4 \text{Var}(X) \text{Var}(Y) \leq 0 \implies \text{Cov}(X, Y)^2 \leq \text{Var}(X) \text{Var}(Y).$$

Dividiendo entre $\sigma_X^2 \sigma_Y^2 > 0$ y tomando raíz cuadrada, $|\rho_{XY}| \leq 1$. □

Qué conviene recordar

Esta demostración –minimizar $\text{Var}(X - tY)$ sobre t y usar que un discriminante no positivo– es *exactamente* el mismo tipo de argumento de optimización cuadrática que usaremos en la Sección 3 para deducir $\hat{\beta}_1$: en ambos casos se trata de encontrar el mínimo de una parábola. La desigualdad de Cauchy–Schwarz y la regresión de MCO no son temas separados; son la misma estructura algebraica aplicada dos veces.

2.4. Ejemplo: varianza de un portafolio de dos activos

Ejemplo 2.9 (Riesgo de un portafolio). Retomando el Ejemplo 1.4, $R_p = wR_1 + (1 - w)R_2$. Por el Teorema 2.5 con $a = w$, $b = 1 - w$,

$$\text{Var}(R_p) = w^2 \text{Var}(R_1) + (1 - w)^2 \text{Var}(R_2) + 2w(1 - w) \text{Cov}(R_1, R_2).$$

A diferencia del rendimiento esperado (Ejemplo 1.4), el **riesgo** del portafolio sí depende crucialmente de $\text{Cov}(R_1, R_2)$: si $\text{Cov}(R_1, R_2) < 0$ (activos que se mueven en direcciones opuestas), el tercer término resta y el portafolio puede tener *menor* varianza que cualquiera

de los dos activos por separado –el principio matemático detrás de la diversificación (Markowitz, 1952).

Con $\sigma_1^2 = 0.04$, $\sigma_2^2 = 0.09$, $\text{Cov}(R_1, R_2) = -0.01$ y $w = 0.5$:

$$\text{Var}(R_p) = 0.25(0.04) + 0.25(0.09) + 2(0.5)(0.5)(-0.01) = 0.01 + 0.0225 - 0.005 = 0.0275,$$

es decir $\sigma_p \approx 16.58\%$, *menor* que $\sigma_2 = 30\%$ y más cercano a $\sigma_1 = 20\%$: diversificar con un activo negativamente correlacionado reduce el riesgo del portafolio por debajo del riesgo del activo más volátil.

2.5. Ejercicios

Ejercicio 2.10. Si X y Y son independientes con $\text{Var}(X) = 4$ y $\text{Var}(Y) = 9$, calcule $\text{Var}(2X - 3Y)$.

Solución. Por independencia, $\text{Cov}(X, Y) = 0$, así que por el Teorema 2.5, $\text{Var}(2X - 3Y) = 4 \text{Var}(X) + 9 \text{Var}(Y) = 4(4) + 9(9) = 16 + 81 = 97$. $\square$

Ejercicio 2.11. Demuestre que $\text{Var}(X - Y) = \text{Var}(X) + \text{Var}(Y) - 2 \text{Cov}(X, Y)$, y úselo para explicar por qué, si X y Y están *muy* correlacionadas positivamente (con varianzas parecidas), la diferencia $X - Y$ puede tener varianza mucho menor que X o Y por separado. (Esta es la lógica detrás de una estrategia de *pairs trading* sobre dos activos cointegrados.)

Solución. Del Teorema 2.5 con $a = 1$, $b = -1$: $\text{Var}(X - Y) = \text{Var}(X) + \text{Var}(Y) - 2 \text{Cov}(X, Y)$. Si $\text{Var}(X) \approx \text{Var}(Y) = \sigma^2$ y $\rho_{XY} \rightarrow 1$ (de modo que $\text{Cov}(X, Y) \rightarrow \sigma^2$), entonces $\text{Var}(X - Y) \rightarrow 2\sigma^2 - 2\sigma^2 = 0$: el spread $X - Y$ se vuelve casi constante, precisamente el comportamiento que una estrategia de arbitraje estadístico busca explotar. $\square$

Ejercicio 2.12. Con los datos del Ejemplo 2.9 ($\sigma_1^2 = 0.04$, $\sigma_2^2 = 0.09$, $\text{Cov}(R_1, R_2) = -0.01$), encuentre el peso w^* que *minimiza* $\text{Var}(R_p)$. (Sugerencia: derive la expresión de $\text{Var}(R_p)$ del Ejemplo 2.9 respecto a w e iguale a cero; el mismo procedimiento de primer orden que se usa en la Sección 3.)

Solución. $\text{Var}(R_p) = w^2\sigma_1^2 + (1 - w)^2\sigma_2^2 + 2w(1 - w) \text{Cov}(R_1, R_2)$. Derivando respecto a w e igualando a cero:

$$2w\sigma_1^2 - 2(1 - w)\sigma_2^2 + 2(1 - 2w) \text{Cov}(R_1, R_2) = 0 \implies w^* = \frac{\sigma_2^2 - \text{Cov}(R_1, R_2)}{\sigma_1^2 + \sigma_2^2 - 2 \text{Cov}(R_1, R_2)}.$$

$$\text{Sustituyendo: } w^* = \frac{0.09 - (-0.01)}{0.04 + 0.09 - 2(-0.01)} = \frac{0.10}{0.15} = \frac{2}{3} \approx 0.667. \quad \square$$

Ejercicio 2.13 (Propuesto). Pruebe que $\text{Cov}(X, Y)^2 \leq \text{Var}(X) \text{Var}(Y)$ es equivalente a decir que la matriz de varianzas y covarianzas $\begin{pmatrix} \text{Var}(X) & \text{Cov}(X, Y) \\ \text{Cov}(X, Y) & \text{Var}(Y) \end{pmatrix}$ tiene determinante no negativo. ¿Qué le dice esto sobre la matriz de varianzas y covarianzas de un vector de rendimientos de n activos?

3. Regresión lineal simple: deducción de MCO

3.1. Planteamiento

Considérese una muestra de n observaciones $(x_1, y_1), \dots, (x_n, y_n)$ –por ejemplo, x_i el rendimiento de un índice de mercado y y_i el rendimiento de un activo individual– y el modelo de regresión lineal simple

$$y_i = \beta_0 + \beta_1 x_i + u_i, \quad i = 1, \dots, n,$$

donde β_0, β_1 son parámetros poblacionales desconocidos y u_i es el término de error. El método de **Mínimos Cuadrados Ordinarios** (MCO), propuesto por Legendre (1805) y Gauss (1809) –de forma independiente, en el contexto de ajustar órbitas planetarias a observaciones astronómicas con error– elige, de entre todas las rectas posibles, la que minimiza la suma de los cuadrados de las distancias verticales entre los puntos observados y_i y la recta ajustada.

Definición 3.1 (Función de regresión muestral y residual). Dados candidatos b_0, b_1 , la *función de regresión muestral* es $\hat{y}_i = b_0 + b_1 x_i$, y el *residual* de la observación i es

$$\hat{u}_i(b_0, b_1) = y_i - \hat{y}_i = y_i - b_0 - b_1 x_i.$$

Definición 3.2 (Suma de cuadrados residuales).

$$\text{SCR}(b_0, b_1) = \sum_{i=1}^n \hat{u}_i(b_0, b_1)^2 = \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2.$$

Los estimadores de MCO son $(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{b_0, b_1} \text{SCR}(b_0, b_1)$.

3.2. Condiciones de primer orden

Teorema 3.3 (Ecuaciones normales). Si $(\hat{\beta}_0, \hat{\beta}_1)$ minimiza SCR, entonces satisface el sistema (ecuaciones normales)

$$\sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0, \quad \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0.$$

Demostración. SCR es una función diferenciable de $(b_0, b_1) \in \mathbb{R}^2$; en un mínimo, sus

derivadas parciales se anulan. Derivando bajo el signo de suma (una suma finita, así que esto es válido sin condiciones adicionales):

$$\frac{\partial \text{SCR}}{\partial b_0} = \sum_{i=1}^n 2(y_i - b_0 - b_1 x_i)(-1) = -2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i),$$

$$\frac{\partial \text{SCR}}{\partial b_1} = \sum_{i=1}^n 2(y_i - b_0 - b_1 x_i)(-x_i) = -2 \sum_{i=1}^n x_i (y_i - b_0 - b_1 x_i).$$

Igualando ambas a cero en $(b_0, b_1) = (\hat{\beta}_0, \hat{\beta}_1)$ y dividiendo entre -2 se obtienen las dos ecuaciones del enunciado. $\square$

Qué conviene recordar

La primera ecuación normal dice, en palabras: *los residuales suman cero*, $\sum_i \hat{u}_i = 0$. La segunda dice: *los residuales no están correlacionados (en la muestra) con el regresor*, $\sum_i x_i \hat{u}_i = 0$. Ambas son, literalmente, la definición de “ajustar lo mejor posible” bajo el criterio de mínimos cuadrados –no supuestos adicionales, sino consecuencias directas de la Proposición del cálculo diferencial: en un mínimo, el gradiente es cero.

3.3. Fórmulas cerradas: dónde entran la varianza y la covarianza

Teorema 3.4 (Estimadores de MCO). Si $\sum_i (x_i - \bar{x})^2 > 0$ (es decir, x_i no es constante), las ecuaciones normales tienen solución única

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x},$$

donde $\bar{x} = \frac{1}{n} \sum_i x_i$, $\bar{y} = \frac{1}{n} \sum_i y_i$, y S_{xy}, S_{xx} son la covarianza y la varianza muestrales (sin dividir entre n) definidas exactamente como en la Sección 2.

Demostración. De la primera ecuación normal, $\sum_i y_i - n\hat{\beta}_0 - \hat{\beta}_1 \sum_i x_i = 0$; dividiendo entre n y usando $\bar{x} = \frac{1}{n} \sum_i x_i$, $\bar{y} = \frac{1}{n} \sum_i y_i$:

$$\bar{y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{x} = 0 \implies \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}. \quad (*)$$

Esto ya prueba la fórmula de $\hat{\beta}_0$ en términos de $\hat{\beta}_1$. Para $\hat{\beta}_1$, sustituimos $(*)$ en la segunda ecuación normal:

$$\sum_i x_i (y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) - \hat{\beta}_1 x_i) = 0 \implies \sum_i x_i ((y_i - \bar{y}) - \hat{\beta}_1 (x_i - \bar{x})) = 0,$$

es decir $\sum_i x_i (y_i - \bar{y}) = \hat{\beta}_1 \sum_i x_i (x_i - \bar{x})$. Ahora se usa un truco algebraico estándar: para cualquier constante c , $\sum_i (x_i - c)(x_i - \bar{x})$ no cambia si se reemplaza x_i por $x_i - \bar{x}$ dentro del primer factor cuando $c = \bar{x}$, porque $\sum_i \bar{x}(x_i - \bar{x}) = \bar{x} \sum_i (x_i - \bar{x}) = 0$ (la suma de desviaciones respecto a la media es siempre cero). Aplicando esto dos veces –una a x_i y

otra a y_i^- ,

$$\sum_i x_i(y_i - \bar{y}) = \sum_i (x_i - \bar{x})(y_i - \bar{y}) = S_{xy}, \quad \sum_i x_i(x_i - \bar{x}) = \sum_i (x_i - \bar{x})^2 = S_{xx},$$

porque en ambos casos restar $\bar{x}$ (o $\bar{y}$) del factor que ya tiene $(x_i - \bar{x})$ (o $(y_i - \bar{y})$) sólo resta un término que suma cero sobre i . Por lo tanto $S_{xy} = \hat{\beta}_1 S_{xx}$, y como $S_{xx} = \sum_i (x_i - \bar{x})^2 > 0$ por hipótesis, se despeja $\hat{\beta}_1 = S_{xy}/S_{xx}$, que junto con (*) da el resultado. $\square$

Qué conviene recordar

La fórmula $\hat{\beta}_1 = S_{xy}/S_{xx}$ es *exactamente* la covarianza muestral entre x y y dividida entre la varianza muestral de x –el mismo par de cantidades definido y estudiado en la Sección 2, ahora aplicado a los datos observados en lugar de a la distribución poblacional. Dicho de otro modo: la pendiente de MCO es, por construcción, un cociente de covarianza entre varianza. No es una coincidencia notacional; es la razón por la que se estudia primero la varianza y la covarianza antes de deducir MCO.

3.4. Condición de segundo orden

Proposición 3.5 (SCR tiene un mínimo, no un máximo ni un punto silla). *Si $S_{xx} > 0$, la matriz Hessiana de SCR es definida positiva en todo punto, así que el punto crítico $(\hat{\beta}_0, \hat{\beta}_1)$ del Teorema 3.4 es el mínimo global de SCR.*

Demostración. Las segundas derivadas parciales de SCR son constantes en (b_0, b_1) :

$$\frac{\partial^2 \text{SCR}}{\partial b_0^2} = 2n, \quad \frac{\partial^2 \text{SCR}}{\partial b_1^2} = 2 \sum_i x_i^2, \quad \frac{\partial^2 \text{SCR}}{\partial b_0 \partial b_1} = 2 \sum_i x_i,$$

así que la Hessiana es $H = 2 \begin{pmatrix} n & \sum_i x_i \\ \sum_i x_i & \sum_i x_i^2 \end{pmatrix}$. Su primer menor principal, $2n > 0$; su determinante,

$$\det H = 4 \left(n \sum_i x_i^2 - \left(\sum_i x_i \right)^2 \right) = 4n \left(\sum_i x_i^2 - n \bar{x}^2 \right) = 4n \sum_i (x_i - \bar{x})^2 = 4n S_{xx},$$

usando la misma identidad de suma de cuadrados que en la Proposición 2.3. Como $n > 0$ y $S_{xx} > 0$ por hipótesis, $\det H > 0$: ambos menores principales son positivos, así que H es definida positiva en todo punto (no depende de b_0, b_1), y SCR es una función estrictamente convexa. Un punto crítico de una función estrictamente convexa es su mínimo global. $\square$

3.5. Consecuencias algebraicas inmediatas

Corolario 3.6 (La recta de MCO pasa por $(\bar{x}, \bar{y})$). $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x} = \bar{y}$: la recta ajustada pasa exactamente por el punto de medias muestrales.

Demostración. Inmediato de (*) en la demostración del Teorema 3.4: $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$, así que $\hat{\beta}_0 + \hat{\beta}_1 \bar{x} = \bar{y}$. $\square$

Corolario 3.7 (Residuales de media cero). $\frac{1}{n} \sum_i \hat{u}_i = 0$, donde $\hat{u}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$.

Demostración. Es exactamente la primera ecuación normal del Teorema 3.3, dividida entre n . $\square$

3.6. Ejemplo numérico completo

Ejemplo 3.8. Considérese la muestra $n = 5$:

i	1	2	3	4	5
x_i	1	2	3	4	5
y_i	2	3	5	4	6

Aquí $\bar{x} = 3$, $\bar{y} = 4$. La siguiente tabla calcula las desviaciones respecto a la media y sus productos:

i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
1	-2	-2		4
2	-1	-1		1
3	0	1		0
4	1	0		1
5	2	2		4
Σ			$S_{xy} = 9$	$S_{xx} = 10$

Por el Teorema 3.4,

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{9}{10} = 0.9, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 4 - 0.9(3) = 1.3,$$

así que la recta ajustada es $\hat{y} = 1.3 + 0.9x$. Los residuales son $\hat{u} = (-0.2, -0.1, 1.0, -0.9, 0.2)$, cuya suma es efectivamente 0, confirmando la primera ecuación normal.

3.7. Ejercicios

Ejercicio 3.9. Con la muestra $(x_i, y_i) \in \{(0, 1), (1, 1), (2, 3), (3, 3)\}$ ($n = 4$), calcule $\bar{x}$, $\bar{y}$, S_{xy} , S_{xx} , y los estimadores $\hat{\beta}_0, \hat{\beta}_1$.




Figura 1: Nube de puntos del Ejemplo 3.8 y la recta de MCO $\hat{y} = 1.3 + 0.9x$. Las líneas punteadas grises son los residuales $\hat{u}_i = y_i - \hat{y}_i$ en $i = 1, 3, 4$: por construcción, la suma con signo de *todos* los residuales (incluidos $i = 2, 5$) es cero, y la recta pasa exactamente por $(\bar{x}, \bar{y})$.

Solución. $\bar{x} = \frac{0+1+2+3}{4} = 1.5$, $\bar{y} = \frac{1+1+3+3}{4} = 2$. Desviaciones: $x - \bar{x} = (-1.5, -0.5, 0.5, 1.5)$, $y - \bar{y} = (-1, -1, 1, 1)$. Productos: 1.5, 0.5, 0.5, 1.5, suma $S_{xy} = 4$. Cuadrados: 2.25, 0.25, 0.25, 2.25, suma $S_{xx} = 5$. Entonces $\hat{\beta}_1 = 4/5 = 0.8$, $\hat{\beta}_0 = 2 - 0.8(1.5) = 0.8$. Recta: $\hat{y} = 0.8 + 0.8x$. $\square$

Ejercicio 3.10. Demuestre, a partir de la fórmula $\hat{\beta}_1 = S_{xy}/S_{xx}$ y de la Proposición 2.8 (aplicada a las variables muestrales x, y), que

$$\hat{\beta}_1 = \hat{\rho}_{xy} \cdot \frac{\hat{\sigma}_y}{\hat{\sigma}_x},$$

donde $\hat{\rho}_{xy}$ es la correlación muestral y $\hat{\sigma}_x, \hat{\sigma}_y$ las desviaciones estándar muestrales. Use esta identidad para explicar, sin calcular nada, por qué el signo de $\hat{\beta}_1$ es siempre igual al signo de $\hat{\rho}_{xy}$.

Solución. $\hat{\sigma}_x^2 = S_{xx}/n$, $\hat{\sigma}_y^2 = S_{yy}/n$, y $\hat{\rho}_{xy} = \frac{S_{xy}/n}{\hat{\sigma}_x \hat{\sigma}_y}$, así que $\hat{\rho}_{xy} \hat{\sigma}_x \hat{\sigma}_y = S_{xy}/n$, de donde $S_{xy} = n \hat{\rho}_{xy} \hat{\sigma}_x \hat{\sigma}_y$. Sustituyendo en $\hat{\beta}_1 = S_{xy}/S_{xx} = S_{xy}/(n \hat{\sigma}_x^2)$:

$$\hat{\beta}_1 = \frac{n \hat{\rho}_{xy} \hat{\sigma}_x \hat{\sigma}_y}{n \hat{\sigma}_x^2} = \hat{\rho}_{xy} \frac{\hat{\sigma}_y}{\hat{\sigma}_x}.$$

Como $\hat{\sigma}_x, \hat{\sigma}_y > 0$ siempre, el factor $\hat{\sigma}_y/\hat{\sigma}_x$ es positivo, así que $\hat{\beta}_1$ y $\hat{\rho}_{xy}$ tienen exactamente el mismo signo. $\square$

Ejercicio 3.11. Vuelva a hacer la demostración del Teorema 3.4 pero parametrizando la recta como $y_i = \alpha + \beta(x_i - \bar{x}) + u_i$ (es decir, centrando x desde el inicio). Muestre que las ecuaciones normales se *desacoplan* de inmediato ($\hat{\alpha} = \bar{y}$ sin necesidad de conocer $\hat{\beta}$ primero) y que se obtiene el mismo $\hat{\beta} = S_{xy}/S_{xx}$. ¿Por qué es esto una ventaja computacional?

Ejercicio 3.12 (Propuesto). Para los datos del Ejemplo 3.8, calcule $\text{SCR}(\hat{\beta}_0, \hat{\beta}_1)$ (la suma de cuadrados residuales en el mínimo) y compárela con $\text{SCR}(4, 1)$ (una recta candidata distinta, con pendiente 1 y ordenada 4). Confirme numéricamente que la del mínimo es menor, como garantiza la Proposición 3.5.

Ejercicio 3.13 (Propuesto – síntesis). Explique, en dos o tres líneas y sin nuevas cuentas, por qué las tres piezas de este documento –linealidad del valor esperado (Sección 1), varianza de una combinación lineal y Cauchy–Schwarz (Sección 2), y la deducción de MCO (Sección 3)– son, en el fondo, la misma estructura algebraica aplicada tres veces: sumas/promedios ponderados, una forma cuadrática que se minimiza, y una identidad de covarianza sobre varianza.